

1 Capítulo 2. Marco Teórico

1.1 Representación de datos y reducción de dimensionalidad

En problemas de aprendizaje supervisado, un conjunto de datos puede representarse como una matriz en la que cada fila corresponde a una observación y cada columna a una característica o variable descriptiva. Cuando las observaciones cuentan con una etiqueta de clase, dicha representación se convierte en la base sobre la cual los algoritmos de clasificación buscan identificar patrones que permitan distinguir entre grupos. Por ello, la calidad de la representación de los datos influye directamente en la capacidad de separación alcanzada por los modelos (Hastie et al., 2009).

El manejo de conjuntos de datos con un número elevado de variables plantea desafíos relevantes en términos de costo computacional, redundancia de información y riesgo de sobreajuste (Sorzano et al., 2014). En estos escenarios, no todas las características contribuyen de manera equivalente al proceso de clasificación; algunas pueden ser irrelevantes, redundantes o incluso introducir ruido en el modelo (Tang et al., 2014). La reducción de dimensionalidad aborda este problema al buscar una representación más compacta de los datos, procurando conservar la información más relevante para la tarea de análisis.

De manera general, las técnicas de reducción de dimensionalidad pueden agruparse en dos enfoques principales: selección de características y extracción de características. La selección de características conserva un subconjunto de las variables originales, por lo que mantiene una relación directa con la representación inicial de los datos. En contraste, la extracción de características transforma el espacio original para generar nuevas variables, componentes o proyecciones, como ocurre en métodos basados en componentes principales o análisis discriminante (Jain et al., 2000; Sorzano et al., 2014).

En la Figura 2.1 se presenta una taxonomía general de las técnicas de reducción de dimensionalidad. Esta clasificación permite ubicar los métodos de selección de características, como los enfoques filtro y wrapper, así como los métodos de extracción, entre los que se incluyen técnicas lineales, no lineales, supervisadas y no supervisadas (Medina et al., 2025).




Figura 1: Taxonomía de las técnicas de reducción de dimensionalidad. Tomada de Medina et al. (2025).

Dentro de los métodos de selección de características, los enfoques de tipo filtro evalúan la relevancia de las variables a partir de propiedades intrínsecas de los datos, tales como la varianza, la correlación o la información mutua, sin involucrar directamente un algoritmo de clasificación. Esta independencia del modelo suele hacerlos computacionalmente eficientes y escalables; sin embargo, también puede limitar su capacidad para identificar interacciones complejas entre variables (Chandrashekar & Sahin, 2014).

Por otro lado, los métodos de envoltura (wrapper) evalúan subconjuntos de características utilizando el desempeño de un modelo de aprendizaje como criterio de calidad (Kohavi & John, 1997).

En este tipo de enfoque, se genera un subconjunto de variables, se entrena o evalúa un modelo con dicho subconjunto y posteriormente se calcula una métrica de desempeño que permite determinar la pertinencia de la selección realizada. Aunque estos métodos suelen ser más costosos computacionalmente que los filtros, pueden resultar más adecuados cuando la

utilidad de una característica depende de su interacción con otras variables (Guyon & Elisseeff, 2003).

Esta distinción es especialmente relevante para la presente investigación, debido a que la expansión polinomial genera nuevos términos a partir de combinaciones de variables originales. En este contexto, la utilidad de un término cruzado, por ejemplo $(x_i x_j)$, puede depender de la presencia conjunta de otros términos en el modelo. Por ello, un enfoque de selección basado en la evaluación del desempeño del modelo resulta pertinente para reducir la redundancia del espacio expandido y conservar únicamente aquellas variables o términos que aporten a la separación entre clases (Kohavi & John, 1997).

Desde esta perspectiva, la propuesta desarrollada en esta tesis se ubica en la intersección entre selección y extracción de características: por una parte, emplea selección evolutiva para identificar variables originales y términos polinomiales relevantes; por otra, utiliza el análisis discriminante para obtener una representación proyectada de baja dimensión orientada a favorecer la separación entre clases.

2.2 Análisis Discriminante Lineal

2.2.1 Fundamentos y criterio de Fisher

El Análisis Discriminante Lineal, comúnmente referido como LDA por sus siglas en inglés, es una técnica estadística multivariante propuesta originalmente por Fisher (1936), cuyo propósito es encontrar combinaciones lineales de las variables originales que permitan favorecer la separación entre dos o más clases. En el contexto de la reducción de dimensionalidad supervisada, LDA busca proyectar los datos desde un espacio original de dimensión (p) hacia un subespacio de menor dimensión (d) , procurando que las observaciones pertenecientes a una misma clase permanezcan compactas, mientras que las clases distintas se encuentren lo más separadas posible.

A diferencia del Análisis de Componentes Principales (PCA), que identifica direcciones de máxima varianza sin considerar las etiquetas de clase, LDA incorpora explícitamente la información supervisada del problema. Por ello, mientras PCA puede conservar direcciones con alta variabilidad global pero poca utilidad discriminante, LDA

orienta la proyección hacia la separación entre grupos previamente definidos. En términos generales, esta separación se plantea como un compromiso entre maximizar la dispersión entre clases y minimizar la dispersión dentro de cada clase (Bishop & Nasrabadi, 2006).

Desde una perspectiva probabilística, LDA suele asociarse con el supuesto de que las densidades condicionales de las clases siguen distribuciones normales multivariantes con una matriz de covarianza común, es decir, bajo una condición de homocedasticidad (McLachlan, 2004). Sin embargo, desde la formulación geométrica de Fisher, el método también puede entenderse como la búsqueda de una proyección lineal que maximiza una razón de separabilidad entre clases (Fisher, 1936). Esta distinción es importante, ya que en aplicaciones prácticas LDA puede emplearse tanto como clasificador como técnica de reducción de dimensionalidad supervisada (Martinez & Kak, 2001).

Para introducir la formulación básica, considérese primero un problema de clasificación binaria con dos clases C_1 y C_2 . El objetivo consiste en encontrar un vector de proyección que transforme cada observación del espacio original en un valor escalar mediante una combinación lineal de sus características. La orientación óptima de este vector se determina buscando que las medias de las clases proyectadas queden suficientemente separadas, al mismo tiempo que se controla la variabilidad interna de cada clase.

$$y = \mathbf{w}^T \mathbf{x}$$

Para formalizar esta idea, se definen dos cantidades principales: la matriz de dispersión intraclase (S_b) y la matriz de dispersión inter-clase (S_w). La primera resume la variabilidad de las observaciones alrededor de sus respectivos centroides de clase, mientras que la segunda cuantifica la separación entre los centroides de las clases.

$$\mathbf{S}_W = \sum_{n \in C_1} (\mathbf{x}_n - \mathbf{m}_1) (\mathbf{x}_n - \mathbf{m}_1)^T + \sum_{n \in C_2} (\mathbf{x}_n - \mathbf{m}_2) (\mathbf{x}_n - \mathbf{m}_2)^T$$

A partir de estas matrices, el criterio de Fisher se expresa como una razón entre la dispersión interclase y la dispersión intraclase, de modo que la dirección discriminante óptima es aquella que maximiza dicha razón.

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}}$$

En el caso binario, la solución analítica conduce a una dirección de proyección proporcional al producto entre la inversa de la matriz de dispersión intraclase y la diferencia entre los vectores de medias de ambas clases. Esta formulación permite entender la intuición central del método: proyectar los datos hacia una dirección donde las clases se separen tanto como sea posible, manteniendo simultáneamente baja la dispersión interna de cada grupo (Bishop & Nasrabadi, 2006).

$$\mathbf{w}^* \propto \mathbf{S}_W^{-1}(\mathbf{m}_1 - \mathbf{m}_2)$$

2.2.2 Extensión multiclase y obtención de ejes discriminantes

Aunque la formulación binaria permite presentar la intuición geométrica de LDA, muchos problemas de clasificación involucran tres o más clases. En el caso multiclase, el objetivo general se mantiene: encontrar un conjunto de direcciones discriminantes que maximicen la separación entre clases y minimicen la dispersión dentro de cada clase. Sin embargo, en lugar de obtener una única dirección de proyección, se busca una matriz de proyección formada por varios vectores discriminantes.

Para ello, se define primero la media global del conjunto de datos, así como los vectores de medias correspondientes a cada clase. Con base en estos centroides, la matriz de dispersión intraclase acumula la variabilidad interna de cada grupo, mientras que la matriz de dispersión interclase acumula la separación ponderada entre cada centroide de clase y la media global del conjunto de datos.

$$\mathbf{m} = \frac{1}{N} \sum_{k=1}^K N_k \mathbf{m}_k \quad \mathbf{S}_W = \sum_{k=1}^K \mathbf{S}_k \quad \mathbf{S}_B = \sum_{k=1}^K N_k (\mathbf{m}_k - \mathbf{m})(\mathbf{m}_k - \mathbf{m})^T$$

En esta formulación, el criterio de optimización busca maximizar la razón entre la dispersión interclase y la dispersión intraclase en el espacio proyectado. Una forma común de expresar este criterio es mediante la razón entre los determinantes de las matrices de dispersión proyectadas (Fukunaga, 2013).

$$J(\mathbf{W}) = \frac{|\mathbf{W}^T \mathbf{S}_B \mathbf{W}|}{|\mathbf{W}^T \mathbf{S}_W \mathbf{W}|}$$

La maximización de este criterio conduce a un problema generalizado de valores propios, en el cual los vectores propios definen las direcciones discriminantes y los valores propios asociados indican la relevancia discriminante de cada dirección (Martinez & Kak, 2001).

$$\mathbf{S}_B \mathbf{w}_i = \lambda_i \mathbf{S}_W \mathbf{w}_i$$

Los vectores propios asociados a los valores propios más grandes se seleccionan para formar la matriz de proyección final. En este sentido, cada valor propio puede interpretarse como una medida de la separabilidad capturada por su dirección discriminante correspondiente. Por ello, LDA no maximiza “los ejes” en sí mismos, sino un criterio de separabilidad cuya solución produce los ejes discriminantes del nuevo espacio.

Un aspecto importante de la formulación multiclase es que el número máximo de dimensiones discriminantes que pueden extraerse está limitado por el número de clases. En particular, si existen (C) clases, el número máximo de direcciones discriminantes útiles es (C-1) (Duda et al., 2000). Esto se debe a que la matriz de dispersión interclase tiene un rango máximo determinado por la cantidad de centroides de clase disponibles. Por tanto, LDA no solo reduce la dimensionalidad, sino que también impone una estructura supervisada al espacio reducido (Belhumeur et al., 2002).

2.2.3 Supuestos, limitaciones y comparación con QDA

La formulación clásica de LDA descansa sobre varios supuestos que condicionan su comportamiento. Desde el punto de vista probabilístico, el método asume que las clases pueden modelarse mediante distribuciones normales multivariantes con una matriz de covarianza común. Esta hipótesis conduce a fronteras de decisión lineales. Desde el punto de vista geométrico, LDA asume que una proyección lineal es suficiente para separar adecuadamente las clases en el espacio transformado.

Estas condiciones explican algunas de sus principales limitaciones. Cuando las clases presentan estructuras no lineales, distribuciones multimodales o patrones de separación

complejos, una frontera lineal puede resultar insuficiente. En tales casos, la proyección obtenida por LDA puede no reflejar adecuadamente la separabilidad real de los datos, lo que limita su desempeño como clasificador o como técnica de reducción de dimensionalidad supervisada. (Mika et al., 1999).

Otra limitación importante se relaciona con la necesidad de invertir o resolver sistemas asociados a la matriz de dispersión intraclase. Cuando el número de variables es comparable o superior al número de observaciones, la matriz de dispersión intraclase puede volverse singular o mal condicionada. Este escenario, conocido como problema de muestras pequeñas (*Small Sample Size problem*), impide aplicar directamente la formulación clásica de LDA y puede producir inestabilidad numérica en la obtención de los vectores discriminantes (Gao & Davis, 2006).

Formalmente, sea n el número total de sujetos u observaciones en el estudio y p el número de variables descriptivas. La matriz de dispersión intraclase S_W es de dimensiones $p \times p$. Su rango algebraico máximo está estrictamente acotado por $n - C$, donde C representa el número de clases. En el problema de tamaño de muestra pequeño, donde las variables superan drásticamente a los sujetos ($p > n$), se cumple inevitablemente que $n - C < p$. Esta deficiencia de rango vuelve a la matriz S_W singular (no invertible), imposibilitando el cálculo algebraico de S_W^{-1} requerido para resolver el problema generalizado de valores propios.

Una alternativa clásica frente a la rigidez lineal de LDA es el Análisis Discriminante Cuadrático (QDA). A diferencia de LDA, que estima una matriz de covarianza común para todas las clases, QDA estima una matriz de covarianza distinta para cada clase. Esta diferencia permite construir fronteras de decisión cuadráticas, lo que puede resultar útil cuando las clases presentan estructuras de dispersión diferentes. Sin embargo, QDA debe entenderse principalmente como un clasificador probabilístico y no como un método de proyección supervisada de baja dimensión. Además, al requerir la estimación de una matriz de covarianza por clase, puede ser más sensible que LDA en escenarios de alta dimensionalidad y tamaño muestral reducido (Duda et al., 2000).

$$\delta_k(x) = -\frac{1}{2} \ln |\Sigma_k| - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) + \ln \pi_k$$

En consecuencia, aunque QDA ofrece mayor flexibilidad para modelar fronteras no lineales, no resuelve por sí mismo el problema de reducción de dimensionalidad supervisada ni elimina las dificultades asociadas a la estimación de matrices de covarianza en escenarios

($p > n$). Por ello, su inclusión resulta pertinente como método comparativo, pero no sustituye la necesidad de estrategias orientadas a estabilizar o reformular la proyección discriminante.

2.2.4 Implementación computacional y tratamiento de la singularidad

La formulación algebraica clásica de LDA suele expresarse a partir de la inversión de la matriz de dispersión intraclase (S_W) o, de forma equivalente, mediante un problema generalizado de valores propios. Esta formulación resulta problemática cuando (S_W) es singular o está mal condicionada, situación frecuente en escenarios de alta dimensionalidad, presencia de multicolinealidad o tamaño muestral reducido. En estos casos, el cálculo directo de (S_W^{-1}) puede ser numéricamente inestable o incluso inviable (Friedman, 1989).

En la práctica, algunas implementaciones computacionales de LDA reformulan el problema para evitar la inversión explícita de la matriz de dispersión intraclase. Este es el caso de la función *lda* del paquete MASS en R, cuya implementación construye una transformación de escala que lleva las observaciones hacia funciones discriminantes normalizadas de manera que la covarianza intragrupo sea esférica. Esta operación puede interpretarse como una forma de blanqueamiento del espacio, ya que busca remover la estructura de correlación interna de las clases antes de estimar las direcciones discriminantes (Venables & Ripley, 2002).

Matemáticamente, el proceso de blanqueamiento o esferización busca encontrar una matriz de transformación W tal que, al proyectar el espacio original, la nueva matriz de dispersión intraclase se convierta en la matriz identidad:

$$W^T S_W W = I$$

Mediante la descomposición espectral se tiene que $S_W = U \Lambda U^T$, donde U es la matriz ortogonal de vectores propios y Λ es la matriz diagonal de valores propios asociados. La matriz transformadora se define entonces como $W = U \Lambda^{-1/2}$. Al proyectar los datos originales empleando W , la varianza interna de los grupos se vuelve uniforme en todas las direcciones (esférica), reduciendo la estructura de correlación original y estabilizando los cálculos posteriores

Cuando S_W es singular, esta transformación debe entenderse sobre el subespacio asociado a valores propios positivos o mediante una versión truncada/pseudoinversa, ya que los valores propios nulos no pueden invertirse.

La implementación utiliza descomposición en valores singulares (SVD) para identificar las direcciones discriminantes relevantes. En lugar de depender de la inversión directa de (S_W) , la SVD permite trabajar con el rango efectivo de la matriz y descartar direcciones asociadas con varianza nula o numéricamente despreciable. De esta forma, cuando existen variables colineales o combinaciones lineales con varianza muy baja, el algoritmo puede detectarlas mediante un umbral de tolerancia y restringir el cálculo a las dimensiones que conservan información discriminativa suficiente.

Formalmente, la Descomposición en Valores Singulares factoriza una matriz de datos X (previamente centrada y blanqueada) de la forma $X = U\Sigma V^T$, donde Σ es una matriz diagonal que contiene los valores singulares σ_i . El rango efectivo de la matriz se determina mediante el análisis de estos valores singulares, descartando aquellos que caen por debajo de un umbral de tolerancia τ cercano a cero ($\sigma_i < \tau$). Al truncar la descomposición y conservar únicamente las dimensiones con varianza significativa, el algoritmo evita la división por cero o la inestabilidad numérica que provocarían las dimensiones colineales al calcular las proyecciones discriminantes finales (Golub & Van Loan, 2013).

Esta estrategia no elimina por completo el problema Small Sample Size, ya que la disponibilidad de direcciones discriminantes sigue dependiendo de la información contenida en los datos y del rango efectivo de las matrices involucradas. Sin embargo, puede obtener una proyección en muchos escenarios donde la formulación clásica sería inestable, siempre que exista rango efectivo suficiente (Krzanowski et al., 1995.).

En el contexto de esta investigación, esta consideración es relevante porque la expansión polinomial incrementa el número de variables y puede introducir dependencias lineales o casi lineales entre términos originales, términos cuadrados e interacciones (Montgomery et al., 2021). Por ello, utilizar una implementación de LDA basada en blanqueamiento, control de singularidad y SVD permite emplear el discriminante lineal como motor de evaluación dentro de un esquema wrapper, siempre que previamente se controle la dimensionalidad mediante selección evolutiva. Así, la estabilidad computacional de LDA no

se asume como una solución aislada al problema SSS, sino como un componente operativo que se beneficia de la reducción previa del espacio de características.

2.3 Problema Small Sample Size

El problema *Small Sample Size* (SSS) aparece en escenarios donde el número de variables descriptivas es elevado en relación con el número de observaciones disponibles. En términos generales, esta situación suele expresarse como ($p > n$), donde (p) representa la dimensión del espacio de características y (n) el número de muestras. Este escenario es frecuente en dominios de alta dimensionalidad, como bioinformática, análisis de señales, reconocimiento de patrones y problemas donde se generan nuevas variables mediante transformaciones del espacio original (Raudys et al., 1991; Sorzano et al., 2014).

En métodos basados en la estimación de matrices de covarianza o dispersión, el problema SSS se manifiesta matemáticamente como una deficiencia de rango. En el caso del Análisis Discriminante Lineal (LDA), la matriz de dispersión intraclasses (S_W) tiene dimensión ($p \times p$), pero su rango máximo está limitado por la cantidad de observaciones disponibles y por el número de clases. En particular, para (C) clases, se cumple que:

$$\text{rank}(S_W) \leq n - C$$

Por tanto, bajo la condición de singularidad donde $p > n - C$, la matriz S_W no puede alcanzar un rango completo. Esta deficiencia la vuelve singular (no invertible), lo que impide aplicar directamente la formulación clásica que requiere el cálculo algebraico de S_W^{-1} .

La consecuencia práctica de este problema es que la estimación de las direcciones discriminantes puede volverse numéricamente inestable o no estar definida bajo la formulación algebraica clásica. En LDA, esto afecta la resolución del problema generalizado de valores propios y limita la obtención de proyecciones discriminantes estables (Gao & Davis, 2006; Martinez & Kak, 2001). Aunque existen estrategias computacionales para reducir la dependencia de la inversión directa de S_W , como el uso de la Descomposición en

Valores Singulares (SVD), el blanqueamiento o la regularización, estas alternativas no eliminan por completo la dificultad intrínseca de trabajar con un espacio de variables que supera a la información disponible.

2.4 Expansión polinomial y espacios de características.

Ante las limitaciones geométricas del LDA descritas en la sección anterior, surge la necesidad de transformar el espacio de representación de los datos. Esta investigación adopta el enfoque de **Expansión de Funciones Base** (*Basis Function Expansion*), una técnica fundamental en el aprendizaje automático que permite extender la capacidad de los modelos lineales para representar relaciones no lineales (Bishop & Nasrabadi, 2006).

2.4.1 Formalización de la Expansión Polinomial

El procedimiento consiste en mapear el vector de entrada original $\mathbf{x} \in \mathbb{R}^d$ a un espacio de características de mayor dimensión $\mathcal{F} \in \mathbb{R}^D$ mediante una función no lineal $\phi(\mathbf{x})$. Específicamente, se implementa una expansión polinomial de segundo orden (cuadrática), tal como se detalla en la literatura especializada (Kanade, 2016; Niu & Ma, 2021).

Para un caso base bidimensional donde el vector de entrada es $\mathbf{x} = [x_1, x_2]^T$, la función de mapeo $\phi(\mathbf{x})$ construye un nuevo vector que incluye el sesgo, los términos originales, los términos cuadráticos y las interacciones cruzadas:

$$\phi(\mathbf{x}) = [1, x_1, x_2, x_1^2, x_2^2, x_1x_2]^T$$

Grado = 1

$$\{ \underbrace{A, B}_{\text{Grado 1}} \}$$

Grado = 2

$$\{ \underbrace{A, B}_{\text{Grado 1}}, \underbrace{A^2, AB, B^2}_{\text{Grado 2}} \}$$

Grado = 3

$$\{ \underbrace{A, B}_{\text{Grado 1}}, \underbrace{A^2, AB, B^2}_{\text{Grado 2}}, \underbrace{A^3, A^2B, AB^2, B^3}_{\text{Grado 3}} \}$$

Grado = 4

$$\{ \underbrace{A, B}_{\text{G1}}, \underbrace{A^2, AB, B^2}_{\text{G2}}, \underbrace{A^3, A^2B, AB^2, B^3}_{\text{G3}}, \underbrace{A^4, A^3B, A^2B^2, AB^3, B^4}_{\text{Grado 4}} \}$$

Figura 1. Ejemplo de términos generados mediante expansión polinomial para dos variables. Elaboración propia

Como se ilustra en la **Figura 2**, cada componente cumple un rol discriminante específico:

- * **Términos Lineales** (A, B): preservan la información original.
- * **Términos Cuadráticos** (A^2, B^2): permiten incorporar curvatura en la representación y contribuyen a modelar fronteras de decisión no lineales.
- * **Términos de Interacción** (AB): representan efectos multiplicativos entre variables, permitiendo modelar relaciones que no pueden describirse mediante términos lineales independientes (Kanade, 2016).

La justificación teórica para realizar esta expansión se fundamenta en el **Teorema de Cover**, el cual postula que un problema de clasificación complejo y no lineal en un espacio de baja dimensión puede aumentar la probabilidad de separabilidad lineal bajo una transformación no lineal hacia un espacio de mayor dimensión (Cover, 1965).

2.4.3 Limitaciones: Crecimiento Combinatorio y Complejidad

Si bien la expansión polinomial permite representar relaciones no lineales, introduce un desafío crítico conocido como la **Maldición de la Dimensionalidad**. A medida que aumenta la dimensión original d o el grado del polinomio P , el número de términos generados D crece de forma combinatoria.

Para una expansión polinomial de grado P , la dimensión del espacio resultante D está dada por la combinatoria con repetición:

$$D = \binom{d + P}{P} - 1$$

Tal como se observa en la **Figura 3**, este crecimiento es explosivo. Por ejemplo, expandir un vector modesto de $d = 10$ variables a un grado cuadrático ($P = 2$) genera más de 65 términos.




Figura 2.3. Crecimiento del número de atributos bajo una expansión polinomial de grado 2 sin término de sesgo. Fuente: Elaboración propia.

Este fenómeno conlleva dos consecuencias graves descritas por (Bishop & Nasrabadi, 2006):

- 1. **Costo Computacional:** El cálculo de la matriz de covarianza inversa $\mathbf{S}_W^{-1}$ requerida por el LDA se vuelve computacionalmente prohibitivo ($O(D^3)$).
- 2. **Sobreajuste (Overfitting):** Al tener un exceso de parámetros frente a un número limitado de muestras, el modelo tiende a memorizar el ruido de los datos en lugar de aprender la estructura subyacente.

Referencias

- Belhumeur, P. N., Hespanha, J. P., & Kriegman, D. J. (2002). Eigenfaces vs. Fisherfaces: Recognition using class specific linear projection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 19(7), 711–720.
- Bishop, C. M., & Nasrabadi, N. M. (2006). *Pattern recognition and machine learning* (Vol. 4). Springer.
- Chandrashekar, G., & Sahin, F. (2014). A survey on feature selection methods. *Computers & Electrical Engineering*, 40(1), 16–28.
- Cover, T. M. (1965). Geometrical and statistical properties of systems of linear inequalities with applications in pattern recognition. *IEEE Transactions on Electronic Computers*, (3), 326–334.
- Duda, R., Hart, P., Stork, D., & Ionescu, A. (2000). *Pattern classification*. Wiley-Interscience Publication.
- Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188.
- Friedman, J. H. (1989). Regularized discriminant analysis. *Journal of the American Statistical Association*, 84(405), 165–175.
- Fukunaga, K. (2013). *Introduction to statistical pattern recognition*. Elsevier.
- Gao, H., & Davis, J. W. (2006). Why direct LDA is not equivalent to LDA. *Pattern Recognition*, 39(5), 1002–1006.
- Golub, G. H., & Van Loan, C. F. (2013). *Matrix computations*. JHU press.
- Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3(Mar), 1157–1182.
- Hastie, T., Tibshirani, R., Friedman, J., et al. (2009). *The elements of statistical learning*. Springer series in statistics New-York.
- Jain, A. K., Duin, R. P. W., & Mao, J. (2000). Statistical pattern recognition: A review. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(1), 4–37.
- Kanade, V. (2016). *Machine Learning – Michaelmas Term 2016: Lectures 4, 5: Basis Expansion, Regularization, Validation*. Lecture notes, Department of Computer Science, University of Oxford.
<https://www.cs.ox.ac.uk/people/varun.kanade/teaching/ML-MT2016/lectures/lecture04.pdf>

- Kohavi, R., & John, G. H. (1997). Wrappers for feature subset selection. *Artificial Intelligence*, 97(1-2), 273–324.
- Krzanowski, W. J., Jonathan, P., McCarthy, W., & Thomas, M. R. (1995). Discriminant analysis with singular covariance matrices: Methods and applications to spectroscopic data. *Journal of the Royal Statistical Society Series C: Applied Statistics*, 44(1), 101–115.
- Martinez, A. M., & Kak, A. C. (2001). Pca versus lda. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 23(2), 228–233.
- McLachlan, G. J. (2004). *Discriminant analysis and statistical pattern recognition*. John Wiley & Sons.
- Medina, V. D. G., Mesa, H. G. A., Lobato, A. L. L., & Montes, E. M. (2025). Genetic projective discriminant analysis. *2025 IEEE Latin American Conference on Computational Intelligence (LA-CCI)*, 1–6.
- Mika, S., Ratsch, G., Weston, J., Scholkopf, B., & Mullers, K.-R. (1999). Fisher discriminant analysis with kernels. *Neural Networks for Signal Processing IX: Proceedings of the 1999 IEEE Signal Processing Society Workshop (Cat. No. 98th8468)*, 41–48.
- Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to linear regression analysis*. John Wiley & Sons.
- Raudys, S. J., Jain, A. K., et al. (1991). Small sample size effects in statistical pattern recognition: Recommendations for practitioners. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 13(3), 252–264.
- Sorzano, C. O. S., Vargas, J., & Montano, A. P. (2014). A survey of dimensionality reduction techniques. *arXiv Preprint arXiv:1403.2877*.
- Tang, J., Alelyani, S., & Liu, H. (2014). Feature selection for classification: A review. *Data Classification: Algorithms and Applications*, 37.
- Venables, W. N., & Ripley, B. D. (2013). *Modern applied statistics with s*. Springer Science & Business Media.