



Universidad Veracruzana

Universidad Veracruzana

Análisis Discriminante Polinomial No Lineal Genético (GNLPDA)

Instituto de Investigaciones en Inteligencia Artificial

Presenta:

Ángel García Báez

Director:

Dr. Héctor Gabriel Acosta Mesa

Codirectora:

Dra Adriana Laura López Lobato

Índice general

1. Introducción	1
1.1. Contexto y motivación	1
1.2. Planteamiento del problema	2
1.3. Propuesta	2
1.4. Justificación	3
1.5. Pregunta de investigación	3
1.6. Hipótesis	3
1.7. Objetivos	4
1.7.1. Objetivo general	4
1.7.2. Objetivos específicos	4
1.8. Contribuciones	4
1.9. Alcances y limitaciones	5
1.10. Organización de la tesis	5
2. Marco Teórico	7
2.1. Representación y visualización de datos multidimensionales	7
2.1.1. El desafío de visualizar datos de alta dimensión	7
2.1.2. Reducción dimensional como mecanismo de representación	7
2.1.3. Proyecciones discriminantes para la visualización supervisada	8
2.1.4. Visualización de representaciones de baja dimensión	8
2.2. Análisis Discriminante Lineal	9
2.2.1. Fundamentos y criterio de Fisher	9
2.2.2. Extensión multiclase y obtención de ejes discriminantes	10
2.2.3. Supuestos, limitaciones y comparación con QDA	11
2.2.4. Implementación computacional y tratamiento de la singularidad	12
2.3. Problema de muestras pequeñas (Small Sample Size)	13
2.4. Expansión polinomial y espacios de características	14
2.4.1. Formalización de la expansión polinomial	14
2.4.2. Limitaciones: Crecimiento Combinatorio y Complejidad	15
2.5. Algoritmos genéticos	16
2.5.1. Representación cromosómica y función de aptitud	16
2.5.2. Ciclo evolutivo y operadores genéticos	17
2.5.3. Algoritmos genéticos como estrategia wrapper	18
2.6. Métodos kernel y clasificadores no lineales	18
2.6.1. Truco Kernel y funciones kernel	19
2.6.2. KFDA y SVM como enfoques no lineales de referencia	19
2.6.3. Ventajas, limitaciones e interpretabilidad	20

3. Estado del arte	23
3.1. Variantes lineales del análisis discriminante	23
3.1.1. Regularized LDA	23
3.1.2. LDA en dos etapas	24
3.1.3. Variantes lineales relevantes	24
3.2. Métodos kernel	25
3.2.1. Análisis de Componentes Principales con Kernel (KPCA)	25
3.2.2. Análisis Discriminante de Fisher mediante Kernel (KFDA)	25
3.2.3. SVM Polinomial	25
3.2.4. SVM RBF	26
3.3. Selección de características basada en algoritmos evolutivos	26
3.3.1. GA para selección de variables	26
3.3.2. Métodos híbridos	27
3.3.3. GPDA	27
3.4. Limitaciones identificadas	27
3.5. Posicionamiento de GNLPDA	28
4. Metodología	29
4.1. Selección evolutiva en dos fases	29
4.1.1. Fase I: selección de variables originales	29
4.1.2. Fase II: selección de términos polinomiales	31
4.1.3. Salida del procedimiento y ajuste final de LDA	33
4.2. Configuración y calibración de GNLPDA	34
4.2.1. Configuración del algoritmo genético.	35
4.3. Configuración y calibración de los parámetros de GNLPDA	37
4.4. Diseño experimental	39
4.4.1. Conjuntos de datos utilizados	39
4.4.2. Generación de conjuntos sintéticos tipo Cebolla	40
4.4.3. Métodos comparativos y métrica de evaluación	41
4.4.4. Protocolo de particionamiento y evaluación	42
4.4.5. Evaluación auxiliar del problema Small Sample Size	43
4.4.6. Análisis estadístico de resultados	44
5. Resultados	47
5.1. Resultados del problema de muestras pequeñas (SSS)	47
5.1.1. Caso 1	47
5.1.2. Caso 2	47
5.1.3. Caso 3	48
5.1.4. Caso 4	48
5.1.5. Caso 5	49
5.2. Resultados por conjunto de datos	50
5.2.1. Palmer Penguins	50
5.2.2. Wines	53
5.2.3. Cancer Wisconsin	56
5.2.4. Ionosfera	60
5.2.5. Cebolla 3D	63
5.2.6. Cebolla 10D	65
5.2.7. Cebolla 20D	68

5.2.8. Pima diabetes	71
5.2.9. Indicadores 2015	75
5.2.10. Indicadores 2020	78
6. Discusión	83
6.1. Expansión polinomial y separabilidad de los datos	83
6.2. Comportamiento frente al problema Small Sample Size	83
6.3. Comparación con los métodos evaluados	84
6.4. Interpretación general de la propuesta	85
7. Conclusiones	87

Capítulo 1

Introducción

1.1. Contexto y motivación

En el marco del Aprendizaje Máquina (Machine Learning), el objetivo fundamental es el desarrollo de algoritmos capaces de identificar patrones complejos a partir de datos para la toma de decisiones automatizada en diversos campos de aplicación [10]. En problemas de aprendizaje supervisado, un conjunto de datos puede representarse como una matriz en la que cada fila corresponde a una observación y cada columna a una característica descriptiva. Cuando las observaciones cuentan con una etiqueta de clase, esta representación se convierte en la base sobre la cual los modelos buscan identificar fronteras de separación [36].

Sin embargo, cuando dicha matriz posee un número elevado de características, su análisis y representación gráfica se ven severamente comprometidos debido al fenómeno conocido como la maldición de la dimensionalidad [86]. Para mitigar este problema, las técnicas de reducción de dimensionalidad buscan transformar el espacio original en una representación más compacta, procurando conservar la mayor cantidad de información útil [65, 82].

De manera general, estas técnicas se agrupan en dos enfoques principales (ver Figura 1.1): la **selección de características**, que conserva un subconjunto de las variables originales mediante métodos de filtro o enfoques *wrapper*; y la **extracción de características**, que transforma el espacio original para generar nuevas proyecciones, como ocurre en el Análisis de Componentes Principales (PCA) o el Análisis Discriminante [38].




Figura 1.1: Taxonomía de las técnicas de reducción de dimensionalidad. Tomada de [56].

La proyección de los datos hacia espacios de baja dimensión (dos o tres dimensiones) cum-

ple un propósito exploratorio fundamental. En dominios complejos como la genómica o la radiómica, visualizar la geometría de los datos permite evaluar si los biomarcadores extraídos logran discriminar claramente entre condiciones sanas y patológicas [14, 63]. Comúnmente, esta exploración se realiza proyectando las dos primeras componentes de PCA [40].

1.2. Planteamiento del problema

A pesar de su popularidad, PCA no es la herramienta más adecuada para evaluar la separabilidad de clases. Al ser un método no supervisado cuyo criterio de optimización es la varianza total, no garantiza que las proyecciones obtenidas coincidan con las fronteras que mejor separan a los grupos [71]. El Análisis Discriminante Lineal (LDA) resuelve esta limitación incorporando la información de las etiquetas para maximizar la dispersión inter-clase respecto a la intra-clase, convirtiéndolo en la herramienta natural para la visualización supervisada [17].

No obstante, la formulación clásica de LDA impone supuestos que restringen severamente su aplicabilidad: asume fronteras de decisión estrictamente lineales, normalidad multivariada y matrices de dispersión bien condicionadas, fallando rotundamente en escenarios con tamaños de muestra pequeños [25].

Para superar estas barreras operativas, se han desarrollado variantes evolutivas como el Genetic Projective Discriminant Analysis (GPDA), el cual optimiza la proyección discriminante lineal esquivando los problemas de matrices singulares [56]. Sin embargo, dicha propuesta conserva la restricción de su método base: su formulación esta diseñada para tratar con datos con estructuras linealmente separables.

Una alternativa intuitiva para abordar la no linealidad es expandir explícitamente el espacio de características (por ejemplo, mediante términos polinomiales), convirtiendo relaciones complejas en fronteras lineales tratables por LDA. No obstante, este enfoque introduce una explosión combinatoria del número de variables a medida que aumentan el grado del polinomio, agravando la maldición de la dimensionalidad [11].

En la literatura actual, la alternativa dominante para tratar con estructuras no linealmente separables en los datos sin expandir explícitamente el espacio es el uso de métodos kernel, como las Maquinas de Soporte Vectorial (SVM) o el Análisis discriminante de Kernel Fisher (KFDA). Estos explotan el “truco del kernel” para operar implícitamente en espacios de dimensión alta o infinita. En particular, el KFDA realiza un mapeo de los datos hacia un espacio de mayor dimensionalidad y, posteriormente, los proyecta en una subdimensión reducida de tamaño $(C - 1)$ número de clases. Este proceso de reducción se lleva a cabo mediante combinaciones matemáticas de los datos transformados, lo que posibilita la visualización en baja dimensionalidad, pero dificulta significativamente la interpretación directa de la representación en términos de las variables originales.

Existe, por tanto, una brecha metodológica concreta: no se cuenta con un mecanismo capaz de producir una proyección de baja dimensión para estructuras no linealmente separables que sea simultáneamente visualizable y trazable hacia las variables originales.

1.3. Propuesta

El objetivo es diseñar e implementar un método híbrido que aplique una expansión polinomial explícita para modelar fronteras de decisión no lineales. Se utilizará dentro de un algoritmo genético jerárquico de dos etapas como esquema de envoltura para seleccionar los términos óptimos, empleando el Análisis Discriminante Lineal (LDA) como función de evaluación y motor

para proyectar los datos en un subespacio de máxima separabilidad visualizable en máximo tres dimensiones.

1.4. Justificación

Esta investigación se justifica por la necesidad de encontrar un equilibrio óptimo entre la transformación para la separabilidad no lineal y la parsimonia dimensional. El trabajo propuesto desarrolla un algoritmo de tipo *wrapper* capaz de solventar la no linealidad mediante expansión polinomial, mitigando simultáneamente la maldición de la dimensionalidad a través de una selección evolutiva de variables.

A diferencia de métodos de “caja negra” del estado del arte, como el Análisis Discriminante de Fisher con Kernel (KFDA) o las Máquinas de Soporte Vectorial (SVM), este marco de trabajo ofrece un beneficio dual:

- **Visualización geométrica:** Permite proyectar estructuras no linealmente separables en espacios de baja dimensión (hasta tres dimensiones), facilitando la inspección visual de la separación entre clases.
- **Trazabilidad e interpretabilidad:** El proceso permite rastrear con precisión qué variables originales y qué términos de interacción fueron seleccionados, ofreciendo una explicación técnica de la proyección final. Esto resulta de suma importancia en aplicaciones donde entender el “porqué” de la decisión del modelo es tan importante como la precisión misma.

1.5. Pregunta de investigación

A partir de esta problemática, la presente investigación plantea la siguiente pregunta:

- **¿Es posible integrar la expansión polinomial explícita con un esquema de selección evolutiva en dos fases para proyectar datos con estructuras no linealmente separables en espacios de baja dimensión (hasta tres dimensiones), que sean visualizables, interpretables y trazables a partir de las variables y términos seleccionados, manteniendo al mismo tiempo un desempeño predictivo y un costo computacional competitivos frente a métodos no lineales de referencia?**

1.6. Hipótesis

La integración de un mecanismo de selección evolutiva en dos fases sobre una expansión polinomial explícita permite generar representaciones discriminantes visualizables en baja dimensión (hasta tres dimensiones) para conjuntos de datos con estructuras no linealmente separables. El enfoque permite reducir la dimensionalidad del espacio expandido e identificar los términos polinomiales seleccionados que contribuyen a la separación discriminante, proporcionando trazabilidad sobre el proceso de construcción de la representación y favoreciendo su interpretabilidad. Asimismo, se plantea que esta representación puede obtenerse manteniendo tiempos de ejecución viables y una exactitud de clasificación estadísticamente competitiva frente a métodos no lineales de referencia de tipo caja negra, sin requerir una superioridad sistemática en rendimiento predictivo.

1.7. Objetivos

1.7.1. Objetivo general

Diseñar e implementar un algoritmo con un esquema híbrido de selección y extracción de características que integre expansión polinomial con análisis discriminante lineal mediante un proceso evolutivo en dos etapas, con el propósito de lograr la visualización interpretable y trazable de datos con estructuras no linealmente separables en espacios de baja dimensión, manteniendo un equilibrio entre reducción de características, tiempo de ejecución y rendimiento predictivo.

1.7.2. Objetivos específicos

- **Caracterizar** las limitaciones operativas y visuales del Análisis Discriminante Lineal (LDA) clásico ante escenarios de no linealidad, alta dimensionalidad y muestras pequeñas.
- **Diseñar e implementar** un mecanismo de selección evolutiva que reduzca la redundancia en el espacio expandido mediante la selección de variables originales y términos polinomiales relevantes que sea capaz de generar una proyección en baja dimensión trazable.
- **Evaluar** el desempeño computacional y la reducción dimensional producida por el algoritmo de selección evolutiva, mediante el registro del tiempo de ejecución y la cuantificación de la cantidad de variables retenidas en cada una de sus fases.
- **Comparar de forma cualitativa** las proyecciones visuales de baja dimensión (máximo tres dimensiones) generadas por el método propuesto frente a las representaciones producidas por LDA y KFDA, evaluando su utilidad para la exploración e interpretación de estructuras discriminantes no lineales.
- **Evaluar y contrastar** estadísticamente la exactitud de clasificación (*Accuracy*) de la propuesta frente a las técnicas de referencia, para validar su competitividad predictiva.

1.8. Contribuciones

Las principales contribuciones de este trabajo son las siguientes:

- Proponer un esquema híbrido de extracción de características que combina expansión polinomial, selección evolutiva y análisis discriminante para abordar problemas de clasificación y proyección con datos no linealmente separables.
- Incorporar un mecanismo de selección en dos fases orientado a reducir la dimensionalidad del espacio expandido, primero mediante la selección de variables originales y posteriormente mediante la selección de términos polinomiales relevantes.
- Evaluar la capacidad del método propuesto para generar proyecciones de baja dimensión, hasta un máximo de tres dimensiones que faciliten la visualización de la separación entre clases.

- Demostrar empíricamente que el algoritmo propuesto alcanza una exactitud de clasificación estadísticamente competitiva frente a métodos que manejan la no linealidad (modelos de caja negra), aportando como ventaja fundamental una proyección interpretable y trazable sin incurrir en una pérdida significativa de rendimiento predictivo.
- Cuantificar la eficiencia del mecanismo evolutivo de selección en sus dos fases mediante métricas tangibles de costo computacional (tiempo de ejecución) y optimización de memoria (tasa de reducción de variables del espacio polinomial expandido), validando su viabilidad operativa.

1.9. Alcances y limitaciones

- El enfoque de la investigación se restringe a problemas de aprendizaje supervisado.
- El alcance experimental se restringe de forma estricta a conjuntos de datos tabulares donde las características exclusivamente numéricas. Por tanto, no se consideran en esta etapa datos no estructurados, variables categóricas sin transformación previa, imágenes, texto, señales temporales ni otros tipos de representación.
- Las visualizaciones generadas por el método propuesto se acotan a espacios de baja dimensión, hasta un máximo de tres dimensiones. Esta restricción se relaciona con la naturaleza del análisis discriminante lineal, el cual permite obtener hasta $C - 1$ dimensiones discriminantes, donde C representa el número de clases del problema.
- La propuesta no busca superar en rendimiento a todos los métodos de referencia, sino obtener un desempeño comparable en determinados escenarios, aportando como ventaja la trazabilidad del proceso de selección y la posibilidad de visualizar las proyecciones generadas en baja dimensión.
- La validación empírica del algoritmo se restringe a un conjunto controlado de diez conjuntos de datos, con un máximo de 32 variables cuantitativas originales.

1.10. Organización de la tesis

- El **Capítulo 2** presenta el marco teórico necesario para comprender los fundamentos de la investigación. En este capítulo se abordan las técnicas de reducción de dimensionalidad, los fundamentos algebraicos y operacionales del Análisis Discriminante Lineal y sus variantes, el problema de pequeño tamaño de muestra, la expansión polinomial, los algoritmos genéticos, los métodos kernel, KFDA, las máquinas de soporte vectorial y las métricas de clasificación utilizadas en el estudio.
- El **Capítulo 3** desarrolla el estado del arte. En este capítulo se revisan trabajos relacionados con variantes y mejoras del Análisis Discriminante Lineal, métodos kernel como KPCA, KFDA y SVM, así como enfoques de selección de características basados en algoritmos genéticos. Asimismo, se analizan trabajos relacionados con GPDA y se identifican las limitaciones que motivan el desarrollo de la propuesta.
- El **Capítulo 4** describe la metodología de investigación y el algoritmo propuesto, denominado Genetic Non-Linear Polynomial Discriminant Analysis (GNLPDA). Se presentan la

arquitectura general del método, sus fases de selección, la función fitness, el proceso de calibración y el diseño experimental empleado para su evaluación.

- El **Capítulo 5** presenta los resultados obtenidos al aplicar el método propuesto sobre los conjuntos de datos seleccionados. Se incluyen resultados de clasificación, análisis de proyecciones de baja dimensión y comparaciones frente a los métodos de referencia.
- El **Capítulo 6** discute los hallazgos obtenidos, considerando la interpretación técnica de los resultados, las fortalezas del método, sus limitaciones y las condiciones bajo las cuales la propuesta resulta más adecuada.
- El **Capítulo 7** presenta las conclusiones generales de la investigación, el grado de cumplimiento de los objetivos planteados, las principales contribuciones del trabajo y las líneas de trabajo futuro.

Capítulo 2

Marco Teórico

2.1. Representación y visualización de datos multidimensionales

En el desarrollo de sistemas de aprendizaje automático, el análisis exploratorio de los datos es una etapa fundamental para comprender la naturaleza del problema. Antes de entrenar modelos de clasificación complejos, la capacidad de observar geométricamente cómo se distribuyen las observaciones permite explorar patrones, detectar posibles valores atípicos e inspeccionar el grado de solapamiento entre las distintas clases [68, 1].

En este contexto resulta conveniente distinguir entre la visualización y la representación que la hace posible. La visualización constituye la manifestación gráfica de los datos, mientras que la representación corresponde al espacio de dimensión reducida utilizado para proyectar las observaciones y facilitar su inspección.

2.1.1. El desafío de visualizar datos de alta dimensión

La representación visual directa de datos multidimensionales está limitada por la capacidad de representar simultáneamente un número reducido de dimensiones, por lo que las representaciones visuales convencionales suelen restringirse a una, dos o tres dimensiones [6, 24] .

Intentar comprender la estructura de un conjunto de datos multidimensional a través del análisis aislado por pares de variables resulta ineficiente y propenso a omitir interacciones complejas que sean clave para entenderlos [64]. A medida que la dimensionalidad aumenta, los datos se vuelven escasos en el espacio representativo, agravando los efectos de la maldición de la dimensionalidad [69]. Por lo tanto, surge la necesidad de proyectar esta información hacia espacios de menor dimensión que permitan conservar, de acuerdo con un criterio determinado, características relevantes de la estructura de los datos.

2.1.2. Reducción dimensional como mecanismo de representación

La reducción dimensional comprende un conjunto de técnicas orientadas a representar los datos en un espacio de baja dimensión, con el propósito de preservar, conforme al criterio de la técnica empleada, aquellas propiedades consideradas relevantes de la estructura original [90].

Cuando la dimensión resultante es suficientemente baja, estas representaciones también pueden emplearse para la exploración visual de los datos [35].

En esta tesis se **consideran representaciones** de baja dimensión aquellas cuya dimensión no sea mayor a tres, es decir, $d \leq 3$.

Este proceso de representación puede lograrse seleccionando un subconjunto específico de variables (selección de características) o transformando el espacio mediante combinaciones matemáticas (extracción de características) [67].

La selección de características conserva un subconjunto de variables originales mientras que la extracción construye nuevas **dimensiones** mediante transformaciones o combinaciones de las variables disponibles. En el contexto de la visualización, ambas estrategias pueden producir representaciones de baja dimensión, aunque difieren en el grado de correspondencia directa que mantienen con las variables originales [90].

2.1.3. Proyecciones discriminantes para la visualización supervisada

La utilidad de una visualización depende fuertemente del criterio matemático utilizado para proyectar los datos. El Análisis de Componentes Principales (PCA) constituye una técnica ampliamente utilizada para obtener representaciones de baja dimensión. Al proyectar las observaciones sobre sus primeras componentes, se obtiene un mapa que preserva la mayor varianza global de los datos. Sin embargo, al ser un método no supervisado, PCA no incorpora las etiquetas de clase en el proceso de obtención de las componentes [10].

En problemas de clasificación, la varianza global no siempre coincide con la separabilidad de las clases. Cuando el objetivo específico es favorecer la separación entre grupos, resulta conveniente emplear proyecciones discriminantes supervisadas, cuyo propósito es orientar la proyección hacia direcciones que favorezcan la separación entre los grupos [61].

Para ilustrar esta diferencia fundamental entre la maximización de la varianza global y la maximización de la separabilidad, la figura 2.1 presenta una comparativa geométrica conceptual. Mientras que PCA proyecta los datos buscando la dirección de mayor dispersión general (ignorando las etiquetas de clase), una proyección discriminante orienta los ejes específicamente para maximizar la separación entre las clases respecto a su dispersión interna [25].




Figura 2.1: Comparativa conceptual entre los criterios de proyección de PCA y LDA. Elaboración propia.

2.1.4. Visualización de representaciones de baja dimensión

Las representaciones de baja dimensión permiten convertir un conjunto de observaciones definido originalmente en un espacio multidimensional en una geometría que puede ser inspec-

cionada visualmente. Cuando la representación tiene una, dos o tres dimensiones, es posible recurrir a recursos gráficos que permiten explorar directamente la distribución de las observaciones y su relación con las clases [84].

En un espacio proyectado de baja dimensión, una separación visualmente marcada entre los grupos puede ofrecer evidencia exploratoria acerca de la existencia de una estructura discriminante; sin embargo, dicha representación no constituye por sí misma una prueba estadística de separabilidad ni garantiza desempeño predictivo [2]. Su valor radica en proporcionar una representación geométrica que facilite la exploración de la estructura de los datos y la formulación de hipótesis sobre la relación entre las clases, el grado de solapamiento y la presencia de observaciones atípicas, mientras que la evaluación de la capacidad discriminante y del rendimiento predictivo de un clasificador debe sustentarse en métricas cuantitativas [12].

Además de la posibilidad de inspeccionar visualmente la estructura proyectada, una representación de baja dimensión puede adquirir mayor utilidad interpretativa cuando es posible establecer una relación explícita entre sus dimensiones y las características que intervienen en su construcción [60].

Desde esta perspectiva, la trazabilidad de los ejes resulta relevante para determinar que características participan en la construcción de la representación.

En ciertos métodos de reducción dimensional, especialmente aquellos que recurren a transformaciones implícitas del espacio de características, la relación explícita entre los ejes obtenidos y las variables originales tiende a ser menos directa, lo que dificulta la interpretación de la representación en términos de las características iniciales [13].

La necesidad de contar con representaciones de baja dimensión que, además de facilitar la inspección visual, incorporen explícitamente la información sobre la pertenencia de las observaciones a distintas clases, motiva el empleo de técnicas de proyección discriminante. En este contexto, LDA ofrece un marco matemático que permite construir ejes orientados a maximizar la separación entre clases, estableciendo así la base de una representación discriminante supervisada [92].

2.2. Análisis Discriminante Lineal

2.2.1. Fundamentos y criterio de Fisher

El Análisis Discriminante Lineal, comúnmente referido como LDA por sus siglas en inglés, es una técnica estadística multivariante propuesta originalmente por Fisher (1936) [26], cuyo propósito es encontrar combinaciones lineales de las variables originales que permitan favorecer la separación entre dos o más clases. En el contexto de la reducción de dimensionalidad supervisada, LDA busca proyectar los datos desde un espacio original de dimensión (p) hacia un subespacio de menor dimensión (d), procurando que las observaciones pertenecientes a una misma clase permanezcan compactas, mientras que las clases distintas se encuentren lo más separadas posible [92].

A diferencia de PCA, LDA incorpora explícitamente la información de clase en la construcción de la proyección, orientando sus direcciones hacia la separación entre los grupos [11].

Desde una perspectiva probabilística, LDA suele asociarse con el supuesto de que las densidades condicionales de las clases siguen distribuciones normales multivariantes con una matriz de covarianza común, es decir, bajo una condición de homocedasticidad [54]. Sin embargo, desde la formulación geométrica de Fisher, el método también puede entenderse como la búsqueda de una proyección lineal que maximiza una razón de separabilidad entre clases [26]. Esta

distinción es importante, ya que en aplicaciones prácticas LDA puede emplearse tanto como clasificador como técnica de reducción de dimensionalidad supervisada [53].

Para introducir la formulación básica, considérese primero un problema de clasificación binaria con dos clases C_1 y C_2 . El objetivo consiste en encontrar un vector de proyección w que transforme cada observación del espacio original en un valor escalar mediante una combinación lineal de sus características. La orientación óptima de este vector se determina buscando que las medias de las clases proyectadas queden suficientemente separadas, al mismo tiempo que se controla la variabilidad interna de cada clase.

$$y = \mathbf{w}^T \mathbf{x} \quad (2.1)$$

Para formalizar esta idea, se definen dos cantidades principales: la matriz de dispersión intraclase (S_W) y la matriz de dispersión inter-clase (S_B). La primera resume la variabilidad de las observaciones alrededor de sus respectivos centroides de clase, mientras que la segunda cuantifica la separación entre los centroides de las clases.

$$\mathbf{S}_W = \sum_{n \in C_1} (\mathbf{x}_n - \mathbf{m}_1)(\mathbf{x}_n - \mathbf{m}_1)^T + \sum_{n \in C_2} (\mathbf{x}_n - \mathbf{m}_2)(\mathbf{x}_n - \mathbf{m}_2)^T \quad (2.2)$$

A partir de estas matrices, el criterio de Fisher se expresa como una razón entre la dispersión interclase y la dispersión intraclase, de modo que la dirección discriminante óptima es aquella que maximiza dicha razón.

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}} \quad (2.3)$$

En el caso binario, la solución analítica conduce a una dirección de proyección proporcional al producto entre la inversa de la matriz de dispersión intraclase y la diferencia entre los vectores de medias de ambas clases. Esta formulación permite entender la intuición central del método: proyectar los datos hacia una dirección donde las clases se separen tanto como sea posible, manteniendo simultáneamente baja la dispersión interna de cada grupo [11].

$$\mathbf{w}^* \propto \mathbf{S}_W^{-1}(\mathbf{m}_1 - \mathbf{m}_2) \quad (2.4)$$

2.2.2. Extensión multiclase y obtención de ejes discriminantes

Aunque la formulación binaria permite presentar la intuición geométrica de LDA, muchos problemas de clasificación involucran tres o más clases. En el caso multiclase, el objetivo general se mantiene: encontrar un conjunto de direcciones discriminantes que maximicen la separación entre clases y minimicen la dispersión dentro de cada clase. Sin embargo, en lugar de obtener una única dirección de proyección, se busca una matriz de proyección formada por varios vectores discriminantes.

Para ello, se define primero la media global del conjunto de datos, así como los vectores de medias correspondientes a cada clase. Con base en estos centroides, la matriz de dispersión intraclase acumula la variabilidad interna de cada grupo, mientras que la matriz de dispersión inter-clase acumula la separación ponderada entre cada centroide de clase y la media global del conjunto de datos.

$$\mathbf{m} = \frac{1}{N} \sum_{k=1}^K N_k \mathbf{m}_k, \quad \mathbf{S}_W = \sum_{k=1}^K \mathbf{S}_k, \quad \mathbf{S}_B = \sum_{k=1}^K N_k (\mathbf{m}_k - \mathbf{m})(\mathbf{m}_k - \mathbf{m})^T \quad (2.5)$$

En esta formulación, el criterio de optimización busca maximizar la razón entre la dispersión interclase y la dispersión intraclase en el espacio proyectado. Una forma común de expresar este criterio es mediante la razón entre los determinantes de las matrices de dispersión proyectadas [28].

$$J(\mathbf{W}) = \frac{|\mathbf{W}^T \mathbf{S}_B \mathbf{W}|}{|\mathbf{W}^T \mathbf{S}_W \mathbf{W}|} \quad (2.6)$$

La maximización de este criterio conduce a un problema generalizado de valores propios, en el cual los vectores propios definen las direcciones discriminantes y los valores propios asociados indican la relevancia discriminante de cada dirección [53].

$$\mathbf{S}_B \mathbf{w}_i = \lambda_i \mathbf{S}_W \mathbf{w}_i \quad (2.7)$$

Los vectores propios asociados a los valores propios más grandes se seleccionan para formar la matriz de proyección final. En este sentido, cada valor propio puede interpretarse como una medida de la separabilidad capturada por su dirección discriminante correspondiente.

Por ello, LDA no maximiza “los ejes” en sí mismos, sino un criterio de separabilidad cuya solución produce los ejes discriminantes del nuevo espacio.

Un aspecto importante de la formulación multiclase es que el número máximo de dimensiones discriminantes que pueden extraerse está limitado por el número de clases. En particular, si existen (C) clases, el número máximo de direcciones discriminantes útiles es ($C - 1$) [23]. Esto se debe a que la matriz de dispersión interclase tiene un rango máximo determinado por la cantidad de centroides de clase disponibles. Por tanto, LDA no solo reduce la dimensionalidad, sino que también impone una estructura supervisada al espacio reducido [9].

2.2.3. Supuestos, limitaciones y comparación con QDA

La formulación clásica de LDA descansa sobre varios supuestos que condicionan su comportamiento. Desde el punto de vista probabilístico, el método asume que las clases pueden modelarse mediante distribuciones normales multivariantes con una matriz de covarianza común. Esta hipótesis conduce a fronteras de decisión lineales. Desde el punto de vista geométrico, LDA asume que una proyección lineal es suficiente para separar adecuadamente las clases en el espacio transformado.

Estas condiciones explican algunas de sus principales limitaciones. Cuando las clases presentan fronteras de decisión no lineales, distribuciones multimodales o patrones de separación complejos, una frontera lineal puede resultar insuficiente. En tales casos, la proyección obtenida por LDA puede no reflejar adecuadamente la separabilidad real de los datos, lo que limita su desempeño como clasificador o como técnica de reducción de dimensionalidad supervisada [57].

Otra limitación importante se relaciona con la necesidad de invertir o resolver sistemas asociados a la matriz de dispersión intraclase. Cuando el número de variables es comparable o superior al número de observaciones, la matriz de dispersión intraclase puede volverse singular o mal condicionada. Este escenario, conocido como problema de muestras pequeñas (Small Sample Size problem), impide aplicar directamente la formulación clásica de LDA y puede producir inestabilidad numérica en la obtención de los vectores discriminantes [29].

Una alternativa clásica frente a la rigidez lineal de LDA es el Análisis Discriminante Cuadrático (QDA). A diferencia de LDA, que estima una matriz de covarianza común para todas las clases, QDA estima una matriz de covarianza distinta para cada clase. Esta diferencia permite construir fronteras de decisión cuadráticas, lo que puede resultar útil cuando las clases presentan

estructuras de dispersión diferentes. Sin embargo, QDA debe entenderse principalmente como un clasificador probabilístico y no como un método de proyección supervisada de baja dimensión. Además, al requerir la estimación de una matriz de covarianza por clase, puede ser más sensible que LDA en escenarios de alta dimensionalidad y tamaño muestral reducido [23].

$$\delta_k(x) = -\frac{1}{2} \ln |\Sigma_k| - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) + \ln \pi_k \quad (2.8)$$

En consecuencia, aunque QDA ofrece mayor flexibilidad para modelar fronteras de decisión no lineales, no resuelve por sí mismo el problema de reducción de dimensionalidad supervisada ni elimina las dificultades asociadas a la estimación de matrices de covarianza en escenarios ($p > n$). Por ello, su inclusión resulta pertinente como método comparativo, pero no sustituye la necesidad de estrategias orientadas a estabilizar o reformular la proyección discriminante.

2.2.4. Implementación computacional y tratamiento de la singularidad

La formulación algebraica clásica de LDA suele expresarse a partir de la inversión de la matriz de dispersión intraclase ($\mathbf{S}_W$) o, de forma equivalente, mediante un problema generalizado de valores propios. Esta formulación resulta problemática cuando ($\mathbf{S}_W$) es singular o está mal condicionada, situación frecuente en escenarios de alta dimensionalidad, presencia de multicolinealidad o tamaño muestral reducido. En estos casos, el cálculo directo de ($\mathbf{S}_W^{-1}$) puede ser numéricamente inestable o incluso inviable [27].

En la práctica, algunas implementaciones computacionales de LDA reformulan el problema para evitar la inversión explícita de la matriz de dispersión intraclase.

Este es el caso de la función `lda` del paquete MASS en R, cuya implementación construye una transformación de escala que lleva las observaciones hacia funciones discriminantes normalizadas de manera que la covarianza intragrupo sea esférica.

Esta operación puede interpretarse como una forma de blanqueamiento del espacio, ya que busca remover la estructura de correlación interna de las clases antes de estimar las direcciones discriminantes [85].

Matemáticamente, el proceso de blanqueamiento o esferización busca encontrar una matriz de transformación $\mathbf{W}$ tal que, al proyectar el espacio original, la nueva matriz de dispersión intraclase se convierta en la matriz identidad:

$$\mathbf{W}^T \mathbf{S}_W \mathbf{W} = \mathbf{I} \quad (2.9)$$

Mediante la descomposición espectral se tiene que

$$\mathbf{S}_W = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^T, \quad (2.10)$$

donde $\mathbf{U}$ es la matriz ortogonal de vectores propios y $\mathbf{\Lambda}$ es la matriz diagonal de valores propios asociados. La matriz transformadora se define entonces como $\mathbf{W} = \mathbf{U} \mathbf{\Lambda}^{-1/2}$.

Al proyectar los datos originales empleando $\mathbf{W}$, la varianza interna de los grupos se vuelve uniforme en todas las direcciones (esférica), reduciendo la estructura de correlación original y estabilizando los cálculos posteriores.

Cuando $\mathbf{S}_W$ es singular, esta transformación debe entenderse sobre el subespacio asociado a valores propios positivos o mediante una versión truncada/pseudoinversa, ya que los valores propios nulos no pueden invertirse.

La implementación utiliza descomposición en valores singulares (SVD) para identificar las direcciones discriminantes relevantes. En lugar de depender de la inversión directa de ($\mathbf{S}_W$), la SVD permite trabajar con el rango efectivo de la matriz y descartar direcciones asociadas con

varianza nula o numéricamente despreciable. De esta forma, cuando existen variables colineales o combinaciones lineales con varianza muy baja, el algoritmo puede detectarlas mediante un umbral de tolerancia y restringir el cálculo a las dimensiones que conservan información discriminativa suficiente.

Formalmente, la Descomposición en Valores Singulares factoriza una matriz de datos $\mathbf{X}$ (previamente centrada y blanqueada) de la forma $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$, donde $\mathbf{\Sigma}$ es una matriz diagonal que contiene los valores singulares σ_i .

El rango efectivo de la matriz se determina mediante el análisis de estos valores singulares, descartando aquellos que caen por debajo de un umbral de tolerancia τ cercano a cero ($\sigma_i < \tau$). Al truncar la descomposición y conservar únicamente las dimensiones con varianza significativa, el algoritmo evita la división por cero o la inestabilidad numérica que provocarían las dimensiones colineales al calcular las proyecciones discriminantes finales [32].

Esta estrategia no elimina por completo el problema Small Sample Size, ya que la disponibilidad de direcciones discriminantes sigue dependiendo de la información contenida en los datos y del rango efectivo de las matrices involucradas. Sin embargo, puede obtener una proyección en muchos escenarios donde la formulación clásica sería inestable, siempre que exista rango efectivo suficiente [44].

En el contexto de esta investigación, esta consideración es relevante porque la expansión polinomial incrementa el número de variables y puede introducir dependencias lineales o casi lineales entre términos originales, términos cuadrados e interacciones [58].

Por ello, utilizar una implementación de LDA basada en blanqueamiento, control de singularidad y SVD permite emplear el discriminante lineal como motor de evaluación dentro de un esquema wrapper, siempre que previamente se controle la dimensionalidad mediante selección evolutiva. Así, la estabilidad computacional de LDA no se asume como una solución aislada al problema SSS, sino como un componente operativo que se beneficia de la reducción previa del espacio de características.

2.3. Problema de muestras pequeñas (Small Sample Size)

El de muestras pequeñas o Small Sample Size (SSS) aparece en escenarios donde el número de variables descriptivas es elevado en relación con el número de observaciones disponibles. En términos generales, esta situación suele expresarse como $(p > n)$, donde (p) representa la dimensión del espacio de características y (n) el número de muestras. Este escenario es frecuente en dominios de alta dimensionalidad, como bioinformática, análisis de señales, reconocimiento de patrones y problemas donde se generan nuevas variables mediante transformaciones del espacio original [72][82].

En métodos basados en la estimación de matrices de covarianza o dispersión, el problema SSS se manifiesta matemáticamente como una deficiencia de rango. En el caso del Análisis Discriminante Lineal (LDA), la matriz de dispersión intraclase ($\mathbf{S}_W$) tiene dimensión $(p \times p)$, pero su rango máximo está limitado por la cantidad de observaciones disponibles y por el número de clases. En particular, para (C) clases, se cumple que:

$$\text{rank}(\mathbf{S}_W) \leq n - C \quad (2.11)$$

Por tanto, bajo la condición de singularidad donde $p > n - C$, la matriz $\mathbf{S}_W$ no puede alcanzar un rango completo. Esta deficiencia la vuelve singular (no invertible), lo que impide aplicar directamente la formulación clásica que requiere el cálculo algebraico de $\mathbf{S}_W^{-1}$.

La consecuencia práctica de este problema es que la estimación de las direcciones discriminantes puede volverse numéricamente inestable o no estar definida bajo la formulación algebraica clásica. En LDA, esto afecta la resolución del problema generalizado de valores propios y limita la obtención de proyecciones discriminantes estables [29] [53]. Aunque existen estrategias computacionales para reducir la dependencia de la inversión directa de $\mathbf{S}_W$, como el uso de la Descomposición en Valores Singulares (SVD), el blanqueamiento o la regularización, estas alternativas no eliminan por completo la dificultad intrínseca de trabajar con un espacio de variables que supera a la información disponible.

2.4. Expansión polinomial y espacios de características

Ante las limitaciones geométricas del LDA descritas en la sección anterior, resulta pertinente transformar el espacio de representación de los datos. Esta investigación adopta el enfoque de Expansión de Funciones Base (Basis Function Expansion), una técnica ampliamente utilizada en el aprendizaje automático que permite extender la capacidad de los modelos lineales para representar relaciones no lineales [11].

2.4.1. Formalización de la expansión polinomial

El procedimiento consiste en mapear el vector de entrada original $\mathbf{x} \in \mathbb{R}^d$ a un espacio de características de mayor dimensión $\mathcal{F} \in \mathbb{R}^D$ mediante una función no lineal $\phi(x)$.

Específicamente, se implementa una expansión polinomial de segundo orden (cuadrática), tal como se detalla en la literatura especializada [41] [66].

Para un caso base bidimensional donde el vector de entrada es $x = [x_1, x_2]^T$, la función de mapeo $\phi(x)$ construye un nuevo vector que incluye el sesgo, los términos originales, los términos cuadráticos y las interacciones cruzadas:

$$\phi(x) = [1, x_1, x_2, x_1^2, x_2^2, x_1x_2]^T \quad (2.12)$$

Para efectos prácticos de su uso en este trabajo, se omitirá el sesgo debido a que no aporta en el modelado de las fronteras no lineales.

Grado = 1

$$\{ \underbrace{A, B}_{\text{Grado 1}} \}$$

Grado = 2

$$\{ \underbrace{A, B}_{\text{Grado 1}}, \underbrace{A^2, AB, B^2}_{\text{Grado 2}} \}$$

Grado = 3

$$\{ \underbrace{A, B}_{\text{Grado 1}}, \underbrace{A^2, AB, B^2}_{\text{Grado 2}}, \underbrace{A^3, A^2B, AB^2, B^3}_{\text{Grado 3}} \}$$

Grado = 4

$$\{ \underbrace{A, B, A^2, AB, B^2}_{G1}, \underbrace{A^3, A^2B, AB^2, B^3}_{G2}, \underbrace{A^4, A^3B, A^2B^2, AB^3, B^4}_{G3} \}$$

Figura 2.2: Ejemplo de términos generados mediante expansión polinomial para dos variables. Elaboración propia.

Como se ilustra en la Figura 2.2, cada componente cumple un rol discriminante específico:

- Términos Lineales (A, B): preservan la información original.
- Términos Cuadráticos (A^2, B^2): permiten incorporar curvatura en la representación y contribuyen a modelar fronteras de decisión no lineales.
- Términos de Interacción (AB): representan efectos multiplicativos entre variables, permitiendo modelar relaciones que no pueden describirse mediante términos lineales independientes [41].

La justificación teórica para realizar esta expansión se fundamenta en el Teorema de Cover, el cual postula que un problema de clasificación complejo y no lineal en un espacio de baja dimensión puede aumentar la probabilidad de separabilidad lineal bajo una transformación no lineal hacia un espacio de mayor dimensión [20].

2.4.2. Limitaciones: Crecimiento Combinatorio y Complejidad

Si bien la expansión polinomial permite representar relaciones no lineales, introduce un desafío crítico conocido como la Maldición de la Dimensionalidad. A medida que aumenta la dimensión original d o el grado del polinomio P , el número de términos generados D crece de forma combinatoria.

Para una expansión polinomial de grado P , la dimensión del espacio resultante D está dada por la combinatoria con repetición:

$$D = \binom{d+P}{P} - 1 \quad (2.13)$$

Tal como se observa en la Figura 2.3, este crecimiento es explosivo. Por ejemplo, expandir un vector modesto de $d = 10$ variables a un grado cuadrático ($P = 2$) genera 65 términos sin incluir el sesgo.




Figura 2.3: Crecimiento del número de atributos bajo una expansión polinomial de grado 2 sin término de sesgo. Fuente: Elaboración propia.

Este fenómeno conlleva dos consecuencias considerables descritas por [11]:

- **Costo Computacional:** El cálculo de la matriz de covarianza inversa S_W^{-1} requerida por el LDA se vuelve computacionalmente costoso ($O(D^3)$).
- **Sobreajuste (Overfitting):** Al tener un exceso de parámetros frente a un número limitado de muestras, el modelo tiende a memorizar el ruido de los datos en lugar de aprender la estructura subyacente.

En el contexto de LDA, este crecimiento dimensional es especialmente relevante porque la matriz de dispersión intraclase pasa a definirse sobre el espacio expandido, por lo que su dimensión depende de (D) y no solo de la dimensión original (d) . En consecuencia, si $(D > n - C)$, la matriz (S_W) no puede alcanzar rango completo, reproduciendo o agravando el problema SSS descrito en la sección anterior. Por esta razón, la expansión polinomial debe acompañarse de mecanismos de selección de características que permitan conservar únicamente los términos con mayor aporte discriminativo y reducir el riesgo de singularidad, colinealidad y sobreajuste.

2.5. Algoritmos genéticos

Los algoritmos genéticos constituyen una familia de métodos de búsqueda y optimización inspirados en mecanismos evolutivos como selección, recombinación y mutación. En términos generales, estos algoritmos trabajan con una población de soluciones candidatas que se modifican iterativamente con el propósito de mejorar una función objetivo o función de aptitud [31].

Su utilidad en problemas de selección de características radica en que permiten explorar espacios combinatorios amplios sin evaluar exhaustivamente todos los subconjuntos posibles de variables. En el contexto de esta investigación, los algoritmos genéticos resultan especialmente pertinentes debido al crecimiento dimensional producido por la expansión polinomial. Una vez generados términos originales, términos cuadráticos e interacciones, el número de predictores puede crecer de manera acelerada, lo que aumenta el riesgo de singularidad, colinealidad y sobreajuste. Por ello, se requiere un mecanismo de selección capaz de identificar subconjuntos informativos dentro del espacio expandido. Desde esta perspectiva, el algoritmo genético opera como una estrategia de búsqueda dentro de un esquema wrapper, ya que la calidad de cada subconjunto se evalúa mediante el desempeño de un modelo discriminante [43].

2.5.1. Representación cromosómica y función de aptitud

En selección de características, una solución candidata puede representarse mediante un cromosoma binario. Cada posición del cromosoma corresponde a una característica del espacio disponible, y su valor indica si dicha característica se incluye o se excluye del subconjunto evaluado. Matemáticamente, el cromosoma se define como un vector binario $z = [z_1, z_2, \dots, z_D]$, donde cada gen $z_j \in \{1, 0\}$ y D representa la dimensión total del espacio de características.

A modo de ejemplo, un cromosoma de cinco dimensiones estructurado como $z = [1, 0, 1, 0, 1]$ codifica un subconjunto que retiene exclusivamente las características $\{x_1, x_3, x_5\}$, descartando el resto.

En el caso de una expansión polinomial, cada gen puede representar una variable original, un término cuadrático o una interacción entre variables. Por ejemplo, si el espacio expandido contiene términos como x_1, x_2, x_1^2, x_2^2 y $x_1 x_2$, el cromosoma determina cuáles de estos términos serán conservados para entrenar el modelo discriminante. Esta representación permite que el

algoritmo genético explore combinaciones de términos que podrían no ser evidentes mediante criterios univariados de selección.

La función de aptitud define el criterio mediante el cual se evalúa la calidad de cada cromosoma. En un esquema wrapper, esta función suele depender del desempeño del clasificador acoplado al subconjunto seleccionado. Para evitar soluciones excesivamente grandes y penalizar la complejidad del modelo, la función de aptitud puede formalmente como [78]:

$$fitness^z = \text{Desempeño}^{(z)} - \lambda \frac{|z|_0}{D} \quad (2.14)$$

En esta expresión, $\text{Desempeño}^{(z)}$ representa una métrica de clasificación (como la Exactitud o el $F1 - Score$) obtenida con el subconjunto activo, $|z|_0$ denota la norma ℓ_0 que contabiliza el número de características seleccionadas (genes con valor 1), D es la dimensión máxima del espacio expandido y λ es un hiperparámetro que controla la magnitud de la penalización por complejidad.

De esta manera, el algoritmo busca optimizar un criterio combinado que maximice la capacidad predictiva y reducir la dimensionalidad efectiva del subconjunto evaluado.

2.5.2. Ciclo evolutivo y operadores genéticos

El proceso evolutivo sigue un ciclo iterativo estructurado, el cual se ilustra en el diagrama de flujo de la figura 2.4. El ciclo comienza con la inicialización de una población de cromosomas, generada comúnmente de forma aleatoria para asegurar una exploración inicial diversa. En cada generación, los cromosomas son sometidos a una fase de evaluación mediante la función de aptitud y, posteriormente, se aplican los operadores genéticos (selección, cruce y mutación) para producir nuevas soluciones candidatas que conformarán la siguiente generación [31].




Figura 2.4: Diagrama de flujo del ciclo evolutivo de un algoritmo genético. Tomada de [76].

El operador de selección favorece la reproducción de los cromosomas con mayor aptitud. Su propósito es incrementar la probabilidad de que las soluciones más prometedoras transmitan su información genética a la siguiente iteración. Existen diferentes estrategias algorítmicas, como el torneo, la ruleta o el elitismo; sin embargo, todas comparten el objetivo guiar la búsqueda hacia regiones del espacio con mejores propiedades discriminativas.

La cruce o recombinación combina segmentos de dos cromosomas padres para generar descendencia. En la selección de características, este operador permite entrelazar subconjuntos parciales de variables provenientes de soluciones distintas, promoviendo la combinación de términos polinomiales. Un ejemplo de cruce de un punto, asumiendo un punto de corte en la tercera posición, se ilustra de la siguiente forma:

- Padre 1: $z_{P1} = [1, 0, 1|0, 1]$
- Padre 2: $z_{P2} = [0, 1, 0|1, 0]$
- Hijo resultante: $z_H = [1, 0, 1|1, 0]$

La mutación introduce alteraciones estocásticas en genes individuales, invirtiendo sus valores lógicos (de 0 a 1, o viceversa). Este operador es importante para preservar la diversidad dentro de la población y evadir la convergencia prematura en óptimos locales.

Un ejemplo de mutación uniforme sobre el tercer gen de un cromosoma se representa como:

- Cromosoma original: $z = [1, 0, \mathbf{1}, 0, 1]$
- Cromosoma mutado: $z' = [1, 0, \mathbf{0}, 0, 1]$

En conjunto, estos operadores permiten navegar de forma iterativa el vasto espacio de combinaciones posibles. El algoritmo concluye su ejecución al alcanzar un límite de generaciones, al agotar un presupuesto computacional o cuando el cambio en la aptitud intergeneracional cae por debajo de un umbral predefinido.

2.5.3. Algoritmos genéticos como estrategia wrapper

La aplicación de algoritmos genéticos a la selección de características puede entenderse como una estrategia wrapper, dado que cada subconjunto candidato se evalúa a partir del desempeño del modelo de aprendizaje final. A diferencia de los métodos de tipo filtro, los enfoques wrapper incorporan la retroalimentación directa del clasificador y permiten considerar la interacción entre las características seleccionadas y el comportamiento del modelo [43] [34]. Esta propiedad resulta especialmente relevante cuando los predictores incluyen términos polinomiales, ya que la utilidad de una interacción (x_i, x_j) puede depender de su combinación con otros términos del espacio expandido.

En la arquitectura propuesta para esta investigación, el algoritmo genético actúa como mecanismo de exploración sobre el espacio formado por variables originales y términos polinomiales. El objetivo principal no es someter el espacio expandido completo al análisis discriminante, sino identificar un subconjunto que conserve capacidad de separación interclase y reduzca la dimensionalidad efectiva del problema. De esta forma, la búsqueda evolutiva contribuye a mitigar los efectos del crecimiento combinatorio y del problema Small Sample Size. La pertinencia de acoplar un algoritmo genético con LDA radica en que la selección previa de características puede mejorar la estabilidad algebraica del modelo discriminante. Si el espacio polinomial completo se utiliza sin reducción, la matriz de dispersión intraclase puede volverse singular o mal condicionada. En contraste, la reducción previa mediante la metaheurística puede favorecer una representación más compacta y manejable para la estimación discriminante. Por lo tanto, el algoritmo genético no actúa como sustituto del análisis discriminante, sino como un mecanismo previo de selección y reducción que facilita su aplicación sobre un espacio polinomial controlado.

2.6. Métodos kernel y clasificadores no lineales

Los métodos kernel constituyen una familia de enfoques ampliamente utilizados para extender modelos lineales hacia escenarios no lineales. Su idea central consiste en transformar los

datos originales hacia un espacio de características de mayor dimensión, donde relaciones que no son linealmente separables en el espacio original pueden representarse mediante fronteras lineales en el espacio transformado. Esta lógica se relaciona con la motivación subyacente de la expansión polinomial: aumentar la capacidad de representación del modelo mediante transformaciones del espacio de entrada [75].

2.6.1. Truco Kernel y funciones kernel

Sea $x \in \mathbb{R}^p$ un vector de entrada. Un método kernel asume la existencia de una función de mapeo $\phi(x)$, que proyecta las observaciones desde el espacio original hacia un espacio de características posiblemente de alta o incluso infinita dimensión. En principio, el producto interno en dicho espacio transformado se define como:

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j) \quad (2.15)$$

La ventaja computacional fundamental de los métodos kernel consiste en que no es necesario calcular explícitamente las coordenadas proyectadas $\phi(x)$. En su lugar, se define una función kernel $K(x_i, x_j)$ que evalúa directamente el producto interno entre dos observaciones en el espacio transformado. Este procedimiento algorítmico se conoce como el kernel trick y permite trabajar con espacios de características de alta dimensionalidad sin incurrir en el costo de construirlos de forma explícita [11].

Entre las funciones kernel más estandarizadas en la literatura se encuentran el kernel lineal, el kernel polinomial y el kernel de función de base radial (RBF). El kernel lineal equivale al producto interno ordinario, mientras que el kernel polinomial permite incorporar interacciones de orden superior de forma implícita. Por su parte, el kernel RBF mide la similitud local entre observaciones e induce fronteras de decisión altamente flexibles.

Matemáticamente, se expresan de la siguiente manera:

Kernel lineal:

$$K(\mathbf{x}, \mathbf{z}) = \mathbf{x}^T \mathbf{z} \quad (2.16)$$

Kernel polinomial:

$$K(\mathbf{x}, \mathbf{z}) = (\gamma \mathbf{x}^T \mathbf{z} + c)^r \quad (2.17)$$

Kernel RBF:

$$K(\mathbf{x}, \mathbf{z}) = \exp(-\gamma \|\mathbf{x} - \mathbf{z}\|^2) \quad (2.18)$$

En el contexto de esta tesis, el kernel polinomial resulta particularmente relevante por su vinculación teórica con la expansión polinomial explícita. La diferencia principal radica en que, mientras la expansión polinomial construye explícitamente los términos cuadráticos y las interacciones cruzadas, el kernel polinomial opera sobre un espacio expandido de forma implícita. Esta distinción es crítica porque el enfoque propuesto en esta investigación busca conservar una relación directa rastreable con los términos generados, favoreciendo la trazabilidad analítica de las variables seleccionadas.

2.6.2. KFDA y SVM como enfoques no lineales de referencia

El Análisis Discriminante de Fisher con Kernel (KFDA) se concibe como una extensión no lineal del criterio de Fisher clásico. Mientras que LDA busca direcciones discriminantes en el espacio original mediante combinaciones lineales, KFDA traslada el problema de optimización al espacio de características inducido por el kernel. En dicho espacio, el objetivo se mantiene:

maximizar la separación interclase y minimizar la dispersión intraclase; no obstante, la solución algebraica se reformula en términos de productos kernel y matrices de Gram [57].

Una diferencia relevante entre KFDDA y otros clasificadores kernel radica en su relación con la reducción de dimensionalidad supervisada. Al heredar la lógica del criterio de Fisher, KFDDA puede formularse como un método orientado a obtener ejes o proyecciones discriminantes en el espacio de características inducido por el kernel. En este sentido, mantiene una relación conceptual más cercana con LDA, aunque opera mediante una formulación dual basada en productos kernel. Por el contrario, aunque SVM también puede utilizar funciones kernel para inducir fronteras no lineales, su objetivo principal no es construir una proyección discriminante de baja dimensión, sino estimar una frontera de decisión con margen máximo para clasificar nuevas observaciones.

De manera análoga, las Máquinas de Vectores de Soporte (SVM) emplean el kernel trick para construir fronteras de decisión no lineales. En su formulación clásica, SVM busca un hiperplano de separación que maximice el margen geométrico entre las clases, apoyándose en las observaciones más relevantes, denominadas vectores de soporte [19]. Al integrar funciones kernel, la función de decisión para una nueva observación x se formula de la siguiente manera general:

$$f(x) = \sum_{i=1}^n \alpha_i y_i K(x_i, x) + b \quad (2.19)$$

Para el marco experimental de esta investigación, SVM con kernel polinomial y SVM con kernel RBF se consideran los clasificadores no lineales de referencia. Ambos enfoques, sin embargo, presentan una alta sensibilidad a la parametrización, dependiendo de la correcta sintonización de hiperparámetros estructurales como el grado del polinomio r , el coeficiente γ , o la constante de regularización (C) [16].

2.6.3. Ventajas, limitaciones e interpretabilidad

Los métodos kernel presentan una ventaja importante: permiten introducir capacidad de modelado no lineal sin construir explícitamente todas las variables transformadas. En lugar de generar de manera directa los términos del espacio de características, estos métodos operan mediante productos internos definidos por una función kernel. Esta propiedad reduce la necesidad de manipular explícitamente espacios expandidos de alta dimensión y permite modelar fronteras de decisión no lineales estructuras de separación complejas en el espacio original.

No obstante, esta formulación también introduce limitaciones. Al permanecer el espacio transformado de forma implícita, la interpretación directa de las variables originales y de sus interacciones puede volverse menos transparente. En consecuencia, aunque el modelo puede alcanzar buen desempeño predictivo, puede ser más difícil identificar qué variables o combinaciones de variables explican la separación entre clases. Además, el desempeño de los métodos kernel depende de la elección de la función kernel y de la adecuada sintonización de sus hiperparámetros, lo cual puede afectar la capacidad de generalización, especialmente en escenarios de tamaño muestral reducido [16] [74]. En contraste, la expansión polinomial explícita permite observar directamente los términos generados, como variables originales, términos cuadrados e interacciones.

Esta característica favorece la trazabilidad de la representación transformada y permite identificar qué términos son conservados después del proceso de selección. Sin embargo, dicha ventaja tiene como costo el crecimiento combinatorio del número de características. Por ello, la

arquitectura propuesta en esta investigación combina expansión polinomial explícita con selección evolutiva, buscando conservar términos informativos y controlar la dimensionalidad antes de aplicar el análisis discriminante.

En síntesis, los métodos kernel y las SVM proporcionan un marco de referencia relevante para el modelado no lineal. Su inclusión en este Marco Teórico permite contrastar dos estrategias distintas: la no linealidad implícita inducida por funciones kernel y la no linealidad explícita mediante expansión polinomial y selección de características. Esta diferencia resulta central para ubicar la propuesta de esta tesis frente a enfoques kernel tradicionales.

Capítulo 3

Estado del arte

3.1. Variantes lineales del análisis discriminante

3.1.1. Regularized LDA

Históricamente, el Análisis Discriminante Lineal (LDA) ha sido una metodología central para la reducción de dimensionalidad supervisada a partir de la cual se pueden obtener representaciones visualizables y la clasificación lineal. No obstante, su formulación clásica presenta limitaciones importantes en escenarios de alta dimensionalidad y tamaño muestral reducido. En particular, cuando el número de variables es comparable o superior al número de observaciones, la matriz de dispersión intraclase puede volverse singular o estar mal condicionada, lo que dificulta resolver directamente el problema generalizado asociado al criterio de Fisher [89].

Para mitigar esta dificultad, las variantes regularizadas de LDA incorporan términos de penalización sobre la matriz de dispersión, con el objetivo de mejorar su estabilidad numérica. En términos generales, estas estrategias modifican la estimación de la matriz de covarianza o añaden un término de regularización que favorece la inversión del sistema y reduce la sensibilidad del modelo ante fluctuaciones derivadas de muestras pequeñas. En este sentido, la regularización no elimina por completo los riesgos asociados al problema de muestras pequeñas (SSS), pero constituye una alternativa práctica para mejorar la estabilidad del discriminante lineal en contextos de alta dimensionalidad que preserva las bondades de LDA [7].

Además, propuestas recientes como la de Mahadi y colaboradores [49] ofrecen una alternativa para mitigar el problema de muestras pequeñas y mejorar el rendimiento de clasificación de LDA mediante su enfoque denominado Análisis Discriminante Lineal Regularizado No Lineal (NL-RLDA). En este caso, lo “no lineal” hace referencia al estimador de la matriz inversa de covarianzas, diseñado para reducir la influencia de valores pequeños y resolver con mayor estabilidad el problema de valores propios generalizado. Este ajuste permite enfrentar escenarios de alta dimensionalidad y covarianzas mal condicionadas, logrando una mayor efectividad como clasificador. Sin embargo, es importante puntualizar que, pese a la incorporación de un estimador no lineal, la formulación del método sigue buscando un discriminante lineal sobre las características consideradas, manteniendo la naturaleza lineal de la representación.

Estas estrategias pueden mejorar la estabilidad numérica del procedimiento discriminante, pero no modifican la naturaleza lineal de la representación obtenida.

3.1.2. LDA en dos etapas

Una estrategia alternativa frente a la singularidad en espacios de alta dimensionalidad consiste en utilizar esquemas de reducción de dimensionalidad en dos etapas. En la arquitectura comúnmente denominada PCA-LDA, primero se aplica Análisis de Componentes Principales para proyectar los datos hacia un subespacio de menor dimensión. Esta etapa permite comprimir la información de las variables originales en unas pocas componentes principales que mejoran el condicionamiento de la matriz de dispersión al trabajar con LDA [3].

Posteriormente, LDA incorpora la información de clase para buscar una proyección que favorezca la separabilidad entre grupos dentro del subespacio retenido. Esta aproximación ha sido empleada en diversos problemas aplicados debido a su simplicidad y viabilidad computacional. Sin embargo, debe considerarse que PCA es un método no supervisado, por lo que puede descartar componentes de baja varianza que podrían contener información discriminativa relevante. En consecuencia, PCA-LDA puede ser útil en contextos donde se cuenta con más variables que observaciones ($p > n$), pero la reducción inicial está guiada por varianza global y no por discriminación entre clases. Además, aunque la relación con las variables originales se conserva a través de la transformación realizada por PCA, esta resulta más indirecta debido a la etapa intermedia de extracción de componentes [15].

3.1.3. Variantes lineales relevantes

Además de la regularización directa y de los esquemas en dos etapas, se han propuesto variantes lineales orientadas a mejorar la estabilidad, la interpretabilidad y la selección de variables en escenarios de alta dimensionalidad. Una línea relevante corresponde a las formulaciones basadas en el problema Trace-Ratio, que buscan optimizar de forma más directa la relación entre dispersión interclase e intraclase. En particular, las formulaciones recientes de Trace-Ratio LDA han sido estudiadas como alternativas para enfrentar el problema de muestras pequeñas (SSS), al reformular el criterio discriminante de manera más adecuada para matrices de dispersión deficientes en rango [46, 77].

También se cuenta con el enfoque Análisis Discriminante Lineal Disperso (Sparse LDA) que incorporan mecanismos de penalización o selección que promueven soluciones con un número reducido de variables activas. Esta propiedad resulta especialmente relevante cuando, además de clasificar correctamente, se requiere identificar predictores interpretables [47].

En esta misma línea, los enfoques de Inteligencia Artificial Explicable basados en SHAP han sido explorados como mecanismos de apoyo para la selección de variables en escenarios de alta dimensionalidad con pocas muestras. IterSHAP, por ejemplo, utiliza valores de Shapley de manera iterativa para estimar la importancia relativa de las características y descartar aquellas menos informativas, lo que permite mejorar el rendimiento de clasificación en comparación con filtros clásicos o métodos de eliminación recursiva [59]. Sin embargo, es importante subrayar que SHAP actúa como un criterio de priorización y no sustituye la formulación discriminante del modelo, su papel consiste en cuantificar la contribución de cada variable al resultado de un clasificador, mientras que la capacidad de separación entre clases depende del modelo subyacente. De este modo, SHAP aporta información sobre la importancia de las características y puede utilizarse como apoyo para su selección, pero no constituye por sí mismo un método discriminante ni un mecanismo de proyección en baja dimensión.

3.2. Métodos kernel

3.2.1. Análisis de Componentes Principales con Kernel (KPCA)

Las proyecciones lineales pueden resultar insuficientes para capturar distribuciones de datos subyacentes complejas, lo que justifica la adopción de enfoques basados en mapeos no lineales. El Análisis de Componentes Principales con Kernel (KPCA) permite relajar la restricción de linealidad al mapear las características originales hacia un espacio de Hilbert de alta dimensionalidad, donde es posible extraer componentes principales no lineales de forma no supervisada [55].

En escenarios de alta dimensionalidad, esta transformación puede facilitar la obtención de representaciones no lineales de menor dimensión; sin embargo, al operar mediante un mapeo implícito introduce la desventaja de que la relación directa entre componentes obtenidas y las variables originales no es tan transparente como en una transformación explícita. En consecuencia, se dificulta rastrear la influencia individual de cada variable en la representación reducida [13].

3.2.2. Análisis Discriminante de Fisher mediante Kernel (KFDA)

Aunque la reducción de dimensionalidad no supervisada es útil, los escenarios de clasificación exigen estrategias que prioricen la discriminación entre clases. El Análisis Discriminante de Fisher mediante Kernel (KFDA) aprovecha mapeos no lineales inducidos por funciones kernel para transformar problemas fuertemente no separables en hiperespacios donde las clases pueden delimitarse analíticamente [22]. En este sentido, KFDA demuestra que es posible combinar el manejo de la no linealidad y la proyección discriminante, pero lo hace mediante un espacio de características inducido implícitamente por el kernel, manteniendo la formulación del discriminante lineal en dicho espacio.

Al trasladar la métrica de Fisher al espacio de Hilbert, el algoritmo enfrenta inevitablemente el desafío de la deficiencia de rango en la matriz de covarianza proyectada, un problema crítico cuando la cantidad de sujetos (n) es escasa. Para contrarrestar esta inestabilidad intrínseca, arquitecturas contemporáneas optan por integrar el KFDA dentro de métodos de ensamble y regularización estocástica, lo que promueve una mayor diversidad en los subespacios discriminativos y estabiliza el cálculo del hiperplano sin sacrificar el poder del análisis no lineal [42].

3.2.3. SVM Polinomial

Las Máquinas de Vectores de Soporte (SVM) constituyen una alternativa ampliamente utilizada para problemas de clasificación, especialmente cuando se emplean funciones kernel que permiten modelar fronteras de decisión no lineales. En el caso del kernel polinomial, la transformación inducida permite capturar interacciones entre variables sin calcular explícitamente todas las combinaciones en el espacio expandido ([75]).

A diferencia de LDA y KFDA, cuyo procedimiento produce una representación discriminante, SVM está orientado principalmente a construir una función de decisión para clasificación, es decir, generar una proyección discriminante de baja dimensión no constituye el objetivo principal de SVM.

No obstante, su aplicación en escenarios de alta dimensionalidad ($p > n$) requiere una selección cuidadosa de hiperparámetros. Un grado polinomial elevado puede producir fronteras de decisión excesivamente complejas y aumentar el riesgo de sobreajuste, especialmente cuando el número de observaciones es reducido. Por ello, la selección del grado del polinomio y de los

parámetros asociados al kernel resulta determinante para equilibrar flexibilidad y capacidad de generalización [39].

3.2.4. SVM RBF

A diferencia del kernel polinomial, cuyo grado controla explícitamente la complejidad de las interacciones modeladas, el kernel de Función de Base Radial (RBF) permite inducir fronteras de decisión altamente no lineales mediante una medida de similitud local entre observaciones. Esta flexibilidad lo convierte en una alternativa atractiva para problemas donde las clases no son linealmente separables. Sin embargo, en escenarios SSS también puede incrementar el riesgo de sobreajuste si los hiperparámetros no se ajustan adecuadamente [73].

En particular, el parámetro de ancho de banda, usualmente expresado mediante (γ) o (σ) , controla el alcance de influencia de cada observación en el espacio inducido por el kernel. Valores inadecuados pueden producir fronteras excesivamente fragmentadas o, por el contrario, modelos demasiado suaves. Por ello, la selección de hiperparámetros resulta crítica para obtener un equilibrio entre flexibilidad y generalización. Asimismo, trabajos recientes han explorado mecanismos de explicación para modelos SVM-RBF mediante patrones de activación, con el propósito de mejorar la interpretabilidad de modelos kernel tradicionalmente difíciles de analizar [91].

3.3. Selección de características basada en algoritmos evolutivos

3.3.1. GA para selección de variables

La maldición de la dimensionalidad dificulta el uso de enfoques exhaustivos de selección deterministas, dado que el volumen de permutaciones crece exponencialmente en función de las variables de entrada. Para navegar este vasto espacio de búsqueda sin incurrir en costos computacionales prohibitivos, los Algoritmos Genéticos (GA) han sido ampliamente empleados como estrategias de búsqueda estocástica. En lugar de evaluar características de forma aislada, un GA codifica subconjuntos de variables en estructuras cromosómicas, sometiéndolas a un proceso de evolución iterativa mediante selección, cruza y mutación [4]. Una ventaja potencial de este enfoque en el contexto $p > n$ reside en su capacidad para explorar combinaciones de variables sin evaluar exhaustivamente todo el espacio de búsqueda. Investigaciones recientes han sofisticado estas arquitecturas implementando mecanismos de selección multiobjetivo adaptativos, buscando un equilibrio entre la minimización del número de características retenidas y la maximización del poder predictivo del clasificador final [88].

La integración de algoritmos genéticos con LDA puede entenderse como una estrategia de selección de características orientada a reducir la dimensionalidad antes de estimar el discriminante lineal. En escenarios donde $p > n$, seleccionar un subconjunto de variables puede reducir la dimensión efectiva del problema y, bajo determinadas condiciones, contribuir a disminuir los problemas asociados con la singularidad de la matriz de dispersión intraclase y mejorar la estabilidad del modelo. Bajo enfoques de este tipo, el algoritmo genético explora combinaciones de variables, mientras que LDA puede utilizarse como clasificador o como criterio de evaluación de la calidad discriminativa del subconjunto seleccionado [45].

La literatura reciente muestra aplicaciones de algoritmos genéticos para selección de características en problemas de clasificación; sin embargo, su integración específica con LDA debe

presentarse como una estrategia posible más que como una mejora universal frente a alternativas paramétricas [83, 5].

3.3.2. Métodos híbridos

Los métodos híbridos de selección de características surgen como una alternativa para reducir el costo computacional de las estrategias evolutivas puras en dominios de alta dimensionalidad. En general, estas arquitecturas combinan una etapa inicial de filtrado, basada en criterios estadísticos o medidas de relevancia, con una etapa posterior de búsqueda más fina mediante metaheurísticas. La primera fase permite descartar un número considerable de variables redundantes o poco informativas, mientras que la segunda explora subconjuntos candidatos considerando posibles interacciones entre predictores.

Esta combinación puede favorecer una búsqueda más eficiente y mejorar la estabilidad de la selección en determinados contextos, especialmente cuando el espacio original de variables es muy amplio. Sin embargo, su desempeño depende del criterio de filtrado, de la metaheurística empleada, de la función objetivo y del clasificador final. Por ello, más que garantizar una convergencia acelerada o una estabilidad superior en todos los casos, los métodos híbridos se presentan como una estrategia prometedora cuyo rendimiento requiere validación empírica en cada dominio de aplicación [87] [51].

El resultado principal de estas estrategias es un subconjunto reducido de variables; la visualización o extracción de una representación de baja dimensión requiere un procedimiento adicional.

3.3.3. GPDA

Con el propósito de afrontar las limitaciones que presentan LDA y sus variantes en escenarios de Small Sample Size (SSS), Medina y colaboradores propusieron el Análisis Discriminante Proyectivo Genético (GPDA) [56], una técnica de reducción de dimensionalidad basada en computación evolutiva. A diferencia de los enfoques tradicionales sustentados en el criterio de Fisher y en la estimación de matrices de dispersión, GPDA formula la búsqueda de proyecciones discriminantes como un problema de optimización evolutiva sobre matrices ortonormales. La calidad de cada proyección se evalúa mediante el índice de silueta, permitiendo maximizar directamente la separabilidad entre clases sin recurrir a la inversión o descomposición de la matriz de dispersión intraclase. Esta estrategia permite evitar la inversión directa de matrices de dispersión, mitigando los problemas de singularidad característicos del escenario SSS y proporciona representaciones de baja dimensión con elevada capacidad discriminativa.

No obstante, al formular la proyección directamente sobre el espacio original mediante matrices de proyección, GPDA mantiene una representación lineal y no incorpora una transformación explícita destinada a modelar relaciones polinomiales no lineales.

3.4. Limitaciones identificadas

A partir de la revisión anterior, puede observarse que las metodologías empleadas para abordar la alta dimensionalidad y el problema de muestras pequeñas (SSS) enfrentan compromisos recurrentes entre estabilidad numérica, capacidad discriminativa, interpretabilidad y costo computacional. En los enfoques derivados de LDA, una dificultad central se presenta cuando el número de variables es comparable o superior al número de observaciones ($p > n$), ya que la matriz de dispersión intraclase puede volverse singular o mal condicionada. Para mitigar esta

limitación, la literatura ha propuesto estrategias como regularización, reducción previa de dimensionalidad, selección de características, métodos evolutivos y formulaciones Trace-Ratio orientadas al problema de muestras pequeñas [46].

Los métodos kernel, por su parte, permiten capturar relaciones no lineales mediante mapeos implícitos hacia espacios de mayor dimensionalidad. Esta propiedad resulta útil cuando las clases no son separables linealmente; sin embargo, también dificulta la interpretación directa de la contribución de las variables originales. Aunque trabajos recientes han propuesto mecanismos para explicar modelos kernel, como KPCA o SVM-RBF, la trazabilidad de los predictores continúa siendo menos directa que en modelos basados en transformaciones explícitas [13] [91].

De forma complementaria, los algoritmos evolutivos y los métodos híbridos ofrecen una vía flexible para explorar subconjuntos de variables o matrices de proyección sin depender necesariamente de la inversión directa de matrices de dispersión. No obstante, estas estrategias pueden implicar mayores costos computacionales y requieren definir cuidadosamente la función objetivo, los operadores evolutivos y los criterios de convergencia. En consecuencia, el estado del arte muestra que aún existe espacio para propuestas que combinen la reducción de dimensionalidad, generación de representaciones visualizables de baja dimensión, manejo del problema de las muestras pequeñas (SSS), modelado no lineal explícito y trazabilidad respecto de los predictores originales.

3.5. Posicionamiento de GNLPDA

Frente a estas limitaciones, el **Análisis Discriminante Polinomial No Lineal Genético (GNLPDA)** se posiciona como una alternativa metodológica orientada a la integración de selección evolutiva, modelado no lineal explícito, proyección discriminante de baja dimensión, trazabilidad de las características utilizadas, en escenarios de alta dimensionalidad y problemas de muestras pequeñas (SSS). En este sentido, GNLPDA retoma la lógica evolutiva presente en GPDA, al formular la búsqueda de proyecciones como un problema de optimización [56], pero introduce una expansión polinomial explícita que permite representar interacciones entre variables sin recurrir necesariamente a un mapeo kernel implícito basado en matrices de Gram.

El aporte central de GNLPDA radica en la incorporación del manejo de la no linealidad mediante términos polinomiales definidos sobre las variables originales. A diferencia de los métodos kernel, donde el mapeo al espacio de características suele operar de manera implícita, esta formulación permite conservar una relación más directa entre los predictores iniciales, sus interacciones y la proyección discriminativa resultante. Por ello, el método busca equilibrar la capacidad de modelar fronteras de decisión no lineales con una mayor trazabilidad analítica de las características utilizadas.

En este sentido, GNLPDA se plantea como una formulación que integra, dentro de un mismo procedimiento, la selección evolutiva de características, la representación explícita de relaciones no lineales y la obtención de proyecciones discriminantes de baja dimensión. Esta integración permite abordar conjuntamente aspectos que en los métodos revisados se presentan de manera parcial o mediante mecanismos distintos, particularmente la reducción del espacio de características, la representación visualizable de la estructura discriminante y la trazabilidad respecto de las variables y términos polinomiales seleccionados. Su evaluación experimental se orienta, por tanto, a analizar estas propiedades en conjunto con el desempeño predictivo, la estabilidad y el costo computacional, frente a métodos lineales y basados en kernel.

Capítulo 4

Metodología

4.1. Selección evolutiva en dos fases

La arquitectura GNLPDA realiza la búsqueda de características mediante dos fases evolutivas consecutivas. La primera fase opera sobre el espacio de variables originales y tiene como objetivo identificar qué variables conviene expandir mediante la transformación polinomial. La segunda fase opera sobre el espacio polinomial generado a partir del subconjunto seleccionado en la primera etapa, con el propósito de conservar únicamente los términos lineales, cuadráticos o de interacción que aportan al desempeño discriminante.

Ambas fases siguen una lógica de envoltura: cada cromosoma codifica un subconjunto candidato de características, dicho subconjunto se evalúa mediante LDA y el valor de aptitud se calcula a partir de la exactitud promedio obtenida mediante validación cruzada estratificada de cinco pliegues. Además, ambas etapas emplean la misma configuración general del algoritmo genético, incluyendo tamaño de población, número de generaciones, probabilidad de cruce, probabilidad de mutación y valor de penalización (λ). La diferencia entre ambas fases no radica en los operadores evolutivos utilizados, sino en el espacio sobre el que se realiza la búsqueda.

En el protocolo experimental de esta investigación, la búsqueda evolutiva se realiza únicamente sobre la partición de entrenamiento. Dentro de esta partición, GNLPDA calcula la aptitud de cada cromosoma mediante validación cruzada interna estratificada de cinco pliegues. La partición de prueba permanece separada durante todo el proceso de selección y se utiliza únicamente para la evaluación final del modelo seleccionado. De esta manera, la validación cruzada interna guía la búsqueda evolutiva, mientras que la evaluación sobre la partición de prueba estima la capacidad de generalización del método.

4.1.1. Fase I: selección de variables originales

En la primera fase, el algoritmo genético explora subconjuntos de las variables originales del conjunto de datos. Sea $X_{train} \in \mathbb{R}^{n \times p}$ la matriz de entrenamiento, donde n representa el número de observaciones y p el número de variables originales. Cada solución candidata se representa mediante un cromosoma binario de longitud p :

$$z^{(1)} = [z_1, z_2, \dots, z_p], \quad z_j \in \{0, 1\} \quad (4.1)$$

El valor $z_j = 1$ indica que la variable x_j es seleccionada, mientras que $z_j = 0$ indica que dicha variable es excluida. El número de variables originales activas en el cromosoma se define mediante la norma ℓ_0 :

$$q = |z^1|_0 \quad (4.2)$$

Para evitar soluciones degeneradas, se establece una condición mínima de factibilidad: todo cromosoma debe seleccionar al menos dos variables originales. Si $q < 2$, la solución se considera no válida y recibe automáticamente una aptitud igual a cero. Esta regla evita evaluar subconjuntos insuficientes para construir una expansión polinomial útil o para estimar una proyección discriminante mediante LDA. En cambio, no se impone un límite superior al número de variables activas; la complejidad de las soluciones grandes se controla mediante el término de penalización incluido en la función de aptitud.

A partir del cromosoma $z^{(1)}$, se construye el subconjunto $X_{z^{(1)}}$, formado únicamente por las variables originales activas. Sobre este subconjunto se aplica una expansión polinomial de segundo grado, denotada como $\phi_2(X_{z^{(1)}})$. Esta expansión genera términos lineales, términos cuadráticos e interacciones entre las variables seleccionadas. Por ejemplo, si un cromosoma activa las variables $\{x_1, x_3\}$, la expansión cuadrática restringida produce el conjunto:

$$\phi_2(\{x_1, x_3\}) = \{x_1, x_3, x_1^2, x_1x_3, x_3^2\} \quad (4.3)$$

El subconjunto expandido se evalúa mediante LDA usando validación cruzada estratificada de cinco pliegues. Para cada cromosoma válido, la aptitud se define como la exactitud promedio obtenida por LDA menos una penalización proporcional al número de variables originales seleccionadas. Por tanto, la función de aptitud de la primera fase queda definida como:

$$F_1(z^{(1)}) = \begin{cases} 0, & \text{si } q < 2, \\ \text{Acc}_{CV5}(\phi_2(X_{z^{(1)}}), \mathbf{y}_{\text{train}}) - \lambda \frac{q}{p}, & \text{si } q \geq 2. \end{cases} \quad (4.4)$$

En esta expresión, Acc_{CV5} representa la exactitud promedio de validación cruzada, q es el número de variables originales seleccionadas, p es el número total de variables originales disponibles y λ controla la intensidad de la penalización por complejidad. La fracción $\frac{q}{p}$ normaliza la penalización respecto al tamaño del espacio original, favoreciendo soluciones que logren buen desempeño con un menor número de variables.

La salida de esta fase es el cromosoma con mayor valor de aptitud:

$$\mathbf{z}^{(1)*} = \underset{\mathbf{z}^{(1)}}{\text{argmax}} F_1(\mathbf{z}^{(1)}) \quad (4.5)$$

así como el subconjunto de variables originales asociado:

$$S^* = \{x_j : z_j^{(1)} = 1\} \quad (4.6)$$

Este subconjunto define qué variables originales serán utilizadas para construir el espacio polinomial restringido de la segunda fase.

Para reducir el costo computacional de la evaluación de la Fase 1, la expansión polinomial de segundo grado de las variables originales se calcula previamente. Para cada individuo, el subconjunto de variables codificado en el cromosoma se utiliza para determinar los términos polinomiales correspondientes dentro de dicha expansión, los cuales son recuperados sin volver a ejecutar el proceso de expansión.

En ambas fases del proceso evolutivo se incorpora un mecanismo de memoria caché inspirado en la propuesta de Barradas-Palmeros y colaboradores [8]. Dicho mecanismo consiste en almacenar dentro de una lista a cada individuo previamente evaluado junto con el valor de

aptitud correspondiente. El objetivo principal de esta estrategia es evitar la re evaluación innecesaria de individuos repetidos que puedan surgir conforme avanza el ciclo evolutivo, asignándole directamente el valor ya calculado en lugar de someterlos nuevamente al proceso de evaluación.

A continuación se muestra el pseudo-código que describe el funcionamiento de esta primer etapa:

Algoritmo 1: Evaluación de aptitud con expansión polinomial

Entrada: I : Individuo binario de variables originales, X_{orig} : datos originales, X_{pool} : expansión polinomial precomputada de X_{orig} , y : etiquetas, M : modelo base LDA, λ : penalización, Mem : memoria de evaluaciones

Salida: Aptitud f_1

```

1  $q \leftarrow$  número de variables activas en  $I$ ;
2  $p \leftarrow$  número total de variables originales;
3 if  $q < 2$  then
4   return 0;
5 if  $I \in Mem$  then
6   return  $Mem[I]$ ;
7  $T \leftarrow$  obtener términos polinomiales de  $X_{\text{pool}}$  correspondientes a las variables activas en  $I$ ;
8  $\mu \leftarrow$  exactitud media obtenida mediante validación cruzada estratificada de 5 particiones usando  $M$  sobre  $T$ ;
9  $f_1 \leftarrow \mu - \lambda \cdot (k/N)$ ;
10  $Mem[I] \leftarrow f_1$ ;
11 return  $f_1$ ;

```

4.1.2. Fase II: selección de términos polinomiales

La segunda fase toma como entrada el subconjunto ganador S^* obtenido en la Fase I. A partir de estas variables se genera una expansión polinomial de segundo grado, pero ahora el algoritmo genético no selecciona variables originales, sino términos individuales del espacio expandido. Estos términos pueden corresponder a variables lineales, términos cuadráticos o interacciones.

Sea D^* el número total de términos generados por la expansión polinomial restringida de S^* .

Si la expansión es cuadrática y no incluye término de sesgo, entonces:

$$D^* = \binom{q+2}{2} - 1 \quad (4.7)$$

El cromosoma de la segunda fase se define como:

$$Z^{(2)} = [z_1, z_2, \dots, z_{D^*}], \quad z_j \in \{0, 1\} \quad (4.8)$$

En esta fase, cada gen representa un término específico del espacio polinomial restringido. Por ejemplo, si $S^* = \{x_1, x_3\}$, los genes pueden corresponder a los términos ordenados del espacio:

$$\{x_1, x_3, x_1^2, x_1x_3, x_3^2\} \quad (4.9)$$

Así, un cromosoma de la forma:

$$\{x_1, x_1^2, x_1 x_3\} \quad (4.10)$$

El número de términos activos en la segunda fase se define mediante:

$$s = |z^{(2)}|_0 \quad (4.11)$$

De manera análoga a la primera fase, se establece una condición mínima de factibilidad. Si un cromosoma selecciona menos de dos términos polinomiales, es decir, si $s < 2$, la solución se considera no válida y recibe una aptitud igual a cero. Esta regla evita evaluar representaciones excesivamente reducidas que no ofrecen una base suficiente para estimar una proyección discriminante mediante LDA. Para cada cromosoma válido, se construye una matriz de datos formada únicamente por los términos polinomiales activos. Esta matriz se evalúa nuevamente mediante LDA y validación cruzada estratificada de cinco pliegues. La función de aptitud de la segunda fase se define como:

$$F_2(\mathbf{z}^{(2)}) = \begin{cases} 0, & \text{si } s < 2, \\ \text{Acc}_{CV5}(X_{\phi, z^{(2)}}, \mathbf{y}_{\text{train}}) - \lambda \frac{s}{D^*}, & \text{si } s \geq 2. \end{cases} \quad (4.12)$$

En esta expresión, $X_{\phi, z^{(2)}}$ representa la matriz formada por los términos polinomiales seleccionados, s es el número de términos activos, D^* es el número total de términos disponibles en el espacio expandido restringido y λ es el mismo parámetro de penalización utilizado en la primera fase. Esta función favorece subconjuntos que alcancen alta exactitud con un número reducido de términos polinomiales.

La salida de la segunda fase es el subconjunto de términos polinomiales que maximiza la función de aptitud:

$$\mathbf{z}^{(2)*} = \underset{\mathbf{z}^{(2)}}{\text{argmax}} F_2(\mathbf{z}^{(2)}) \quad (4.13)$$

Este subconjunto constituye la representación final seleccionada por GNLPDA. Su propósito es conservar únicamente los términos que contribuyen al desempeño discriminante, descartando variables lineales, términos cuadráticos o interacciones cuya inclusión no compense el aumento de complejidad del modelo.

Algoritmo 2: Evaluación de aptitud en espacio polinomial restringido

Entrada: I : Individuo binario de términos polinomiales, X^* : espacio polinomial restringido, y : etiquetas de clase, M : modelo base LDA, λ : penalización, Mem : memoria de evaluaciones

Salida: Aptitud f_2

```

1  $s \leftarrow$  número de términos activos en  $I$ ;
2  $D^* \leftarrow$  número total de términos en  $X^*$ ;
3 if  $s < 2$  then
4   return 0;
5 if  $I \in Mem$  then
6   return  $Mem[I]$ ;
7  $X_{sub} \leftarrow$  seleccionar de  $X^*$  los términos correspondientes a las posiciones activas de  $I$ ;
8  $\mu \leftarrow$  exactitud media obtenida mediante validación cruzada estratificada de 5
   particiones usando  $M$  sobre  $X_{sub}$  y  $y$ ;
9  $f_2 \leftarrow \mu - \lambda \cdot (s/D^*)$ ;
10  $Mem[I] \leftarrow f_2$ ;
11 return  $f_2$ ;

```

4.1.3. Salida del procedimiento y ajuste final de LDA

Una vez finalizadas ambas fases, GNLPGA devuelve un subconjunto final de términos polinomiales seleccionados. En el protocolo experimental, dicho subconjunto se utiliza para transformar tanto la partición de entrenamiento como la partición de prueba. Posteriormente, se ajusta un modelo LDA final sobre la partición de entrenamiento transformada y se evalúa su desempeño sobre la partición de prueba transformada.

El conjunto de prueba permanece separado del proceso de búsqueda evolutiva y no participa en la selección de variables originales, en la selección de términos polinomiales ni en el cálculo interno de la aptitud. De esta manera, su uso se reserva exclusivamente para estimar la capacidad de generalización del modelo seleccionado.

La salida del método puede resumirse en tres elementos: el subconjunto de variables originales retenidas en la primera fase, el subconjunto de términos polinomiales seleccionados en la segunda fase y la proyección discriminante final de baja dimensión, destinada a la representación y visualización de la estructura de las clases. En conjunto, estos elementos permiten reportar tanto el desempeño predictivo del método como la reducción dimensional lograda respecto al espacio polinomial completo.

En términos metodológicos, la primera fase reduce el espacio de variables que serán consideradas en la expansión, mientras que la segunda fase reduce el espacio polinomial resultante. Esta doble selección evita explorar directamente todas las combinaciones de términos de la expansión polinomial completa y permite controlar el crecimiento combinatorio del problema. Por ello, GNLPGA busca obtener una representación discriminante parsimoniosa y adecuada para la **delección** entre clases, reduciendo el tamaño del espacio de características sobre el cual se ajusta el discriminante y favoreciendo la obtención de una representación de baja dimensión que pueda ser inspeccionada visualmente.

Siendo entonces, que el pseudo-código completo con las funciones de aptitud es el siguiente:

Algoritmo 3: Procedimiento principal de GNLPDA mediante selección evolutiva en dos fases

Entrada: X_{orig} : datos originales, X_{pool} : expansión polinomial precomputada, y : etiquetas de clase, C : configuraciones de los algoritmos genéticos, λ : parámetro de penalización, M : modelo LDA

Salida: I_1^* : mejor individuo de la Fase 1, I_2^* : mejor individuo de la Fase 2, X_{final} : términos polinomiales seleccionados, Z : representación discriminante final de baja dimensión

- 1 Inicializar población P_1 según C ;
 - 2 Inicializar $Mem_1 \leftarrow \emptyset$;
 - 3 Evaluar P_1 mediante F_1 (Algoritmo 1);
 - 4 Guardar el mejor individuo I_1^* ;
 - 5 **while** *criterio de parada de GA no se cumple* **do**
 - 6 Seleccionar padres de P_1 ;
 - 7 Aplicar cruce a los padres seleccionados;
 - 8 Aplicar mutación a los descendientes;
 - 9 Evaluar descendientes mediante F_1 ;
 - 10 Formar nueva población mediante elitismo;
 - 11 Actualizar I_1^* si se obtiene una mejor solución;
 - 12 Obtener S^* a partir de I_1^* ;
 - 13 Construir X^* recuperando de X_{pool} los términos correspondientes a S^* ;
 - 14 Inicializar población P_2 según C ;
 - 15 Inicializar $Mem_2 \leftarrow \emptyset$;
 - 16 Evaluar P_2 mediante F_2 (Algoritmo 2);
 - 17 Guardar el mejor individuo I_2^* ;
 - 18 **while** *criterio de parada de GA no se cumple* **do**
 - 19 Seleccionar padres de P_2 ;
 - 20 Aplicar cruce a los padres seleccionados;
 - 21 Aplicar mutación a los descendientes;
 - 22 Evaluar descendientes mediante F_2 ;
 - 23 Formar nueva población mediante elitismo;
 - 24 Actualizar I_2^* si se obtiene una mejor solución;
 - 25 $X_{\text{final}} \leftarrow$ seleccionar términos de X^* según I_2^* ;
 - 26 Ajustar M sobre X_{final} ;
 - 27 Obtener Z ;
 - 28 **return** $I_1^*, I_2^*, X_{\text{final}}, Z$;
-

4.2. Configuración y calibración de GNLPDA

Una vez definida la arquitectura general de GNLPDA, fue necesario establecer la configuración del algoritmo genético utilizado en ambas fases de selección. En esta sección se describen los mecanismos que conforman el proceso evolutivo, la representación utilizada y los principales parámetros de configuración. Posteriormente, se presenta el procedimiento de calibración automática mediante *irace* [48], utilizado para determinar los valores de los parámetros sometidos a búsqueda.

4.2.1. Configuración del algoritmo genético.

Representación

El algoritmo genético empleado en GNLPGA utiliza una representación binaria pura. En ambas fases, cada cromosoma se codifica como un vector de ceros y unos, donde el valor 1 indica la inclusión de una variable o término, y el valor 0 indica su exclusión.

Por ejemplo, para un conjunto de cinco variables $\{A, B, C, D, E\}$, el individuo de la primera fase puede ser:

$$\text{Individuo} = \{1, 0, 1, 0, 0\} \quad (4.14)$$

Lo cual tiene una correspondencia directa con la selección de variables $\{A, C\}$.

En la segunda fase, se representan términos del espacio polinomial restringido. Si previamente la selección de variables fue $\{A, C\}$ entonces el subconjunto expandido sobre el que se hara la búsqueda en la segunda fase es $\{A, C, A^2, A * C, C^2\}$. Dicho subconjunto al tener 5 términos en total, da origen a la siguiente representación binaria:

$$\text{Individuo} = \{0, 0, 1, 1, 0\} \quad (4.15)$$

Lo cual tiene una correspondencia directa con la selección de términos $\{A^2, A * C\}$.

Siendo así que ambas fases usan la misma representación binaria pero mapeando diferentes conjuntos.

Selección

En este esquema, dos individuos se seleccionan aleatoriamente de la población y compiten con base en su valor de aptitud. El individuo con mayor aptitud es seleccionado como progenitor.

$$\text{Padre} = \begin{cases} I_i, & \text{si } f(I_i) \geq f(I_j) \\ I_j, & \text{en otro caso} \end{cases} \quad (4.16)$$

Cruza

En el proceso de cruce de un solo punto, dos individuos progenitores son seleccionados y se define un único punto de corte aleatorio común para ambos. A partir de este punto, se construyen los descendientes intercambiando las secciones correspondientes de los padres. De esta manera, cada hijo conserva una parte inicial de un progenitor y una parte final del otro, garantizando la recombinación de información genética en un esquema clásico de cruce. A continuación se muestra un ejemplo de cruce a partir de dos progenitores seleccionando como punto de corte el segundo elemento del vector:

$$P_1 = \{1, 1, 0, 0, 1\}, \quad P_2 = \{1, 0, 1, 0, 1\} \quad (4.17)$$

$$H_1 = \{1, 1, 1, 0, 1\}, \quad H_2 = \{1, 0, 0, 0, 1\} \quad (4.18)$$

Mutación

La mutación implementada es el esquema de mutación por inversión de bits (*bit-flip*).

Este operador actúa sobre cada gen del individuo de manera independiente, aplicando una probabilidad de mutación previamente definida. En caso de que la mutación ocurra, el valor binario del gen se invierte: un 1 se transforma en 0 y, de manera análoga, un 0 se convierte en 1.

$$I = \{1, 0, 1, 0, 1\} \quad (4.19)$$

$$I' = \{1, 1, 1, 0, 0\} \quad (4.20)$$

Después de la mutación se aplica una corrección de factibilidad para que el individuo conserve al menos dos genes activos.

Remplazo generacional

El algoritmo genético se implementó bajo un esquema de remplazo generacional, en el cual la población completa es sustituida en cada generación por individuos recién generados.

Dentro de este esquema se incorpora un componente de elitismo, mediante el cual se garantiza la preservación automática de los dos individuos con mayor aptitud de la generación actual, asegurando que las soluciones de mayor calidad no se pierdan en el proceso. A continuación se muestra un breve ejemplo donde t representa la generación actual y $t + 1$ la generación siguiente.

$$Población^{(t)} = \{ \{1, 1, 0, 1, 0\}, \{1, 0, 1, 0, 1\}, \dots, \{0, 1, 1, 0, 0\} \} \quad (4.21)$$

$$Elites^{(t)} = \{ \{1, 1, 0, 1, 0\}, \{1, 0, 1, 0, 1\} \} \quad (4.22)$$

$$Descendientes^{(t)} = \{ \{1, 1, 1, 0, 1\}, \{0, 1, 0, 1, 0\}, \dots \} \quad (4.23)$$

$$Población^{(t+1)} = Elites^{(t)} \cup Descendientes^{(t)} \quad (4.24)$$

La aplicación conjunta de estos operadores define el ciclo evolutivo empleado en cada fase de GNLPGA. A partir de una población inicial de individuos, cada generación evalúa la aptitud de las soluciones, selecciona progenitores mediante torneo binario, aplica cruce y mutación para generar nuevos individuos y conserva los dos mejores individuos mediante elitismo. Este proceso se repite durante el número de generaciones establecido, manteniendo además un registro de la mejor solución encontrada a lo largo de toda la ejecución.

En conjunto, los elementos descritos determinan la configuración del algoritmo genético utilizada en cada una de las fases de selección de GNLPGA. Si bien los operadores y la representación binaria se mantienen fijos, algunos parámetros de control deben establecerse antes de ejecutar el proceso evolutivo. La Tabla 4.1 resume los principales elementos que conforman esta configuración, distinguiendo los operadores empleados de los parámetros cuyos valores serán determinados mediante el procedimiento de calibración descrito en la siguiente sección.

Parámetro	Notación
Número de generaciones	$ngens$
Tamaño de población	$pobsize$
Probabilidad de cruce	P_c
Probabilidad de mutación	P_m
Penalización por complejidad	λ
Selección	Torneo binario
Cruza	Cruza de un solo punto
Representación	Binaria
Elitismo	Conservación de los 2 mejores individuos

Tabla 4.1: Configuración del algoritmo genético empleado en GNLPDA.

4.3. Configuración y calibración de los parámetros de GNLPDA

Una vez definida la arquitectura general de GNLPDA, fue necesario establecer la configuración del algoritmo genético utilizado en ambas fases de selección. Dado que el desempeño de los algoritmos evolutivos puede depender de la elección de sus parámetros de control, se realizó una calibración automática mediante la herramienta *irace* [48], con el propósito de identificar una configuración adecuada para el problema de selección de características considerado en esta investigación.

Los parámetros considerados para la calibración del algoritmo se presentan en la Tabla 4.2. Los dominios de búsqueda se establecieron tomando como referencia configuraciones empleadas en trabajos previos de selección de características mediante algoritmos genéticos, y posteriormente se adaptaron a las características particulares de GNLPDA.

Parámetro	Símbolo	Tipo	Rango de búsqueda
Número de generaciones	$ngens$	Entero	[20, 100]
Tamaño de población	$pobsize$	Entero	[20, 100]
Probabilidad de cruce	P_c	Real	[0.4, 0.95]
Probabilidad de mutación	P_m	Real	[0.05, 0.2]
Penalización por complejidad	λ	Real	[0.01, 0.2]

Tabla 4.2: Rangos de calibración considerados por *irace*.

Para los parámetros $ngens$, $pobsize$, P_c y P_m se tomaron como referencia los rangos empleados por [80], debido a que en dicho trabajo se propone un enfoque de envoltura para la selección de características mediante algoritmos genéticos con representación binaria y una estructura jerárquica de selección de variables.

A partir de estos rangos, se realizaron adaptaciones al contexto de GNLPDA. Debido al costo computacional asociado con la evaluación del espacio generado por la expansión polinomial, se redujeron los rangos correspondientes al número de generaciones y al tamaño de la población. Por otra parte, se ampliaron los dominios de búsqueda de P_c y P_m para permitir que *irace* explorara configuraciones con diferentes niveles de recombinación y perturbación de los individuos.

La penalización por complejidad λ constituye un parámetro propio de la función de aptitud de GNLPDA. Su dominio se estableció entre [0,01,0,2], con el propósito de explorar distintos

niveles de penalización y favorecer, ante desempeños comparables, soluciones que utilicen una menor cantidad de variables o términos seleccionados.

Para realizar la calibración mediante *irace* se utilizaron cuatro instancias que corresponden a los conjuntos de datos: *wines*, *pimadiabetes*, Cebolla3D y Cebolla10D. Dichos conjuntos y sus características se presentan más adelante en la Tabla 4.4. Las instancias fueron seleccionadas para representar escenarios complementarios: *wines* como un caso favorable para la separación lineal; *pimadiabetes* como un escenario real con mayor dificultad de separación; y Cebolla3D y Cebolla10D como escenarios sintéticos con estructuras no linealmente separables y diferente dimensionalidad, utilizados para evaluar el efecto de la expansión polinomial. En conjunto, estas instancias permitieron evaluar la configuración del algoritmo bajo diferentes condiciones de dimensionalidad y separabilidad.

Dado que *irace* opera como un procedimiento de minimización, el criterio objetivo se definió a partir de la aptitud penalizada obtenida por GNLPDA en la Fase II. Para cada configuración candidata e instancia de calibración, se ejecutó el procedimiento completo de dos fases y se registró el mejor valor global de aptitud encontrado durante la Fase II, denotado como $F_2(z^{(2)*})$. A partir de este valor, la función de costo que guió la búsqueda de *irace* se definió como:

$$\mathcal{L}_{irace} = 1 - F_2(z^{(2)*}) \quad (4.25)$$

De esta forma, minimizar $\mathcal{L}_{irace}$ equivale a favorecer configuraciones que produzcan una mayor aptitud penalizada en la segunda etapa.

El presupuesto máximo de calibración se fijó en 3000 evaluaciones para realizar la búsqueda de configuraciones. Con la finalidad de reducir el tiempo de ejecución, las evaluaciones se realizaron de manera paralela utilizando 11 núcleos de procesamiento.

La configuración seleccionada por *irace* bajo estas condiciones y utilizada posteriormente en la experimentación se presenta en la Tabla 4.3.

Parámetro	Símbolo	Valor final
Número de generaciones	$ngens$	94
Tamaño de población	$pobsize$	64
Probabilidad de cruza	P_c	0.90
Probabilidad de mutación	P_m	0.05
Penalización por complejidad	λ	0.01

Tabla 4.3: Valores finales de los parámetros del algoritmo genético obtenidos mediante *irace*.

4.4. Diseño experimental

4.4.1. Conjuntos de datos utilizados

Para evaluar el desempeño de GNLPDA se utilizaron diez conjuntos de datos con diferentes tamaños muestrales, dimensionalidades, números de clases y niveles de complejidad geométrica. La selección de estos conjuntos busca cubrir escenarios de clasificación binaria y multiclase, así como problemas donde la frontera de separación entre clases puede variar desde casos relativamente favorables para métodos lineales hasta escenarios con estructuras no lineales o traslape significativo entre clases.

Los conjuntos Palmer Penguins y Wines se incorporaron como puntos de partida experimentales. Ambos corresponden a conjuntos de referencia ampliamente utilizados en clasificación supervisada y presentan una estructura de clases relativamente favorable para métodos lineales. Palmer Penguins contiene mediciones morfológicas de tres especies de pingüinos, mientras que Wines describe muestras de vino mediante variables químicas asociadas a tres clases. Estos conjuntos permiten verificar el comportamiento de GNLPDA en escenarios clásicos donde se espera que métodos lineales como LDA tengan un desempeño competitivo [33][18].

Los conjuntos Breast Cancer Wisconsin Diagnostic (WDBC) e Ionosphere se incluyeron como escenarios de referencia con mayor dimensionalidad. Aunque también pueden presentar una separación relativamente favorable para clasificadores lineales, su interés experimental radica en el incremento del número de variables. WDBC corresponde a un problema binario de diagnóstico de cáncer de mama a partir de características extraídas de imágenes digitalizadas de masas celulares. Por su parte, Ionosphere corresponde a un problema binario asociado con señales de radar, donde las observaciones se describen mediante un conjunto de variables numéricas de mayor dimensión. Estos conjuntos permiten analizar si GNLPDA conserva un comportamiento adecuado cuando aumenta el número de características originales disponibles [50] [79].

Para evaluar explícitamente el comportamiento de los métodos ante estructuras no lineales, se generaron tres conjuntos sintéticos denominados Cebolla3D, Cebolla10D y Cebolla20D. Estos conjuntos fueron contruidos mediante un procedimiento de generación de datos concéntricos, de elaboración propia, en el que las clases se distribuyen en capas o regiones radiales. Por construcción, estos escenarios no presentan una separación lineal directa en el espacio original, por lo que permiten analizar la utilidad de la expansión polinomial y de la selección evolutiva de términos dentro de GNLPDA. La inclusión de versiones en 3, 10 y 20 dimensiones permiten observar el efecto del incremento dimensional en un problema no lineal controlado.

El conjunto pimiadabetes se incorporó como un caso clásico de clasificación binaria con mayor dificultad práctica. Este conjunto reúne variables clínicas asociadas al diagnóstico de diabetes y es conocido por presentar traslape entre clases, ruido y presencia de valores faltantes o codificados de forma problemática. Por ello, constituye un escenario útil para evaluar el desempeño de GNLPDA en un problema donde la separación entre clases no es necesariamente clara, incluso después de aplicar transformaciones al espacio de características [81].

Finalmente, se incluyeron dos conjuntos de indicadores de rezago social correspondientes a los años 2015 y 2020. Estos datos fueron proporcionados por un investigador colaborador y corresponden a una aplicación reciente en un contexto real. A diferencia de los conjuntos clásicos de referencia, estos datos presentan un mayor número de observaciones y cinco clases, lo que permite evaluar el comportamiento de GNLPDA en un problema multiclase aplicado. Además, su inclusión amplía el análisis experimental hacia un dominio distinto al de los repositorios tradicionales de aprendizaje automático [62].

La Tabla 4.4, resume las principales características de los conjuntos de datos utilizados en la evaluación experimental:

Dataset	Muestras	Variables	Clases	Referencia
penguins	342	4	3	[33]
wines	178	13	3	[18]
Breast Cancer (WDBC)	569	30	2	[50]
Ionosphere	351	34	2	[79]
Cebolla3D	300	3	3	Sintéticos
Cebolla10D	300	10	3	Sintéticos
Cebolla20D	300	20	3	Sintéticos
pimadiabetes	768	8	2	[81]
Indicadores 2015	2446	12	5	[62]
Indicadores 2020	2470	12	5	[62]

Tabla 4.4: Resumen de datasets y características.

En conjunto, estos datos permiten evaluar el método en cuatro tipos de escenarios: conjuntos clásicos con separabilidad relativamente favorable, conjuntos de referencia con mayor número de variables, conjuntos sintéticos no lineales de estructura controlada y aplicaciones reales con mayor tamaño muestral. Esta diversidad experimental permite analizar no solo la exactitud predictiva de GNLPDA, sino también su capacidad para seleccionar representaciones compactas en problemas con distintas características geométricas y dimensionales.

4.4.2. Generación de conjuntos sintéticos tipo Cebolla

Además de los conjuntos de referencia y de aplicación real, se generaron tres conjuntos sintéticos denominados Cebolla3D, Cebolla10D y Cebolla20D. Estos conjuntos fueron diseñados con el propósito de evaluar el comportamiento de los métodos en escenarios donde la separación entre clases no es lineal en el espacio original. A diferencia de los conjuntos reales, cuya estructura depende de datos observados, los conjuntos tipo Cebolla permiten controlar explícitamente la geometría del problema y controlar explícitamente la estructura concéntrica de clases.

El procedimiento de generación se basa en distribuir observaciones sobre capas radiales alrededor de un centro común. Cada clase se asocia con un intervalo de radios distinto, de manera que la pertenencia de clase depende principalmente de la distancia al origen y no de una combinación lineal de las variables. Por esta razón, las clases no presentan una separación lineal adecuada mediante hiperplanos en el espacio original, lo que convierte a estos conjuntos en escenarios adecuados para evaluar métodos que incorporan transformaciones no lineales del espacio de características.

A continuación se describe el procedimiento propuesto por [52] para generar los datos con estas características.

Sea $x_i \in \mathbb{R}^d$ una observación generada en un espacio de dimensión d , con $d \in \{3, 10, 20\}$.

Para cada clase $c \in \{1, 2, 3\}$, se define un intervalo radial:

$$a_c = 2(c - 1), \quad b_c = a_c + 1,5 \quad (4.26)$$

De esta forma, las tres clases quedan asociadas a los intervalos radiales $[0, 1.5]$, $[2, 3.5]$ y $[4, 5.5]$, respectivamente. La separación entre intervalos radiales introduce una estructura de

capas concéntricas, mientras que la dimensión d determina el número de variables del conjunto sintético generado.

Para generar cada observación, primero se obtiene un vector aleatorio $v_i \in \mathbb{R}^d$ con componentes independientes provenientes de una distribución normal estándar:

$$v_i \sim \mathcal{N}(\mathbf{0}, I_d) \quad (4.27)$$

Posteriormente, este vector se normaliza para obtener una dirección unitaria:

$$u_i = \frac{v_i}{|v_i|} \quad (4.28)$$

El radio de la observación se genera de manera uniforme dentro del intervalo correspondiente a su clase:

$$r_i \sim U(a_c, b_c) \quad (4.29)$$

Finalmente, la observación se obtiene escalando la dirección unitaria por el radio generado y agregando una perturbación uniforme por coordenada:

$$x_i = r_i u_i + \varepsilon_i \quad (4.30)$$

Donde:

$$\varepsilon_i \sim U\left(-\frac{\eta}{2}, \frac{\eta}{2}\right)^d \quad (4.31)$$

y $\eta = 0,1$ controla la magnitud del ruido añadido. La etiqueta de clase se asigna de acuerdo con el intervalo radial utilizado en la generación, produciendo las clases G_1 , G_2 y G_3 .

En cada conjunto sintético se generaron 100 observaciones por clase, para un total de 300 observaciones distribuidas en tres clases. Cebolla3D permite visualizar directamente la estructura concéntrica del problema, mientras que Cebolla10D y Cebolla20D permiten analizar el comportamiento de los métodos cuando la misma estructura no lineal se presenta en espacios de mayor dimensionalidad.

Estos conjuntos fueron generados específicamente para esta investigación, por lo que se reportan como datos de elaboración propia. Su inclusión permite evaluar si GNLPGA logra aprovechar la expansión polinomial y la selección evolutiva de términos para construir una representación discriminante adecuada en problemas donde la no linealidad está presente por construcción.

4.4.3. Métodos comparativos y métrica de evaluación

Para evaluar el desempeño de GNLPGA se consideraron seis métodos comparativos: LDA, QDA, KFPA con kernel gaussiano, SVM con kernel polinomial de grado 2, SVM con kernel polinomial de grado 3 y SVM con kernel gaussiano. La selección de estos competidores busca contrastar la propuesta frente a clasificadores lineales clásicos, clasificadores cuadráticos, métodos kernel discriminantes y clasificadores kernel ampliamente utilizados en problemas de clasificación supervisada.

El primer método comparativo fue LDA, implementado mediante la función `lda` de la paquetería MASS de R. Este método se incluyó como línea base, ya que representa el enfoque clásico de separación y proyección lineal supervisada. Además, resulta especialmente relevante porque GNLPGA utiliza internamente esta implementación de LDA para evaluar las representaciones

generadas durante su proceso de selección evolutiva. La implementación de MASS es pertinente en este contexto debido a su tratamiento computacional de la estimación discriminante, particularmente cuando aparecen problemas de colinealidad o alta dimensionalidad relativa.

El segundo método fue QDA, considerado como una extensión clásica del análisis discriminante que relaja el supuesto de covarianzas iguales entre clases. A diferencia de LDA, QDA permite fronteras de decisión cuadráticas, por lo que se incorporó como un competidor tradicional capaz de modelar separaciones no estrictamente lineales en el espacio original.

También se incluyó KFDA con kernel gaussiano. Este método constituye una alternativa kernel de análisis discriminante de Fisher, al permitir que la separación entre clases se realice en un espacio de características inducido implícitamente por el kernel. Su inclusión resulta relevante porque conserva una interpretación discriminante y proyectiva, pero incorpora la capacidad de modelar relaciones no lineales entre las observaciones. Se implementó manualmente siguiendo las especificaciones de su artículo fundacional[57] y una explicación más reciente su funcionamiento [30]. Fue utilizado como extractor discriminante de características. La decisión de clase se realizó posteriormente mediante el criterio de mínima distancia euclidiana al centroide de cada clase en el espacio generado por KFDA.

Adicionalmente, se evaluaron tres variantes de SVM. La primera corresponde a SVM con kernel polinomial de grado 2, incluida como referencia frente a una transformación polinomial implícita de segundo grado. La segunda corresponde a SVM con kernel polinomial de grado 3, considerada para analizar el efecto de una transformación polinomial implícita de mayor orden. Finalmente, se incluyó SVM con kernel gaussiano, debido a su uso extendido en el estado del arte y a su capacidad para modelar fronteras de decisión no lineales flexibles.

Método	Variante	Propósito en la comparación
LDA	LDA de la paquetería MASS	Línea base de separación lineal y proyectiva; implementación usada internamente por GNLPDA.
QDA	Clásico	Clasificador discriminante con fronteras cuadráticas.
KFDA	Gaussiano	Alternativa kernel de Fisher para separación no lineal.
SVM	Pol (2)	Comparación frente a una transformación polinomial implícita de segundo grado.
SVM	Pol (3)	Comparación frente a una transformación polinomial implícita de mayor orden.
SVM	Gaussiano	Clasificador kernel no lineal ampliamente utilizado.

Tabla 4.5: Resume los métodos comparativos considerados y su propósito dentro del diseño experimental.

4.4.4. Protocolo de particionamiento y evaluación

El preprocesamiento de los conjuntos de datos se mantuvo al mínimo con el propósito de evaluar los métodos sobre representaciones cercanas a los datos originales. No se aplicaron procedimientos de estandarización, normalización, reducción dimensional previa ni transformacio-

nes adicionales sobre las variables de entrada. Únicamente se realizaron depuraciones puntuales cuando fue necesario, tales como la eliminación de variables no predictoras, identificadores o columnas incompatibles con el análisis numérico. De esta forma, las diferencias observadas entre métodos se atribuyen principalmente al procedimiento de clasificación o transformación propio de cada técnica evaluada.

Para estimar el desempeño de los métodos se utilizó un esquema de particionamiento aleatorio repetido. En cada conjunto de datos se generaron 30 particiones independientes con proporción 70/30, donde el 70 % de las observaciones se utilizó como conjunto de entrenamiento y el 30 % restante como conjunto de prueba. Cada partición fue generada a partir de una semilla aleatoria prefijada, de manera que el procedimiento pudiera reproducirse.

Todos los métodos comparativos fueron evaluados utilizando exactamente las mismas particiones de entrenamiento y prueba. Por tanto, para una semilla dada, GNLPGA, LDA, QDA, KFDA y las variantes de SVM fueron entrenados y evaluados sobre el mismo bloque experimental. Este diseño permite realizar comparaciones emparejadas entre algoritmos, ya que las diferencias de desempeño no dependen de variaciones en los datos utilizados para entrenamiento o prueba, sino del comportamiento de cada método bajo la misma partición.

En el caso particular de GNLPGA, la búsqueda evolutiva se realizó únicamente dentro del conjunto de entrenamiento de cada partición. A su vez, la evaluación interna de los cromosomas se llevó a cabo mediante validación cruzada estratificada de cinco pliegues sobre dicho conjunto de entrenamiento. El conjunto de prueba no participó en la selección de variables originales, en la selección de términos polinomiales ni en el cálculo de la aptitud. Una vez finalizado el proceso de selección, el modelo final se ajustó con la representación seleccionada sobre el conjunto de entrenamiento y se evaluó sobre el conjunto de prueba correspondiente.

El rendimiento de los métodos se evaluó mediante exactitud (accuracy) sobre el conjunto de prueba. Para una partición dada, la exactitud se calculó como la proporción de observaciones correctamente clasificadas:

$$\text{Accuracy} = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} \mathbb{I}(\hat{y}_i = y_i) \quad (4.32)$$

Dado que cada método fue evaluado sobre las mismas 30 particiones por dataset, para cada combinación método-dataset se obtuvieron 30 valores de exactitud. Estos valores fueron utilizados posteriormente para el análisis estadístico mediante la prueba de Friedman y, cuando correspondió, la prueba post hoc de Nemenyi.

4.4.5. Evaluación auxiliar del problema Small Sample Size

Además del análisis comparativo principal, se diseñó una evaluación auxiliar para visualizar el efecto del problema Small Sample Size (SSS) sobre métodos discriminantes. Esta evaluación no tuvo como objetivo comparar exhaustivamente todos los algoritmos del estudio, sino ilustrar el comportamiento de LDA en su formulación manual, la implementación lda de la paquetería MASS y KFDA bajo escenarios donde la relación entre número de observaciones y número de variables se vuelve desfavorable.

Para ello, se construyeron cinco escenarios sintéticos con tres clases balanceadas.

En cada caso se controló el número total de observaciones, el número de atributos originales y el número de atributos resultantes después de aplicar una expansión polinomial de segundo grado sin término de sesgo. Si (d) representa el número de atributos originales, el número de términos generados por la expansión cuadrática se calculó como:

$$D_\phi = \binom{d+2}{2} - 1 \quad (4.33)$$

La Tabla 4. resume los cinco escenarios considerados:

Caso	Muestras	Atributos	Atributos expandido	Clases	Muestras por clase
1	150	3	9	3	50
2	150	10	65	3	50
3	15	3	9	3	5
4	15	10	65	3	5
5	15	15	135	3	5

Tabla 4.6: Resumen de los escenarios de prueba sintéticos.

Los dos primeros casos representan escenarios con un número relativamente suficiente de observaciones por clase. En el Caso 1, la dimensionalidad es baja tanto en el espacio original como en el espacio expandido. En el Caso 2, la expansión polinomial incrementa considerablemente el número de atributos, aunque el tamaño muestral sigue siendo relativamente amplio.

Los Casos 3, 4 y 5 introducen una condición de escasez muestral, con únicamente 15 observaciones totales y cinco muestras por clase. El Caso 3 permite observar el efecto de una muestra reducida con baja dimensionalidad. En el Caso 4, la expansión polinomial genera 65 atributos a partir de 10 variables originales, produciendo una relación desfavorable entre dimensión y tamaño muestral. Finalmente, el Caso 5 representa el escenario más severo, ya que combina baja muestra, mayor número de atributos originales y una expansión polinomial de 135 términos.

Esta evaluación permite observar visualmente cómo la expansión del espacio de características puede agravar el problema SSS. En particular, cuando el número de atributos se aproxima o supera el número de observaciones disponibles, la estimación de matrices de dispersión o covarianza puede volverse inestable o singular. Por ello, estos escenarios resultan útiles para contrastar la formulación clásica de LDA, la implementación computacional de LDA en MASS y KFDA bajo condiciones de alta dimensionalidad relativa.

Los resultados derivados de esta evaluación se presentan como un análisis complementario al experimento principal. Su propósito es apoyar la discusión metodológica sobre las limitaciones de los enfoques discriminantes cuando el espacio de características crece de manera considerable respecto al número de observaciones disponibles, especialmente después de aplicar expansiones polinomiales.

4.4.6. Análisis estadístico de resultados

El análisis estadístico se realizó de manera independiente para cada conjunto de datos. Dado que todos los métodos fueron evaluados sobre las mismas 30 particiones de entrenamiento y prueba, el diseño experimental puede interpretarse como un diseño en bloques emparejados, donde cada partición constituye un bloque y cada algoritmo representa un tratamiento. Bajo este esquema, las comparaciones entre métodos se realizan considerando que todos enfrentan las mismas condiciones experimentales dentro de cada bloque.

Para detectar diferencias globales entre los algoritmos se aplicó la prueba no paramétrica de Friedman. Esta prueba permite comparar múltiples métodos bajo un diseño de bloques, utilizando los rangos de desempeño obtenidos por los algoritmos dentro de cada partición.

En este trabajo, para cada dataset se construyó una matriz de resultados con 30 filas, correspondientes a las particiones aleatorias, y una columna por cada método evaluado. A partir de esta matriz se aplicó la prueba de Friedman con el objetivo de determinar si existían diferencias estadísticamente significativas entre los desempeños de los algoritmos [70].

Cuando la prueba de Friedman indicó diferencias significativas, se aplicó la prueba post hoc de Nemenyi para identificar entre qué pares de métodos se presentaban diferencias estadísticamente significativas. Esta prueba permite comparar los rangos promedio de los algoritmos y determinar si la diferencia entre dos métodos supera la diferencia crítica establecida para el nivel de significancia considerado [21].

El análisis se realizó en dos niveles. En primer lugar, se consideró el conjunto completo de métodos comparativos, incluyendo LDA, QDA, KFDA, SVM con kernel polinomial de grado 2, SVM con kernel polinomial de grado 3, SVM con kernel gaussiano y GNLPDA.

Esta comparación permite situar la propuesta frente a clasificadores lineales, cuadráticos y no lineales.

En segundo lugar, se repitió el análisis excluyendo a LDA y QDA. Esta segunda comparación se centró únicamente en métodos no lineales o basados en transformaciones del espacio de características, es decir, KFDA, las variantes kernel de SVM y GNLPDA. El propósito de este análisis adicional fue evaluar el comportamiento relativo de la propuesta frente a competidores más cercanos en términos metodológicos, evitando que las diferencias frente a clasificadores lineales dominaran la interpretación de los resultados.

En todos los casos, el análisis estadístico se basó en los resultados obtenidos sobre las 30 particiones aleatorias de cada dataset. De esta forma, la comparación entre métodos incorpora la variabilidad inducida por las particiones entrenamiento-prueba y no depende de una única división de los datos.

Capítulo 5

Resultados

5.1. Resultados del problema de muestras pequeñas (SSS)

5.1.1. Caso 1




Figura 5.1: Comparativa de los espacios latentes generados por LDA, LDA MASS y KFDA ante el impacto de la alta dimensionalidad (caso 1).

La figura 5.1 muestra las proyecciones obtenidas por los tres métodos en un escenario ideal ($n > p$). Se observa que la estructura geométrica del mapeo lograda por el LDA clásico y LDA MASS es sumamente similar, diferenciándose principalmente por la orientación de los datos y la escala de los ejes. Por su parte, la proyección del KFDA presenta un comportamiento geométrico distinto: las clases quedan visualmente más alejadas entre sí y altamente compactas, a diferencia de los modelos LDA que exhiben una mayor dispersión intra-clase.

5.1.2. Caso 2

La Figura 5.2 muestra las proyecciones obtenidas por los tres métodos en un escenario de mayor complejidad donde ($n < p$). Se observa que pese a ser más variables que observaciones, la estructura geométrica del mapeo lograda por el LDA clásico y LDA MASS es similar, diferenciándose principalmente por la orientación de los datos y la escala de los ejes nuevamente. Por su parte, la proyección del KFDA genera un espacio ultra compacto donde la dispersión intra-clase es mínima y la dispersión entre-clases es máxima en un espacio muy reducido.




Figura 5.2: Comparativa de los espacios latentes generados por LDA, LDA MASS y KFDA ante el impacto de la alta dimensionalidad (caso 2).




Figura 5.3: Comparativa de los espacios latentes generados por LDA, LDA MASS y KFDA ante el impacto de la alta dimensionalidad (caso 3).

5.1.3. Caso 3

La Figura 5.3 muestra las proyecciones obtenidas por los tres métodos en un escenario de mayor complejidad donde ($n < p$). Pese a que la cantidad de observaciones por grupo es menor a la cantidad de variables presentes, los modelos aún son capaces de ofrecer proyecciones de los datos. La estructura geométrica del mapeo lograda por el LDA clásico y LDA MASS es similar, diferenciándose principalmente por la orientación de los datos y la escala de los ejes nuevamente. Por su parte, la proyección del KFDA vuelve a generar una proyección donde la dispersión intra-clase es mínima y la dispersión entre clase es máxima, diferenciándose de los comportamientos mostrados por los demás métodos.

5.1.4. Caso 4

La Figura 5.4 ilustra el impacto de una condición extrema del problema de tamaño de muestra pequeño ($p > n$). Ante esta desproporción severa, la matriz de covarianza se vuelve singular, provocando que el LDA clásico resulte matemáticamente incomputable. No obstante, las variantes LDA MASS y KFDA logran converger y generar proyecciones del espacio latente. La proyección obtenida por LDA MASS permite distinguir la separación de los grupos con una elevada dispersión intra-clase. Por su parte, el mapeo de KFDA induce una compresión máxima de la varianza intra-clase, colapsando visualmente las observaciones en coordenadas singulares; si bien esto exhibe una separación inter-clase total, el comportamiento sugiere fuertemente un sobreajuste geométrico en el espacio transformado.




Figura 5.4: Comparativa de los espacios latentes generados por LDA, LDA MASS y KFDA ante el impacto de la alta dimensionalidad (caso 4).

5.1.5. Caso 5




Figura 5.5: Comparativa de los espacios latentes generados por LDA, LDA MASS y KFDA ante el impacto de la alta dimensionalidad (caso 5).

La Figura 5.5 ilustra el impacto de una condición extrema del problema de tamaño de muestra pequeño ($p > n$) más agresivo que el del caso 4. La matriz de covarianza se vuelve singular, provocando que el LDA clásico resulte matemáticamente incomputable. No obstante, las variantes LDA MASS y KFDA logran converger y generar proyecciones del espacio latente. La proyección obtenida por LDA MASS permite distinguir la separación de los grupos, pero con un cierto grado de traslape entre algunas observaciones de ellos, además de tener una elevada dispersión intra-clase. Por su parte, el mapeo de KFDA induce una compresión máxima de la varianza intra-clase y maximizando la separación inter-clase. Sin embargo, esto puede deberse a un severo problema de sobre ajuste.

5.2. Resultados por conjunto de datos

En esta sección se encuentran desarrollados los resultados correspondientes a la exploración de cada uno de los conjuntos de datos, sus proyecciones de baja dimensionalidad obtenidas mediante LDA, KFDA y GNLPCA además de los resultados comparativos de rendimientos en cuanto a clasificación.

5.2.1. Palmer Penguins

El conjunto de datos pingüinos Palmer fue originalmente introducido por K. B. Gorman, T. D. Williams y W. R. Fraser en el 2014 [33]. El conjunto consiste en 342 observaciones distribuidas desigualmente entre tres especies de pingüinos: Adelie (44,2 %), Chinstrap (19,8 %) y Gentoo (36 %). Cada observación consta de cuatro variables continuas numéricas: largo del pico en milímetros, ancho del pico en milímetros, largo de la aleta en milímetros y la masa corporal en gramos.

Desde la perspectiva del reconocimiento de patrones, el conjunto Palmer Penguins presenta propiedades que lo hacen particularmente útil para la evaluación experimental de métodos de clasificación y reducción de dimensionalidad. Los análisis exploratorios reportados en la literatura indican que las observaciones correspondientes a la especie Gentoo tienden a formar un grupo relativamente diferenciado, mientras que las especies Adelie y Chinstrap exhiben cierto grado de solapamiento en el espacio de características, dando lugar a clases con distintos niveles de separabilidad [37]. Adicionalmente, la distribución desigual de observaciones entre especies introduce un escenario de desbalance de clases que permite examinar la sensibilidad y robustez de los métodos analizados frente a distribuciones no uniformes. En conjunto, estas características hacen de Palmer Penguins un caso de estudio pertinente para analizar la capacidad discriminativa de técnicas de proyección y clasificación, así como su comportamiento ante conjuntos de datos que combinan separabilidad parcial y desbalance entre clases.

A continuación se muestra mediante gráficos de dispersión el comportamiento de las observaciones por especies en pares de variables:




Figura 5.6: Gráficos de dispersión por pares de Palmer Penguins.

En el gráfico 5.6 se observa el comportamiento por pares de variables para el conjunto de pingüinos Palmer. Se observa principalmente que **los** grupos se alcanzan a diferenciar bien entre la longitud del pico y el ancho del pico pero mantienen un grado de traslape principalmente observable entre dos especies al observar la dispersión que se forma entre el ancho del pico y la masa corporal.

A continuación se obtuvieron las proyecciones visuales mediante la reducción de características con LDA, KFDA y GNLPGA.




Figura 5.7: Comparativa geométrica de los espacios de proyección para el conjunto de datos Palmer Penguins.

La Figura 5.7 presenta los espacios latentes generados por los tres enfoques evaluados con capacidad de proyectar. Dada la baja complejidad geométrica del conjunto Palmer Penguins, se advierte que la aproximación lineal (LDA MASS) logra una separación de clases adecuada. Simultáneamente, el mapeo no lineal implícito (KFDA) maximiza de forma esperada la distancia inter-clase, consolidando agrupaciones visualmente compactas. El hallazgo más destacable reside en la proyección obtenida por el método propuesto: GNLPGA no solo iguala la capacidad de separación óptima del kernel gaussiano y del LDA MASS, sino que alcanza este rendimiento filtrando y seleccionando explícitamente solo 3 variables del espacio de características expandido, preservando así la interpretabilidad y trazabilidad del modelo obtenido.




Figura 5.8: Distribución empírica del rendimiento predictivo para el conjunto de datos Penguins.

La Figura 5.8 presenta la distribución del rendimiento a lo largo de las ejecuciones experimentales. Los resultados revelan un escenario de alta separabilidad donde la mayoría de los algoritmos incluyendo enfoques lineales (LDA, QDA) y máquinas de vectores de soporte (SVM) convergen en medianas superiores a 0.97 con rangos intercuartílicos estrechos. La excepción estadística es el modelo KFDA, el cual exhibe una caída significativa en su rendimiento central y una varianza pronunciada con múltiples valores atípicos inferiores a 0.95. Por su parte, el algoritmo GNLPDA demuestra un comportamiento empírico robusto y competitivo; consolida una mediana equiparable a los mejores enfoques evaluados y alcanza la exactitud perfecta (1.0) en el límite superior de su distribución.




Figura 5.9: Análisis de significancia estadística post-hoc mediante distancias críticas de Nemenyi para el conjunto de datos Palmer penguins.

Con el objetivo de validar formalmente las diferencias observadas en el rendimiento predictivo, se aplicó la prueba de rangos de Friedman, la cual arrojó un estadístico $\chi^2 = 48,175$, $p < 0,001$, proporcionando evidencia suficiente para rechazar la hipótesis de equivalencia entre los clasificadores. Posteriormente, el diagrama de Nemenyi permitió identificar grupos de clasificadores sin diferencias estadísticamente significativas (conectados por líneas horizontales). Se observa que el método propuesto (GNLPDA, rango 4.05) se sitúa en un clúster intermedio; si bien comparte grupo estadístico con modelos de SVM polinomiales y Gaussianos, no presenta diferencias significativas frente a los métodos lineales (LDA/QDA) de mejor rango global. No obstante, destaca la superioridad absoluta de GNLPDA sobre el método KFDA ($p < 0,05$), consolidando su posición como una alternativa competitiva y estadísticamente robusta frente al estado del arte en este entorno de baja complejidad.

Para profundizar en la evaluación del rendimiento frente a arquitecturas no lineales, se realizó una comparativa excluyendo los métodos deterministas lineales. La prueba de Friedman ratifica la existencia de diferencias estadísticamente significativas en este subconjunto ($\chi^2 = 31,391$, $p < 0,001$). El diagrama de Nemenyi resultante evidencia que el método propuesto (GNLPDA, rango 2.77) se integra al clúster de máxima eficacia estadística, compartiendo línea de desempeño con SVM(POL2) y SVM(Gauss). Este resultado es particularmente valioso, pues confirma que GNLPDA logra equiparar la potencia de clasificación de las máquinas de vectores de soporte sin sacrificar la interpretabilidad de su espacio de características. En contraste, KFDA (rango 4.27) se aleja significativamente de este grupo.




Figura 5.10: Análisis de significancia estadística post-hoc y corrección por enmascaramiento mediante distancias críticas de Nemenyi para el conjunto de datos Palmer penguins.

5.2.2. Wines

El conjunto de datos Wine fue desarrollado a partir de análisis químicos realizados sobre vinos producidos en una misma región de Italia y derivados de tres cultivares diferentes, siendo posteriormente incorporado al repositorio UCI Machine Learning Repository por Stefan Aeberhard y colaboradores [18]. El conjunto está conformado por 178 observaciones distribuidas en tres clases correspondientes a los distintos tipos de vino: clase 1 (33,1 %), clase 2 (39,9 %) y clase 3 (27,0 %). Cada observación se describe mediante trece variables continuas relacionadas con propiedades fisicoquímicas de la muestra, entre ellas el contenido de alcohol, ácido málico, cenizas, magnesio, fenoles totales, flavonoides, intensidad de color y prolina.

Desde la perspectiva del reconocimiento de patrones, el conjunto Wine constituye un referente clásico para la evaluación de métodos de clasificación y reducción de dimensionalidad. Los datos corresponden a un problema multiclase bien definido, en el que las trece variables químicas proporcionan información discriminativa suficiente para distinguir entre los tres cultivares de vino. De hecho, la documentación original del conjunto lo describe como un problema de clasificación con una estructura de clases bien comportada, lo que lo convierte en un escenario apropiado para la validación inicial de nuevos clasificadores, aunque con un nivel de complejidad moderado. Asimismo, la presencia de trece características continuas en un espacio de mayor dimensionalidad que otros conjuntos de referencia favorece el análisis de técnicas de proyección y extracción de características, permitiendo estudiar la capacidad de los métodos para preservar la estructura discriminativa de los datos en representaciones de menor dimensión. Adicionalmente, el conjunto presenta un ligero desbalance entre clases y no contiene valores perdidos, por lo que resulta útil para comparar el desempeño de distintos enfoques bajo condiciones controladas y ampliamente documentadas en la literatura.

A continuación se muestra mediante gráficos de dispersión el comportamiento de las observaciones por clase en pares de variables:




Figura 5.11: Gráficos de dispersión por pares de Wines.

La figura 5.11 muestra el comportamiento de las clases de vinos mediante gráficos de dispersión por partes, salta a la vista que existen pares de variables donde la separabilidad entre clases es más evidente que en otras, por ejemplo, entre las variables V1 y V7 las clases se encuentran bien separadas con un grado mínimo de traslape. Mientras que al observar pares como V5 y V10, se observa como las observaciones por clase se encuentran traslapadas entre ellas.

A continuación se obtuvieron las proyecciones visuales mediante la reducción de características con LDA, KFDD y GNLPPDA.




Figura 5.12: Comparativa geométrica de los espacios de proyección para el conjunto de datos Wines.

La Figura 5.12 muestra los espacios latentes generados para el conjunto de datos Wines. Se observa que la aproximación lineal (LDA MASS) logra una separación geométrica exitosa, preservando la varianza natural de los datos y alcanzando una exactitud perfecta. En contraste, el mapeo no lineal implícito (KFDD) exhibe una ligera degradación en su rendimiento predictivo, lo cual sugiere que la compresión extrema de la dispersión intra-clase inducida por el kernel gaussiano genera un leve sobreajuste en las fronteras de decisión. Resulta crítico destacar el comportamiento del método propuesto (GNLPPDA), el cual recupera la exactitud perfecta mediante la selección exclusiva de 5 términos de interacción polinomial. Este hallazgo demuestra

la capacidad del algoritmo para superar la robustez predictiva de enfoques complejos, aislando interacciones de orden superior.




Figura 5.13: Distribución empírica del rendimiento predictivo para el conjunto de datos Wines.

La Figura 5.13 sintetiza el desempeño de los clasificadores, se observa que los modelos SVM y los métodos lineales (LDA/QDA) alcanzan una estabilización superior, con rangos intercuartílicos compactos y una exactitud que supera el 0.99. Por su parte, el método propuesto (GNLPGA) exhibe una mayor dispersión en su rendimiento, con un rango intercuartílico desplazado por debajo de las arquitecturas SVM y los métodos clásicos y la presencia de una varianza predictiva más pronunciada. Pese a esta brecha, el modelo sostiene una capacidad discriminante superior a métodos como KFDA, validando su competitividad frente a las aproximaciones basadas en kernel, aun cuando la parsimonia en la selección de variables incrementa la exigencia sobre el proceso evolutivo.




Figura 5.14: Análisis de significancia estadística post-hoc mediante distancias críticas de Nemenyi para el conjunto de datos Wines.

En este escenario de alta dimensionalidad, el test de Friedman reporta un estadístico $\chi^2 = 94,416 (p < 0,001)$, lo que confirma la existencia de diferencias significativas en el rendimiento

de los algoritmos. El diagrama de Nemenyi resultante ilustra una clara estratificación: mientras que los métodos lineales (LDA/QDA) y las SVM de configuración polinomial y gaussiana ocupan los rangos superiores, el método GNLPDA se posiciona en un nivel de desempeño intermedio, diferenciándose estadísticamente de los clasificadores con menor rango. Si bien el modelo no alcanza la competitividad de los métodos de kernel altamente optimizados en este dataset específico, su rango global es superior al de KFDA y en líneas generales, se mantiene competitivo.




Figura 5.15: Análisis de significancia estadística post-hoc y corrección por enmascaramiento mediante distancias críticas de Nemenyi para el conjunto de datos Wines.

Con el propósito de aislar la capacidad discriminante de los clasificadores no lineales, se realizó una comparativa excluyendo los métodos lineales. La prueba de Friedman ratifica la existencia de diferencias estadísticamente significativas ($\chi^2 = 68,914, p < 0,001$). El diagrama de Nemenyi resultante revela una jerarquía clara: los modelos SVM (con kernels polinomiales y gaussianos) lideran el rendimiento estadístico, manteniéndose en el clúster de máxima eficacia. En este escenario, el método propuesto (GNLPDA, rango 3.82) se sitúa en una posición intermedia, mostrando una brecha significativa respecto a las SVM, aunque conservando una ventaja estadística determinante frente al modelo KFDA (rango 4.50).

5.2.3. Cancer Wisconsin

El conjunto de datos Wisconsin Breast Cancer (Diagnostic) fue desarrollado por W. H. Wolberg, W. N. Street y O. L. Mangasarian como parte de investigaciones orientadas al diagnóstico asistido de cáncer de mama, y posteriormente fue descrito en la literatura por O. L. Mangasarian y colaboradores [50]. El conjunto está conformado por 569 observaciones correspondientes a muestras de tejido mamario obtenidas mediante aspiración con aguja fina. Las observaciones se distribuyen en dos clases diagnósticas: tumores benignos (62,7 %) y tumores malignos (37,3 %). Cada muestra se representa mediante 30 variables continuas calculadas a partir de imágenes digitalizadas de los núcleos celulares presentes en el tejido, incluyendo medidas relacionadas con el radio, textura, perímetro, área, suavidad, compacidad, concavidad, simetría y dimensión fractal.

Desde la perspectiva del reconocimiento de patrones, el conjunto Wisconsin Breast Cancer constituye un referente ampliamente utilizado para la evaluación de métodos de clasificación supervisada y reducción de dimensionalidad. Las características fueron diseñadas para capturar propiedades morfológicas relevantes de los núcleos celulares, proporcionando una representación numérica con alto contenido discriminativo entre las clases benigna y maligna. Asimismo,

la dimensionalidad relativamente elevada del conjunto, dada por sus treinta variables continuas, favorece el estudio de técnicas de selección de características, extracción de variables y proyección a espacios de menor dimensión. Adicionalmente, la distribución no uniforme entre clases introduce un grado moderado de desbalance que permite analizar la sensibilidad de los métodos ante distribuciones de datos asimétricas. En conjunto, estas características hacen de Wisconsin Breast Cancer un caso de estudio apropiado para comparar la capacidad discriminativa de distintos métodos de clasificación y evaluar la calidad de las representaciones obtenidas mediante técnicas de reducción de dimensionalidad.

A continuación se muestra mediante gráficos de dispersión el comportamiento de las observaciones por clase en pares de variables:




Figura 5.16: Gráficos de dispersión por pares de Cancer Wisconsin.

En la figura 5.16 se observa el comportamiento de las clases por pares de variables. Destaca el comportamiento de traslape que se puede observar en pares de variables como *smoothness2* y *symmetry2* donde las observaciones están traslapadas. Así como también existen pares de variables que muestran una separación más clara de las clases como es el caso del gráfico de dispersión entre *perimeter2* y *radius3*.

A continuación se obtuvieron las proyecciones visuales mediante la reducción de características con LDA, KFDA y GNLPDA.




Figura 5.17: Comparativa geométrica de los espacios de proyección para el conjunto de datos Cancer Wisconsin.

La Figura 5.17 presenta las distribuciones de densidad estimadas para el escenario de clasificación binaria en el conjunto de datos de Cancer Wisconsin. Se observa que el enfoque lineal (LDA MASS) alcanza un alto rendimiento predictivo (0.982), manteniendo una transición suave entre las clases con un área de solapamiento natural. Por su parte, el KFDA empata esta exactitud, pero su espacio latente exhibe una severa deformación multimodal con picos de densidad muy marcados; este comportamiento sugiere que pese a lograr un buen desempeño, el método deforma el espacio de una manera muy agresiva. En contraste, el método propuesto (GNLPDA) iguala la exactitud óptima de 0.982 restaurando una distribución de densidad unimodal, fluida, suave y estadísticamente coherente. Esta separación geométrica robusta se logra mediante la selección explícita de 16 términos polinomiales, demostrando que GNLPDA evade las distorsiones geométricas de los mapeos implícitos sin sacrificar capacidad predictiva.




Figura 5.18: Distribución empírica del rendimiento predictivo para el conjunto de datos Cancer Wisconsin.

La Figura 5.18 resume el desempeño de los clasificadores en un problema de diagnóstico binario. Se observa que el método propuesto (GNLPDA) exhibe un rendimiento sobresaliente, superando consistentemente en mediana a los enfoques lineales (LDA/QDA) y consolidándose por encima de la inestabilidad operativa mostrada por el modelo KFDA. Si bien SVM-POL2 alcanza una mediana ligeramente superior, GNLPDA mantiene un rango intercuartílico notablemente compacto y una dispersión acotada, lo que refleja una alta resiliencia y predictibilidad ante las variaciones en las muestras de entrenamiento.




Figura 5.19: Análisis de significancia estadística post-hoc mediante distancias críticas de Nemenyi para el conjunto de datos Cancer Wisconsin.

El test de Friedman reporta un estadístico $\chi^2 = 64,27 (p < 0,001)$ que confirma diferencias estadísticamente significativas entre el desempeño de los clasificadores. El diagrama de Nemenyi evidencia una estructura de rangos donde los modelos SVM(POL2) y SVM(POL3) ocupan la posición de mayor eficacia estadística. El método propuesto (GNLPDA, rango 3.70) se ubica en un clúster intermedio, mostrando una competitividad estadística superior frente a los modelos LDA y KFDA, y manteniéndose a una distancia crítica de los modelos líderes. Este resultado valida la robustez de la aproximación estocástica, la cual logra un posicionamiento competitivo frente a la mayoría de los métodos evaluados sin incurrir en la fragilidad paramétrica de las aproximaciones de kernel tradicional.




Figura 5.20: Análisis de significancia estadística post-hoc y corrección por enmascaramiento mediante distancias críticas de Nemenyi para el conjunto de datos Cancer Wisconsin.

Al evaluar exclusivamente el subconjunto de métodos no lineales, el test de Friedman ($\chi^2 = 44,898, p < 0,001$) ratifica la existencia de diferencias estadísticamente significativas. El diagrama de Nemenyi detalla la jerarquía de desempeño: las arquitecturas SVM(POL2) y SVM(POL3) mantienen el rango superior, mientras que el método propuesto (GNLPDA, rango 3.13) se posiciona en un nivel intermedio. La relevancia de este resultado reside en que, a pesar de la brecha estadística frente a los modelos polinomiales de mejor rango, GNLPDA demuestra un comportamiento estadísticamente indiferenciado respecto al grupo de alto rendimiento.

5.2.4. Ionosfera

El conjunto de datos *Ionosphere* fue originalmente introducido por V. G. Sigillito y colaboradores en 1989 [79]. El conjunto consiste en 351 observaciones correspondientes a retornos de radar de alta frecuencia dirigidos a electrones libres en la ionosfera, distribuidas en dos clases: retornos estructurados o de interés (*good*, 64,1 %) y retornos no estructurados (*bad*, 35,9 %). Cada observación consta de 34 variables numéricas continuas que representan las partes real e imaginaria provenientes de una función de autocorrelación aplicada a patrones de multipulso de las señales electromagnéticas (comúnmente se descarta una variable constante con valor cero en la primera componente continua, resultando en 33 predictores efectivos). Desde la perspectiva del reconocimiento de patrones, el conjunto *Ionosphere* presenta propiedades relevantes para la evaluación experimental de clasificadores y algoritmos de selección o reducción de dimensionalidad en espacios de moderada a alta dimensión. A diferencia de conjuntos con límites de decisión simples, sus características exhiben patrones complejos y no lineales con un nivel apreciable de solapamiento interclase en el espacio proyectado, lo que demanda métodos capaces de capturar interacciones de mayor orden para una separación efectiva. Adicionalmente, la desproporción entre las clases introduce un escenario de desbalance moderado que permite examinar la capacidad de generalización y la robustez de las técnicas analizadas ante representaciones asimétricas del espacio de características. En conjunto, estas propiedades convierten a *Ionosphere* en un caso de estudio idóneo para evaluar el rendimiento de modelos de clasificación y la preservación de estructura discriminativa mediante técnicas de proyección continua.

A continuación se muestra mediante gráficos de dispersión el comportamiento de las observaciones por clase en pares de variables:




Figura 5.21: Gráficos de dispersión por pares de *Ionosphere*.

En la figura 5.21 se puede observar como para todos los pares de variables las observaciones se encuentran ampliamente dispersas y sin mostrar indicios de una separación lineal definida.

A continuación se obtuvieron las proyecciones visuales mediante la reducción de características con LDA, KFDA y GNLPCA.

La Figura 5.22 ilustra las distribuciones de densidad para un escenario caracterizado por una alta complejidad topológica y un severo solapamiento de clases. Se advierte que el enfoque lineal (LDA MASS) resulta bueno pero insuficiente para capturar la frontera de decisión,




Figura 5.22: Comparativa geométrica de los espacios de proyección para el conjunto de datos Ionosphere.

exhibiendo una extensa área de ambigüedad predictiva (0.904). Por su parte, el mapeo no lineal (KFDA) incrementa la exactitud empírica (0.962), pero a expensas de inducir una extrema deformación multimodal en el espacio latente; los agudos picos de densidad evidencian que el kernel gaussiano está sobreajustando la geometría para aislar muestras específicas. En agudo contraste, el método propuesto (GNLPDA) mantiene un rendimiento altamente competitivo (0.952) penalizando estas distorsiones y restaurando distribuciones de densidad fluidas y generalizables. Mediante la selección explícita de 21 términos polinomiales, GNLPCA demuestra su capacidad para lidiar con el solapamiento severo construyendo un margen de separación matemáticamente interpretable.




Figura 5.23: Distribución empírica del rendimiento predictivo para el conjunto de datos Ionosphere.

La Figura 5.23 resume el desempeño de los clasificadores en un entorno caracterizado por una alta dimensionalidad de características. El método propuesto (GNLPDA) exhibe una estabilidad destacable, con un rango intercuartílico comparable al de los métodos basados en kernel. Es preciso señalar que, en este escenario, el modelo QDA resultó computacionalmente inviable, reportando una exactitud nula debido a la singularidad o falta de rango completo en la matriz de covarianza requerida para la discriminación cuadrática. Frente a esta limitación del modelo

determinista, GNLPDA demuestra una robustez operativa superior ante escenarios complicados y de alta dimensionalidad.




Figura 5.24: Análisis de significancia estadística post-hoc mediante distancias críticas de Nemenyi para el conjunto de datos Ionosphere.

Tras la exclusión del modelo QDA por inviabilidad computacional, el análisis inferencial subraya una estructura de rendimiento heterogénea ($\chi^2 = 88,363, p < 0,001$). El diagrama de Nemenyi muestra que, mientras los modelos SVM(Gauss), KFDA y SVM(POL2) se posicionan en el clúster de mayor eficacia estadística, el método propuesto (GNLPDA, rango 3.95) ocupa una posición intermedia. Es notable que, a pesar de la complejidad del dominio, el método logra una separación estadística clara frente a los modelos de menor rango, consolidándose como una alternativa funcional y robusta allí donde otros clasificadores estadísticos tradicionales enfrentan fallos de convergencia numérica.




Figura 5.25: Análisis de significancia estadística post-hoc y corrección por enmascaramiento mediante distancias críticas de Nemenyi para el conjunto de datos Ionosphere.

Al restringir el análisis exclusivamente a los clasificadores no lineales, el test de Friedman corrobora la persistencia de diferencias estadísticamente ($\chi^2 = 88,363, p < 0,001$). El diagrama de Nemenyi resultante revela una jerarquía donde las configuraciones de SVM (Gauss y POL2) y KFDA dominan la eficacia estadística. El método propuesto (GNLPDA) mantiene su posición intermedia, evidenciando que, aun prescindiendo de los métodos lineales, la brecha de rendimiento frente a las máquinas de soporte vectorial permanece estable.

5.2.5. Cebolla 3D

El conjunto de datos sintético Cebolla3D consiste en 300 observaciones generadas sintéticamente y distribuidas equitativamente en tres clases concéntricas en un espacio tridimensional ($p = 3$). Cada clase corresponde a un cascarón esférico definido por un radio característico perturbado mediante un factor de ruido gaussiano. Desde la perspectiva del reconocimiento de patrones, constituye un caso de prueba geométrico controlado de baja dimensión pero estrictamente no lineal, diseñado para evaluar la capacidad de proyección y clasificación ante manifolds cerrados donde las fronteras de decisión lineales fracasan por completo.

A continuación se muestra mediante gráficos de dispersión el comportamiento de las observaciones por clase en pares de variables:




Figura 5.26: Gráficos de dispersión por pares de Cebolla3D.

En la figura 5.26 se observa esta formación característica de capas concéntricas con diferentes grados de dispersión que no son linealmente separables.

A continuación se obtuvieron las proyecciones visuales mediante la reducción de características con LDA, KFPA y GNLPA.




Figura 5.27: Comparativa geométrica de los espacios de proyección para el conjunto de datos cebolla 3D.

La Figura 5.27 evidencia el comportamiento algorítmico frente a la búsqueda de una frontera de separación no lineal. Como es esperable ante estructuras de distribución concéntrica, el

enfoque estrictamente lineal (LDA MASS) fracasa en la proyección del espacio latente separable, colapsando las clases en un solapamiento masivo que resulta en una exactitud predictiva deficiente (0.433). En contraparte, el mapeo implícito (KFDA) logra desdoblar exitosamente esta complejidad geométrica utilizando el kernel gaussiano, alcanzando una separación casi perfecta (0.989). El hallazgo analítico más trascendental se observa en el método propuesto (GNLPDA), el cual iguala el rendimiento máximo del kernel mediante la selección de únicamente 4 términos. Es particularmente destacable mencionar que el algoritmo seleccionó los predictores cuadráticos; este comportamiento demuestra que la búsqueda estocástica identifica con precisión las transformaciones polinomiales necesarias para linealizar la estructura concéntrica, logrando proyectar fronteras de decisión óptimas dentro de un espacio de características explícito, parsimonioso y totalmente interpretable.




Figura 5.28: Distribución empírica del rendimiento predictivo para el conjunto de datos cebolla 3D.

La Figura 5.28 ilustra el desempeño de los clasificadores ante una geometría no lineal de tres dimensiones. Se observa un colapso operativo del clasificador lineal (LDA), cuya exactitud basada en la mediana se desploma por debajo de 0.40, validando la inoperancia de los enfoques lineales ante distribuciones de clases no linealmente separables. En contraste, el método propuesto (GNLPDA) exhibe una alta eficacia predictiva, alcanzando medianas superiores a 0.90 y manteniéndose competitivo frente a los modelos basados en kernel y máquinas de vectores de soporte. Es destacable que QDA logra obtener desempeños competitivos ante este escenario, sosteniendo un rango intercuartílico compacto y una mediana superior a 0.8.




Figura 5.29: Análisis de significancia estadística post-hoc mediante distancias críticas de Nemenyi para el conjunto de datos cebolla 3D.

La prueba de Friedman confirma la existencia de diferencias estadísticamente significativas en el rendimiento de los algoritmos ($\chi^2 = 142,551, p < 0,001$). El diagrama de Nemenyi revela una segmentación clara: las configuraciones de SVM (POL2, Gauss y POL3) integran el clúster de máxima eficacia estadística. El método propuesto (GNLPDA, rango 4.27) se posiciona en un nivel intermedio, mostrando un desempeño estadísticamente indiferenciado respecto al KFDA, siendo que en ultima instancia, se genera un grupo donde están LDA y QDA, siendo los de menor rendimiento en comparación.




Figura 5.30: Análisis de significancia estadística post-hoc y corrección por enmascaramiento mediante distancias críticas de Nemenyi para el conjunto de datos Cebolla 3D.

Al evaluar exclusivamente el subconjunto de métodos no lineales, la prueba de Friedman ratifica la existencia de diferencias estadísticamente significativas ($\chi^2 = 89,354, p < 0,001$). El diagrama de Nemenyi detalla una clara jerarquía: las máquinas de vectores de soporte (SVM-POL2, SVM-Gauss y SVM-POL3) integran el clúster de máxima eficacia estadística. El método propuesto (GNLPDA, rango 4.08) se posiciona en un nivel intermedio, manteniendo una equivalencia estadística frente al KFDA (rango 4.23).

5.2.6. Cebolla 10D

El conjunto de datos sintético Cebolla10D consta de 300 observaciones pertenecientes a tres clases concéntricas proyectadas en un espacio de 10 dimensiones ($p = 10$). El conjunto

conserva la estructura de hiper-esferas imbricadas con perturbación gaussiana radial. Desde la perspectiva del reconocimiento de patrones, este conjunto escala la dificultad geométrica al añadir dimensiones ruidosas u ortogonales al espacio de la variedad, permitiendo examinar la estabilidad y robustez de los algoritmos de selección de características y transformación no lineal a medida que aumenta la dimensionalidad del espacio original.

A continuación se muestra mediante gráficos de dispersión el comportamiento de las observaciones por clase en pares de variables:




Figura 5.31: Gráficos de dispersión por pares de Cebolla10D.

En la figura 5.31 se observa la dispersión presente por cada clase de forma que los traslapes hacen que no se observe una separación clara entre las clases.

A continuación se obtuvieron las proyecciones visuales mediante la reducción de características con LDA, KFDD y GNLPPDA.




Figura 5.32: Comparativa geométrica de los espacios de proyección para el conjunto de datos cebolla 10D.

La Figura 5.32 ilustra el comportamiento de los clasificadores ante un escenario que escala la complejidad de la separación concéntrica a diez dimensiones. Como resulta previsible, la restricción del enfoque estrictamente lineal (LDA MASS) provoca un colapso geométrico absoluto, evidenciado por un solapamiento masivo de las clases y una exactitud predictiva apenas

superior al azar (0.511). En contraste, la expansión implícita del kernel gaussiano (KFDA) logra sortear esta geometría no lineal, alcanzando una separación perfecta (1.0). No obstante, se observa en la proyección del método propuesto que sostiene un rendimiento casi óptimo (0.989) a través de un subconjunto explícito de 24 términos. Resulta excepcionalmente destacable que la búsqueda estocástica logró identificar e incorporar la totalidad de los predictores cuadráticos de las variables originales. Esta evidencia empírica demuestra de forma contundente que el algoritmo es capaz de reconstruir analíticamente la ecuación de una hiperesfera en espacios de alta dimensionalidad, logrando linealizar el problema mediante una base polinomial exacta y totalmente transparente.




Figura 5.33: Distribución empírica del rendimiento predictivo para el conjunto de datos Cancer cebolla 10D.

La Figura 5.33 muestra el desempeño de los clasificadores ante una geometría no **linealmente** separable de diez dimensiones. El colapso del modelo lineal (LDA) es absoluto, con una exactitud mediana inferior a 0.45. Mientras que los modelos de kernel (KFDA y SVM-Gauss) alcanzan los niveles máximos de eficacia predictiva, el método propuesto (GNLPDA) mantiene un rendimiento sólido, con una mediana superior a 0.88. Cabe destacar que el modelo QDA se mantiene con una mediana superior al 0.8, donde si bien, no figura como los mejores, se mantiene competente.




Figura 5.34: Análisis de significancia estadística post-hoc mediante distancias críticas de Nemenyi para el conjunto de datos cebolla 10D.

La prueba de Friedman confirma la existencia de diferencias estadísticamente significativas en el rendimiento de los algoritmos ($\chi^2 = 144,857, p < 0,001$). El diagrama de Nemenyi revela una estratificación jerárquica: el clúster de mayor eficacia estadística está integrado por los modelos KFDA y SVM (Gauss). El método propuesto (GNLPGA, rango 4.33) se posiciona en un nivel intermedio, mostrando equivalencia estadística frente a los modelos SVM(POL2) y SVM(POL3). Finalmente, los modelos QDA y LDA ocupan los rangos inferiores, reafirmando la superioridad de los enfoques no lineales frente a estructuras de discriminación lineal o cuadrática simple en este entorno de alta dimensionalidad.




Figura 5.35: Análisis de significancia estadística post-hoc y corrección por enmascaramiento mediante distancias críticas de Nemenyi para el conjunto de datos cebolla 10D.

Al evaluar exclusivamente el subconjunto de métodos no lineales, el test de Friedman corrobora la existencia de diferencias estadísticamente significativas ($\chi^2 = 89,354, p < 0,001$). El diagrama de Nemenyi muestra una separación clara: el clúster de mayor eficacia estadística está compuesto por KFDA y SVM(Gauss). El método propuesto (GNLPGA, rango 3.93) se posiciona junto a las variantes polinomiales de SVM (POL2 y POL3) en un nivel de desempeño intermedio.

5.2.7. Cebolla 20D

El conjunto de datos sintético Cebolla20D comprende 300 observaciones organizadas en tres clases concéntricas dentro de un espacio de 20 dimensiones ($p = 20$). Al igual que las

variantes anteriores, el proceso de generación emplea hiper-esferas con ruido estocástico integrado. Desde la perspectiva del reconocimiento de patrones, representa un escenario de prueba en moderada-alta dimensión donde la dispersión del espacio geométrico (maldición de la dimensionalidad) complica la identificación de manifolds concéntricos, resultando idóneo para evaluar la preservación de la estructura discriminativa y la capacidad de generalización de los clasificadores no lineales.

A continuación se muestra mediante gráficos de dispersión el comportamiento de las observaciones por clase en pares de variables:




Figura 5.36: Gráficos de dispersión por pares de Cebolla20D.

En la figura 5.36 se observa un fuerte traslape entre las clases así como un alto grado de dispersión que no permite encontrar límites de separación claros entre una clase y otra.

A continuación se obtuvieron las proyecciones visuales mediante la reducción de características con LDA, KFDD y GNLPPDA.




Figura 5.37: Comparativa geométrica de los espacios de proyección para el conjunto de datos cebolla 20D.

La Figura 5.37 exhibe el límite de estrés dimensional al proyectar una geometría concéntrica de 20 variables. El clasificador lineal (LDA MASS) confirma su inoperatividad ante esta estructura, registrando un severo solapamiento inter-clase y una exactitud deficiente (0.600). Por el

contrario, el mapeo implícito (KFDA) absorbe la complejidad proyectando una separación perfecta (1.000). El análisis de la proyección generada por el método propuesto (GNLPDA) revela un comportamiento de alto valor heurístico: a pesar de enfrentarse a una explosión combinatoria en el espacio de características expandido (230 términos posibles), el algoritmo sostiene un rendimiento predictivo sobresaliente (0.933) empleando un subconjunto de apenas 38 variables. Resulta notable que la búsqueda estocástica logró identificar 11 de los 20 predictores cuadráticos fundamentales. Esta evidencia empírica demuestra que, ante un escalamiento dimensional masivo, el método prioriza un equilibrio óptimo entre la parsimonia del modelo, la extracción de los componentes no lineales subyacentes y una alta capacidad de separación, conservando la explicabilidad matemática frente al enfoque de caja negra del kernel.




Figura 5.38: Distribución empírica del rendimiento predictivo para el conjunto de datos cebolla 20D.

La Figura 5.38 sintetiza el desempeño de los clasificadores ante una geometría no lineal de veinte dimensiones. En este entorno, se observa una degradación significativa del rendimiento general, donde incluso las arquitecturas de kernel más robustas experimentan una mayor dispersión. El modelo lineal (LDA) confirma su ineficacia estructural, situándose en rendimientos cercanos al azar. Por su parte, el método propuesto (GNLPDA) mantiene una mediana de rendimiento competitiva, aunque con una varianza **creciente producto** del aumento exponencial en el espacio de búsqueda. Los modelos SVM (Gauss) y KFDA se destacan del resto por mantener los desempeños más altos del gráfico, así como un rango intercuartílico pequeño en comparación con los demás competidores.




Figura 5.39: Análisis de significancia estadística post-hoc mediante distancias críticas de Nemenyi para el conjunto de datos cebolla 20D.

La prueba de Friedman ($\chi^2 = 2 = 167,214, p < 0,001$) corrobora la existencia de diferencias estadísticamente significativas entre los clasificadores ante la complejidad extrema del espacio de 20 dimensiones. El diagrama de Nemenyi evidencia una jerarquía donde los modelos SVM(Gauss) y KFDA lideran la eficacia estadística. El método propuesto (GNLPDA, rango 4.13) se sitúa en un nivel intermedio, manteniendo una equivalencia estadística frente al modelo QDA y SVM(POL2).




Figura 5.40: Análisis de significancia estadística post-hoc y corrección por enmascaramiento mediante distancias críticas de Nemenyi para el conjunto de datos cebolla 20D.

Al evaluar exclusivamente el subconjunto de métodos no lineales, el test de Friedman corrobora la existencia de diferencias estadísticamente significativas ($\chi^2 = 113,539, p < 0,001$). El diagrama de Nemenyi muestra una separación clara donde los modelos SVM(Gauss) y KFDA lideran el desempeño. El método propuesto (GNLPDA, rango 3.77) se sitúa en un nivel de desempeño intermedio, manteniendo una equivalencia estadística frente a SVM(POL2).

5.2.8. Pima diabetes

El conjunto de datos Pima Indians Diabetes fue originalmente introducido por J. W. Smith y colaboradores en 1988 [81]. El conjunto consiste en 768 observaciones recopiladas del Instituto Nacional de Diabetes y Enfermedades Digestivas y del Riñón, limitadas a mujeres de al menos 21 años de edad pertenecientes a la herencia indígena Pima. La variable respuesta es

binaria e indica la presencia (34,9 %) o ausencia (65,1 %) de diabetes mellitus tipo 2 según los criterios del examen de la OMS. Cada observación consta de ocho variables médicas continuas y discretas: número de embarazos, concentración de glucosa en plasma, presión arterial diastólica, grosor del pliegue cutáneo del tríceps, insulina sérica de dos horas, índice de masa corporal, función de pedigrí de diabetes y edad. Desde la perspectiva del reconocimiento de patrones, el conjunto Pima Diabetes representa un escenario de prueba fundamental en el dominio biomédico para la evaluación experimental de clasificadores y métodos de reducción de dimensionalidad o selección de características. Sus predictores presentan correlaciones complejas y grados variables de no linealidad, sumado a un solapamiento considerable entre las clases en el espacio multivariado de características que dificulta la delimitación de fronteras de decisión lineales simples. Asimismo, la distribución desproporcionada de observaciones genera un escenario de desbalance moderado de clases, mientras que la presencia implícita de valores numéricamente inviables (como presiones arteriales o índices de masa corporal iguales a cero) permite examinar la sensibilidad, estabilidad y robustez de los algoritmos ante datos ruidosos e incompletos en un contexto analítico realista.

A continuación se muestra mediante gráficos de dispersión el comportamiento de las observaciones por clase en pares de variables:




Figura 5.41: Gráficos de dispersión por pares de Pima Diabetes

El la figura 5.41 como las distribuciones por clase de las variables mantienen estructuras similares, mostrando un grado de traslape y dispersión que las hace difíciles de diferenciar entre una clase y otra.

A continuación se obtuvieron las proyecciones visuales mediante la reducción de características con LDA, KFDA y GNLPDA.

La Figura 5.42 presenta las distribuciones de densidad estimadas para un escenario biomédico caracterizado por un alto grado de solapamiento natural. En este contexto, el enfoque lineal (LDA MASS) establece una línea base de rendimiento (0.817), proyectando curvas con una dispersión amplia que refleja la varianza intrínseca de los datos fisiológicos. Por su parte, el mapeo implícito (KFDA) presenta una leve degradación predictiva (0.809) acompañada de un notable cambio topológico: una compresión extrema del espacio intraclase que genera picos de densidad inusualmente agudos. Esta aglomeración forzada evidencia que el kernel gaussiano




Figura 5.42: Comparativa geométrica de los espacios de proyección para el conjunto de datos Pima diabetes.

tiende a colapsar las proyecciones hacia coordenadas singulares, distorsionando y perdiendo la representación de la dispersión biológica original sin que esto se traduzca en una mejora para la separabilidad del modelo. Resulta sumamente relevante que el método propuesto (GNLPGA) supera el rendimiento del kernel (0.813) y evita este colapso, restaurando la fluidez y amplitud natural de las distribuciones. Esta resiliencia geométrica se alcanza mediante la extracción de un subconjunto interpretable de 10 términos, destacando interacciones entre variables fisiológicas clave (como glucosa, edad y masa corporal), lo que demuestra que la búsqueda estocástica modela eficazmente la complejidad clínica sin recurrir a deformaciones extremas del espacio latente.




Figura 5.43: Distribución empírica del rendimiento predictivo para el conjunto de datos Pima diabetes.

La Figura 5.43 resume el desempeño de los clasificadores en un problema de diagnóstico biomédico con alta tasa de ruido. El método propuesto (GNLPGA) exhibe un rendimiento sobresaliente, posicionándose con la mediana de exactitud más elevada del conjunto, superando incluso a los modelos de kernel (SVM y KFDA) y lineales (LDA/QDA) aunque se observa una dispersión moderada. Por lo demás, los métodos SVM y QDA parecen mantener rendimientos similares por la posición de su mediana y su rango intercuartílico.




Figura 5.44: Análisis de significancia estadística post-hoc mediante distancias críticas de Nemenyi para el conjunto de datos pima diabetes.

La prueba de Friedman ($\chi^2 = 48,175, p < 0,001$) ratifica la existencia de diferencias estadísticamente significativas en el desempeño de los algoritmos. El diagrama de Nemenyi muestra la formación de clústeres basados en el rendimiento estadístico: el método propuesto (GNLPDA, rango 2.58) se integra en el primer grupo junto con LDA (rango 2.97), denotando que ambos clasificadores comparten el rango de mejor desempeño en este conjunto de datos. Por otro lado, los clasificadores SVM(POL3), SVM(Gauss), SVM(POL2) y KFDA se ubican en niveles de rango intermedios, mientras que el modelo QDA (rango 5.95) se posiciona en el extremo inferior de la jerarquía estadística. Las líneas horizontales negras y la línea verde conectan a los clasificadores que no presentan diferencias estadísticamente significativas entre sí de acuerdo con el umbral de Diferencia Crítica (CD) establecido.




Figura 5.45: Análisis de significancia estadística post-hoc y corrección por enmascaramiento mediante distancias críticas de Nemenyi para el conjunto de datos Pima diabetes.

La prueba de Friedman ($\chi^2 = 15,129, p < 0,001$) corrobora la existencia de diferencias estadísticamente significativas entre los clasificadores. El diagrama de Nemenyi presenta la jerarquía de rangos observada: el método propuesto (GNLPDA, rango 2.12) se ubica en la posición de mejor desempeño estadístico, distanciándose del resto de los clasificadores. Los modelos SVM (POL3, rango 3.02), SVM (POL2, rango 3.12) y SVM(Gauss, rango 3.15) conforman un grupo intermedio sin diferencias estadísticamente significativas entre ellos. Finalmente, el clasificador KFDA (rango 3.60) se posiciona en el extremo inferior de la jerarquía presentada. Las conexiones por líneas horizontales indican los conjuntos de clasificadores que, bajo el umbral de Diferencia Crítica (CD), no muestran diferencias estadísticas significativas.

5.2.9. Indicadores 2015

El conjunto de datos Indicadores 2015 fue consolidado por J. A. Navarro-Acosta y colaboradores en el 2025, a partir de mediciones sociodemográficas reales del CONEVAL y la Encuesta Intercensal de INEGI [62]. El conjunto consta de 2,446 observaciones municipales organizadas en cinco clases ordinales según el Grado de Rezago Social: muy bajo, bajo, medio, alto y muy alto. Cada observación integra 12 variables continuas que abarcan 11 indicadores de carencias socioeconómicas en educación, salud, vivienda y bienes del hogar, más el índice sintético. Desde la perspectiva del reconocimiento de patrones, representa un caso de estudio real de mediana dimensión caracterizado por un severo desbalance de clases y distribuciones con asimetría pronunciada. Estas propiedades generan solapamiento en el espacio de características, lo que permite evaluar la capacidad de los clasificadores para delimitar fronteras de decisión no lineales complejas sin asumir normalidad en los predictores.

A continuación se muestra mediante gráficos de dispersión el comportamiento de las observaciones por clase en pares de variables:




Figura 5.46: Gráficos de dispersión por pares de indicadores 2015

En la figura 5.46 se observa un grado de traslape entre las clases de forma que mantienen una baja dispersión.

A continuación se obtuvieron las proyecciones visuales mediante la reducción de características con LDA, KFDA y GNLPDA.




Figura 5.47: Comparativa geométrica de los espacios de proyección para el conjunto de datos Indicadores 2015 (2D).




Figura 5.48: Comparativa geométrica de los espacios de proyección para el conjunto de datos Indicadores 2015 (3D).

Las Figuras 20 y 21 exhiben las proyecciones geométricas para un escenario socioeconómico de cinco clases que representan niveles ordinales de rezago. Dada esta naturaleza progresiva, la geometría esperada es la de una trayectoria curva que transicione de forma continua a medida que avanzan los niveles. Las vistas en 2D y 3D demuestran que el enfoque lineal (LDA MASS) logra capturar esta progresión ordinal, estructurando dicha curva con una exactitud destacable (0.919). En drástico contraste, el mapeo implícito (KFDA) sufre un colapso topológico severo; el kernel gaussiano destruye por completo la relación secuencial de los datos, provocando un solapamiento masivo que desploma el rendimiento predictivo (0.682). El aporte analítico definitivo se consolida en el método propuesto (GNLPGA), el cual maximiza la exactitud general (0.941) mediante la selección de 27 términos. La proyección tridimensional evidencia que la evolución estocástica no solo optimiza la separabilidad inter-clase, sino que refina matemáticamente esta curva, proyectando una transición geométrica fluida, parsimoniosa y perfectamente estructurada que respeta y acentúa la naturaleza ordinal del fenómeno subyacente.




Figura 5.49: Distribución empírica del rendimiento predictivo para el conjunto de datos Indicadores 2015.

La Figura 5.49 detalla el comportamiento de los clasificadores en términos de exactitud (accuracy). Los modelos SVM(POL2), SVM(POL3) y SVM(Gauss) alcanzan las medianas más elevadas, posicionándose consistentemente por encima de 0.98. El método propuesto (GNLPGA) exhibe una mediana superior a 0.92, mostrando una distribución concentrada con valores de exactitud competitivos. Seguidamente, los clasificadores LDA y QDA presentan medianas situadas en el rango de 0.87 a 0.89. Finalmente, el clasificador KFDA muestra el menor desempeño, con una mediana de exactitud próxima a 0.65 y una mayor dispersión en los datos en comparación con el resto de los algoritmos evaluados.




Figura 5.50: Análisis de significancia estadística post-hoc mediante distancias críticas de Nemenyi para el conjunto de datos Indicadores 2015.

La prueba de Friedman ($\chi^2 = 169,526, p < 0,001$) ratifica la existencia de diferencias estadísticamente significativas en el desempeño de los algoritmos. El diagrama de Nemenyi evidencia una jerarquía donde los modelos SVM(POL2), SVM(Gauss) y SVM(POL3) conforman el grupo de mayor eficacia estadística. El método propuesto (GNLPGA, rango 4.00) ocupa una posición intermedia en la jerarquía, presentando una diferencia estadística significativa respecto

al clúster líder, pero superando a los modelos LDA, QDA y KFDA. Las conexiones mediante líneas horizontales agrupan a los clasificadores que no presentan diferencias estadísticas significativas entre sí, de acuerdo con la diferencia crítica (CD) calculada.




Figura 5.51: Análisis de significancia estadística post-hoc y corrección por enmascaramiento mediante distancias críticas de Nemenyi para el conjunto de datos Indicadores 2015.

Al restringir el análisis exclusivamente a los clasificadores no lineales, la prueba de Friedman corrobora la existencia de diferencias estadísticamente significativas en el desempeño de los algoritmos ($\chi^2 = 103,159, p < 0,001$). El diagrama de Nemenyi detalla una jerarquía donde los modelos SVM(POL2), SVM(Gauss) y SVM(POL3) conforman el clúster de mayor eficacia estadística, sin diferencias significativas entre ellos. El método propuesto (GNLPGA, rango 4.00) se posiciona en un nivel intermedio, presentando una diferencia estadística significativa respecto al grupo líder, pero superando al clasificador KFDA (rango 5.00), el cual se ubica en el extremo inferior de la jerarquía. Las conexiones mediante líneas horizontales identifican a los grupos de clasificadores que, según el umbral de Diferencia Crítica (CD), no muestran diferencias estadísticas significativas.

5.2.10. Indicadores 2020

El conjunto de datos Indicadores 2020 proviene de la misma investigación desarrollada por J. A. Navarro-Acosta y colaboradores en el 2025, incorporando mediciones reales procedentes del Censo de Población y Vivienda 2020 del INEGI [62]. Este conjunto comprende 2,470 observaciones correspondientes a la totalidad de los municipios medidos en dicho periodo. Conserva la misma estructura de 12 variables continuas (11 predictores socioeconómicos y el índice sintético) distribuidas en las mismas cinco categorías del Grado de Rezago Social. Desde la perspectiva del reconocimiento de patrones, al tratarse de un conjunto de datos real y reciente, ofrece un escenario idóneo para examinar la estabilidad y capacidad de generalización de los algoritmos ante la evolución temporal de las clases. Al compartir el mismo espacio de características que su versión de 2015 pero reflejar la transición demográfica reciente, permite evaluar la sensibilidad de las técnicas de reducción de dimensionalidad y clasificación frente a distribuciones no uniformes y esquemas de desbalance entre clases en contextos socioeconómicos actuales.

A continuación se muestra mediante gráficos de dispersión el comportamiento de las observaciones por clase en pares de variables:




Figura 5.52: Gráficos de dispersión por pares de indicadores 2020

En la figura 5.52 se observa baja dispersión entre las variables y un considerable grado de traslape.

A continuación se obtuvieron las proyecciones visuales mediante la reducción de características con LDA, KFDD y GNLPGA.




Figura 5.53: Comparativa geométrica de los espacios de proyección para el conjunto de datos Indicadores 2020 (2D).




Figura 5.54: Comparativa geométrica de los espacios de proyección para el conjunto de datos Indicadores 2020 (3D).

Las Figuras 5.53 y 5.54 corroboran el comportamiento geométrico analizado previamente, extendiendo la evaluación a la actualización socioeconómica del año 2020. La consistencia geométrica es evidente: el enfoque lineal (LDA MASS) reafirma su capacidad para estructurar la trayectoria curva que representa la progresión ordinal de los niveles de rezago, logrando una alta exactitud (0.938). De manera análoga, el mapeo implícito (KFDA) confirma su deficiencia estructural para este dominio; el kernel gaussiano colapsa nuevamente la relación secuencial, generando un aglomeramiento caótico que desploma su capacidad predictiva (0.707). Finalmente, el método propuesto (GNLPDA) valida su superioridad algorítmica al maximizar el rendimiento general (0.959) a través de la extracción de 39 términos polinomiales. Las proyecciones, especialmente en su vista tridimensional, demuestran que la búsqueda estocástica no solo preserva, sino que acentúa y clarifica la trayectoria continua entre los cinco niveles categóricos. Esta reproducibilidad geométrica a través de diferentes periodos censales consolida la robustez del GNLPDA para generar espacios de características explícitos y parsimoniosos que respetan la naturaleza ordinal del problema.




Figura 5.55: Distribución empírica del rendimiento predictivo para el conjunto de datos Indicadores 2020.

La Figura 5.55 detalla el comportamiento de los clasificadores en términos de exactitud (accuracy). Los modelos SVM(POL2), SVM(POL3) y SVM(Gauss) alcanzan las medianas más elevadas, situándose consistentemente por encima de 0.95 con rangos muy compactos. El método propuesto (GNLPDA) exhibe una mediana superior a 0.92, mostrando una distribución concentrada con valores de exactitud competitivos. Por su parte, los clasificadores LDA y QDA presentan medianas situadas por encima del 0.85 con rangos de dispersión moderadamente compactos. Finalmente, el clasificador KFDA muestra el desempeño más bajo, con una mediana de exactitud próxima a 0.68 y una mayor dispersión en los datos en comparación con el resto de los algoritmos evaluados.




Figura 5.56: Análisis de significancia estadística post-hoc mediante distancias críticas de Nemenyi para el conjunto de datos Indicadores 2020.

La prueba de Friedman ($\chi^2 = 169,856, p < 0,001$) ratifica la existencia de diferencias estadísticamente significativas en el desempeño de los algoritmos. El diagrama de Nemenyi evidencia una jerarquía donde los modelos SVM(POL2, rango 1.47), SVM (POL3, rango 2.03) y SVM (Gauss, rango 2.50) integran el clúster de mayor eficacia estadística, sin diferencias significativas entre ellos. El método propuesto (GNLPDA, rango 4.15) se posiciona en una jerarquía intermedia, seguido por los modelos LDA (rango 4.85), QDA (rango 6.00) y KFDA (rango 7.00), los cuales ocupan los rangos inferiores de la distribución. Las líneas horizontales conectan a los clasificadores que, de acuerdo con el umbral de Diferencia Crítica (CD), no muestran diferencias estadísticas significativas.




Figura 5.57: Análisis de significancia estadística post-hoc y corrección por enmascaramiento mediante distancias críticas de Nemenyi para el conjunto de datos Indicadores 2020.

Al restringir el análisis exclusivamente a los clasificadores no lineales, el test de Friedman corrobora la existencia de diferencias estadísticamente significativas ($\chi^2 = 103,811, p < 0,001$). El diagrama de Nemenyi detalla una jerarquía donde los modelos SVM(POL2, rango 1.47), SVM(POL3, rango 2.03) y SVM(Gauss, rango 2.50) conforman el clúster de mayor eficacia estadística, sin diferencias significativas entre ellos. El método propuesto (GNLPDA, rango 4.00) se posiciona en un nivel intermedio, presentando una diferencia estadística significativa respecto al grupo líder, pero superando al clasificador KFDA (rango 5.00), el cual se ubica en el extremo inferior de la jerarquía. Las líneas horizontales conectan a los grupos de clasificadores que, según el umbral de Diferencia Crítica (CD), no muestran diferencias estadísticas significativas.

Capítulo 6

Discusión

Los resultados obtenidos permiten analizar el comportamiento de GNLPDA desde una perspectiva tanto geométrica como estadística, evidenciando los alcances y limitaciones de la propuesta frente a distintos tipos de problemas de clasificación. En conjunto, los experimentos muestran que el desempeño del método depende en gran medida de la naturaleza del conjunto de datos, confirmando que no existe un clasificador universalmente superior para todos los escenarios.

6.1. Expansión polinomial y separabilidad de los datos

Las proyecciones obtenidas mediante GNLPDA evidencian el efecto de incorporar una expansión polinomial explícita antes del proceso de selección de características. En diversos conjuntos de datos se observó que las proyecciones generadas por GNLPDA conservan una estructura geométrica similar a la obtenida mediante LDA, aunque presentan modificaciones suficientes para incrementar la separación entre las clases. Este comportamiento sugiere que la expansión polinomial no sustituye la información contenida en el espacio original, sino que incorpora términos de interacción capaces de revelar regiones donde la separación lineal resulta más factible.

En contraste, las proyecciones obtenidas mediante KFDA presentan una geometría considerablemente distinta. Al construir una matriz kernel y realizar la discriminación sobre un espacio inducido implícitamente, las observaciones tienden a formar agrupamientos más compactos dentro de cada clase, favoreciendo la separación entre grupos. Sin embargo, dicha representación ocurre en un espacio cuya transformación no puede interpretarse directamente, lo que dificulta identificar como están afectando las variables o que está ocurriendo en el espacio original de las características.

Desde esta perspectiva, GNLPDA constituye una alternativa intermedia entre los métodos lineales y los métodos kernel. Mientras que conserva la capacidad de generar proyecciones explícitas e interpretables, incorpora relaciones no lineales mediante la expansión polinomial y la selección evolutiva de términos, permitiendo aproximar parte de la capacidad discriminante de los enfoques kernel sin renunciar completamente a la trazabilidad del modelo.

6.2. Comportamiento frente al problema **Small Sample Size**

El estudio realizado sobre escenarios **Small Sample Size** confirmó experimentalmente las limitaciones teóricas asociadas a la formulación clásica del Análisis Discriminante Lineal. Con-

forme el número de variables superó ampliamente al número de observaciones, la matriz de dispersión intra-clase perdió invertibilidad, imposibilitando la obtención de las direcciones discriminantes mediante la formulación tradicional.

En contraste, tanto la implementación de LDA basada en descomposición en valores singulares, disponible en el paquete MASS de R, como KFDA lograron mantener su capacidad para generar proyecciones discriminantes bajo estas condiciones. Estos resultados ponen de manifiesto la importancia de emplear formulaciones numéricamente robustas cuando se trabaja con conjuntos de datos de alta dimensionalidad y tamaño de muestra reducido, ya que permiten evitar el colapso observado en la formulación clásica sin modificar el objetivo discriminante del método.

Asimismo, este estudio permitió ilustrar de forma visual cómo distintas formulaciones de un mismo modelo pueden presentar comportamientos considerablemente diferentes frente a un mismo problema, evidenciando que la implementación computacional también desempeña un papel importante en la aplicabilidad práctica de los métodos discriminantes.

6.3. Comparación con los métodos evaluados

La comparación experimental mostró que GNLPDA presenta un comportamiento competitivo respecto a los métodos considerados, aunque su desempeño depende de las características particulares del conjunto de datos.

En problemas con fronteras de decisión relativamente simples, como Palmer Penguins o Wine, los mejores resultados fueron obtenidos por LDA y QDA, cuyos valores de exactitud mostraron una menor variabilidad y un desempeño superior al resto de los métodos. Estos resultados evidencian que, cuando los supuestos de los modelos clásicos se cumplen de forma aproximada, la incorporación de mecanismos más sofisticados no necesariamente produce mejoras significativas.

Por otra parte, el conjunto Ionosphere representó un escenario distinto debido a su elevada dimensionalidad y al reducido número de observaciones disponibles. En este caso, QDA no logró ejecutarse debido a las dificultades asociadas con la estimación de las matrices de covarianza requeridas por el modelo, mientras que las formulaciones más robustas de LDA y los métodos kernel conservaron su capacidad operativa.

En los conjuntos de datos caracterizados por fronteras de decisión claramente no lineales, los métodos basados en kernels, particularmente la SVM con kernel gaussiano, alcanzaron los mejores resultados de clasificación, acompañados además de una menor dispersión entre las distintas ejecuciones. Aunque GNLPDA no logró superar este comportamiento, sí obtuvo desempeños competitivos y estadísticamente comparables con las configuraciones basadas en kernels polinomiales, especialmente con SVM de grado dos. Este resultado sugiere que una expansión explícita, acompañada de un mecanismo adecuado de selección de variables, puede aproximar la capacidad discriminante obtenida mediante kernels implícitos.

En contraste, el conjunto Pima Diabetes representó un escenario particularmente complejo debido al elevado traslape existente entre clases. En este caso, todos los métodos evaluados alcanzaron desempeños similares, independientemente de su complejidad. Este comportamiento pone en evidencia que la capacidad predictiva de un clasificador no depende únicamente del algoritmo empleado, sino también de la calidad, estructura y separabilidad inherente de los datos disponibles.

Finalmente, los conjuntos correspondientes a los indicadores de rezago social mostraron un comportamiento diferente al observado en los problemas anteriores. GNLPDA obtuvo un desempeño intermedio entre los métodos clásicos y las máquinas de soporte vectorial, mientras

que KFDA presentó una disminución importante en su capacidad de clasificación. Las proyecciones obtenidas sugieren que estos conjuntos presentan una estructura caracterizada por clases progresivas con fronteras poco definidas, situación en la que la representación inducida por KFDA no logró capturar adecuadamente las diferencias sutiles entre grupos. En cambio, tanto LDA como GNLPDA conservaron una representación más consistente de la organización gradual presente en los datos.

6.4. Interpretación general de la propuesta

En conjunto, los resultados obtenidos permiten interpretar a GNLPDA como una estrategia que busca equilibrar capacidad predictiva, interpretabilidad y representación geométrica de los datos. La propuesta no pretende reemplazar a los métodos clásicos cuando éstos resultan suficientes, ni competir directamente con los enfoques kernel en aquellos escenarios donde las transformaciones implícitas ofrecen ventajas evidentes. En cambio, plantea una alternativa que incorpora relaciones no lineales de manera explícita, conservando la posibilidad de identificar las variables y términos polinomiales responsables de la separación obtenida.

Esta característica adquiere especial relevancia cuando, además del desempeño predictivo, resulta importante comprender la estructura del problema y explicar el comportamiento del modelo. En este sentido, GNLPDA ofrece una representación visual compacta de la información contenida en espacios de alta dimensionalidad, permitiendo analizar la geometría de las clases y facilitando la interpretación de las transformaciones realizadas durante el proceso de aprendizaje.

Capítulo 7

Conclusiones

Se **logro** desarrollar e **implementar el marco de trabajo completo mismo** que constituye una alternativa híbrida viable para construir proyecciones discriminantes no lineales mediante expansión polinomial explícita y selección evolutiva.

Su desempeño no muestra una superioridad sistemática frente a métodos **kernell** del estado del arte en términos de exactitud, pero sí evidencian un comportamiento competitivo en diversos escenarios y una ventaja metodológica relevante: la posibilidad de obtener representaciones compactas, proyectables y trazables.

Los resultados sugieren que la elección del método de clasificación debe entenderse como un compromiso entre la complejidad del problema, la capacidad predictiva requerida y el nivel de interpretabilidad deseado. Mientras que en algunos escenarios los métodos clásicos continúan siendo la alternativa más eficiente, en otros resulta necesario recurrir a modelos capaces de representar relaciones no lineales más complejas. GNLPPDA se posiciona precisamente en ese punto intermedio, ofreciendo una solución que combina expansión explícita de características, selección evolutiva y reducción de dimensionalidad con el propósito de mantener un equilibrio entre rendimiento e interpretabilidad.

Bibliografía

- [1] ABUKMEIL, Mohanad ; FERRARI, Stefano ; GENOVESE, Angelo ; PIURI, Vincenzo ; SCOTTI, Fabio: A survey of unsupervised generative models for exploratory data analysis and representation learning. In: *Acm computing surveys (csur)* 54 (2021), Nr. 5, S. 1–40
- [2] ACEVEDO, Aldo ; WU, Yue ; TRAVERSA, Fabio L. ; CANNISTRACI, Carlo V.: Geometric separability of mesoscale patterns in embedding representation and visualization of multidimensional data and complex networks. In: *PLOS Complex Systems* 1 (2024), Nr. 2, S. e0000012
- [3] AGATRA, Denaya Ferrari N. ; MARUTHO, Dhendra ; XIONG, Xinqi: Evaluating PCA and LDA to Improve Machine Learning Classification of Consumer Behavior in Health Informatics. In: *Journal of Intelligent Computing and Health Informatics (JICHI)*. Vol 6 (2025), Nr. 1
- [4] AL-MILLI, Nabeel ; HUDAIB, Amjad ; OBEID, Nadim: Population diversity control of genetic algorithm using a novel injection method for bankruptcy prediction problem. In: *Mathematics* 9 (2021), Nr. 8, S. 823
- [5] ALI, Liaqat ; WAJAHAT, Iram ; AMIRI GOLILARZ, Noorbakhsh ; KESHTKAR, Fazel ; BUKHARI, Syed Ahmad C.: LDA–GA–SVM: improved hepatocellular carcinoma prediction through dimensionality reduction and genetically optimized support vector machine. In: *Neural Computing and Applications* 33 (2021), Nr. 7, S. 2783–2792
- [6] ANDREWS, David F.: Plots of high-dimensional data. In: *Biometrics* (1972), S. 125–136
- [7] ARAVEEPORN, Autcha ; BANDITVILAI, Somsri: A Classification Study in High-Dimensional Data of Linear Discriminant Analysis and Regularized Discriminant Analysis. In: *WSEAS TRANSACTIONS ON MATHEMATICS* 22 (2023), Mai, 315–323. <http://dx.doi.org/10.37394/23206.2023.22.37>. – DOI 10.37394/23206.2023.22.37. – ISSN 1109–2769
- [8] BARRADAS-PALMEROS, Jesús-Arnulfo ; MEZURA-MONTES, Efrén ; RIVERA-LÓPEZ, Rafael ; ACOSTA-MESA, Hector-Gabriel: Computational cost reduction in wrapper approaches for feature selection: a case of study using permutational-based differential evolution. In: *2024 IEEE congress on evolutionary computation (CEC)* IEEE, 2024, S. 1–8
- [9] BELHUMEUR, Peter N. ; HESPANHA, Joao P. ; KRIEGMAN, David J.: Eigenfaces vs. fisherfaces: Recognition using class specific linear projection. In: *IEEE Transactions on pattern analysis and machine intelligence* 19 (1997), Nr. 7, S. 711–720
- [10] BHARADIYA, Jasmin P.: A tutorial on principal component analysis for dimensionality reduction in machine learning. In: *International journal of innovative science and research technology* 8 (2023), Nr. 5, S. 2028–2032

- [11] BISHOP, Christopher M. ; NASRABADI, Nasser M.: *Pattern recognition and machine learning*. Springer, 2006
- [12] BODT, Cyril de ; DIAZ-PAPKOVICH, Alex ; BLEHER, Michael ; BUNTE, Kerstin ; COUPETTE, Corinna ; DAMRICH, Sebastian ; SANMARTIN, Enrique F. ; HAMPRECHT, Fred A. ; HORVÁT, Emőke-Ágnes ; KOHLI, Dhruv u. a.: Low-dimensional embeddings of high-dimensional data. In: *arXiv preprint arXiv:2508.15929* (2025)
- [13] BRISCIK, Mitja ; DILLIES, Marie-Agnès ; DÉJEAN, Sébastien: Improvement of variables interpretability in kernel PCA. In: *BMC bioinformatics* 24 (2023), Nr. 1, S. 282
- [14] BRUNO, Pierangela ; CALIMERI, Francesco ; KITANIDIS, Alexandre S. ; DE MOMI, Elena: Data reduction and data visualization for automatic diagnosis using gene expression and clinical data. In: *Artificial Intelligence in Medicine* 107 (2020), S. 101884
- [15] BUHAS, Bogdan A. ; MUNTEAN, Lucia Ana-Maria ; PLOUSSARD, Guillaume ; FECICHE, Bogdan O. ; ANDRAS, Iulia ; TOMA, Valentin ; MAGHIAR, Teodor A. ; CRIȘAN, Nicolae ; ȘTIUFUIC, Rareș-Ionuț ; LUCACIU, Constantin M.: Renal cell carcinoma discrimination through attenuated total reflection Fourier transform infrared spectroscopy of dried human urine and machine learning techniques. In: *International Journal of Molecular Sciences* 25 (2024), Nr. 18, S. 9830
- [16] CHAPELLE, Olivier ; VAPNIK, Vladimir ; BOUSQUET, Olivier ; MUKHERJEE, Sayan: Choosing multiple parameters for support vector machines. In: *Machine learning* 46 (2002), Nr. 1, S. 131–159
- [17] CHHIKARA, Prateek ; JAIN, Nikhil ; TEKCHANDANI, Rajkumar ; KUMAR, Neeraj: Data dimensionality reduction techniques for Industry 4.0: Research results, challenges, and future research directions. In: *Software: Practice and Experience* 52 (2022), Nr. 3, S. 658–688
- [18] COOMANS, D ; AEGERHARD, S ; VEL, O de: Comparison of classifiers in high dimensional settings / Technical Report 92-02, Dept. of Computer Science and Dept. of Mathematics 1992. – Forschungsbericht
- [19] CORTES, Corinna ; VAPNIK, Vladimir: Support-vector networks. In: *Machine learning* 20 (1995), Nr. 3, S. 273–297
- [20] COVER, Thomas M.: Geometrical and statistical properties of systems of linear inequalities with applications in pattern recognition. In: *IEEE transactions on electronic computers* (1965), Nr. 3, S. 326–334
- [21] DEMŠAR, Janez: Statistical comparisons of classifiers over multiple data sets. In: *Journal of Machine learning research* 7 (2006), Nr. Jan, S. 1–30
- [22] DU, Ke-Lin ; JIANG, Bingchun ; LU, Jiabin ; HUA, Jingyu ; SWAMY, MNS: Exploring kernel machines and support vector machines: Principles, techniques, and future directions. In: *Mathematics* 12 (2024), Nr. 24, S. 3935
- [23] DUDA, R ; HART, P ; STORK, D ; IONESCU, Alexandru: *Pattern classification, chapter nonparametric techniques*. 2000

- [24] ESPADOTO, Mateus ; APPLEBY, Gabriel ; SUH, Ashley ; CASHMAN, Dylan ; LI, Mingwei ; SCHEIDEGGER, Carlos ; ANDERSON, Erik W. ; CHANG, Remco ; TELEA, Alexandru C.: UnProjection: Leveraging inverse-projections for visual analytics of high-dimensional data. In: *IEEE Transactions on Visualization and Computer Graphics* 29 (2021), Nr. 2, S. 1559–1572
- [25] FENG, Siyi ; WANG, Huaixiu: Comparison of PCA and LDA dimensionality reduction algorithms based on wine dataset. In: *2021 33rd Chinese Control and Decision Conference (CCDC)* IEEE, 2021, S. 2791–2796
- [26] FISHER, Ronald A.: The use of multiple measurements in taxonomic problems. In: *Annals of eugenics* 7 (1936), Nr. 2, S. 179–188
- [27] FRIEDMAN, Jerome H.: Regularized discriminant analysis. In: *Journal of the American statistical association* 84 (1989), Nr. 405, S. 165–175
- [28] FUKUNAGA, Keinosuke: *Introduction to statistical pattern recognition*. Elsevier, 2013
- [29] GAO, Hui ; DAVIS, James W.: Why direct LDA is not equivalent to LDA. In: *Pattern Recognition* 39 (2006), Nr. 5, S. 1002–1006
- [30] GHOJOGH, Benyamin ; KARRAY, Fakhri ; CROWLEY, Mark: Fisher and kernel Fisher discriminant analysis: Tutorial. In: *arXiv preprint arXiv:1906.09436* (2019)
- [31] GOLDBERG, David E. ; HOLLAND, John H.: Genetic Algorithms and Machine Learning. In: *Machine Learning* 3 (1988), Oktober, Nr. 2-3, 95–99. <http://dx.doi.org/10.1023/a:1022602019183>. – DOI 10.1023/a:1022602019183. – ISSN 1573–0565
- [32] GOLUB, Gene H. ; VAN LOAN, Charles F.: *Matrix computations*. Bd. 3. JHU press, 2013
- [33] GORMAN, Kristen B. ; WILLIAMS, Tony D. ; FRASER, William R.: Ecological sexual dimorphism and environmental variability within a community of Antarctic penguins (genus *Pygoscelis*). In: *PloS one* 9 (2014), Nr. 3, S. e90081
- [34] GUYON, Isabelle ; ELISSEEFF, André: An introduction to variable and feature selection. In: *Journal of machine learning research* 3 (2003), Nr. Mar, S. 1157–1182
- [35] HASAN, Basna Mohammed S. ; ABDULAZEEZ, Adnan M.: A review of principal component analysis algorithm for dimensionality reduction. In: *Journal of Soft Computing and Data Mining* 2 (2021), Nr. 1, S. 20–30
- [36] HASTIE, Trevor ; TIBSHIRANI, Robert ; FRIEDMAN, Jerome u. a.: *The elements of statistical learning*. 2009
- [37] HORST, Allison M. ; HILL, Alison P. ; GORMAN, Kristen B.: Palmer Archipelago Penguins Data in the palmerpenguins R Package-An Alternative to Anderson’s Irises. In: *R Journal* 14 (2022), Nr. 1, S. 244
- [38] JAIN, Anil K. ; DUIN, Robert P. W. ; MAO, Jianchang: Statistical pattern recognition: A review. In: *IEEE Transactions on pattern analysis and machine intelligence* 22 (2000), Nr. 1, S. 4–37

- [39] JALILI, Amir ; SALEKI, Ziba ; LUO, YA ; PAN, Feng ; CHEN, Ai X. ; DRAAYER, Jerry P.: Performance of various kernel functions for mass prediction with support vector machine. In: *The European Physical Journal A* 61 (2025), Nr. 6, S. 143
- [40] KABIR, Md F. ; CHEN, Tianjie ; LUDWIG, Simone A.: A performance analysis of dimensionality reduction algorithms in machine learning models for cancer prediction. In: *Healthcare Analytics* 3 (2023), S. 100125
- [41] KANADE, Varun: *Machine Learning – Michaelmas Term 2016: Lectures 4, 5: Basis Expansion, Regularization, Validation*. Lecture notes, Department of Computer Science, University of Oxford. <https://www.cs.ox.ac.uk/people/varun.kanade/teaching/ML-MT2016/lectures/lecture04.pdf>. Version: 2016. – Accessed: 2026-06-25
- [42] KIM, Donghwan ; PARK, Seung H. ; BAEK, Jun-Geol: A Kernel fisher discriminant analysis-based tree ensemble classifier: Kfda forest. In: *arXiv preprint arXiv:2606.29053* (2026)
- [43] KOHAVI, Ron ; JOHN, George H.: Wrappers for feature subset selection. In: *Artificial intelligence* 97 (1997), Nr. 1-2, S. 273–324
- [44] KRZANOWSKI, Wojtek J. ; JONATHAN, Philip ; MCCARTHY, WV ; THOMAS, Mervyn R.: Discriminant analysis with singular covariance matrices: methods and applications to spectroscopic data. In: *Journal of the Royal Statistical Society Series C: Applied Statistics* 44 (1995), Nr. 1, S. 101–115
- [45] LARA-ARELLANO, Edgar ; TAKACS, Andras ; TOVAR-ARRIAGA, Saul ; RODRÍGUEZ-RESÉNDIZ, Juvenal: Feature Generation with Genetic Algorithms for Imagined Speech Electroencephalogram Signal Classification. In: *Eng* 6 (2025), Nr. 4, S. 75
- [46] LI, Zhengxin ; NIE, Feiping ; WANG, Rong ; LI, Xuelong: A revised formation of trace ratio LDA for small sample size problem. In: *IEEE transactions on neural networks and learning systems* 36 (2024), Nr. 3, S. 5803–5809
- [47] LIU, Jingjing ; FENG, Manlong ; XIU, Xianchao ; LIU, Wanquan ; ZENG, Xiaoyang: Efficient and robust sparse linear discriminant analysis for data classification. In: *IEEE Transactions on Emerging Topics in Computational Intelligence* 9 (2024), Nr. 1, S. 617–629
- [48] LÓPEZ-IBÁÑEZ, Manuel ; DUBOIS-LACOSTE, Jérémie ; CÁCERES, Leslie P. ; BIRATTARI, Mauro ; STÜTZLE, Thomas: The irace package: Iterated racing for automatic algorithm configuration. In: *Operations Research Perspectives* 3 (2016), S. 43–58
- [49] MAHADI, Maaz ; BALLAL, Tarig ; MOINUDDIN, Muhammad ; AL-NAFFOURI, Tareq Y. ; AL-SAGGAF, Ubaid M.: Regularized linear discriminant analysis using a nonlinear covariance matrix estimator. In: *IEEE Transactions on Signal Processing* 72 (2024), S. 1049–1064
- [50] MANGASARIAN, Olvi L. ; STREET, W N. ; WOLBERG, William H.: Breast cancer diagnosis and prognosis via linear programming. In: *Operations research* 43 (1995), Nr. 4, S. 570–577

- [51] MANHRAWY, Ibrahim I. ; FATHI, Hanaa ; ALSEKAIT, Deema M. ; ALTAWIL, Arar ; KE-LANY, Ayda K.: Hybrid feature selection and classification model using high-dimensional data based on a metaheuristic algorithm for brain cancer diagnosis. In: *Scientific Reports* 16 (2026), Nr. 1, S. 11909
- [52] MARSAGLIA, George: Choosing a point from the surface of a sphere. In: *The Annals of Mathematical Statistics* 43 (1972), Nr. 2, S. 645–646
- [53] MARTINEZ, Aleix M. ; KAK, Avinash C.: Pca versus lda. In: *IEEE transactions on pattern analysis and machine intelligence* 23 (2001), Nr. 2, S. 228–233
- [54] MCLACHLAN, Geoffrey J.: *Discriminant analysis and statistical pattern recognition*. Bd. 93. Wiley New York, 1992
- [55] MEDINA, Marco A. ; DAVIS, Richard A. ; SAMORODNITSKY, Gennady: Insights into kernel pca with application to multivariate extremes. In: *SIAM Journal on Mathematics of Data Science* 7 (2025), Nr. 2, S. 777–801
- [56] MEDINA, Víctor David G. ; MESA, Héctor Gabriel A. ; LOBATO, Adriana Laura L. ; MONTES, Efrén M.: Genetic Projective Discriminant Analysis. In: *2025 IEEE Latin American Conference on Computational Intelligence (LA-CCI)*, 2025, S. 1–6
- [57] MIKA, Sebastian ; RATSCH, Gunnar ; WESTON, Jason ; SCHOLKOPF, Bernhard ; MULLERS, Klaus-Robert: Fisher discriminant analysis with kernels. In: *Neural networks for signal processing IX: Proceedings of the 1999 IEEE signal processing society workshop (cat. no. 98th8468)* Ieee, 1999, S. 41–48
- [58] MONTGOMERY, Douglas C. ; PECK, Elizabeth A. ; VINING, G G.: *Introduction to Linear Regression Analysis, 6e Solutions Manual*. John Wiley & Sons, 2022
- [59] MOURIK, Frank van ; HAERI, Maryam A. ; BUKHSH, Faiza A. ; AHMED, Faizan: Itershap: An xai-based feature selection method for small high-dimensional datasets. In: *Proceedings of the Future Technologies Conference* Springer, 2024, S. 526–545
- [60] MURDOCH, W J. ; SINGH, Chandan ; KUMBIER, Karl ; ABBASI-ASL, Reza ; YU, Bin: Definitions, methods, and applications in interpretable machine learning. In: *Proceedings of the National Academy of Sciences* 116 (2019), Nr. 44, S. 22071–22080
- [61] NANGA, Salifu ; BAWAH, Ahmed T. ; ACQUAYE, Benjamin A. ; BILLA, Mac-Issaka ; BAETA, Francis D. ; ODAI, Nii A. ; OBENG, Samuel K. ; NSIAH, Ampem D.: Review of dimension reduction methods. In: *Journal of Data Analysis and Information Processing* 9 (2021), Nr. 3, S. 189–231
- [62] NAVARRO-ACOSTA, Jesús A. ; DIOS, Jesús-Adolfo Mejía-de ; GONZÁLEZ LARA, José M. ; SANCHEZ CARRERA, Edgar J.: Bayesian Networks and Machine Learning Approaches Applied to Social Backwardness. In: *Computational Economics* (2025), S. 1–28
- [63] NEHA, Fnu ; SHUKLA, Deepak K.: Radiomics in Medical Imaging: Methods, Applications, and Challenges. In: *Journal of Imaging* 12 (2026), Nr. 6, S. 220
- [64] NETO, Mário P. ; PAULOVICH, Fernando V.: Multivariate data explanation by jumping emerging patterns visualization. In: *IEEE Transactions on Visualization and Computer Graphics* 30 (2022), Nr. 2, S. 1549–1563

- [65] NGUYEN, Lan H. ; HOLMES, Susan: Ten quick tips for effective dimensionality reduction. In: *PLoS computational biology* 15 (2019), Nr. 6, S. e1006907
- [66] NIU, Guo ; MA, Zhengming: Local quasi-linear embedding based on kronecker product expansion of vectors. In: *Journal of Intelligent & Fuzzy Systems* 41 (2021), Nr. 1, S. 2195–2205
- [67] NOGALES, Rubén E ; BENALCÁZAR, Marco E.: Analysis and evaluation of feature selection and feature extraction methods. In: *International Journal of Computational Intelligence Systems* 16 (2023), Nr. 1, S. 153
- [68] OETTL, Felix C. ; OEDING, Jacob F. ; FELDT, Robert ; LEY, Christophe ; HIRSCHMANN, Michael T. ; SAMUELSSON, Kristian ; GROUP, ESSKA Artificial Intelligence W.: *The artificial intelligence advantage: Supercharging exploratory data analysis*. 2024
- [69] PENG, Dehua ; GUI, Zhipeng ; WU, Huayi: Interpreting the curse of dimensionality from distance concentration and manifold effect. In: *arXiv preprint arXiv:2401.00422* (2023)
- [70] PEREIRA, Dulce G. ; AFONSO, Anabela ; MEDEIROS, Fátima Melo: Overview of Friedman’s test and post-hoc analysis. In: *Communications in Statistics-Simulation and Computation* 44 (2015), Nr. 10, S. 2636–2653
- [71] RABBI, Md Sakhawat H. ; BARI, Md M. ; DEBNATH, Tanoy ; RAHMAN, Anichur ; DAS, Avik K. ; HOSSAIN, Md P. ; MUHAMMAD, Ghulam: Performance evaluation of optimal ensemble learning approaches with PCA and LDA-based feature extraction for heart disease prediction. In: *Biomedical Signal Processing and Control* 101 (2025), S. 107138
- [72] RAUDYS, Sarunas J. ; JAIN, Anil K. u. a.: Small sample size effects in statistical pattern recognition: Recommendations for practitioners. In: *IEEE Transactions on pattern analysis and machine intelligence* 13 (1991), Nr. 3, S. 252–264
- [73] REMAKI, Lakhdar: RBF Kernel Parameter Formula for Data Classification Methods. In: *arXiv preprint arXiv:2604.01258* (2026)
- [74] RUDIN, Cynthia: Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. In: *Nature machine intelligence* 1 (2019), Nr. 5, S. 206–215
- [75] SCHOLKOPF, Bernhard ; SMOLA, Alexander J.: *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT press, 2018
- [76] SEVILLA, Departamento de Ciencias de la Computación e Inteligencia A. d.: *Algoritmos Genéticos*. https://www.cs.us.es/~fsancho/Blog/posts/Algoritmos_Geneticos.md.html, . – Accedido el 7 de septiembre de 2026
- [77] SHI, Wenya ; WU, Gang: New algorithms for trace-ratio problem with application to high-dimension and large-sample data dimensionality reduction. In: *Machine Learning* 113 (2024), Nr. 7, S. 3889–3916
- [78] SIEDLECKI, Wojciech ; SKLANSKY, Jack: A note on genetic algorithms for large-scale feature selection. In: *Pattern recognition letters* 10 (1989), Nr. 5, S. 335–347

- [79] SIGILLITO, Vincent G. ; WING, Simon P. ; HUTTON, Larrie V. ; BAKER, Kile B.: Clas-sification of radar returns from the ionosphere using neural networks. In: *Johns Hopkins APL Technical Digest* 10 (1989), Nr. 3, S. 262–266
- [80] SILVA, Pablo N. ; PLASTINO, Alexandre ; FREITAS, Alex A.: A Novel Genetic Algorithm for Feature Selection in Hierarchical Feature Spaces. In: *SDM*, 2018, S. 738–746
- [81] SMITH, Jack W. ; EVERHART, James E. ; DICKSON, William C. ; KNOWLER, William C. ; JOHANNES, Robert S.: Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. In: *Proceedings of the annual symposium on computer application in medical care*, 1988, S. 261
- [82] SORZANO, Carlos Oscar S. ; VARGAS, Javier ; MONTANO, A P.: A survey of dimensionality reduction techniques. In: *arXiv preprint arXiv:1403.2877* (2014)
- [83] SOUSA PAPA, Ângela W. ; OLIVEIRA, Anne N. ; LAWRYNHUK URBANO FERREIRA, Rannapaula ; OLIVEIRA ROSENDO, Geovanna B. ; MAURÍCIO SENA-EVANGELISTA, Karine C. ; GOMES LIMA, Josivan ; BARBOSA JR, Fernando ; MORAIS, Camilo de L. d. ; LIMA, Kássio M. ; MENDONÇA ARAÚJO, Renata u. a.: Nuclear magnetic resonance combined with genetic algorithm with linear discriminant analysis (GA-LDA) is a suitable model for discriminating urinary metabolomic profiles of individuals with glycemic disorders. In: *Annals of Medicine* 57 (2025), Nr. 1, S. 2566870
- [84] THRUN, PhD Michael C. u. a.: Uncovering high-dimensional structures of projections from dimensionality reduction methods. In: *MethodsX* 7 (2020), S. 101093
- [85] VENABLES, William N. ; RIPLEY, Brian D.: *Modern applied statistics with S*. springer, 2002
- [86] VENKAT, Naveen: The curse of dimensionality: Inside out. In: *Pilani (IN): Birla Institute of Technology and Science, Pilani, Department of Computer Science and Information Systems* 10 (2018), Nr. 10.13140
- [87] WANG, Yangyang ; GAO, Xiaoguang ; RU, Xinxin ; SUN, Pengzhan ; WANG, Jihan: A hybrid feature selection algorithm and its application in bioinformatics. In: *PeerJ Computer Science* 8 (2022), S. e933
- [88] WANG, Ying ; FAN, Renjie ; CHENG, Lei ; GONG, Bo ; LIU, Jiahao: An Improved Adaptive NSGA-II with Multiple Filtering for High-Dimensional Feature Selection. In: *Electronics* 15 (2026), Nr. 1, S. 236
- [89] YANG, Hannan ; LIN, DY ; LI, Quefeng: An efficient greedy search algorithm for high-dimensional linear discriminant analysis. In: *Statistica Sinica* 33 (2023), Nr. SI, S. 1343
- [90] ZEBARI, Rizgar ; ABDULAZEEZ, Adnan ; ZEEBAREE, Diyar ; ZEBARI, Dilovan ; SAEED, Jwan: A comprehensive review of dimensionality reduction techniques for feature selection and feature extraction. In: *Journal of Applied Science and Technology Trends* 1 (2020), Nr. 1, S. 56–70
- [91] ZHANG, Mengqi ; TREDER, Matthias ; MARSHALL, David ; LI, Yuhua: Fast explanation of RBF-kernel SVM models using activation patterns. In: *2024 International Joint Conference on Neural Networks (IJCNN)* IEEE, 2024, S. 1–8

- [92] ZHAO, Shuping ; ZHANG, Bob ; YANG, Jian ; ZHOU, Jianhang ; XU, Yong: Linear discriminant analysis. In: *Nature Reviews Methods Primers* 4 (2024), Nr. 1, S. 70