



Universidad Veracruzana

Universidad Veracruzana

Análisis Discriminante Polinomial No Lineal Genético (GNLPDA)

Instituto de Investigaciones en Inteligencia Artificial

Presenta:

Ángel García Báez

Director:

Héctor Gabriel Acosta Mesa

Codirectora:

Adriana Laura López Lobato

Índice general

1. Introducción	1
1.1. Contexto y motivación	1
1.2. Planteamiento del problema	2
1.3. Propuesta	2
1.4. Justificación	3
1.5. Pregunta de investigación	3
1.6. Hipótesis	3
1.7. Objetivos	4
1.7.1. Objetivo general	4
1.7.2. Objetivos específicos	4
1.8. Contribuciones	4
1.9. Alcances y limitaciones	5
1.10. Organización de la tesis	5
2. Marco Teórico	7
2.1. Representación y visualización de datos multidimensionales	7
2.1.1. El desafío de visualizar datos de alta dimensión	7
2.1.2. Reducción dimensional como mecanismo de representación	7
2.1.3. Proyecciones discriminantes para la visualización supervisada	8
2.1.4. Visualización de representaciones de baja dimensión	8
2.2. Análisis Discriminante Lineal	9
2.2.1. Fundamentos y criterio de Fisher	9
2.2.2. Extensión multiclase y obtención de ejes discriminantes	10
2.2.3. Supuestos, limitaciones y comparación con QDA	11
2.2.4. Implementación computacional y tratamiento de la singularidad	12
2.3. Problema de muestras pequeñas (Small Sample Size)	13
2.4. Expansión polinomial y espacios de características	14
2.4.1. Formalización de la expansión polinomial	14
2.4.2. Limitaciones: Crecimiento Combinatorio y Complejidad	15
2.5. Algoritmos genéticos	16
2.5.1. Representación cromosómica y función de aptitud	16
2.5.2. Ciclo evolutivo y operadores genéticos	17
2.5.3. Algoritmos genéticos como estrategia wrapper	18
2.6. Métodos kernel y clasificadores no lineales	18
2.6.1. Truco Kernel y funciones kernel	19
2.6.2. KFDA y SVM como enfoques no lineales de referencia	19
2.6.3. Ventajas, limitaciones e interpretabilidad	20

3. Estado del arte	23
3.1. Variantes lineales del análisis discriminante	23
3.1.1. Regularized LDA	23
3.1.2. LDA en dos etapas	24
3.1.3. Variantes lineales relevantes	24
3.2. Métodos kernel	25
3.2.1. Análisis de Componentes Principales con Kernel (KPCA)	25
3.2.2. Análisis Discriminante de Fisher mediante Kernel (KFDA)	25
3.2.3. SVM Polinomial	25
3.2.4. SVM RBF	26
3.3. Selección de características basada en algoritmos evolutivos	26
3.3.1. GA para selección de variables	26
3.3.2. Métodos híbridos	27
3.3.3. GPDA	27
3.4. Limitaciones identificadas	27
3.5. Posicionamiento de GNLPDA	28
4. Metodología	29
4.1. Selección evolutiva en dos fases	29
4.1.1. Fase I: selección de variables originales	29
4.1.2. Fase II: selección de términos polinomiales	31
4.1.3. Salida del procedimiento y ajuste final de LDA	33
4.2. Configuración y calibración de GNLPDA	34
4.2.1. Configuración del algoritmo genético.	35
4.2.2. Parámetros del algoritmo genético	36
4.2.3. Calibración mediante irace	37
4.3. Diseño experimental	38
4.3.1. Conjuntos de datos utilizados	38
4.3.2. Generación de conjuntos sintéticos tipo Cebolla	40
4.3.3. Protocolo de particionamiento y evaluación	41
4.3.4. Análisis estadístico de resultados	41
4.3.5. Evaluación auxiliar del problema Small Sample Size	42
4.3.6. Métodos comparativos y métrica de evaluación	43

Capítulo 1

Introducción

1.1. Contexto y motivación

En el marco del Aprendizaje Máquina (Machine Learning), el objetivo fundamental es el desarrollo de algoritmos capaces de identificar patrones complejos a partir de datos para la toma de decisiones automatizada en diversos campos de aplicación [11]. En problemas de aprendizaje supervisado, un conjunto de datos puede representarse como una matriz en la que cada fila corresponde a una observación y cada columna a una característica descriptiva. Cuando las observaciones cuentan con una etiqueta de clase, esta representación se convierte en la base sobre la cual los modelos buscan identificar fronteras de separación [34].

Sin embargo, cuando dicha matriz posee un número elevado de características, su análisis y representación gráfica se ven severamente comprometidos debido al fenómeno conocido como la maldición de la dimensionalidad [82]. Para mitigar este problema, las técnicas de reducción de dimensionalidad buscan transformar el espacio original en una representación más compacta, procurando conservar la mayor cantidad de información útil [61, 78].

De manera general, estas técnicas se agrupan en dos enfoques principales (ver Figura 1.1): la **selección de características**, que conserva un subconjunto de las variables originales mediante métodos de filtro o enfoques *wrapper*; y la **extracción de características**, que transforma el espacio original para generar nuevas proyecciones, como ocurre en el Análisis de Componentes Principales (PCA) o el Análisis Discriminante [36].




Figura 1.1: Taxonomía de las técnicas de reducción de dimensionalidad. Tomada de [52].

La proyección de los datos hacia espacios de baja dimensión (dos o tres dimensiones) cum-

ple un propósito exploratorio fundamental. En dominios complejos como la genómica o la radiómica, visualizar la geometría de los datos permite evaluar si los biomarcadores extraídos logran discriminar claramente entre condiciones sanas y patológicas [15, 59]. Comúnmente, esta exploración se realiza proyectando las dos primeras componentes de PCA [38].

1.2. Planteamiento del problema

A pesar de su popularidad, PCA no es la herramienta más adecuada para evaluar la separabilidad de clases. Al ser un método no supervisado cuyo criterio de optimización es la varianza total, no garantiza que las proyecciones obtenidas coincidan con las fronteras que mejor separan a los grupos [67]. El Análisis Discriminante Lineal (LDA) resuelve esta limitación incorporando la información de las etiquetas para maximizar la dispersión inter-clase respecto a la intra-clase, convirtiéndolo en la herramienta natural para la visualización supervisada [18].

No obstante, la formulación clásica de LDA impone supuestos que restringen severamente su aplicabilidad: asume fronteras de decisión estrictamente lineales, normalidad multivariada y matrices de dispersión bien condicionadas, fallando rotundamente en escenarios con tamaños de muestra pequeños [25].

Para superar estas barreras operativas, se han desarrollado variantes evolutivas como el Genetic Projective Discriminant Analysis (GPDA), el cual optimiza la proyección discriminante lineal esquivando los problemas de matrices singulares [52]. Sin embargo, dicha propuesta conserva la restricción de su método base: su formulación esta diseñada para tratar con datos con estructuras linealmente separables.

Una alternativa intuitiva para abordar la no linealidad es expandir explícitamente el espacio de características (por ejemplo, mediante términos polinomiales), convirtiendo relaciones complejas en fronteras lineales tratables por LDA. No obstante, este enfoque introduce una explosión combinatoria del número de variables a medida que aumentan el grado del polinomio, agravando la maldición de la dimensionalidad [12].

En la literatura actual, la alternativa dominante para tratar con estructuras no linealmente separables en los datos sin expandir explícitamente el espacio es el uso de métodos kernel, como las Maquinas de Soporte Vectorial (SVM) o el Análisis discriminante de Kernel Fisher (KFDA). Estos explotan el “truco del kernel” para operar implícitamente en espacios de dimensión alta o infinita. En particular, el KFDA realiza un mapeo de los datos hacia un espacio de mayor dimensionalidad y, posteriormente, los proyecta en una subdimensión reducida de tamaño $(C - 1)$ número de clases. Este proceso de reducción se lleva a cabo mediante combinaciones matemáticas de los datos transformados, lo que posibilita la visualización en baja dimensionalidad, pero dificulta significativamente la interpretación directa de la representación en términos de las variables originales.

Existe, por tanto, una brecha metodológica concreta: no se cuenta con un mecanismo capaz de producir una proyección de baja dimensión para estructuras no linealmente separables que sea simultáneamente visualizable y trazable hacia las variables originales.

1.3. Propuesta

El objetivo es diseñar e implementar un método híbrido que aplique una expansión polinomial explícita para modelar fronteras de decisión no lineales. Se utilizará dentro de un algoritmo genético jerárquico de dos etapas como esquema de envoltura para seleccionar los términos óptimos, empleando el Análisis Discriminante Lineal (LDA) como función de evaluación y motor

para proyectar los datos en un subespacio de máxima separabilidad visualizable en máximo tres dimensiones.

1.4. Justificación

Esta investigación se justifica por la necesidad de encontrar un equilibrio óptimo entre la transformación para la separabilidad no lineal y la parsimonia dimensional. El trabajo propuesto desarrolla un algoritmo de tipo *wrapper* capaz de solventar la no linealidad mediante expansión polinomial, mitigando simultáneamente la maldición de la dimensionalidad a través de una selección evolutiva de variables.

A diferencia de métodos de “caja negra” del estado del arte, como el Análisis Discriminante de Fisher con Kernel (KFDA) o las Máquinas de Soporte Vectorial (SVM), este marco de trabajo ofrece un beneficio dual:

- **Visualización geométrica:** Permite proyectar estructuras no linealmente separables en espacios de baja dimensión (hasta tres dimensiones), facilitando la inspección visual de la separación entre clases.
- **Trazabilidad e interpretabilidad:** El proceso permite rastrear con precisión qué variables originales y qué términos de interacción fueron seleccionados, ofreciendo una explicación técnica de la proyección final. Esto resulta de suma importancia en aplicaciones donde entender el “porqué” de la decisión del modelo es tan importante como la precisión misma.

1.5. Pregunta de investigación

A partir de esta problemática, la presente investigación plantea la siguiente pregunta:

- **¿Es posible integrar la expansión polinomial explícita con un esquema de selección evolutiva en dos fases para proyectar datos con estructuras no linealmente separables en espacios de baja dimensión (hasta tres dimensiones), que sean visualizables, interpretables y trazables a partir de las variables y términos seleccionados, manteniendo al mismo tiempo un desempeño predictivo y un costo computacional competitivos frente a métodos no lineales de referencia?**

1.6. Hipótesis

La integración de un mecanismo de selección evolutiva en dos fases sobre una expansión polinomial explícita permite generar representaciones discriminantes visualizables en baja dimensión (hasta tres dimensiones) para conjuntos de datos con estructuras no linealmente separables. El enfoque permite reducir la dimensionalidad del espacio expandido e identificar los términos polinomiales seleccionados que contribuyen a la separación discriminante, proporcionando trazabilidad sobre el proceso de construcción de la representación y favoreciendo su interpretabilidad. Asimismo, se plantea que esta representación puede obtenerse manteniendo tiempos de ejecución viables y una exactitud de clasificación estadísticamente competitiva frente a métodos no lineales de referencia de tipo caja negra, sin requerir una superioridad sistemática en rendimiento predictivo.

1.7. Objetivos

1.7.1. Objetivo general

Diseñar e implementar un algoritmo con un esquema híbrido de selección y extracción de características que integre expansión polinomial con análisis discriminante lineal mediante un proceso evolutivo en dos etapas, con el propósito de lograr la visualización interpretable y trazable de datos con estructuras no linealmente separables en espacios de baja dimensión, manteniendo un equilibrio entre reducción de características, tiempo de ejecución y rendimiento predictivo.

1.7.2. Objetivos específicos

- **Caracterizar** las limitaciones operativas y visuales del Análisis Discriminante Lineal (LDA) clásico ante escenarios de no linealidad, alta dimensionalidad y muestras pequeñas.
- **Diseñar e implementar** un mecanismo de selección evolutiva que reduzca la redundancia en el espacio expandido mediante la selección de variables originales y términos polinomiales relevantes que sea capaz de generar una proyección en baja dimensión trazable.
- **Evaluar** el desempeño computacional y la reducción dimensional producida por el algoritmo de selección evolutiva, mediante el registro del tiempo de ejecución y la cuantificación de la cantidad de variables retenidas en cada una de sus fases.
- **Comparar de forma cualitativa** las proyecciones visuales de baja dimensión (máximo tres dimensiones) generadas por el método propuesto frente a las representaciones producidas por LDA y KFDA, evaluando su utilidad para la exploración e interpretación de estructuras discriminantes no lineales.
- **Evaluar y contrastar** estadísticamente la exactitud de clasificación (*Accuracy*) de la propuesta frente a las técnicas de referencia, para validar su competitividad predictiva.

1.8. Contribuciones

Las principales contribuciones de este trabajo son las siguientes:

- Proponer un esquema híbrido de extracción de características que combina expansión polinomial, selección evolutiva y análisis discriminante para abordar problemas de clasificación y proyección con datos no linealmente separables.
- Incorporar un mecanismo de selección en dos fases orientado a reducir la dimensionalidad del espacio expandido, primero mediante la selección de variables originales y posteriormente mediante la selección de términos polinomiales relevantes.
- Evaluar la capacidad del método propuesto para generar proyecciones de baja dimensión, hasta un máximo de tres dimensiones que faciliten la visualización de la separación entre clases.

- Demostrar empíricamente que el algoritmo propuesto alcanza una exactitud de clasificación estadísticamente competitiva frente a métodos que manejan la no linealidad (modelos de caja negra), aportando como ventaja fundamental una proyección interpretable y trazable sin incurrir en una pérdida significativa de rendimiento predictivo.
- Cuantificar la eficiencia del mecanismo evolutivo de selección en sus dos fases mediante métricas tangibles de costo computacional (tiempo de ejecución) y optimización de memoria (tasa de reducción de variables del espacio polinomial expandido), validando su viabilidad operativa.

1.9. Alcances y limitaciones

- El enfoque de la investigación se restringe a problemas de aprendizaje supervisado.
- El alcance experimental se restringe de forma estricta a conjuntos de datos tabulares donde las características exclusivamente numéricas. Por tanto, no se consideran en esta etapa datos no estructurados, variables categóricas sin transformación previa, imágenes, texto, señales temporales ni otros tipos de representación.
- Las visualizaciones generadas por el método propuesto se acotan a espacios de baja dimensión, hasta un máximo de tres dimensiones. Esta restricción se relaciona con la naturaleza del análisis discriminante lineal, el cual permite obtener hasta $C - 1$ dimensiones discriminantes, donde C representa el número de clases del problema.
- La propuesta no busca superar en rendimiento a todos los métodos de referencia, sino obtener un desempeño comparable en determinados escenarios, aportando como ventaja la trazabilidad del proceso de selección y la posibilidad de visualizar las proyecciones generadas en baja dimensión.
- La validación empírica del algoritmo se restringe a un conjunto controlado de diez conjuntos de datos, con un máximo de 32 variables cuantitativas originales.

1.10. Organización de la tesis

- El **Capítulo 2** presenta el marco teórico necesario para comprender los fundamentos de la investigación. En este capítulo se abordan las técnicas de reducción de dimensionalidad, los fundamentos algebraicos y operacionales del Análisis Discriminante Lineal y sus variantes, el problema de pequeño tamaño de muestra, la expansión polinomial, los algoritmos genéticos, los métodos kernel, KFDA, las máquinas de soporte vectorial y las métricas de clasificación utilizadas en el estudio.
- El **Capítulo 3** desarrolla el estado del arte. En este capítulo se revisan trabajos relacionados con variantes y mejoras del Análisis Discriminante Lineal, métodos kernel como KPCA, KFDA y SVM, así como enfoques de selección de características basados en algoritmos genéticos. Asimismo, se analizan trabajos relacionados con GPDA y se identifican las limitaciones que motivan el desarrollo de la propuesta.
- El **Capítulo 4** describe la metodología de investigación y el algoritmo propuesto, denominado Genetic Non-Linear Polynomial Discriminant Analysis (GNLPDA). Se presentan la

arquitectura general del método, sus fases de selección, la función fitness, el proceso de calibración y el diseño experimental empleado para su evaluación.

- El **Capítulo 5** presenta los resultados obtenidos al aplicar el método propuesto sobre los conjuntos de datos seleccionados. Se incluyen resultados de clasificación, análisis de proyecciones de baja dimensión y comparaciones frente a los métodos de referencia.
- El **Capítulo 6** discute los hallazgos obtenidos, considerando la interpretación técnica de los resultados, las fortalezas del método, sus limitaciones y las condiciones bajo las cuales la propuesta resulta más adecuada.
- El **Capítulo 7** presenta las conclusiones generales de la investigación, el grado de cumplimiento de los objetivos planteados, las principales contribuciones del trabajo y las líneas de trabajo futuro.

Capítulo 2

Marco Teórico

2.1. Representación y visualización de datos multidimensionales

En el desarrollo de sistemas de aprendizaje automático, el análisis exploratorio de los datos es una etapa fundamental para comprender la naturaleza del problema. Antes de entrenar modelos de clasificación complejos, la capacidad de observar geométricamente cómo se distribuyen las observaciones permite explorar patrones, detectar posibles valores atípicos e inspeccionar el grado de solapamiento entre las distintas clases [64, 1].

En este contexto resulta conveniente distinguir entre la visualización y la representación que la hace posible. La visualización constituye la manifestación gráfica de los datos, mientras que la representación corresponde al espacio de dimensión reducida utilizado para proyectar las observaciones y facilitar su inspección.

2.1.1. El desafío de visualizar datos de alta dimensión

La representación visual directa de datos multidimensionales está limitada por la capacidad de representar simultáneamente un número reducido de dimensiones, por lo que las representaciones visuales convencionales suelen restringirse a una, dos o tres dimensiones [6, 24] .

Intentar comprender la estructura de un conjunto de datos multidimensional a través del análisis aislado por pares de variables resulta ineficiente y propenso a omitir interacciones complejas que sean clave para entenderlos [60]. A medida que la dimensionalidad aumenta, los datos se vuelven escasos en el espacio representativo, agravando los efectos de la maldición de la dimensionalidad [65]. Por lo tanto, surge la necesidad de proyectar esta información hacia espacios de menor dimensión que permitan conservar, de acuerdo con un criterio determinado, características relevantes de la estructura de los datos.

2.1.2. Reducción dimensional como mecanismo de representación

La reducción dimensional comprende un conjunto de técnicas orientadas a representar los datos en un espacio de baja dimensión, con el propósito de preservar, conforme al criterio de la técnica empleada, aquellas propiedades consideradas relevantes de la estructura original [86].

Cuando la dimensión resultante es suficientemente baja, estas representaciones también pueden emplearse para la exploración visual de los datos [33].

En esta tesis se consideran representaciones de baja dimensión aquellas cuya dimensión no sea mayor a tres, es decir, $d \leq 3$.

Este proceso de representación puede lograrse seleccionando un subconjunto específico de variables (selección de características) o transformando el espacio mediante combinaciones matemáticas (extracción de características) [63].

La selección de características conserva un subconjunto de variables originales mientras que la extracción construye nuevas dimensiones mediante transformaciones o combinaciones de las variables disponibles. En el contexto de la visualización, ambas estrategias pueden producir representaciones de baja dimensión, aunque difieren en el grado de correspondencia directa que mantienen con las variables originales [86].

2.1.3. Proyecciones discriminantes para la visualización supervisada

La utilidad de una visualización depende fuertemente del criterio matemático utilizado para proyectar los datos. El Análisis de Componentes Principales (PCA) constituye una técnica ampliamente utilizada para obtener representaciones de baja dimensión. Al proyectar las observaciones sobre sus primeras componentes, se obtiene un mapa que preserva la mayor varianza global de los datos. Sin embargo, al ser un método no supervisado, PCA no incorpora las etiquetas de clase en el proceso de obtención de las componentes [11].

En problemas de clasificación, la varianza global no siempre coincide con la separabilidad de las clases. Cuando el objetivo específico es favorecer la separación entre grupos, resulta conveniente emplear proyecciones discriminantes supervisadas, cuyo propósito es orientar la proyección hacia direcciones que favorezcan la separación entre los grupos [57].

Para ilustrar esta diferencia fundamental entre la maximización de la varianza global y la maximización de la separabilidad, la figura 2.1 presenta una comparativa geométrica conceptual. Mientras que PCA proyecta los datos buscando la dirección de mayor dispersión general (ignorando las etiquetas de clase), una proyección discriminante orienta los ejes específicamente para maximizar la separación entre las clases respecto a su dispersión interna [25].




Figura 2.1: Comparativa conceptual entre los criterios de proyección de PCA y LDA. Elaboración propia.

2.1.4. Visualización de representaciones de baja dimensión

Las representaciones de baja dimensión permiten convertir un conjunto de observaciones definido originalmente en un espacio multidimensional en una geometría que puede ser inspec-

cionada visualmente. Cuando la representación tiene una, dos o tres dimensiones, es posible recurrir a recursos gráficos que permiten explorar directamente la distribución de las observaciones y su relación con las clases [80].

En un espacio proyectado de baja dimensión, una separación visualmente marcada entre los grupos puede ofrecer evidencia exploratoria acerca de la existencia de una estructura discriminante; sin embargo, dicha representación no constituye por sí misma una prueba estadística de separabilidad ni garantiza desempeño predictivo [2]. Su valor radica en proporcionar una representación geométrica que facilite la exploración de la estructura de los datos y la formulación de hipótesis sobre la relación entre las clases, el grado de solapamiento y la presencia de observaciones atípicas, mientras que la evaluación de la capacidad discriminante y del rendimiento predictivo de un clasificador debe sustentarse en métricas cuantitativas [13].

Además de la posibilidad de inspeccionar visualmente la estructura proyectada, una representación de baja dimensión puede adquirir mayor utilidad interpretativa cuando es posible establecer una relación explícita entre sus dimensiones y las características que intervienen en su construcción [56].

Desde esta perspectiva, la trazabilidad de los ejes resulta relevante para determinar que características participan en la construcción de la representación.

En ciertos métodos de reducción dimensional, especialmente aquellos que recurren a transformaciones implícitas del espacio de características, la relación explícita entre los ejes obtenidos y las variables originales tiende a ser menos directa, lo que dificulta la interpretación de la representación en términos de las características iniciales [14].

La necesidad de contar con representaciones de baja dimensión que, además de facilitar la inspección visual, incorporen explícitamente la información sobre la pertenencia de las observaciones a distintas clases, motiva el empleo de técnicas de proyección discriminante. En este contexto, LDA ofrece un marco matemático que permite construir ejes orientados a maximizar la separación entre clases, estableciendo así la base de una representación discriminante supervisada [88].

2.2. Análisis Discriminante Lineal

2.2.1. Fundamentos y criterio de Fisher

El Análisis Discriminante Lineal, comúnmente referido como LDA por sus siglas en inglés, es una técnica estadística multivariante propuesta originalmente por Fisher (1936) [26], cuyo propósito es encontrar combinaciones lineales de las variables originales que permitan favorecer la separación entre dos o más clases. En el contexto de la reducción de dimensionalidad supervisada, LDA busca proyectar los datos desde un espacio original de dimensión (p) hacia un subespacio de menor dimensión (d), procurando que las observaciones pertenecientes a una misma clase permanezcan compactas, mientras que las clases distintas se encuentren lo más separadas posible [88].

A diferencia de PCA, LDA incorpora explícitamente la información de clase en la construcción de la proyección, orientando sus direcciones hacia la separación entre los grupos [12].

Desde una perspectiva probabilística, LDA suele asociarse con el supuesto de que las densidades condicionales de las clases siguen distribuciones normales multivariantes con una matriz de covarianza común, es decir, bajo una condición de homocedasticidad [50]. Sin embargo, desde la formulación geométrica de Fisher, el método también puede entenderse como la búsqueda de una proyección lineal que maximiza una razón de separabilidad entre clases [26]. Esta

distinción es importante, ya que en aplicaciones prácticas LDA puede emplearse tanto como clasificador como técnica de reducción de dimensionalidad supervisada [49].

Para introducir la formulación básica, considérese primero un problema de clasificación binaria con dos clases C_1 y C_2 . El objetivo consiste en encontrar un vector de proyección w que transforme cada observación del espacio original en un valor escalar mediante una combinación lineal de sus características. La orientación óptima de este vector se determina buscando que las medias de las clases proyectadas queden suficientemente separadas, al mismo tiempo que se controla la variabilidad interna de cada clase.

$$y = \mathbf{w}^T \mathbf{x} \quad (2.1)$$

Para formalizar esta idea, se definen dos cantidades principales: la matriz de dispersión intraclase (S_W) y la matriz de dispersión inter-clase (S_B). La primera resume la variabilidad de las observaciones alrededor de sus respectivos centroides de clase, mientras que la segunda cuantifica la separación entre los centroides de las clases.

$$\mathbf{S}_W = \sum_{n \in C_1} (\mathbf{x}_n - \mathbf{m}_1)(\mathbf{x}_n - \mathbf{m}_1)^T + \sum_{n \in C_2} (\mathbf{x}_n - \mathbf{m}_2)(\mathbf{x}_n - \mathbf{m}_2)^T \quad (2.2)$$

A partir de estas matrices, el criterio de Fisher se expresa como una razón entre la dispersión interclase y la dispersión intraclase, de modo que la dirección discriminante óptima es aquella que maximiza dicha razón.

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}} \quad (2.3)$$

En el caso binario, la solución analítica conduce a una dirección de proyección proporcional al producto entre la inversa de la matriz de dispersión intraclase y la diferencia entre los vectores de medias de ambas clases. Esta formulación permite entender la intuición central del método: proyectar los datos hacia una dirección donde las clases se separen tanto como sea posible, manteniendo simultáneamente baja la dispersión interna de cada grupo [12].

$$\mathbf{w}^* \propto \mathbf{S}_W^{-1}(\mathbf{m}_1 - \mathbf{m}_2) \quad (2.4)$$

2.2.2. Extensión multiclase y obtención de ejes discriminantes

Aunque la formulación binaria permite presentar la intuición geométrica de LDA, muchos problemas de clasificación involucran tres o más clases. En el caso multiclase, el objetivo general se mantiene: encontrar un conjunto de direcciones discriminantes que maximicen la separación entre clases y minimicen la dispersión dentro de cada clase. Sin embargo, en lugar de obtener una única dirección de proyección, se busca una matriz de proyección formada por varios vectores discriminantes.

Para ello, se define primero la media global del conjunto de datos, así como los vectores de medias correspondientes a cada clase. Con base en estos centroides, la matriz de dispersión intraclase acumula la variabilidad interna de cada grupo, mientras que la matriz de dispersión interclase acumula la separación ponderada entre cada centroide de clase y la media global del conjunto de datos.

$$\mathbf{m} = \frac{1}{N} \sum_{k=1}^K N_k \mathbf{m}_k, \quad \mathbf{S}_W = \sum_{k=1}^K \mathbf{S}_k, \quad \mathbf{S}_B = \sum_{k=1}^K N_k (\mathbf{m}_k - \mathbf{m})(\mathbf{m}_k - \mathbf{m})^T \quad (2.5)$$

En esta formulación, el criterio de optimización busca maximizar la razón entre la dispersión interclase y la dispersión intraclase en el espacio proyectado. Una forma común de expresar este criterio es mediante la razón entre los determinantes de las matrices de dispersión proyectadas [28].

$$J(\mathbf{W}) = \frac{|\mathbf{W}^T \mathbf{S}_B \mathbf{W}|}{|\mathbf{W}^T \mathbf{S}_W \mathbf{W}|} \quad (2.6)$$

La maximización de este criterio conduce a un problema generalizado de valores propios, en el cual los vectores propios definen las direcciones discriminantes y los valores propios asociados indican la relevancia discriminante de cada dirección [49].

$$\mathbf{S}_B \mathbf{w}_i = \lambda_i \mathbf{S}_W \mathbf{w}_i \quad (2.7)$$

Los vectores propios asociados a los valores propios más grandes se seleccionan para formar la matriz de proyección final. En este sentido, cada valor propio puede interpretarse como una medida de la separabilidad capturada por su dirección discriminante correspondiente.

Por ello, LDA no maximiza “los ejes” en sí mismos, sino un criterio de separabilidad cuya solución produce los ejes discriminantes del nuevo espacio.

Un aspecto importante de la formulación multiclase es que el número máximo de dimensiones discriminantes que pueden extraerse está limitado por el número de clases. En particular, si existen (C) clases, el número máximo de direcciones discriminantes útiles es ($C - 1$) [23]. Esto se debe a que la matriz de dispersión interclase tiene un rango máximo determinado por la cantidad de centroides de clase disponibles. Por tanto, LDA no solo reduce la dimensionalidad, sino que también impone una estructura supervisada al espacio reducido [10].

2.2.3. Supuestos, limitaciones y comparación con QDA

La formulación clásica de LDA descansa sobre varios supuestos que condicionan su comportamiento. Desde el punto de vista probabilístico, el método asume que las clases pueden modelarse mediante distribuciones normales multivariantes con una matriz de covarianza común. Esta hipótesis conduce a fronteras de decisión lineales. Desde el punto de vista geométrico, LDA asume que una proyección lineal es suficiente para separar adecuadamente las clases en el espacio transformado.

Estas condiciones explican algunas de sus principales limitaciones. Cuando las clases presentan fronteras de decisión no lineales, distribuciones multimodales o patrones de separación complejos, una frontera lineal puede resultar insuficiente. En tales casos, la proyección obtenida por LDA puede no reflejar adecuadamente la separabilidad real de los datos, lo que limita su desempeño como clasificador o como técnica de reducción de dimensionalidad supervisada [53].

Otra limitación importante se relaciona con la necesidad de invertir o resolver sistemas asociados a la matriz de dispersión intraclase. Cuando el número de variables es comparable o superior al número de observaciones, la matriz de dispersión intraclase puede volverse singular o mal condicionada. Este escenario, conocido como problema de muestras pequeñas (Small Sample Size problem), impide aplicar directamente la formulación clásica de LDA y puede producir inestabilidad numérica en la obtención de los vectores discriminantes [29].

Una alternativa clásica frente a la rigidez lineal de LDA es el Análisis Discriminante Cuadrático (QDA). A diferencia de LDA, que estima una matriz de covarianza común para todas las clases, QDA estima una matriz de covarianza distinta para cada clase. Esta diferencia permite construir fronteras de decisión cuadráticas, lo que puede resultar útil cuando las clases presentan

estructuras de dispersión diferentes. Sin embargo, QDA debe entenderse principalmente como un clasificador probabilístico y no como un método de proyección supervisada de baja dimensión. Además, al requerir la estimación de una matriz de covarianza por clase, puede ser más sensible que LDA en escenarios de alta dimensionalidad y tamaño muestral reducido [23].

$$\delta_k(x) = -\frac{1}{2} \ln |\Sigma_k| - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) + \ln \pi_k \quad (2.8)$$

En consecuencia, aunque QDA ofrece mayor flexibilidad para modelar fronteras de decisión no lineales, no resuelve por sí mismo el problema de reducción de dimensionalidad supervisada ni elimina las dificultades asociadas a la estimación de matrices de covarianza en escenarios ($p > n$). Por ello, su inclusión resulta pertinente como método comparativo, pero no sustituye la necesidad de estrategias orientadas a estabilizar o reformular la proyección discriminante.

2.2.4. Implementación computacional y tratamiento de la singularidad

La formulación algebraica clásica de LDA suele expresarse a partir de la inversión de la matriz de dispersión intraclase ($\mathbf{S}_W$) o, de forma equivalente, mediante un problema generalizado de valores propios. Esta formulación resulta problemática cuando ($\mathbf{S}_W$) es singular o está mal condicionada, situación frecuente en escenarios de alta dimensionalidad, presencia de multicolinealidad o tamaño muestral reducido. En estos casos, el cálculo directo de ($\mathbf{S}_W^{-1}$) puede ser numéricamente inestable o incluso inviable [27].

En la práctica, algunas implementaciones computacionales de LDA reformulan el problema para evitar la inversión explícita de la matriz de dispersión intraclase.

Este es el caso de la función `lda` del paquete MASS en R, cuya implementación construye una transformación de escala que lleva las observaciones hacia funciones discriminantes normalizadas de manera que la covarianza intragrupo sea esférica.

Esta operación puede interpretarse como una forma de blanqueamiento del espacio, ya que busca remover la estructura de correlación interna de las clases antes de estimar las direcciones discriminantes [81].

Matemáticamente, el proceso de blanqueamiento o esferización busca encontrar una matriz de transformación $\mathbf{W}$ tal que, al proyectar el espacio original, la nueva matriz de dispersión intraclase se convierta en la matriz identidad:

$$\mathbf{W}^T \mathbf{S}_W \mathbf{W} = \mathbf{I} \quad (2.9)$$

Mediante la descomposición espectral se tiene que

$$\mathbf{S}_W = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^T, \quad (2.10)$$

donde $\mathbf{U}$ es la matriz ortogonal de vectores propios y $\mathbf{\Lambda}$ es la matriz diagonal de valores propios asociados. La matriz transformadora se define entonces como $\mathbf{W} = \mathbf{U} \mathbf{\Lambda}^{-1/2}$.

Al proyectar los datos originales empleando $\mathbf{W}$, la varianza interna de los grupos se vuelve uniforme en todas las direcciones (esférica), reduciendo la estructura de correlación original y estabilizando los cálculos posteriores.

Cuando $\mathbf{S}_W$ es singular, esta transformación debe entenderse sobre el subespacio asociado a valores propios positivos o mediante una versión truncada/pseudoinversa, ya que los valores propios nulos no pueden invertirse.

La implementación utiliza descomposición en valores singulares (SVD) para identificar las direcciones discriminantes relevantes. En lugar de depender de la inversión directa de ($\mathbf{S}_W$), la SVD permite trabajar con el rango efectivo de la matriz y descartar direcciones asociadas con

varianza nula o numéricamente despreciable. De esta forma, cuando existen variables colineales o combinaciones lineales con varianza muy baja, el algoritmo puede detectarlas mediante un umbral de tolerancia y restringir el cálculo a las dimensiones que conservan información discriminativa suficiente.

Formalmente, la Descomposición en Valores Singulares factoriza una matriz de datos $\mathbf{X}$ (previamente centrada y blanqueada) de la forma $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$, donde $\mathbf{\Sigma}$ es una matriz diagonal que contiene los valores singulares σ_i .

El rango efectivo de la matriz se determina mediante el análisis de estos valores singulares, descartando aquellos que caen por debajo de un umbral de tolerancia τ cercano a cero ($\sigma_i < \tau$). Al truncar la descomposición y conservar únicamente las dimensiones con varianza significativa, el algoritmo evita la división por cero o la inestabilidad numérica que provocarían las dimensiones colineales al calcular las proyecciones discriminantes finales [31].

Esta estrategia no elimina por completo el problema Small Sample Size, ya que la disponibilidad de direcciones discriminantes sigue dependiendo de la información contenida en los datos y del rango efectivo de las matrices involucradas. Sin embargo, puede obtener una proyección en muchos escenarios donde la formulación clásica sería inestable, siempre que exista rango efectivo suficiente [42].

En el contexto de esta investigación, esta consideración es relevante porque la expansión polinomial incrementa el número de variables y puede introducir dependencias lineales o casi lineales entre términos originales, términos cuadrados e interacciones [54].

Por ello, utilizar una implementación de LDA basada en blanqueamiento, control de singularidad y SVD permite emplear el discriminante lineal como motor de evaluación dentro de un esquema wrapper, siempre que previamente se controle la dimensionalidad mediante selección evolutiva. Así, la estabilidad computacional de LDA no se asume como una solución aislada al problema SSS, sino como un componente operativo que se beneficia de la reducción previa del espacio de características.

2.3. Problema de muestras pequeñas (Small Sample Size)

El de muestras pequeñas o Small Sample Size (SSS) aparece en escenarios donde el número de variables descriptivas es elevado en relación con el número de observaciones disponibles. En términos generales, esta situación suele expresarse como ($p > n$), donde (p) representa la dimensión del espacio de características y (n) el número de muestras. Este escenario es frecuente en dominios de alta dimensionalidad, como bioinformática, análisis de señales, reconocimiento de patrones y problemas donde se generan nuevas variables mediante transformaciones del espacio original [68][78].

En métodos basados en la estimación de matrices de covarianza o dispersión, el problema SSS se manifiesta matemáticamente como una deficiencia de rango. En el caso del Análisis Discriminante Lineal (LDA), la matriz de dispersión intraclase ($\mathbf{S}_W$) tiene dimensión ($p \times p$), pero su rango máximo está limitado por la cantidad de observaciones disponibles y por el número de clases. En particular, para (C) clases, se cumple que:

$$\text{rank}(\mathbf{S}_W) \leq n - C \quad (2.11)$$

Por tanto, bajo la condición de singularidad donde $p > n - C$, la matriz $\mathbf{S}_W$ no puede alcanzar un rango completo. Esta deficiencia la vuelve singular (no invertible), lo que impide aplicar directamente la formulación clásica que requiere el cálculo algebraico de $\mathbf{S}_W^{-1}$.

La consecuencia práctica de este problema es que la estimación de las direcciones discriminantes puede volverse numéricamente inestable o no estar definida bajo la formulación algebraica clásica. En LDA, esto afecta la resolución del problema generalizado de valores propios y limita la obtención de proyecciones discriminantes estables [29] [49]. Aunque existen estrategias computacionales para reducir la dependencia de la inversión directa de $\mathbf{S}_W$, como el uso de la Descomposición en Valores Singulares (SVD), el blanqueamiento o la regularización, estas alternativas no eliminan por completo la dificultad intrínseca de trabajar con un espacio de variables que supera a la información disponible.

2.4. Expansión polinomial y espacios de características

Ante las limitaciones geométricas del LDA descritas en la sección anterior, resulta pertinente transformar el espacio de representación de los datos. Esta investigación adopta el enfoque de Expansión de Funciones Base (Basis Function Expansion), una técnica ampliamente utilizada en el aprendizaje automático que permite extender la capacidad de los modelos lineales para representar relaciones no lineales [12].

2.4.1. Formalización de la expansión polinomial

El procedimiento consiste en mapear el vector de entrada original $\mathbf{x} \in \mathbb{R}^d$ a un espacio de características de mayor dimensión $\mathcal{F} \in \mathbb{R}^D$ mediante una función no lineal $\phi(x)$.

Específicamente, se implementa una expansión polinomial de segundo orden (cuadrática), tal como se detalla en la literatura especializada [39] [62].

Para un caso base bidimensional donde el vector de entrada es $x = [x_1, x_2]^T$, la función de mapeo $\phi(x)$ construye un nuevo vector que incluye el sesgo, los términos originales, los términos cuadráticos y las interacciones cruzadas:

$$\phi(x) = [1, x_1, x_2, x_1^2, x_2^2, x_1x_2]^T \quad (2.12)$$

Para efectos prácticos de su uso en este trabajo, se omitirá el sesgo debido a que no aporta en el modelado de las fronteras no lineales.

Grado = 1

$$\{ \underbrace{A, B}_{\text{Grado 1}} \}$$

Grado = 2

$$\{ \underbrace{A, B}_{\text{Grado 1}}, \underbrace{A^2, AB, B^2}_{\text{Grado 2}} \}$$

Grado = 3

$$\{ \underbrace{A, B}_{\text{Grado 1}}, \underbrace{A^2, AB, B^2}_{\text{Grado 2}}, \underbrace{A^3, A^2B, AB^2, B^3}_{\text{Grado 3}} \}$$

Grado = 4

$$\{ \underbrace{A, B}_{G1}, \underbrace{A^2, AB, B^2}_{G2}, \underbrace{A^3, A^2B, AB^2, B^3}_{G3}, \underbrace{A^4, A^3B, A^2B^2, AB^3, B^4}_{\text{Grado 4}} \}$$

Figura 2.2: Ejemplo de términos generados mediante expansión polinomial para dos variables. Elaboración propia.

Como se ilustra en la Figura 2.2, cada componente cumple un rol discriminante específico:

- Términos Lineales (A, B): preservan la información original.
- - Términos Cuadráticos (A^2, B^2): permiten incorporar curvatura en la representación y contribuyen a modelar fronteras de decisión no lineales.
- - Términos de Interacción (AB): representan efectos multiplicativos entre variables, permitiendo modelar relaciones que no pueden describirse mediante términos lineales independientes [39].

La justificación teórica para realizar esta expansión se fundamenta en el Teorema de Cover, el cual postula que un problema de clasificación complejo y no lineal en un espacio de baja dimensión puede aumentar la probabilidad de separabilidad lineal bajo una transformación no lineal hacia un espacio de mayor dimensión [20].

2.4.2. Limitaciones: Crecimiento Combinatorio y Complejidad

Si bien la expansión polinomial permite representar relaciones no lineales, introduce un desafío crítico conocido como la Maldición de la Dimensionalidad. A medida que aumenta la dimensión original d o el grado del polinomio P , el número de términos generados D crece de forma combinatoria.

Para una expansión polinomial de grado P , la dimensión del espacio resultante D está dada por la combinatoria con repetición:

$$D = \binom{d+P}{P} - 1 \quad (2.13)$$

Tal como se observa en la Figura 2.3, este crecimiento es explosivo. Por ejemplo, expandir un vector modesto de $d = 10$ variables a un grado cuadrático ($P = 2$) genera 65 términos sin incluir el sesgo.




Figura 2.3: Crecimiento del número de atributos bajo una expansión polinomial de grado 2 sin término de sesgo. Fuente: Elaboración propia.

Este fenómeno conlleva dos consecuencias considerables descritas por [12]:

- **Costo Computacional:** El cálculo de la matriz de covarianza inversa S_W^{-1} requerida por el LDA se vuelve computacionalmente costoso ($O(D^3)$).
- **Sobreajuste (Overfitting):** Al tener un exceso de parámetros frente a un número limitado de muestras, el modelo tiende a memorizar el ruido de los datos en lugar de aprender la estructura subyacente.

En el contexto de LDA, este crecimiento dimensional es especialmente relevante porque la matriz de dispersión intraclase pasa a definirse sobre el espacio expandido, por lo que su dimensión depende de (D) y no solo de la dimensión original (d) . En consecuencia, si $(D > n - C)$, la matriz (S_W) no puede alcanzar rango completo, reproduciendo o agravando el problema SSS descrito en la sección anterior. Por esta razón, la expansión polinomial debe acompañarse de mecanismos de selección de características que permitan conservar únicamente los términos con mayor aporte discriminativo y reducir el riesgo de singularidad, colinealidad y sobreajuste.

2.5. Algoritmos genéticos

Los algoritmos genéticos constituyen una familia de métodos de búsqueda y optimización inspirados en mecanismos evolutivos como selección, recombinación y mutación. En términos generales, estos algoritmos trabajan con una población de soluciones candidatas que se modifican iterativamente con el propósito de mejorar una función objetivo o función de aptitud [30].

Su utilidad en problemas de selección de características radica en que permiten explorar espacios combinatorios amplios sin evaluar exhaustivamente todos los subconjuntos posibles de variables. En el contexto de esta investigación, los algoritmos genéticos resultan especialmente pertinentes debido al crecimiento dimensional producido por la expansión polinomial. Una vez generados términos originales, términos cuadráticos e interacciones, el número de predictores puede crecer de manera acelerada, lo que aumenta el riesgo de singularidad, colinealidad y sobreajuste. Por ello, se requiere un mecanismo de selección capaz de identificar subconjuntos informativos dentro del espacio expandido. Desde esta perspectiva, el algoritmo genético opera como una estrategia de búsqueda dentro de un esquema wrapper, ya que la calidad de cada subconjunto se evalúa mediante el desempeño de un modelo discriminante [41].

2.5.1. Representación cromosómica y función de aptitud

En selección de características, una solución candidata puede representarse mediante un cromosoma binario. Cada posición del cromosoma corresponde a una característica del espacio disponible, y su valor indica si dicha característica se incluye o se excluye del subconjunto evaluado. Matemáticamente, el cromosoma se define como un vector binario $z = [z_1, z_2, \dots, z_D]$, donde cada gen $z_j \in \{1, 0\}$ y D representa la dimensión total del espacio de características.

A modo de ejemplo, un cromosoma de cinco dimensiones estructurado como $z = [1, 0, 1, 0, 1]$ codifica un subconjunto que retiene exclusivamente las características $\{x_1, x_3, x_5\}$, descartando el resto.

En el caso de una expansión polinomial, cada gen puede representar una variable original, un término cuadrático o una interacción entre variables. Por ejemplo, si el espacio expandido contiene términos como x_1, x_2, x_1^2, x_2^2 y $x_1 x_2$, el cromosoma determina cuáles de estos términos serán conservados para entrenar el modelo discriminante. Esta representación permite que el

algoritmo genético explore combinaciones de términos que podrían no ser evidentes mediante criterios univariados de selección.

La función de aptitud define el criterio mediante el cual se evalúa la calidad de cada cromosoma. En un esquema wrapper, esta función suele depender del desempeño del clasificador acoplado al subconjunto seleccionado. Para evitar soluciones excesivamente grandes y penalizar la complejidad del modelo, la función de aptitud puede formalmente como [75]:

$$fitness^z = \text{Desempeño}^{(z)} - \lambda \frac{|z|_0}{D} \quad (2.14)$$

En esta expresión, $\text{Desempeño}^{(z)}$ representa una métrica de clasificación (como la Exactitud o el $F1 - Score$) obtenida con el subconjunto activo, $|z|_0$ denota la norma ℓ_0 que contabiliza el número de características seleccionadas (genes con valor 1), D es la dimensión máxima del espacio expandido y λ es un hiperparámetro que controla la magnitud de la penalización por complejidad.

De esta manera, el algoritmo busca optimizar un criterio combinado que maximice la capacidad predictiva y reducir la dimensionalidad efectiva del subconjunto evaluado.

2.5.2. Ciclo evolutivo y operadores genéticos

El proceso evolutivo sigue un ciclo iterativo estructurado, el cual se ilustra en el diagrama de flujo de la figura 2.4. El ciclo comienza con la inicialización de una población de cromosomas, generada comúnmente de forma aleatoria para asegurar una exploración inicial diversa. En cada generación, los cromosomas son sometidos a una fase de evaluación mediante la función de aptitud y, posteriormente, se aplican los operadores genéticos (selección, cruce y mutación) para producir nuevas soluciones candidatas que conformarán la siguiente generación [30].




Figura 2.4: Diagrama de flujo del ciclo evolutivo de un algoritmo genético. Tomada de [73].

El operador de selección favorece la reproducción de los cromosomas con mayor aptitud. Su propósito es incrementar la probabilidad de que las soluciones más prometedoras transmitan su información genética a la siguiente iteración. Existen diferentes estrategias algorítmicas, como el torneo, la ruleta o el elitismo; sin embargo, todas comparten el objetivo guiar la búsqueda hacia regiones del espacio con mejores propiedades discriminativas.

La cruce o recombinación combina segmentos de dos cromosomas padres para generar descendencia. En la selección de características, este operador permite entrelazar subconjuntos parciales de variables provenientes de soluciones distintas, promoviendo la combinación de términos polinomiales. Un ejemplo de cruce de un punto, asumiendo un punto de corte en la tercera posición, se ilustra de la siguiente forma:

- Padre 1: $z_{P1} = [1, 0, 1|0, 1]$
- Padre 2: $z_{P2} = [0, 1, 0|1, 0]$
- Hijo resultante: $z_H = [1, 0, 1|1, 0]$

La mutación introduce alteraciones estocásticas en genes individuales, invirtiendo sus valores lógicos (de 0 a 1, o viceversa). Este operador es importante para preservar la diversidad dentro de la población y evadir la convergencia prematura en óptimos locales.

Un ejemplo de mutación uniforme sobre el tercer gen de un cromosoma se representa como:

- Cromosoma original: $z = [1, 0, \mathbf{1}, 0, 1]$
- Cromosoma mutado: $z' = [1, 0, \mathbf{0}, 0, 1]$

En conjunto, estos operadores permiten navegar de forma iterativa el vasto espacio de combinaciones posibles. El algoritmo concluye su ejecución al alcanzar un límite de generaciones, al agotar un presupuesto computacional o cuando el cambio en la aptitud intergeneracional cae por debajo de un umbral predefinido.

2.5.3. Algoritmos genéticos como estrategia wrapper

La aplicación de algoritmos genéticos a la selección de características puede entenderse como una estrategia wrapper, dado que cada subconjunto candidato se evalúa a partir del desempeño del modelo de aprendizaje final. A diferencia de los métodos de tipo filtro, los enfoques wrapper incorporan la retroalimentación directa del clasificador y permiten considerar la interacción entre las características seleccionadas y el comportamiento del modelo [41] [32]. Esta propiedad resulta especialmente relevante cuando los predictores incluyen términos polinomiales, ya que la utilidad de una interacción (x_i, x_j) puede depender de su combinación con otros términos del espacio expandido.

En la arquitectura propuesta para esta investigación, el algoritmo genético actúa como mecanismo de exploración sobre el espacio formado por variables originales y términos polinomiales. El objetivo principal no es someter el espacio expandido completo al análisis discriminante, sino identificar un subconjunto que conserve capacidad de separación interclase y reduzca la dimensionalidad efectiva del problema. De esta forma, la búsqueda evolutiva contribuye a mitigar los efectos del crecimiento combinatorio y del problema Small Sample Size. La pertinencia de acoplar un algoritmo genético con LDA radica en que la selección previa de características puede mejorar la estabilidad algebraica del modelo discriminante. Si el espacio polinomial completo se utiliza sin reducción, la matriz de dispersión intraclase puede volverse singular o mal condicionada. En contraste, la reducción previa mediante la metaheurística puede favorecer una representación más compacta y manejable para la estimación discriminante. Por lo tanto, el algoritmo genético no actúa como sustituto del análisis discriminante, sino como un mecanismo previo de selección y reducción que facilita su aplicación sobre un espacio polinomial controlado.

2.6. Métodos kernel y clasificadores no lineales

Los métodos kernel constituyen una familia de enfoques ampliamente utilizados para extender modelos lineales hacia escenarios no lineales. Su idea central consiste en transformar los

datos originales hacia un espacio de características de mayor dimensión, donde relaciones que no son linealmente separables en el espacio original pueden representarse mediante fronteras lineales en el espacio transformado. Esta lógica se relaciona con la motivación subyacente de la expansión polinomial: aumentar la capacidad de representación del modelo mediante transformaciones del espacio de entrada [72].

2.6.1. Truco Kernel y funciones kernel

Sea $x \in \mathbb{R}^p$ un vector de entrada. Un método kernel asume la existencia de una función de mapeo $\phi(x)$, que proyecta las observaciones desde el espacio original hacia un espacio de características posiblemente de alta o incluso infinita dimensión. En principio, el producto interno en dicho espacio transformado se define como:

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j) \quad (2.15)$$

La ventaja computacional fundamental de los métodos kernel consiste en que no es necesario calcular explícitamente las coordenadas proyectadas $\phi(x)$. En su lugar, se define una función kernel $K(x_i, x_j)$ que evalúa directamente el producto interno entre dos observaciones en el espacio transformado. Este procedimiento algorítmico se conoce como el kernel trick y permite trabajar con espacios de características de alta dimensionalidad sin incurrir en el costo de construirlos de forma explícita [12].

Entre las funciones kernel más estandarizadas en la literatura se encuentran el kernel lineal, el kernel polinomial y el kernel de función de base radial (RBF). El kernel lineal equivale al producto interno ordinario, mientras que el kernel polinomial permite incorporar interacciones de orden superior de forma implícita. Por su parte, el kernel RBF mide la similitud local entre observaciones e induce fronteras de decisión altamente flexibles.

Matemáticamente, se expresan de la siguiente manera:

Kernel lineal:

$$K(\mathbf{x}, \mathbf{z}) = \mathbf{x}^T \mathbf{z} \quad (2.16)$$

Kernel polinomial:

$$K(\mathbf{x}, \mathbf{z}) = (\gamma \mathbf{x}^T \mathbf{z} + c)^r \quad (2.17)$$

Kernel RBF:

$$K(\mathbf{x}, \mathbf{z}) = \exp(-\gamma \|\mathbf{x} - \mathbf{z}\|^2) \quad (2.18)$$

En el contexto de esta tesis, el kernel polinomial resulta particularmente relevante por su vinculación teórica con la expansión polinomial explícita. La diferencia principal radica en que, mientras la expansión polinomial construye explícitamente los términos cuadráticos y las interacciones cruzadas, el kernel polinomial opera sobre un espacio expandido de forma implícita. Esta distinción es crítica porque el enfoque propuesto en esta investigación busca conservar una relación directa rastreable con los términos generados, favoreciendo la trazabilidad analítica de las variables seleccionadas.

2.6.2. KFDA y SVM como enfoques no lineales de referencia

El Análisis Discriminante de Fisher con Kernel (KFDA) se concibe como una extensión no lineal del criterio de Fisher clásico. Mientras que LDA busca direcciones discriminantes en el espacio original mediante combinaciones lineales, KFDA traslada el problema de optimización al espacio de características inducido por el kernel. En dicho espacio, el objetivo se mantiene:

maximizar la separación interclase y minimizar la dispersión intraclase; no obstante, la solución algebraica se reformula en términos de productos kernel y matrices de Gram [53].

Una diferencia relevante entre KFDA y otros clasificadores kernel radica en su relación con la reducción de dimensionalidad supervisada. Al heredar la lógica del criterio de Fisher, KFDA puede formularse como un método orientado a obtener ejes o proyecciones discriminantes en el espacio de características inducido por el kernel. En este sentido, mantiene una relación conceptual más cercana con LDA, aunque opera mediante una formulación dual basada en productos kernel. Por el contrario, aunque SVM también puede utilizar funciones kernel para inducir fronteras no lineales, su objetivo principal no es construir una proyección discriminante de baja dimensión, sino estimar una frontera de decisión con margen máximo para clasificar nuevas observaciones.

De manera análoga, las Máquinas de Vectores de Soporte (SVM) emplean el kernel trick para construir fronteras de decisión no lineales. En su formulación clásica, SVM busca un hiperplano de separación que maximice el margen geométrico entre las clases, apoyándose en las observaciones más relevantes, denominadas vectores de soporte [19]. Al integrar funciones kernel, la función de decisión para una nueva observación x se formula de la siguiente manera general:

$$f(x) = \sum_{i=1}^n \alpha_i y_i K(x_i, x) + b \quad (2.19)$$

Para el marco experimental de esta investigación, SVM con kernel polinomial y SVM con kernel RBF se consideran los clasificadores no lineales de referencia. Ambos enfoques, sin embargo, presentan una alta sensibilidad a la parametrización, dependiendo de la correcta sintonización de hiperparámetros estructurales como el grado del polinomio r , el coeficiente γ , o la constante de regularización (C) [17].

2.6.3. Ventajas, limitaciones e interpretabilidad

Los métodos kernel presentan una ventaja importante: permiten introducir capacidad de modelado no lineal sin construir explícitamente todas las variables transformadas. En lugar de generar de manera directa los términos del espacio de características, estos métodos operan mediante productos internos definidos por una función kernel. Esta propiedad reduce la necesidad de manipular explícitamente espacios expandidos de alta dimensión y permite modelar fronteras de decisión no lineales estructuras de separación complejas en el espacio original.

No obstante, esta formulación también introduce limitaciones. Al permanecer el espacio transformado de forma implícita, la interpretación directa de las variables originales y de sus interacciones puede volverse menos transparente. En consecuencia, aunque el modelo puede alcanzar buen desempeño predictivo, puede ser más difícil identificar qué variables o combinaciones de variables explican la separación entre clases. Además, el desempeño de los métodos kernel depende de la elección de la función kernel y de la adecuada sintonización de sus hiperparámetros, lo cual puede afectar la capacidad de generalización, especialmente en escenarios de tamaño muestral reducido [17] [70]. En contraste, la expansión polinomial explícita permite observar directamente los términos generados, como variables originales, términos cuadrados e interacciones.

Esta característica favorece la trazabilidad de la representación transformada y permite identificar qué términos son conservados después del proceso de selección. Sin embargo, dicha ventaja tiene como costo el crecimiento combinatorio del número de características. Por ello, la

arquitectura propuesta en esta investigación combina expansión polinomial explícita con selección evolutiva, buscando conservar términos informativos y controlar la dimensionalidad antes de aplicar el análisis discriminante.

En síntesis, los métodos kernel y las SVM proporcionan un marco de referencia relevante para el modelado no lineal. Su inclusión en este Marco Teórico permite contrastar dos estrategias distintas: la no linealidad implícita inducida por funciones kernel y la no linealidad explícita mediante expansión polinomial y selección de características. Esta diferencia resulta central para ubicar la propuesta de esta tesis frente a enfoques kernel tradicionales.

Capítulo 3

Estado del arte

3.1. Variantes lineales del análisis discriminante

3.1.1. Regularized LDA

Históricamente, el Análisis Discriminante Lineal (LDA) ha sido una metodología central para la reducción de dimensionalidad supervisada a partir de la cual se pueden obtener representaciones visualizables y la clasificación lineal. No obstante, su formulación clásica presenta limitaciones importantes en escenarios de alta dimensionalidad y tamaño muestral reducido. En particular, cuando el número de variables es comparable o superior al número de observaciones, la matriz de dispersión intraclass puede volverse singular o estar mal condicionada, lo que dificulta resolver directamente el problema generalizado asociado al criterio de Fisher [85].

Para mitigar esta dificultad, las variantes regularizadas de LDA incorporan términos de penalización sobre la matriz de dispersión, con el objetivo de mejorar su estabilidad numérica. En términos generales, estas estrategias modifican la estimación de la matriz de covarianza o añaden un término de regularización que favorece la inversión del sistema y reduce la sensibilidad del modelo ante fluctuaciones derivadas de muestras pequeñas. En este sentido, la regularización no elimina por completo los riesgos asociados al problema de muestras pequeñas (SSS), pero constituye una alternativa práctica para mejorar la estabilidad del discriminante lineal en contextos de alta dimensionalidad que preserva las bondades de LDA [7].

Además, propuestas recientes como la de Mahadi y colaboradores [47] ofrecen una alternativa para mitigar el problema de muestras pequeñas y mejorar el rendimiento de clasificación de LDA mediante su enfoque denominado Análisis Discriminante Lineal Regularizado No Lineal (NL-RLDA). En este caso, lo “no lineal” hace referencia al estimador de la matriz inversa de covarianzas, diseñado para reducir la influencia de valores pequeños y resolver con mayor estabilidad el problema de valores propios generalizado. Este ajuste permite enfrentar escenarios de alta dimensionalidad y covarianzas mal condicionadas, logrando una mayor efectividad como clasificador. Sin embargo, es importante puntualizar que, pese a la incorporación de un estimador no lineal, la formulación del método sigue buscando un discriminante lineal sobre las características consideradas, manteniendo la naturaleza lineal de la representación.

Estas estrategias pueden mejorar la estabilidad numérica del procedimiento discriminante, pero no modifican la naturaleza lineal de la representación obtenida.

3.1.2. LDA en dos etapas

Una estrategia alternativa frente a la singularidad en espacios de alta dimensionalidad consiste en utilizar esquemas de reducción de dimensionalidad en dos etapas. En la arquitectura comúnmente denominada PCA-LDA, primero se aplica Análisis de Componentes Principales para proyectar los datos hacia un subespacio de menor dimensión. Esta etapa permite comprimir la información de las variables originales en unas pocas componentes principales que mejoran el condicionamiento de la matriz de dispersión al trabajar con LDA [3].

Posteriormente, LDA incorpora la información de clase para buscar una proyección que favorezca la separabilidad entre grupos dentro del subespacio retenido. Esta aproximación ha sido empleada en diversos problemas aplicados debido a su simplicidad y viabilidad computacional. Sin embargo, debe considerarse que PCA es un método no supervisado, por lo que puede descartar componentes de baja varianza que podrían contener información discriminativa relevante. En consecuencia, PCA-LDA puede ser útil en contextos donde se cuenta con más variables que observaciones ($p > n$), pero la reducción inicial está guiada por varianza global y no por discriminación entre clases. Además, aunque la relación con las variables originales se conserva a través de la transformación realizada por PCA, esta resulta más indirecta debido a la etapa intermedia de extracción de componentes [16].

3.1.3. Variantes lineales relevantes

Además de la regularización directa y de los esquemas en dos etapas, se han propuesto variantes lineales orientadas a mejorar la estabilidad, la interpretabilidad y la selección de variables en escenarios de alta dimensionalidad. Una línea relevante corresponde a las formulaciones basadas en el problema Trace-Ratio, que buscan optimizar de forma más directa la relación entre dispersión interclase e intraclase. En particular, las formulaciones recientes de Trace-Ratio LDA han sido estudiadas como alternativas para enfrentar el problema de muestras pequeñas (SSS), al reformular el criterio discriminante de manera más adecuada para matrices de dispersión deficientes en rango [44, 74].

También se cuenta con el enfoque Análisis Discriminante Lineal Disperso (Sparse LDA) que incorporan mecanismos de penalización o selección que promueven soluciones con un número reducido de variables activas. Esta propiedad resulta especialmente relevante cuando, además de clasificar correctamente, se requiere identificar predictores interpretables [45].

En esta misma línea, los enfoques de Inteligencia Artificial Explicable basados en SHAP han sido explorados como mecanismos de apoyo para la selección de variables en escenarios de alta dimensionalidad con pocas muestras. IterSHAP, por ejemplo, utiliza valores de Shapley de manera iterativa para estimar la importancia relativa de las características y descartar aquellas menos informativas, lo que permite mejorar el rendimiento de clasificación en comparación con filtros clásicos o métodos de eliminación recursiva [55]. Sin embargo, es importante subrayar que SHAP actúa como un criterio de priorización y no sustituye la formulación discriminante del modelo, su papel consiste en cuantificar la contribución de cada variable al resultado de un clasificador, mientras que la capacidad de separación entre clases depende del modelo subyacente. De este modo, SHAP aporta información sobre la importancia de las características y puede utilizarse como apoyo para su selección, pero no constituye por sí mismo un método discriminante ni un mecanismo de proyección en baja dimensión.

3.2. Métodos kernel

3.2.1. Análisis de Componentes Principales con Kernel (KPCA)

Las proyecciones lineales pueden resultar insuficientes para capturar distribuciones de datos subyacentes complejas, lo que justifica la adopción de enfoques basados en mapeos no lineales. El Análisis de Componentes Principales con Kernel (KPCA) permite relajar la restricción de linealidad al mapear las características originales hacia un espacio de Hilbert de alta dimensionalidad, donde es posible extraer componentes principales no lineales de forma no supervisada [51].

En escenarios de alta dimensionalidad, esta transformación puede facilitar la obtención de representaciones no lineales de menor dimensión; sin embargo, al operar mediante un mapeo implícito introduce la desventaja de que la relación directa entre componentes obtenidas y las variables originales no es tan transparente como en una transformación explícita. En consecuencia, se dificulta rastrear la influencia individual de cada variable en la representación reducida [14].

3.2.2. Análisis Discriminante de Fisher mediante Kernel (KFDA)

Aunque la reducción de dimensionalidad no supervisada es útil, los escenarios de clasificación exigen estrategias que prioricen la discriminación entre clases. El Análisis Discriminante de Fisher mediante Kernel (KFDA) aprovecha mapeos no lineales inducidos por funciones kernel para transformar problemas fuertemente no separables en hiperespacios donde las clases pueden delimitarse analíticamente [22]. En este sentido, KFDA demuestra que es posible combinar el manejo de la no linealidad y la proyección discriminante, pero lo hace mediante un espacio de características inducido implícitamente por el kernel, manteniendo la formulación del discriminante lineal en dicho espacio.

Al trasladar la métrica de Fisher al espacio de Hilbert, el algoritmo enfrenta inevitablemente el desafío de la deficiencia de rango en la matriz de covarianza proyectada, un problema crítico cuando la cantidad de sujetos (n) es escasa. Para contrarrestar esta inestabilidad intrínseca, arquitecturas contemporáneas optan por integrar el KFDA dentro de métodos de ensamble y regularización estocástica, lo que promueve una mayor diversidad en los subespacios discriminativos y estabiliza el cálculo del hiperplano sin sacrificar el poder del análisis no lineal [40].

3.2.3. SVM Polinomial

Las Máquinas de Vectores de Soporte (SVM) constituyen una alternativa ampliamente utilizada para problemas de clasificación, especialmente cuando se emplean funciones kernel que permiten modelar fronteras de decisión no lineales. En el caso del kernel polinomial, la transformación inducida permite capturar interacciones entre variables sin calcular explícitamente todas las combinaciones en el espacio expandido ([72]).

A diferencia de LDA y KFDA, cuyo procedimiento produce una representación discriminante, SVM está orientado principalmente a construir una función de decisión para clasificación, es decir, generar una proyección discriminante de baja dimensión no constituye el objetivo principal de SVM.

No obstante, su aplicación en escenarios de alta dimensionalidad ($p > n$) requiere una selección cuidadosa de hiperparámetros. Un grado polinomial elevado puede producir fronteras de decisión excesivamente complejas y aumentar el riesgo de sobreajuste, especialmente cuando el número de observaciones es reducido. Por ello, la selección del grado del polinomio y de los

parámetros asociados al kernel resulta determinante para equilibrar flexibilidad y capacidad de generalización [37].

3.2.4. SVM RBF

A diferencia del kernel polinomial, cuyo grado controla explícitamente la complejidad de las interacciones modeladas, el kernel de Función de Base Radial (RBF) permite inducir fronteras de decisión altamente no lineales mediante una medida de similitud local entre observaciones. Esta flexibilidad lo convierte en una alternativa atractiva para problemas donde las clases no son linealmente separables. Sin embargo, en escenarios SSS también puede incrementar el riesgo de sobreajuste si los hiperparámetros no se ajustan adecuadamente [69].

En particular, el parámetro de ancho de banda, usualmente expresado mediante (γ) o (σ) , controla el alcance de influencia de cada observación en el espacio inducido por el kernel. Valores inadecuados pueden producir fronteras excesivamente fragmentadas o, por el contrario, modelos demasiado suaves. Por ello, la selección de hiperparámetros resulta crítica para obtener un equilibrio entre flexibilidad y generalización. Asimismo, trabajos recientes han explorado mecanismos de explicación para modelos SVM-RBF mediante patrones de activación, con el propósito de mejorar la interpretabilidad de modelos kernel tradicionalmente difíciles de analizar [87].

3.3. Selección de características basada en algoritmos evolutivos

3.3.1. GA para selección de variables

La maldición de la dimensionalidad dificulta el uso de enfoques exhaustivos de selección deterministas, dado que el volumen de permutaciones crece exponencialmente en función de las variables de entrada. Para navegar este vasto espacio de búsqueda sin incurrir en costos computacionales prohibitivos, los Algoritmos Genéticos (GA) han sido ampliamente empleados como estrategias de búsqueda estocástica. En lugar de evaluar características de forma aislada, un GA codifica subconjuntos de variables en estructuras cromosómicas, sometiéndolas a un proceso de evolución iterativa mediante selección, cruza y mutación [4]. Una ventaja potencial de este enfoque en el contexto $p > n$ reside en su capacidad para explorar combinaciones de variables sin evaluar exhaustivamente todo el espacio de búsqueda. Investigaciones recientes han sofisticado estas arquitecturas implementando mecanismos de selección multiobjetivo adaptativos, buscando un equilibrio entre la minimización del número de características retenidas y la maximización del poder predictivo del clasificador final [84].

La integración de algoritmos genéticos con LDA puede entenderse como una estrategia de selección de características orientada a reducir la dimensionalidad antes de estimar el discriminante lineal. En escenarios donde $p > n$, seleccionar un subconjunto de variables puede reducir la dimensión efectiva del problema y, bajo determinadas condiciones, contribuir a disminuir los problemas asociados con la singularidad de la matriz de dispersión intraclase y mejorar la estabilidad del modelo. Bajo enfoques de este tipo, el algoritmo genético explora combinaciones de variables, mientras que LDA puede utilizarse como clasificador o como criterio de evaluación de la calidad discriminativa del subconjunto seleccionado [43].

La literatura reciente muestra aplicaciones de algoritmos genéticos para selección de características en problemas de clasificación; sin embargo, su integración específica con LDA debe

presentarse como una estrategia posible más que como una mejora universal frente a alternativas paramétricas [79, 5].

3.3.2. Métodos híbridos

Los métodos híbridos de selección de características surgen como una alternativa para reducir el costo computacional de las estrategias evolutivas puras en dominios de alta dimensionalidad. En general, estas arquitecturas combinan una etapa inicial de filtrado, basada en criterios estadísticos o medidas de relevancia, con una etapa posterior de búsqueda más fina mediante metaheurísticas. La primera fase permite descartar un número considerable de variables redundantes o poco informativas, mientras que la segunda explora subconjuntos candidatos considerando posibles interacciones entre predictores.

Esta combinación puede favorecer una búsqueda más eficiente y mejorar la estabilidad de la selección en determinados contextos, especialmente cuando el espacio original de variables es muy amplio. Sin embargo, su desempeño depende del criterio de filtrado, de la metaheurística empleada, de la función objetivo y del clasificador final. Por ello, más que garantizar una convergencia acelerada o una estabilidad superior en todos los casos, los métodos híbridos se presentan como una estrategia prometedora cuyo rendimiento requiere validación empírica en cada dominio de aplicación [83] [48].

El resultado principal de estas estrategias es un subconjunto reducido de variables; la visualización o extracción de una representación de baja dimensión requiere un procedimiento adicional.

3.3.3. GPDA

Con el propósito de afrontar las limitaciones que presentan LDA y sus variantes en escenarios de Small Sample Size (SSS), Medina y colaboradores propusieron el Análisis Discriminante Proyectivo Genético (GPDA) [52], una técnica de reducción de dimensionalidad basada en computación evolutiva. A diferencia de los enfoques tradicionales sustentados en el criterio de Fisher y en la estimación de matrices de dispersión, GPDA formula la búsqueda de proyecciones discriminantes como un problema de optimización evolutiva sobre matrices ortonormales. La calidad de cada proyección se evalúa mediante el índice de silueta, permitiendo maximizar directamente la separabilidad entre clases sin recurrir a la inversión o descomposición de la matriz de dispersión intraclase. Esta estrategia permite evitar la inversión directa de matrices de dispersión, mitigando los problemas de singularidad característicos del escenario SSS y proporciona representaciones de baja dimensión con elevada capacidad discriminativa.

No obstante, al formular la proyección directamente sobre el espacio original mediante matrices de proyección, GPDA mantiene una representación lineal y no incorpora una transformación explícita destinada a modelar relaciones polinomiales no lineales.

3.4. Limitaciones identificadas

A partir de la revisión anterior, puede observarse que las metodologías empleadas para abordar la alta dimensionalidad y el problema de muestras pequeñas (SSS) enfrentan compromisos recurrentes entre estabilidad numérica, capacidad discriminativa, interpretabilidad y costo computacional. En los enfoques derivados de LDA, una dificultad central se presenta cuando el número de variables es comparable o superior al número de observaciones ($p > n$), ya que la matriz de dispersión intraclase puede volverse singular o mal condicionada. Para mitigar esta

limitación, la literatura ha propuesto estrategias como regularización, reducción previa de dimensionalidad, selección de características, métodos evolutivos y formulaciones Trace-Ratio orientadas al problema de muestras pequeñas [44].

Los métodos kernel, por su parte, permiten capturar relaciones no lineales mediante mapeos implícitos hacia espacios de mayor dimensionalidad. Esta propiedad resulta útil cuando las clases no son separables linealmente; sin embargo, también dificulta la interpretación directa de la contribución de las variables originales. Aunque trabajos recientes han propuesto mecanismos para explicar modelos kernel, como KPCA o SVM-RBF, la trazabilidad de los predictores continúa siendo menos directa que en modelos basados en transformaciones explícitas [14] [87].

De forma complementaria, los algoritmos evolutivos y los métodos híbridos ofrecen una vía flexible para explorar subconjuntos de variables o matrices de proyección sin depender necesariamente de la inversión directa de matrices de dispersión. No obstante, estas estrategias pueden implicar mayores costos computacionales y requieren definir cuidadosamente la función objetivo, los operadores evolutivos y los criterios de convergencia. En consecuencia, el estado del arte muestra que aún existe espacio para propuestas que combinen la reducción de dimensionalidad, generación de representaciones visualizables de baja dimensión, manejo del problema de las muestras pequeñas (SSS), modelado no lineal explícito y trazabilidad respecto de los predictores originales.

3.5. Posicionamiento de GNLPDA

Frente a estas limitaciones, el Análisis Discriminante Polinomial No Lineal Genético (GNLPDA) se posiciona como una alternativa metodológica orientada a la integración de selección evolutiva, modelado no lineal explícito, proyección discriminante de baja dimensión, trazabilidad de las características utilizadas, bajo escenarios de alta dimensionalidad o problemas de muestras pequeñas (SSS). En este sentido, GNLPDA retoma la lógica evolutiva presente en GPDA, al formular la búsqueda de proyecciones como un problema de optimización [52], pero introduce una expansión polinomial explícita que permite representar interacciones entre variables sin recurrir necesariamente a un mapeo kernel implícito basado en matrices de Gram.

El aporte central de GNLPDA radica en que la no linealidad se incorpora mediante términos polinomiales definidos sobre las variables originales. A diferencia de los métodos kernel, donde el mapeo al espacio de características suele operar de manera implícita, esta formulación permite conservar una relación más directa entre los predictores iniciales, sus interacciones y la proyección discriminativa resultante. Por ello, el método busca equilibrar la capacidad de modelar fronteras de decisión no lineales con una mayor trazabilidad analítica de las características utilizadas.

No obstante, el posicionamiento de GNLPDA debe plantearse de manera prudente: su ventaja no radica en eliminar por completo las dificultades asociadas con la interpretabilidad, el costo computacional o el sobreajuste, sino en proponer una vía explícita para abordarlos dentro de una formulación evolutiva. En consecuencia, su pertinencia debe evaluarse empíricamente frente a métodos lineales, kernel, evolutivos e híbridos, considerando tanto el desempeño discriminativo como la estabilidad, la complejidad computacional y la interpretabilidad del modelo obtenido.

Capítulo 4

Metodología

4.1. Selección evolutiva en dos fases

La arquitectura GNLPDA realiza la búsqueda de características mediante dos fases evolutivas consecutivas. La primera fase opera sobre el espacio de variables originales y tiene como objetivo identificar qué variables conviene expandir mediante la transformación polinomial. La segunda fase opera sobre el espacio polinomial generado a partir del subconjunto seleccionado en la primera etapa, con el propósito de conservar únicamente los términos lineales, cuadráticos o de interacción que aportan al desempeño discriminante.

Ambas fases siguen una lógica *wrapper*: cada cromosoma codifica un subconjunto candidato de características, dicho subconjunto se evalúa mediante LDA y el valor de aptitud se calcula a partir de la exactitud promedio obtenida mediante validación cruzada estratificada de cinco pliegues. Además, ambas etapas emplean la misma configuración general del algoritmo genético, incluyendo tamaño de población, número de generaciones, probabilidad de cruce, probabilidad de mutación y valor de penalización (λ). La diferencia entre ambas fases no radica en los operadores evolutivos utilizados, sino en el espacio sobre el que se realiza la búsqueda.

En el protocolo experimental de esta investigación, la búsqueda evolutiva se realiza únicamente sobre la partición de entrenamiento. Dentro de esta partición, GNLPDA calcula la aptitud de cada cromosoma mediante validación cruzada interna estratificada de cinco pliegues. La partición de prueba permanece separada durante todo el proceso de selección y se utiliza únicamente para la evaluación final del modelo seleccionado. De esta manera, la validación cruzada interna guía la búsqueda evolutiva, mientras que la evaluación sobre la partición de prueba estima la capacidad de generalización del método.

4.1.1. Fase I: selección de variables originales

En la primera fase, el algoritmo genético explora subconjuntos de las variables originales del conjunto de datos. Sea $X_{train} \in \mathbb{R}^{n \times p}$ la matriz de entrenamiento, donde n representa el número de observaciones y p el número de variables originales. Cada solución candidata se representa mediante un cromosoma binario de longitud p :

$$z^{(1)} = [z_1, z_2, \dots, z_p], \quad z_j \in \{0, 1\} \quad (4.1)$$

El valor $z_j = 1$ indica que la variable x_j es seleccionada, mientras que $z_j = 0$ indica que dicha variable es excluida. El número de variables originales activas en el cromosoma se define mediante la norma ℓ_0 :

$$q = |z^1|_0 \quad (4.2)$$

Para evitar soluciones degeneradas, se establece una condición mínima de factibilidad: todo cromosoma debe seleccionar al menos dos variables originales. Si $q < 2$, la solución se considera no válida y recibe automáticamente una aptitud igual a cero. Esta regla evita evaluar subconjuntos insuficientes para construir una expansión polinomial útil o para estimar una proyección discriminante mediante LDA. En cambio, no se impone un límite superior al número de variables activas; la complejidad de las soluciones grandes se controla mediante el término de penalización incluido en la función de aptitud.

A partir del cromosoma $z^{(1)}$, se construye el subconjunto $X_{z^{(1)}}$, formado únicamente por las variables originales activas. Sobre este subconjunto se aplica una expansión polinomial de segundo grado, denotada como $\phi_2(X_{z^{(1)}})$. Esta expansión genera términos lineales, términos cuadráticos e interacciones entre las variables seleccionadas. Por ejemplo, si un cromosoma activa las variables $\{x_1, x_3\}$, la expansión cuadrática restringida produce el conjunto:

$$\phi_2(\{x_1, x_3\}) = \{x_1, x_3, x_1^2, x_1x_3, x_3^2\} \quad (4.3)$$

El subconjunto expandido se evalúa mediante LDA usando validación cruzada estratificada de cinco pliegues. Para cada cromosoma válido, la aptitud se define como la exactitud promedio obtenida por LDA menos una penalización proporcional al número de variables originales seleccionadas. Por tanto, la función de aptitud de la primera fase queda definida como:

$$F_1(z^{(1)}) = \begin{cases} 0, & \text{si } q < 2, \\ \text{Acc}_{CV5}(\phi_2(X_{z^{(1)}}), \mathbf{y}_{\text{train}}) - \lambda \frac{q}{p}, & \text{si } q \geq 2. \end{cases} \quad (4.4)$$

En esta expresión, Acc_{CV5} representa la exactitud promedio de validación cruzada, q es el número de variables originales seleccionadas, p es el número total de variables originales disponibles y λ controla la intensidad de la penalización por complejidad. La fracción $\frac{q}{p}$ normaliza la penalización respecto al tamaño del espacio original, favoreciendo soluciones que logren buen desempeño con un menor número de variables.

La salida de esta fase es el cromosoma con mayor valor de aptitud:

$$\mathbf{z}^{(1)*} = \underset{\mathbf{z}^{(1)}}{\text{argmax}} F_1(\mathbf{z}^{(1)}) \quad (4.5)$$

así como el subconjunto de variables originales asociado:

$$S^* = \{x_j : z_j^{(1)} = 1\} \quad (4.6)$$

Este subconjunto define qué variables originales serán utilizadas para construir el espacio polinomial restringido de la segunda fase.

Para reducir el costo computacional de la evaluación de la Fase 1, la expansión polinomial de segundo grado de las variables originales se calcula previamente. Para cada individuo, el subconjunto de variables codificado en el cromosoma se utiliza para determinar los términos polinomiales correspondientes dentro de dicha expansión, los cuales son recuperados sin volver a ejecutar el proceso de expansión.

En ambas fases del proceso evolutivo se incorpora un mecanismo de memoria caché inspirado en la propuesta de Barradas-Palmeros y colaboradores [8]. Dicho mecanismo consiste en almacenar dentro de una lista a cada individuo previamente evaluado junto con el valor de

aptitud correspondiente. El objetivo principal de esta estrategia es evitar la re evaluación innecesaria de individuos repetidos que puedan surgir conforme avanza el ciclo evolutivo, asignándole directamente el valor ya calculado en lugar de someterlos nuevamente al proceso de evaluación.

A continuación se muestra el pseudo-código que describe el funcionamiento de esta primer etapa:

Algoritmo 1: Evaluación de aptitud con expansión polinomial

Entrada: I : Individuo binario de variables originales, X_{orig} : datos originales, X_{pool} : expansión polinomial precomputada de X_{orig} , y : etiquetas, M : modelo base LDA, λ : penalización, Mem : memoria de evaluaciones

Salida: Aptitud f_1

```

1  $q \leftarrow$  número de variables activas en  $I$ ;
2  $p \leftarrow$  número total de variables originales;
3 if  $q < 2$  then
4   return 0;
5 if  $I \in Mem$  then
6   return  $Mem[I]$ ;
7  $T \leftarrow$  obtener términos polinomiales de  $X_{\text{pool}}$  correspondientes a las variables activas en  $I$ ;
8  $\mu \leftarrow$  exactitud media obtenida mediante validación cruzada estratificada de 5 particiones usando  $M$  sobre  $T$ ;
9  $f_1 \leftarrow \mu - \lambda \cdot (k/N)$ ;
10  $Mem[I] \leftarrow f_1$ ;
11 return  $f_1$ ;

```

4.1.2. Fase II: selección de términos polinomiales

La segunda fase toma como entrada el subconjunto ganador S^* obtenido en la Fase I. A partir de estas variables se genera una expansión polinomial de segundo grado, pero ahora el algoritmo genético no selecciona variables originales, sino términos individuales del espacio expandido. Estos términos pueden corresponder a variables lineales, términos cuadráticos o interacciones.

Sea D^* el número total de términos generados por la expansión polinomial restringida de S^* .

Si la expansión es cuadrática y no incluye término de sesgo, entonces:

$$D^* = \binom{q+2}{2} - 1 \quad (4.7)$$

El cromosoma de la segunda fase se define como:

$$Z^{(2)} = [z_1, z_2, \dots, z_{D^*}], \quad z_j \in \{0, 1\} \quad (4.8)$$

En esta fase, cada gen representa un término específico del espacio polinomial restringido. Por ejemplo, si $S^* = \{x_1, x_3\}$, los genes pueden corresponder a los términos ordenados del espacio:

$$\{x_1, x_3, x_1^2, x_1x_3, x_3^2\} \quad (4.9)$$

Así, un cromosoma de la forma:

$$\{x_1, x_1^2, x_1 x_3\} \quad (4.10)$$

El número de términos activos en la segunda fase se define mediante:

$$s = |z^{(2)}|_0 \quad (4.11)$$

De manera análoga a la primera fase, se establece una condición mínima de factibilidad. Si un cromosoma selecciona menos de dos términos polinomiales, es decir, si $s < 2$, la solución se considera no válida y recibe una aptitud igual a cero. Esta regla evita evaluar representaciones excesivamente reducidas que no ofrecen una base suficiente para estimar una proyección discriminante mediante LDA. Para cada cromosoma válido, se construye una matriz de datos formada únicamente por los términos polinomiales activos. Esta matriz se evalúa nuevamente mediante LDA y validación cruzada estratificada de cinco pliegues. La función de aptitud de la segunda fase se define como:

$$F_2(\mathbf{z}^{(2)}) = \begin{cases} 0, & \text{si } s < 2, \\ \text{Acc}_{CV5}(X_{\phi, z^{(2)}}, \mathbf{y}_{\text{train}}) - \lambda \frac{s}{D^*}, & \text{si } s \geq 2. \end{cases} \quad (4.12)$$

En esta expresión, $X_{\phi, z^{(2)}}$ representa la matriz formada por los términos polinomiales seleccionados, s es el número de términos activos, D^* es el número total de términos disponibles en el espacio expandido restringido y λ es el mismo parámetro de penalización utilizado en la primera fase. Esta función favorece subconjuntos que alcancen alta exactitud con un número reducido de términos polinomiales.

La salida de la segunda fase es el subconjunto de términos polinomiales que maximiza la función de aptitud:

$$\mathbf{z}^{(2)*} = \underset{\mathbf{z}^{(2)}}{\text{argmax}} F_2(\mathbf{z}^{(2)}) \quad (4.13)$$

Este subconjunto constituye la representación final seleccionada por GNLPDA. Su propósito es conservar únicamente los términos que contribuyen al desempeño discriminante, descartando variables lineales, términos cuadráticos o interacciones cuya inclusión no compense el aumento de complejidad del modelo.

Algoritmo 2: Evaluación de aptitud en espacio polinomial restringido

Entrada: I : Individuo binario de términos polinomiales, X^* : espacio polinomial restringido, y : etiquetas de clase, M : modelo base LDA, λ : penalización, Mem : memoria de evaluaciones

Salida: Aptitud f_2

```

1  $s \leftarrow$  número de términos activos en  $I$ ;
2  $D^* \leftarrow$  número total de términos en  $X^*$ ;
3 if  $s < 2$  then
4   return 0;
5 if  $I \in Mem$  then
6   return  $Mem[I]$ ;
7  $X_{sub} \leftarrow$  seleccionar de  $X^*$  los términos correspondientes a las posiciones activas de  $I$ ;
8  $\mu \leftarrow$  exactitud media obtenida mediante validación cruzada estratificada de 5
   particiones usando  $M$  sobre  $X_{sub}$  y  $y$ ;
9  $f_2 \leftarrow \mu - \lambda \cdot (s/D^*)$ ;
10  $Mem[I] \leftarrow f_2$ ;
11 return  $f_2$ ;

```

4.1.3. Salida del procedimiento y ajuste final de LDA

Una vez finalizadas ambas fases, GNLPDA devuelve un subconjunto final de términos polinomiales seleccionados. En el protocolo experimental, dicho subconjunto se utiliza para transformar tanto la partición de entrenamiento como la partición de prueba. Posteriormente, se ajusta un modelo LDA final sobre la partición de entrenamiento transformada y se evalúa su desempeño sobre la partición de prueba transformada.

El conjunto de prueba permanece separado del proceso de búsqueda evolutiva y no participa en la selección de variables originales, en la selección de términos polinomiales ni en el cálculo interno de la aptitud. De esta manera, su uso se reserva exclusivamente para estimar la capacidad de generalización del modelo seleccionado.

La salida del método puede resumirse en tres elementos: el subconjunto de variables originales retenidas en la primera fase, el subconjunto de términos polinomiales seleccionados en la segunda fase y la proyección discriminante final de baja dimensión, destinada a la representación y visualización de la estructura de las clases. En conjunto, estos elementos permiten reportar tanto el desempeño predictivo del método como la reducción dimensional lograda respecto al espacio polinomial completo.

En términos metodológicos, la primera fase reduce el espacio de variables que serán consideradas en la expansión, mientras que la segunda fase reduce el espacio polinomial resultante. Esta doble selección evita explorar directamente todas las combinaciones de términos de la expansión polinomial completa y permite controlar el crecimiento combinatorio del problema. Por ello, GNLPDA busca obtener una representación discriminante parsimoniosa y adecuada para la selección entre clases, reduciendo el tamaño del espacio de características sobre el cual se ajusta el discriminante y favoreciendo la obtención de una representación de baja dimensión que pueda ser inspeccionada visualmente.

Siendo entonces, que el pseudo-código completo con las funciones de aptitud es el siguiente:

Algoritmo 3: Procedimiento principal de GNLPDA mediante selección evolutiva en dos fases

Entrada: X_{orig} : datos originales, X_{pool} : expansión polinomial precomputada, y : etiquetas de clase, C : configuraciones de los algoritmos genéticos, λ : parámetro de penalización, M : modelo LDA

Salida: I_1^* : mejor individuo de la Fase 1, I_2^* : mejor individuo de la Fase 2, X_{final} : términos polinomiales seleccionados, Z : representación discriminante final de baja dimensión

- 1 Inicializar población P_1 según C ;
 - 2 Inicializar $Mem_1 \leftarrow \emptyset$;
 - 3 Evaluar P_1 mediante F_1 (Algoritmo 1);
 - 4 Guardar el mejor individuo I_1^* ;
 - 5 **while** *criterio de parada de GA no se cumple* **do**
 - 6 Seleccionar padres de P_1 ;
 - 7 Aplicar cruce a los padres seleccionados;
 - 8 Aplicar mutación a los descendientes;
 - 9 Evaluar descendientes mediante F_1 ;
 - 10 Formar nueva población mediante elitismo;
 - 11 Actualizar I_1^* si se obtiene una mejor solución;
 - 12 Obtener S^* a partir de I_1^* ;
 - 13 Construir X^* recuperando de X_{pool} los términos correspondientes a S^* ;
 - 14 Inicializar población P_2 según C ;
 - 15 Inicializar $Mem_2 \leftarrow \emptyset$;
 - 16 Evaluar P_2 mediante F_2 (Algoritmo 2);
 - 17 Guardar el mejor individuo I_2^* ;
 - 18 **while** *criterio de parada de GA no se cumple* **do**
 - 19 Seleccionar padres de P_2 ;
 - 20 Aplicar cruce a los padres seleccionados;
 - 21 Aplicar mutación a los descendientes;
 - 22 Evaluar descendientes mediante F_2 ;
 - 23 Formar nueva población mediante elitismo;
 - 24 Actualizar I_2^* si se obtiene una mejor solución;
 - 25 $X_{\text{final}} \leftarrow$ seleccionar términos de X^* según I_2^* ;
 - 26 Ajustar M sobre X_{final} ;
 - 27 Obtener Z ;
 - 28 **return** $I_1^*, I_2^*, X_{\text{final}}, Z$;
-

4.2. Configuración y calibración de GNLPDA

Una vez definida la arquitectura general de GNLPDA, fue necesario establecer la configuración del algoritmo genético utilizado en ambas fases de selección. En esta sección se describen los mecanismos que conforman el proceso evolutivo, la representación utilizada y los principales parámetros de configuración. Posteriormente, se presenta el procedimiento de calibración automática mediante *irace* [46], utilizado para determinar los valores de los parámetros sometidos a búsqueda.

4.2.1. Configuración del algoritmo genético.

Representación

El algoritmo genético empleado en GNLPGA utiliza una representación binaria pura. En ambas fases, cada cromosoma se codifica como un vector de ceros y unos, donde el valor 1 indica la inclusión de una variable o término, y el valor 0 indica su exclusión.

Por ejemplo, para un conjunto de cinco variables $\{A, B, C, D, E\}$, el individuo de la primera fase puede ser:

$$\text{Individuo} = \{1, 0, 1, 0, 0\} \quad (4.14)$$

Lo cual tiene una correspondencia directa con la selección de variables $\{A, C\}$.

En la segunda fase, se representan términos del espacio polinomial restringido. Si previamente la selección de variables fue $\{A, C\}$ entonces el subconjunto expandido sobre el que se hará la búsqueda en la segunda fase es $\{A, C, A^2, A * C, C^2\}$. Dicho subconjunto al tener 5 términos en total, da origen a la siguiente representación binaria:

$$\text{Individuo} = \{0, 0, 1, 1, 0\} \quad (4.15)$$

Lo cual tiene una correspondencia directa con la selección de términos $\{A^2, A * C\}$.

Siendo así que ambas fases usan la misma representación binaria pero mapeando diferentes conjuntos.

Selección

En este esquema, dos individuos se seleccionan aleatoriamente de la población y compiten con base en su valor de aptitud. El individuo con mayor aptitud es seleccionado como progenitor.

$$\text{Padre} = \begin{cases} I_i, & \text{si } f(I_i) \geq f(I_j) \\ I_j, & \text{en otro caso} \end{cases} \quad (4.16)$$

Cruza

En el proceso de cruce de un solo punto, dos individuos progenitores son seleccionados y se define un único punto de corte aleatorio común para ambos. A partir de este punto, se construyen los descendientes intercambiando las secciones correspondientes de los padres. De esta manera, cada hijo conserva una parte inicial de un progenitor y una parte final del otro, garantizando la recombinación de información genética en un esquema clásico de cruce. A continuación se muestra un ejemplo de cruce a partir de dos progenitores seleccionando como punto de corte el segundo elemento del vector:

$$P_1 = \{1, 1, 0, 0, 1\}, \quad P_2 = \{1, 0, 1, 0, 1\} \quad (4.17)$$

$$H_1 = \{1, 1, 1, 0, 1\}, \quad H_2 = \{1, 0, 0, 0, 1\} \quad (4.18)$$

Mutación

La mutación implementada es el esquema de mutación por inversión de bits (*bit-flip*).

Este operador actúa sobre cada gen del individuo de manera independiente, aplicando una probabilidad de mutación previamente definida. En caso de que la mutación ocurra, el valor binario del gen se invierte: un 1 se transforma en 0 y, de manera análoga, un 0 se convierte en 1.

$$I = \{1, 0, 1, 0, 1\} \quad (4.19)$$

$$I' = \{1, 1, 1, 0, 0\} \quad (4.20)$$

Después de la mutación se aplica una corrección de factibilidad para que el individuo conserve al menos dos genes activos.

Remplazo generacional

El algoritmo genético se implementó bajo un esquema de reemplazo generacional, en el cual la población completa es sustituida en cada generación por individuos recién generados.

Dentro de este esquema se incorpora un componente de elitismo, mediante el cual se garantiza la preservación automática de los dos individuos con mayor aptitud de la generación actual, asegurando que las soluciones de mayor calidad no se pierdan en el proceso. A continuación se muestra un breve ejemplo donde t representa la generación actual y $t + 1$ la generación siguiente.

$$Población^{(t)} = \{ \{1, 1, 0, 1, 0\}, \{1, 0, 1, 0, 1\}, \dots, \{0, 1, 1, 0, 0\} \} \quad (4.21)$$

$$Elites^{(t)} = \{ \{1, 1, 0, 1, 0\}, \{1, 0, 1, 0, 1\} \} \quad (4.22)$$

$$Descendientes^{(t)} = \{ \{1, 1, 1, 0, 1\}, \{0, 1, 0, 1, 0\}, \dots \} \quad (4.23)$$

$$Población^{(t+1)} = Elites^{(t)} \cup Descendientes^{(t)} \quad (4.24)$$

La aplicación conjunta de estos operadores define el ciclo evolutivo empleado en cada fase de GNLPGA. A partir de una población inicial de individuos, cada generación evalúa la aptitud de las soluciones, selecciona progenitores mediante torneo binario, aplica cruce y mutación para generar nuevos individuos y conserva los dos mejores individuos mediante elitismo. Este proceso se repite durante el número de generaciones establecido, manteniendo además un registro de la mejor solución encontrada a lo largo de toda la ejecución.

4.3. Calibración mediante Irace

El algoritmo genético empleado en GNLPGA utiliza una representación binaria pura. En ambas fases, cada cromosoma se codifica como un vector de ceros y unos, donde el valor 1 indica la inclusión de una variable o término, y el valor 0 indica su exclusión. En la primera fase, los genes representan variables originales; en la segunda fase, representan términos del espacio polinomial restringido.

La selección de individuos se realiza mediante torneo binario. En este esquema, dos individuos son seleccionados aleatoriamente de la población y compiten con base en su valor de

Parámetro	Notación
Número de generaciones	$ngens$
Tamaño de población	$pobsize$
Probabilidad de cruce	P_c
Probabilidad de mutación	P_m
Penalización	λ
Selección	Torneo binario
Cruce	Cruce de un solo punto
Representación	Binaria
Elitismo	Conservación de los 2 mejores individuos

Tabla 4.1: Configuración del algoritmo genético empleado en GNLPGA.

aptitud; el individuo con mejor aptitud tiene mayor probabilidad de ser elegido como progenitor. Para la recombinación, se emplea cruce de un solo punto, mientras que la mutación se implementa como inversión de bits sobre la representación binaria. Además, se incorpora elitismo, preservando automáticamente los dos mejores individuos de cada generación para la generación siguiente. Esta estrategia evita que las mejores soluciones encontradas se pierdan por efecto de los operadores estocásticos.

Los parámetros de control del algoritmo genético son comunes para ambas fases de GNLPGA. Es decir, la Fase I y la Fase II utilizan el mismo número de generaciones, tamaño de población, probabilidad de cruce, probabilidad de mutación y valor de penalización (λ).

La diferencia entre fases está determinada por el espacio de búsqueda: variables originales en la primera fase y términos polinomiales en la segunda.

Parámetro	Valor final
Número de generaciones	94
Tamaño de población	64
Probabilidad de cruce	0.9
Probabilidad de mutación	0.05
Penalización	0.01
Selección	Torneo binario
Cruce	Un punto
Representación	Binaria
Elitismo	2 mejores individuos

Tabla 4.2: Parámetros finales del algoritmo genético empleado en GNLPGA.

4.3.1. Calibración mediante irace

La calibración de parámetros se realizó mediante irace, una herramienta de configuración automática basada en carreras iteradas. Este procedimiento evalúa distintas configuraciones candidatas sobre un conjunto de instancias de calibración y descarta progresivamente aquellas configuraciones con menor desempeño, concentrando el presupuesto de evaluación en las alternativas más prometedoras.

En esta investigación, irace fue utilizado para calibrar cinco parámetros principales de GNLPDA: probabilidad de mutación, tamaño de población, probabilidad de cruza, penalización por complejidad y número de generaciones. Los rangos de búsqueda considerados fueron los siguientes:

Parámetro	Tipo	Rango de búsqueda
ngen	Entero	[20, 100]
pobsize	Entero	[20, 100]
prob cruza	Real	[0.4, 0.95]
prob muta	Real	[0.05, 0.2]
Penalizador	Real	[0.01, 0.2]

Tabla 4.3: Rangos de calibración considerados por irace.

Dado que irace opera como un procedimiento de minimización, el criterio objetivo se definió a partir del aptitud penalizado obtenido por GNLPDA al finalizar la segunda etapa. En particular, para cada configuración candidata se ejecutó el procedimiento completo de dos fases y se tomó el mejor valor de aptitud obtenido en la Fase II, denotado como $F_2(z^{(2)*})$. A partir de este valor, la función de costo entregada a irace se definió como:

$$\mathcal{L}_{irace} = 1 - F_2(z^{(2)*}) \quad (4.25)$$

De esta forma, minimizar $\mathcal{L}_{irace}$ equivale a favorecer configuraciones que produzcan un mayor aptitud penalizado en la segunda etapa. Este criterio incorpora simultáneamente la exactitud promedio estimada mediante validación cruzada estratificada de cinco pliegues y la penalización por complejidad asociada al número de términos polinomiales seleccionados.

Se estableció un presupuesto de 5000 experimentos considerando el número de parámetros, el costo computacional de ejecutar GNLPDA y la disponibilidad de recursos. Para reducir el tiempo de ejecución, el proceso se paralelizó utilizando 11 núcleos de procesamiento.

4.4. Diseño experimental

4.4.1. Conjuntos de datos utilizados

Para evaluar el desempeño de GNLPDA se utilizaron diez conjuntos de datos con diferentes tamaños muestrales, dimensionalidades, números de clases y niveles de complejidad geométrica. La selección de estos conjuntos busca cubrir escenarios de clasificación binaria y multiclase, así como problemas donde la frontera de separación entre clases puede variar desde casos relativamente favorables para métodos lineales hasta escenarios con estructuras no lineales o traslape significativo entre clases.

Los conjuntos Palmer Penguins y Wines se incorporaron como puntos de partida experimentales. Ambos corresponden a conjuntos de referencia ampliamente utilizados en clasificación supervisada y presentan una estructura de clases relativamente favorable para métodos lineales. Palmer Penguins contiene mediciones morfológicas de tres especies de pingüinos, mientras que Wines describe muestras de vino mediante variables químicas asociadas a tres clases. Estos conjuntos permiten verificar el comportamiento de GNLPDA en escenarios clásicos donde se espera que métodos lineales como LDA tengan un desempeño competitivo [35][9].

Los conjuntos Breast Cancer Wisconsin Diagnostic (WDBC) e Ionosphere se incluyeron como escenarios de referencia con mayor dimensionalidad. Aunque también pueden presentar una separación relativamente favorable para clasificadores lineales, su interés experimental radica en el incremento del número de variables. WDBC corresponde a un problema binario de diagnóstico de cáncer de mama a partir de características extraídas de imágenes digitalizadas de masas celulares. Por su parte, Ionosphere corresponde a un problema binario asociado con señales de radar, donde las observaciones se describen mediante un conjunto de variables numéricas de mayor dimensión. Estos conjuntos permiten analizar si GNLPGA conserva un comportamiento adecuado cuando aumenta el número de características originales disponibles [71] [76].

Para evaluar explícitamente el comportamiento de los métodos ante estructuras no lineales, se generaron tres conjuntos sintéticos denominados Cebolla3D, Cebolla10D y Cebolla20D. Estos conjuntos fueron contruidos mediante un procedimiento de generación de datos concéntricos, de elaboración propia, en el que las clases se distribuyen en capas o regiones radiales. Por construcción, estos escenarios no presentan una separación lineal directa en el espacio original, por lo que permiten analizar la utilidad de la expansión polinomial y de la selección evolutiva de términos dentro de GNLPGA. La inclusión de versiones en 3, 10 y 20 dimensiones permiten observar el efecto del incremento dimensional en un problema no lineal controlado.

El conjunto pimadiabetes se incorporó como un caso clásico de clasificación binaria con mayor dificultad práctica. Este conjunto reúne variables clínicas asociadas al diagnóstico de diabetes y es conocido por presentar traslape entre clases, ruido y presencia de valores faltantes o codificados de forma problemática. Por ello, constituye un escenario útil para evaluar el desempeño de GNLPGA en un problema donde la separación entre clases no es necesariamente clara, incluso después de aplicar transformaciones al espacio de características [77].

Finalmente, se incluyeron dos conjuntos de indicadores de rezago social correspondientes a los años 2015 y 2020. Estos datos fueron proporcionados por un investigador colaborador y corresponden a una aplicación reciente en un contexto real. A diferencia de los conjuntos clásicos de referencia, estos datos presentan un mayor número de observaciones y cinco clases, lo que permite evaluar el comportamiento de GNLPGA en un problema multiclase aplicado. Además, su inclusión amplía el análisis experimental hacia un dominio distinto al de los repositorios tradicionales de aprendizaje automático [58].

La Tabla 4.4, resume las principales características de los conjuntos de datos utilizados en la evaluación experimental:

Dataset	Muestras	Variables	Clases
penguins	342	4	3
wines	178	13	3
Breast Cancer (WDBC)	569	30	2
Ionosphere	351	34	2
Cebolla3D	300	3	3
Cebolla10D	300	10	3
Cebolla20D	300	20	3
pimadiabetes	768	8	2
Indicadores 2015	2446	12	5
Indicadores 2020	2470	12	5

Tabla 4.4: Resumen de datasets y características.

En conjunto, estos datos permiten evaluar el método en cuatro tipos de escenarios: conjuntos

clásicos con separabilidad relativamente favorable, conjuntos de referencia con mayor número de variables, conjuntos sintéticos no lineales de estructura controlada y aplicaciones reales con mayor tamaño muestral. Esta diversidad experimental permite analizar no solo la exactitud predictiva de GNLPDA, sino también su capacidad para seleccionar representaciones compactas en problemas con distintas características geométricas y dimensionales.

4.4.2. Generación de conjuntos sintéticos tipo Cebolla

Además de los conjuntos de referencia y de aplicación real, se generaron tres conjuntos sintéticos denominados Cebolla3D, Cebolla10D y Cebolla20D. Estos conjuntos fueron diseñados con el propósito de evaluar el comportamiento de los métodos en escenarios donde la separación entre clases no es lineal en el espacio original. A diferencia de los conjuntos reales, cuya estructura depende de datos observados, los conjuntos tipo Cebolla permiten controlar explícitamente la geometría del problema y garantizar una estructura concéntrica de clases.

El procedimiento de generación se basa en distribuir observaciones sobre capas radiales alrededor de un centro común. Cada clase se asocia con un intervalo de radios distinto, de manera que la pertenencia de clase depende principalmente de la distancia al origen y no de una combinación lineal de las variables. Por esta razón, las clases no pueden separarse adecuadamente mediante hiperplanos en el espacio original, lo que convierte a estos conjuntos en escenarios adecuados para evaluar métodos que incorporan transformaciones no lineales del espacio de características.

Sea $x_i \in \mathbb{R}^d$ una observación generada en un espacio de dimensión d , con $d \in \{3, 10, 20\}$.

Para cada clase $c \in \{1, 2, 3\}$, se define un intervalo radial:

$$a_c = 2(c - 1), \quad b_c = a_c + 1,5 \quad (4.26)$$

De esta forma, las tres clases quedan asociadas a los intervalos radiales $[0, 1.5]$, $[2, 3.5]$ y $[4, 5.5]$, respectivamente. La separación entre intervalos radiales introduce una estructura de capas concéntricas, mientras que la dimensión d determina el número de variables del conjunto sintético generado.

Para generar cada observación, primero se obtiene un vector aleatorio $v_i \in \mathbb{R}^d$ con componentes independientes provenientes de una distribución normal estándar:

$$v_i \sim \mathcal{N}(\mathbf{0}, I_d) \quad (4.27)$$

Posteriormente, este vector se normaliza para obtener una dirección unitaria:

$$u_i = \frac{v_i}{|v_i|} \quad (4.28)$$

El radio de la observación se genera de manera uniforme dentro del intervalo correspondiente a su clase:

$$r_i \sim U(a_c, b_c) \quad (4.29)$$

Finalmente, la observación se obtiene escalando la dirección unitaria por el radio generado y agregando una perturbación uniforme por coordenada:

$$x_i = r_i u_i + \varepsilon_i \quad (4.30)$$

Donde:

$$\varepsilon_i \sim U\left(-\frac{\eta}{2}, \frac{\eta}{2}\right)^d \quad (4.31)$$

y $\eta = 0,1$ controla la magnitud del ruido añadido. La etiqueta de clase se asigna de acuerdo con el intervalo radial utilizado en la generación, produciendo las clases G_1 , G_2 y G_3 .

En cada conjunto sintético se generaron 100 observaciones por clase, para un total de 300 observaciones distribuidas en tres clases. Cebolla3D permite visualizar directamente la estructura concéntrica del problema, mientras que Cebolla10D y Cebolla20D permiten analizar el comportamiento de los métodos cuando la misma estructura no lineal se presenta en espacios de mayor dimensionalidad.

Estos conjuntos fueron generados específicamente para esta investigación, por lo que se reportan como datos de elaboración propia. Su inclusión permite evaluar si GNLPDA logra aprovechar la expansión polinomial y la selección evolutiva de términos para construir una representación discriminante adecuada en problemas donde la no linealidad está presente por construcción.

4.4.3. Protocolo de particionamiento y evaluación

El preprocesamiento de los conjuntos de datos se mantuvo al mínimo con el propósito de evaluar los métodos sobre representaciones cercanas a los datos originales. No se aplicaron procedimientos de estandarización, normalización, reducción dimensional previa ni transformaciones adicionales sobre las variables de entrada. Únicamente se realizaron depuraciones puntuales cuando fue necesario, tales como la eliminación de variables no predictoras, identificadores o columnas incompatibles con el análisis numérico. De esta forma, las diferencias observadas entre métodos se atribuyen principalmente al procedimiento de clasificación o transformación propio de cada técnica evaluada.

Para estimar el desempeño de los métodos se utilizó un esquema de particionamiento aleatorio repetido. En cada conjunto de datos se generaron 30 particiones independientes con proporción 70/30, donde el 70 % de las observaciones se utilizó como conjunto de entrenamiento y el 30 % restante como conjunto de prueba. Cada partición fue generada a partir de una semilla aleatoria prefijada, de manera que el procedimiento pudiera reproducirse.

Todos los métodos comparativos fueron evaluados utilizando exactamente las mismas particiones de entrenamiento y prueba. Por tanto, para una semilla dada, GNLPDA, LDA, QDA, KFDA y las variantes de SVM fueron entrenados y evaluados sobre el mismo bloque experimental. Este diseño permite realizar comparaciones emparejadas entre algoritmos, ya que las diferencias de desempeño no dependen de variaciones en los datos utilizados para entrenamiento o prueba, sino del comportamiento de cada método bajo la misma partición.

En el caso particular de GNLPDA, la búsqueda evolutiva se realizó únicamente dentro del conjunto de entrenamiento de cada partición. A su vez, la evaluación interna de los cromosomas se llevó a cabo mediante validación cruzada estratificada de cinco pliegues sobre dicho conjunto de entrenamiento. El conjunto de prueba no participó en la selección de variables originales, en la selección de términos polinomiales ni en el cálculo de la aptitud. Una vez finalizado el proceso de selección, el modelo final se ajustó con la representación seleccionada sobre el conjunto de entrenamiento y se evaluó sobre el conjunto de prueba correspondiente.

Como resultado, para cada combinación de dataset y método se obtuvieron 30 valores de desempeño, uno por cada partición aleatoria. Estos valores constituyen la base para el análisis comparativo y estadístico descrito en la siguiente sección.

4.4.4. Análisis estadístico de resultados

El análisis estadístico se realizó de manera independiente para cada conjunto de datos. Dado que todos los métodos fueron evaluados sobre las mismas 30 particiones de entrenamiento y prueba, el diseño experimental puede interpretarse como un diseño en bloques emparejados, donde cada partición constituye un bloque y cada algoritmo representa un tratamiento. Bajo este esquema, las comparaciones entre métodos se realizan considerando que todos enfrentan las mismas condiciones experimentales dentro de cada bloque.

Para detectar diferencias globales entre los algoritmos se aplicó la prueba no paramétrica de Friedman. Esta prueba permite comparar múltiples métodos bajo un diseño de bloques, utilizando los rangos de desempeño obtenidos por los algoritmos dentro de cada partición.

En este trabajo, para cada dataset se construyó una matriz de resultados con 30 filas, correspondientes a las particiones aleatorias, y una columna por cada método evaluado. A partir de esta matriz se aplicó la prueba de Friedman con el objetivo de determinar si existían diferencias estadísticamente significativas entre los desempeños de los algoritmos [66].

Cuando la prueba de Friedman indicó diferencias significativas, se aplicó la prueba post hoc de Nemenyi para identificar entre qué pares de métodos se presentaban diferencias estadísticamente significativas. Esta prueba permite comparar los rangos promedio de los algoritmos y determinar si la diferencia entre dos métodos supera la diferencia crítica establecida para el nivel de significancia considerado [21].

El análisis se realizó en dos niveles. En primer lugar, se consideró el conjunto completo de métodos comparativos, incluyendo LDA, QDA, KFDA, SVM con kernel polinomial de grado 2, SVM con kernel polinomial de grado 3, SVM con kernel gaussiano y GNLPGA.

Esta comparación permite situar la propuesta frente a clasificadores lineales, cuadráticos y no lineales.

En segundo lugar, se repitió el análisis excluyendo a LDA y QDA. Esta segunda comparación se centró únicamente en métodos no lineales o basados en transformaciones del espacio de características, es decir, KFDA, las variantes kernel de SVM y GNLPGA. El propósito de este análisis adicional fue evaluar el comportamiento relativo de la propuesta frente a competidores más cercanos en términos metodológicos, evitando que las diferencias frente a clasificadores lineales dominaran la interpretación de los resultados.

En todos los casos, el análisis estadístico se basó en los resultados obtenidos sobre las 30 particiones aleatorias de cada dataset. De esta forma, la comparación entre métodos incorpora la variabilidad inducida por las particiones entrenamiento-prueba y no depende de una única división de los datos.

4.4.5. Evaluación auxiliar del problema Small Sample Size

Además del análisis comparativo principal, se diseñó una evaluación auxiliar para visualizar el efecto del problema Small Sample Size (SSS) sobre métodos discriminantes. Esta evaluación no tuvo como objetivo comparar exhaustivamente todos los algoritmos del estudio, sino ilustrar el comportamiento de LDA, la implementación lda de la paquetería MASS y KFDA bajo escenarios donde la relación entre número de observaciones y número de variables se vuelve desfavorable.

Para ello, se construyeron cinco escenarios sintéticos con tres clases balanceadas.

En cada caso se controló el número total de observaciones, el número de atributos originales y el número de atributos resultantes después de aplicar una expansión polinomial de segundo grado sin término de sesgo. Si (d) representa el número de atributos originales, el número de términos generados por la expansión cuadrática se calculó como:

$$D_{\phi} = \binom{d+2}{2} - 1 \quad (4.32)$$

La Tabla 4. resume los cinco escenarios considerados:

Caso	Muestras	Atributos	Atributos expandido	Clases	Muestras por clase
1	150	3	9	3	50
2	150	10	65	3	50
3	15	3	9	3	5
4	15	10	65	3	5
5	15	15	135	3	5

Tabla 4.5: Resumen de los escenarios de prueba sintéticos.

Los dos primeros casos representan escenarios con un número relativamente suficiente de observaciones por clase. En el Caso 1, la dimensionalidad es baja tanto en el espacio original como en el espacio expandido. En el Caso 2, la expansión polinomial incrementa considerablemente el número de atributos, aunque el tamaño muestral sigue siendo relativamente amplio.

Los Casos 3, 4 y 5 introducen una condición de escasez muestral, con únicamente 15 observaciones totales y cinco muestras por clase. El Caso 3 permite observar el efecto de una muestra reducida con baja dimensionalidad. En el Caso 4, la expansión polinomial genera 65 atributos a partir de 10 variables originales, produciendo una relación desfavorable entre dimensión y tamaño muestral. Finalmente, el Caso 5 representa el escenario más severo, ya que combina baja muestra, mayor número de atributos originales y una expansión polinomial de 135 términos.

Esta evaluación permite observar visualmente cómo la expansión del espacio de características puede agravar el problema SSS. En particular, cuando el número de atributos se aproxima o supera el número de observaciones disponibles, la estimación de matrices de dispersión o covarianza puede volverse inestable o singular. Por ello, estos escenarios resultan útiles para contrastar la formulación clásica de LDA, la implementación computacional de LDA en MASS y KFDA bajo condiciones de alta dimensionalidad relativa.

Los resultados derivados de esta evaluación se presentan como un análisis complementario al experimento principal. Su propósito es apoyar la discusión metodológica sobre las limitaciones de los enfoques discriminantes cuando el espacio de características crece de manera considerable respecto al número de observaciones disponibles, especialmente después de aplicar expansiones polinomiales.

4.4.6. Métodos comparativos y métrica de evaluación

Para evaluar el desempeño de GNLPPDA se consideraron seis métodos comparativos: LDA, QDA, KFDA con kernel gaussiano, SVM con kernel polinomial de grado 2, SVM con kernel polinomial de grado 3 y SVM con kernel gaussiano. La selección de estos competidores busca contrastar la propuesta frente a clasificadores lineales clásicos, clasificadores cuadráticos, métodos kernel discriminantes y clasificadores kernel ampliamente utilizados en problemas de clasificación supervisada.

El primer método comparativo fue LDA, implementado mediante la función `lda` de la paquetería MASS de R. Este método se incluyó como línea base, ya que representa el enfoque clásico de separación y proyección lineal supervisada. Además, resulta especialmente relevante porque

GNLPDA utiliza internamente esta implementación de LDA para evaluar las representaciones generadas durante su proceso de selección evolutiva. La implementación de MASS es pertinente en este contexto debido a su tratamiento computacional de la estimación discriminante, particularmente cuando aparecen problemas de colinealidad o alta dimensionalidad relativa.

El segundo método fue QDA, considerado como una extensión clásica del análisis discriminante que relaja el supuesto de covarianzas iguales entre clases. A diferencia de LDA, QDA permite fronteras de decisión cuadráticas, por lo que se incorporó como un competidor tradicional capaz de modelar separaciones no estrictamente lineales en el espacio original.

También se incluyó KFDA con kernel gaussiano. Este método constituye una alternativa kernel al análisis discriminante de Fisher, al permitir que la separación entre clases se realice en un espacio de características inducido implícitamente por el kernel. Su inclusión resulta relevante porque conserva una interpretación discriminante y proyectiva, pero incorpora la capacidad de modelar relaciones no lineales entre las observaciones.

Adicionalmente, se evaluaron tres variantes de SVM. La primera corresponde a SVM con kernel polinomial de grado 2, incluida como referencia frente a una transformación polinomial implícita de segundo grado. La segunda corresponde a SVM con kernel polinomial de grado 3, considerada para analizar el efecto de una transformación polinomial implícita de mayor orden. Finalmente, se incluyó SVM con kernel gaussiano, debido a su uso extendido en el estado del arte y a su capacidad para modelar fronteras de decisión no lineales flexibles.

Método	Variante	Propósito en la comparación
LDA	LDA de la paquetería MASS	Línea base lineal y proyectiva; implementación usada internamente por GNLPDA.
QDA	Clásico	Clasificador discriminante con fronteras cuadráticas.
KFDA	Gauss	Alternativa kernel de Fisher para separación no lineal.
SVM	Pol (2)	Comparación frente a una transformación polinomial implícita de segundo grado.
SVM	Pol (3)	Comparación frente a una transformación polinomial implícita de mayor orden.
SVM	Gauss	Clasificador kernel no lineal ampliamente utilizado.

Tabla 4.6: Resume los métodos comparativos considerados y su propósito dentro del diseño experimental.

El rendimiento de los métodos se evaluó mediante exactitud (accuracy) sobre el conjunto de prueba. Para una partición dada, la exactitud se calculó como la proporción de observaciones correctamente clasificadas:

$$\text{Accuracy} = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} \mathbb{I}(\hat{y}_i = y_i) \quad (4.33)$$

Dado que cada método fue evaluado sobre las mismas 30 particiones por dataset, para cada combinación método-dataset se obtuvieron 30 valores de exactitud. Estos valores fueron utilizados posteriormente para el análisis estadístico mediante la prueba de Friedman y, cuando correspondió, la prueba post hoc de Nemenyi.

Bibliografía

- [1] ABUKMEIL, Mohanad ; FERRARI, Stefano ; GENOVESE, Angelo ; PIURI, Vincenzo ; SCOTTI, Fabio: A survey of unsupervised generative models for exploratory data analysis and representation learning. In: *Acm computing surveys (csur)* 54 (2021), Nr. 5, S. 1–40
- [2] ACEVEDO, Aldo ; WU, Yue ; TRAVERSA, Fabio L. ; CANNISTRACI, Carlo V.: Geometric separability of mesoscale patterns in embedding representation and visualization of multidimensional data and complex networks. In: *PLOS Complex Systems* 1 (2024), Nr. 2, S. e0000012
- [3] AGATRA, Denaya Ferrari N. ; MARUTHO, Dhendra ; XIONG, Xinqi: Evaluating PCA and LDA to Improve Machine Learning Classification of Consumer Behavior in Health Informatics. In: *Journal of Intelligent Computing and Health Informatics (JICHI)*. Vol 6 (2025), Nr. 1
- [4] AL-MILLI, Nabeel ; HUDAIB, Amjad ; OBEID, Nadim: Population diversity control of genetic algorithm using a novel injection method for bankruptcy prediction problem. In: *Mathematics* 9 (2021), Nr. 8, S. 823
- [5] ALI, Liaqat ; WAJAHAT, Iram ; AMIRI GOLILARZ, Noorbakhsh ; KESHTKAR, Fazel ; BUKHARI, Syed Ahmad C.: LDA–GA–SVM: improved hepatocellular carcinoma prediction through dimensionality reduction and genetically optimized support vector machine. In: *Neural Computing and Applications* 33 (2021), Nr. 7, S. 2783–2792
- [6] ANDREWS, David F.: Plots of high-dimensional data. In: *Biometrics* (1972), S. 125–136
- [7] ARAVEEPORN, Autcha ; BANDITVILAI, Somsri: A Classification Study in High-Dimensional Data of Linear Discriminant Analysis and Regularized Discriminant Analysis. In: *WSEAS TRANSACTIONS ON MATHEMATICS* 22 (2023), Mai, 315–323. <http://dx.doi.org/10.37394/23206.2023.22.37>. – DOI 10.37394/23206.2023.22.37. – ISSN 1109–2769
- [8] BARRADAS-PALMEROS, Jesús-Arnulfo ; MEZURA-MONTES, Efrén ; RIVERA-LÓPEZ, Rafael ; ACOSTA-MESA, Hector-Gabriel: Computational cost reduction in wrapper approaches for feature selection: a case of study using permutational-based differential evolution. In: *2024 IEEE congress on evolutionary computation (CEC)* IEEE, 2024, S. 1–8
- [9] BARTH, Jackson ; KATUMULLAGE, Duwani ; YANG, Chenyu ; CAO, Jing: Classification of wines using principal component analysis. In: *Journal of Wine Economics* 16 (2021), Nr. 1, S. 56–67
- [10] BELHUMEUR, Peter N. ; HESPANHA, Joao P. ; KRIEGMAN, David J.: Eigenfaces vs. fisherfaces: Recognition using class specific linear projection. In: *IEEE Transactions on pattern analysis and machine intelligence* 19 (1997), Nr. 7, S. 711–720

- [11] BHARADIYA, Jasmin P.: A tutorial on principal component analysis for dimensionality reduction in machine learning. In: *International journal of innovative science and research technology* 8 (2023), Nr. 5, S. 2028–2032
- [12] BISHOP, Christopher M. ; NASRABADI, Nasser M.: *Pattern recognition and machine learning*. Springer, 2006
- [13] BODT, Cyril de ; DIAZ-PAPKOVICH, Alex ; BLEHER, Michael ; BUNTE, Kerstin ; COUPETTE, Corinna ; DAMRICH, Sebastian ; SANMARTIN, Enrique F. ; HAMPRECHT, Fred A. ; HORVÁT, Emőke-Ágnes ; KOHLI, Dhruv u. a.: Low-dimensional embeddings of high-dimensional data. In: *arXiv preprint arXiv:2508.15929* (2025)
- [14] BRISCIK, Mitja ; DILLIES, Marie-Agnès ; DÉJEAN, Sébastien: Improvement of variables interpretability in kernel PCA. In: *BMC bioinformatics* 24 (2023), Nr. 1, S. 282
- [15] BRUNO, Pierangela ; CALIMERI, Francesco ; KITANIDIS, Alexandre S. ; DE MOMI, Elena: Data reduction and data visualization for automatic diagnosis using gene expression and clinical data. In: *Artificial Intelligence in Medicine* 107 (2020), S. 101884
- [16] BUHAS, Bogdan A. ; MUNTEAN, Lucia Ana-Maria ; PLOUSSARD, Guillaume ; FECICHE, Bogdan O. ; ANDRAS, Iulia ; TOMA, Valentin ; MAGHIAR, Teodor A. ; CRIȘAN, Nicolae ; ȘTIUFUIC, Rareș-Ionuț ; LUCACIU, Constantin M.: Renal cell carcinoma discrimination through attenuated total reflection Fourier transform infrared spectroscopy of dried human urine and machine learning techniques. In: *International Journal of Molecular Sciences* 25 (2024), Nr. 18, S. 9830
- [17] CHAPELLE, Olivier ; VAPNIK, Vladimir ; BOUSQUET, Olivier ; MUKHERJEE, Sayan: Choosing multiple parameters for support vector machines. In: *Machine learning* 46 (2002), Nr. 1, S. 131–159
- [18] CHHIKARA, Prateek ; JAIN, Nikhil ; TEKCHANDANI, Rajkumar ; KUMAR, Neeraj: Data dimensionality reduction techniques for Industry 4.0: Research results, challenges, and future research directions. In: *Software: Practice and Experience* 52 (2022), Nr. 3, S. 658–688
- [19] CORTES, Corinna ; VAPNIK, Vladimir: Support-vector networks. In: *Machine learning* 20 (1995), Nr. 3, S. 273–297
- [20] COVER, Thomas M.: Geometrical and statistical properties of systems of linear inequalities with applications in pattern recognition. In: *IEEE transactions on electronic computers* (1965), Nr. 3, S. 326–334
- [21] DEMŠAR, Janez: Statistical comparisons of classifiers over multiple data sets. In: *Journal of Machine learning research* 7 (2006), Nr. Jan, S. 1–30
- [22] DU, Ke-Lin ; JIANG, Bingchun ; LU, Jiabin ; HUA, Jingyu ; SWAMY, MNS: Exploring kernel machines and support vector machines: Principles, techniques, and future directions. In: *Mathematics* 12 (2024), Nr. 24, S. 3935
- [23] DUDA, R ; HART, P ; STORK, D ; IONESCU, Alexandru: *Pattern classification, chapter nonparametric techniques*. 2000

- [24] ESPADOTO, Mateus ; APPLEBY, Gabriel ; SUH, Ashley ; CASHMAN, Dylan ; LI, Mingwei ; SCHEIDEGGER, Carlos ; ANDERSON, Erik W. ; CHANG, Remco ; TELEA, Alexandru C.: UnProjection: Leveraging inverse-projections for visual analytics of high-dimensional data. In: *IEEE Transactions on Visualization and Computer Graphics* 29 (2021), Nr. 2, S. 1559–1572
- [25] FENG, Siyi ; WANG, Huaixiu: Comparison of PCA and LDA dimensionality reduction algorithms based on wine dataset. In: *2021 33rd Chinese Control and Decision Conference (CCDC)* IEEE, 2021, S. 2791–2796
- [26] FISHER, Ronald A.: The use of multiple measurements in taxonomic problems. In: *Annals of eugenics* 7 (1936), Nr. 2, S. 179–188
- [27] FRIEDMAN, Jerome H.: Regularized discriminant analysis. In: *Journal of the American statistical association* 84 (1989), Nr. 405, S. 165–175
- [28] FUKUNAGA, Keinosuke: *Introduction to statistical pattern recognition*. Elsevier, 2013
- [29] GAO, Hui ; DAVIS, James W.: Why direct LDA is not equivalent to LDA. In: *Pattern Recognition* 39 (2006), Nr. 5, S. 1002–1006
- [30] GOLDBERG, David E. ; HOLLAND, John H.: Genetic Algorithms and Machine Learning. In: *Machine Learning* 3 (1988), Oktober, Nr. 2-3, 95–99. <http://dx.doi.org/10.1023/a:1022602019183>. – DOI 10.1023/a:1022602019183. – ISSN 1573–0565
- [31] GOLUB, Gene H. ; VAN LOAN, Charles F.: *Matrix computations*. Bd. 3. JHU press, 2013
- [32] GUYON, Isabelle ; ELISSEEFF, André: An introduction to variable and feature selection. In: *Journal of machine learning research* 3 (2003), Nr. Mar, S. 1157–1182
- [33] HASAN, Basna Mohammed S. ; ABDULAZEEZ, Adnan M.: A review of principal component analysis algorithm for dimensionality reduction. In: *Journal of Soft Computing and Data Mining* 2 (2021), Nr. 1, S. 20–30
- [34] HASTIE, Trevor ; TIBSHIRANI, Robert ; FRIEDMAN, Jerome u. a.: *The elements of statistical learning*. 2009
- [35] HORST, Allison M. ; HILL, Alison P. ; GORMAN, Kristen B.: Palmer Archipelago Penguins Data in the palmerpenguins R Package-An Alternative to Anderson’s Irises. In: *R Journal* 14 (2022), Nr. 1, S. 244
- [36] JAIN, Anil K. ; DUIN, Robert P. W. ; MAO, Jianchang: Statistical pattern recognition: A review. In: *IEEE Transactions on pattern analysis and machine intelligence* 22 (2000), Nr. 1, S. 4–37
- [37] JALILI, Amir ; SALEKI, Ziba ; LUO, YA ; PAN, Feng ; CHEN, Ai X. ; DRAAYER, Jerry P.: Performance of various kernel functions for mass prediction with support vector machine. In: *The European Physical Journal A* 61 (2025), Nr. 6, S. 143
- [38] KABIR, Md F. ; CHEN, Tianjie ; LUDWIG, Simone A.: A performance analysis of dimensionality reduction algorithms in machine learning models for cancer prediction. In: *Healthcare Analytics* 3 (2023), S. 100125

- [39] KANADE, Varun: *Machine Learning – Michaelmas Term 2016: Lectures 4, 5: Basis Expansion, Regularization, Validation*. Lecture notes, Department of Computer Science, University of Oxford. <https://www.cs.ox.ac.uk/people/varun.kanade/teaching/ML-MT2016/lectures/lecture04.pdf>. Version: 2016. – Accessed: 2026-06-25
- [40] KIM, Donghwan ; PARK, Seung H. ; BAEK, Jun-Geol: A Kernel fisher discriminant analysis-based tree ensemble classifier: Kfda forest. In: *arXiv preprint arXiv:2606.29053* (2026)
- [41] KOHAVI, Ron ; JOHN, George H.: Wrappers for feature subset selection. In: *Artificial intelligence* 97 (1997), Nr. 1-2, S. 273–324
- [42] KRZANOWSKI, Wojtek J. ; JONATHAN, Philip ; MCCARTHY, WV ; THOMAS, Mervyn R.: Discriminant analysis with singular covariance matrices: methods and applications to spectroscopic data. In: *Journal of the Royal Statistical Society Series C: Applied Statistics* 44 (1995), Nr. 1, S. 101–115
- [43] LARA-ARELLANO, Edgar ; TAKACS, Andras ; TOVAR-ARRIAGA, Saul ; RODRÍGUEZ-RESÉNDIZ, Juvenal: Feature Generation with Genetic Algorithms for Imagined Speech Electroencephalogram Signal Classification. In: *Eng* 6 (2025), Nr. 4, S. 75
- [44] LI, Zhengxin ; NIE, Feiping ; WANG, Rong ; LI, Xuelong: A revised formation of trace ratio LDA for small sample size problem. In: *IEEE transactions on neural networks and learning systems* 36 (2024), Nr. 3, S. 5803–5809
- [45] LIU, Jingjing ; FENG, Manlong ; XIU, Xianchao ; LIU, Wanquan ; ZENG, Xiaoyang: Efficient and robust sparse linear discriminant analysis for data classification. In: *IEEE Transactions on Emerging Topics in Computational Intelligence* 9 (2024), Nr. 1, S. 617–629
- [46] LÓPEZ-IBÁÑEZ, Manuel ; DUBOIS-LACOSTE, Jérémie ; CÁCERES, Leslie P. ; BIRATTARI, Mauro ; STÜTZLE, Thomas: The irace package: Iterated racing for automatic algorithm configuration. In: *Operations Research Perspectives* 3 (2016), S. 43–58
- [47] MAHADI, Maaz ; BALLAL, Tarig ; MOINUDDIN, Muhammad ; AL-NAFFOURI, Tareq Y. ; AL-SAGGAF, Ubaid M.: Regularized linear discriminant analysis using a nonlinear covariance matrix estimator. In: *IEEE Transactions on Signal Processing* 72 (2024), S. 1049–1064
- [48] MANHRAWY, Ibrahim I. ; FATHI, Hanaa ; ALSEKAIT, Deema M. ; ALTAWIL, Arar ; KELANY, Ayda K.: Hybrid feature selection and classification model using high-dimensional data based on a metaheuristic algorithm for brain cancer diagnosis. In: *Scientific Reports* 16 (2026), Nr. 1, S. 11909
- [49] MARTINEZ, Aleix M. ; KAK, Avinash C.: Pca versus lda. In: *IEEE transactions on pattern analysis and machine intelligence* 23 (2001), Nr. 2, S. 228–233
- [50] MCLACHLAN, Geoffrey J.: *Discriminant analysis and statistical pattern recognition*. Bd. 93. Wiley New York, 1992

- [51] MEDINA, Marco A. ; DAVIS, Richard A. ; SAMORODNITSKY, Gennady: Insights into kernel pca with application to multivariate extremes. In: *SIAM Journal on Mathematics of Data Science* 7 (2025), Nr. 2, S. 777–801
- [52] MEDINA, Víctor David G. ; MESA, Héctor Gabriel A. ; LOBATO, Adriana Laura L. ; MONTES, Efrén M.: Genetic Projective Discriminant Analysis. In: *2025 IEEE Latin American Conference on Computational Intelligence (LA-CCI)*, 2025, S. 1–6
- [53] MIKA, Sebastian ; RATSCH, Gunnar ; WESTON, Jason ; SCHOLKOPF, Bernhard ; MULLERS, Klaus-Robert: Fisher discriminant analysis with kernels. In: *Neural networks for signal processing IX: Proceedings of the 1999 IEEE signal processing society workshop (cat. no. 98th8468)* Ieee, 1999, S. 41–48
- [54] MONTGOMERY, Douglas C. ; PECK, Elizabeth A. ; VINING, G G.: *Introduction to Linear Regression Analysis, 6e Solutions Manual*. John Wiley & Sons, 2022
- [55] MOURIK, Frank van ; HAERI, Maryam A. ; BUKHSH, Faiza A. ; AHMED, Faizan: Itershap: An xai-based feature selection method for small high-dimensional datasets. In: *Proceedings of the Future Technologies Conference* Springer, 2024, S. 526–545
- [56] MURDOCH, W J. ; SINGH, Chandan ; KUMBIER, Karl ; ABBASI-ASL, Reza ; YU, Bin: Definitions, methods, and applications in interpretable machine learning. In: *Proceedings of the National Academy of Sciences* 116 (2019), Nr. 44, S. 22071–22080
- [57] NANGA, Salifu ; BAWAH, Ahmed T. ; ACQUAYE, Benjamin A. ; BILLA, Mac-Issaka ; BAETA, Francis D. ; ODAI, Nii A. ; OBENG, Samuel K. ; NSIAH, Ampem D.: Review of dimension reduction methods. In: *Journal of Data Analysis and Information Processing* 9 (2021), Nr. 3, S. 189–231
- [58] NAVARRO-ACOSTA, Jesús A. ; DIOS, Jesús-Adolfo Mejía-de ; GONZÁLEZ LARA, José M. ; SANCHEZ CARRERA, Edgar J.: Bayesian Networks and Machine Learning Approaches Applied to Social Backwardness. In: *Computational Economics* (2025), S. 1–28
- [59] NEHA, Fnu ; SHUKLA, Deepak K.: Radiomics in Medical Imaging: Methods, Applications, and Challenges. In: *Journal of Imaging* 12 (2026), Nr. 6, S. 220
- [60] NETO, Mário P. ; PAULOVICH, Fernando V.: Multivariate data explanation by jumping emerging patterns visualization. In: *IEEE Transactions on Visualization and Computer Graphics* 30 (2022), Nr. 2, S. 1549–1563
- [61] NGUYEN, Lan H. ; HOLMES, Susan: Ten quick tips for effective dimensionality reduction. In: *PLoS computational biology* 15 (2019), Nr. 6, S. e1006907
- [62] NIU, Guo ; MA, Zhengming: Local quasi-linear embedding based on kronecker product expansion of vectors. In: *Journal of Intelligent & Fuzzy Systems* 41 (2021), Nr. 1, S. 2195–2205
- [63] NOGALES, Rubén E ; BENALCÁZAR, Marco E.: Analysis and evaluation of feature selection and feature extraction methods. In: *International Journal of Computational Intelligence Systems* 16 (2023), Nr. 1, S. 153

- [64] OETTL, Felix C. ; OEDING, Jacob F. ; FELDT, Robert ; LEY, Christophe ; HIRSCHMANN, Michael T. ; SAMUELSSON, Kristian ; GROUP, ESSKA Artificial Intelligence W.: *The artificial intelligence advantage: Supercharging exploratory data analysis*. 2024
- [65] PENG, Dehua ; GUI, Zhipeng ; WU, Huayi: Interpreting the curse of dimensionality from distance concentration and manifold effect. In: *arXiv preprint arXiv:2401.00422* (2023)
- [66] PEREIRA, Dulce G. ; AFONSO, Anabela ; MEDEIROS, Fátima Melo: Overview of Friedman's test and post-hoc analysis. In: *Communications in Statistics-Simulation and Computation* 44 (2015), Nr. 10, S. 2636–2653
- [67] RABBI, Md Sakhawat H. ; BARI, Md M. ; DEBNATH, Tanoy ; RAHMAN, Anichur ; DAS, Avik K. ; HOSSAIN, Md P. ; MUHAMMAD, Ghulam: Performance evaluation of optimal ensemble learning approaches with PCA and LDA-based feature extraction for heart disease prediction. In: *Biomedical Signal Processing and Control* 101 (2025), S. 107138
- [68] RAUDYS, Sarunas J. ; JAIN, Anil K. u. a.: Small sample size effects in statistical pattern recognition: Recommendations for practitioners. In: *IEEE Transactions on pattern analysis and machine intelligence* 13 (1991), Nr. 3, S. 252–264
- [69] REMAKI, Lakhdar: RBF Kernel Parameter Formula for Data Classification Methods. In: *arXiv preprint arXiv:2604.01258* (2026)
- [70] RUDIN, Cynthia: Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. In: *Nature machine intelligence* 1 (2019), Nr. 5, S. 206–215
- [71] SALAMA, Gouda I. ; ABDELHALIM, MB ; ZEID, MA E. u. a.: Breast cancer diagnosis on three different datasets using multi-classifiers. (2012)
- [72] SCHOLKOPF, Bernhard ; SMOLA, Alexander J.: *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT press, 2018
- [73] SEVILLA, Departamento de Ciencias de la Computación e Inteligencia A. d.: *Algoritmos Genéticos*. https://www.cs.us.es/~fsancho/Blog/posts/Algoritmos_Geneticos.md.html, . – Accedido el 7 de septiembre de 2026
- [74] SHI, Wenya ; WU, Gang: New algorithms for trace-ratio problem with application to high-dimension and large-sample data dimensionality reduction. In: *Machine Learning* 113 (2024), Nr. 7, S. 3889–3916
- [75] SIEDLECKI, Wojciech ; SKLANSKY, Jack: A note on genetic algorithms for large-scale feature selection. In: *Pattern recognition letters* 10 (1989), Nr. 5, S. 335–347
- [76] SIGILLITO, Vincent G. ; WING, Simon P. ; HUTTON, Larrie V. ; BAKER, Kile B.: Classification of radar returns from the ionosphere using neural networks. In: *Johns Hopkins APL Technical Digest* 10 (1989), Nr. 3, S. 262–266
- [77] SMITH, Jack W. ; EVERHART, James E. ; DICKSON, William C. ; KNOWLER, William C. ; JOHANNES, Robert S.: Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. In: *Proceedings of the annual symposium on computer application in medical care*, 1988, S. 261

- [78] SORZANO, Carlos Oscar S. ; VARGAS, Javier ; MONTANO, A P.: A survey of dimensionality reduction techniques. In: *arXiv preprint arXiv:1403.2877* (2014)
- [79] SOUSA PAPA, Ângela W. ; OLIVEIRA, Anne N. ; LAWRYNHUK URBANO FERREIRA, Rannapaula ; OLIVEIRA ROSENDO, Geovanna B. ; MAURÍCIO SENA-EVANGELISTA, Karine C. ; GOMES LIMA, Josivan ; BARBOSA JR, Fernando ; MORAIS, Camilo de L. d. ; LIMA, Kássio M. ; MENDONÇA ARAÚJO, Renata u. a.: Nuclear magnetic resonance combined with genetic algorithm with linear discriminant analysis (GA-LDA) is a suitable model for discriminating urinary metabolomic profiles of individuals with glycemic disorders. In: *Annals of Medicine* 57 (2025), Nr. 1, S. 2566870
- [80] THRUN, PhD Michael C. u. a.: Uncovering high-dimensional structures of projections from dimensionality reduction methods. In: *MethodsX* 7 (2020), S. 101093
- [81] VENABLES, William N. ; RIPLEY, Brian D.: *Modern applied statistics with S*. springer, 2002
- [82] VENKAT, Naveen: The curse of dimensionality: Inside out. In: *Pilani (IN): Birla Institute of Technology and Science, Pilani, Department of Computer Science and Information Systems* 10 (2018), Nr. 10.13140
- [83] WANG, Yangyang ; GAO, Xiaoguang ; RU, Xinxin ; SUN, Pengzhan ; WANG, Jihan: A hybrid feature selection algorithm and its application in bioinformatics. In: *PeerJ Computer Science* 8 (2022), S. e933
- [84] WANG, Ying ; FAN, Renjie ; CHENG, Lei ; GONG, Bo ; LIU, Jiahao: An Improved Adaptive NSGA-II with Multiple Filtering for High-Dimensional Feature Selection. In: *Electronics* 15 (2026), Nr. 1, S. 236
- [85] YANG, Hannan ; LIN, DY ; LI, Quefeng: An efficient greedy search algorithm for high-dimensional linear discriminant analysis. In: *Statistica Sinica* 33 (2023), Nr. SI, S. 1343
- [86] ZEBARI, Rizgar ; ABDULAZEEZ, Adnan ; ZEEBAREE, Diyar ; ZEBARI, Dilovan ; SAEED, Jwan: A comprehensive review of dimensionality reduction techniques for feature selection and feature extraction. In: *Journal of Applied Science and Technology Trends* 1 (2020), Nr. 1, S. 56–70
- [87] ZHANG, Mengqi ; TREDER, Matthias ; MARSHALL, David ; LI, Yuhua: Fast explanation of RBF-kernel SVM models using activation patterns. In: *2024 International Joint Conference on Neural Networks (IJCNN)* IEEE, 2024, S. 1–8
- [88] ZHAO, Shuping ; ZHANG, Bob ; YANG, Jian ; ZHOU, Jianhang ; XU, Yong: Linear discriminant analysis. In: *Nature Reviews Methods Primers* 4 (2024), Nr. 1, S. 70