



Universidad Veracruzana



COVNNEC-App

Genetic Non-Linear Polynomial Discriminant Analysis (GNLPDA)

Instituto de Investigaciones en Inteligencia Artificial
Maestría en Inteligencia Artificial

Research Group on Computer Vision, Neural Networks
Evolutionary Computation and Applications


Presenta: Angel García Báez

Director: Héctor Gabriel Acosta Mesa
Codirector: Adriana Laura López Lobato

Introducción


- **Aprendizaje automático:** Enseñar a las computadoras a aprender directamente a partir de datos para identificar patrones y tomar decisiones.

Aprendizaje supervisado (Clasificación/Predicción)



LDA como método discriminante

LDA: Maximiza la separación entre grupos.



Desafíos: Dimensionalidad, SSS, no linealidad

Maldición de la dimensionalidad

Obs.	X1	X2	X3	X4	X5
1					
2					
3					

$$P > N$$

Problema de muestras pequeñas (SSS)


Obs.	X1	X2	X3	X4	X5	Class
1						
2						
3						
4						
5						

$$P > n1$$


$$P > n2$$

Separabilidad de los datos


Linealmente separable




No Linealmente separable




Taxonomía de reducción de dimensionalidad



Taxonomía de reducción de dimensionalidad



Taxonomía de reducción de dimensionalidad



Expansión polinomial de características

- Construye nuevas características a partir de las originales usando una estructura de polinomio de grado (D).


Obs.	X_1	X_2	X_1^2	X_1X_2	X_2^2	X_1^3	$X_1^2X_2$	$X_1X_2^2$	X_2^3	X_1^4	$X_1^3X_2$	$X_1^2X_2^2$	$X_1X_2^3$	X_2^4
1														
2														
3														
4														
5														
6														

Diagram illustrating the polynomial expansion of features (Grado) for 6 observations across 15 features. The features are grouped by degree (Grado):


- Grado = 1:** X_1 , X_2
- Grado = 2:** X_1^2 , X_1X_2 , X_2^2
- Grado = 3:** X_1^3 , $X_1^2X_2$, $X_1X_2^2$, X_2^3
- Grado = 4:** X_1^4 , $X_1^3X_2$, $X_1^2X_2^2$, $X_1X_2^3$, X_2^4

Costo de la expansión polinomial

Captura relaciones no lineales.



Crece rápidamente en complejidad



$$D = \binom{d + P}{P} - 1$$

Estado del arte

Tabla 1: Estado del arte		
Autor y fecha	Apartado	Contribución
Yang et al. (2023); Araveeporn & Banditvilai (2023)	Variantes Lineales (LDA Regularizado)	Añaden regularización al modelo clásico para estabilizar matrices en problemas de alta dimensionalidad.
Agatra et al. (2025); Buhas et al. (2024)	Variantes Lineales (PCA-LDA)	Reducen la dimensionalidad en dos etapas para eliminar redundancia antes de clasificar.
Li et al. (2024); Shi & Wu (2024)	Variantes Lineales (Trace-Ratio)	Optimizan directamente la relación de dispersión interclase/intraclase para matrices singulares.
Medina et al. (2025); Briscik et al. (2023); Du et al. (2024)	Métodos Kernel (KPCA, KFDA)	Emplean mapeos no lineales para separar clases complejas, asumiendo pérdida de interpretabilidad.
Jalili et al. (2025); Remaki (2026)	Métodos Kernel (SVM)	Modelan fronteras altamente no lineales; exigen control estricto de parámetros para evitar sobreajuste.
Al-Milli et al. (2021); Wang et al. (2026)	Selección Evolutiva (Algoritmos Genéticos)	Extraen subconjuntos de variables evadiendo óptimos locales sin incurrir en costos computacionales prohibitivos.
Wang et al. (2022); Manhrawy et al. (2026)	Métodos Híbridos	Combinan filtrado estadístico inicial con metaheurísticas para acelerar la selección de variables.
Medina et al. (2025)	Selección Evolutiva (GPDA)	Maximizan la separabilidad evaluando proyecciones directamente mediante el índice de silueta (sin invertir matrices).

Definición del problema

- **Limitaciones clásicas:** El Análisis Discriminante Lineal (LDA) permite construir reglas de clasificación y proyecciones discriminantes de baja dimensión; sin embargo, presenta limitaciones ante fronteras de decisión no lineales y se vuelve inestable bajo escenarios SSS.
- **Costo de la Expansión:** Las transformaciones polinomiales mitigan ciertas formas de no linealidad, pero esto puede introducir términos redundantes o irrelevantes, aumentando el riesgo de sobreajuste y la inestabilidad asociada al problema SSS.
- **Brecha metodológica:** Existe una brecha entre los métodos lineales, que son proyectables y trazables pero limitados ante estructuras no lineales, y las estrategias no lineales o expansiones explícitas, que aumentan la flexibilidad del modelo pero pueden perder compacidad, estabilidad e interpretabilidad



Pregunta e hipótesis

Pregunta de investigación

¿Es posible combinar la expansión explícita de característica con reducción de dimensionalidad mediante selección evolutiva para separar datos no lineales y proyectarlos en hasta tres dimensiones?

Hipótesis

La selección de variables sobre una expansión polinomial explícita permitirá obtener exactitudes sin diferencias estadísticamente significativas frente a referencias no lineales, con la ventaja de generar proyecciones compactas y trazables.



Objetivos

Objetivo general

Diseñar e implementar un esquema híbrido que integre expansión polinomial explícita, selección evolutiva en dos etapas y análisis discriminante para mejorar separabilidad y visualización en baja dimensión.


Objetivos específicos

- **Caracterizar:** las limitaciones del Análisis Discriminante Lineal.
- **Diseñar e implementar** un mecanismo de selección evolutiva.
- **Evaluar** experimentalmente el desempeño del método propuesto.
- **Analizar y comparar** las proyecciones logradas en baja dimensión.
- **Analizar** estadísticamente las diferencias entre los métodos evaluados.




Propuesta: idea intuitiva

Idea intuitiva



Propuesta: GNLPPDA en dos etapas



Configuración del algoritmo evolutivo

Tabla 2: Configuración del algoritmo evolutivo	
Componente	Configuración
Representación	Binaria (Cromosomas de tamaño N)
Función de aptitud	$\text{Fit1} = \text{Accuracy}(\text{cv5}) - \lambda(n/N)$ $\text{Fit2} = \text{Accuracy}(\text{cv5}) - \lambda(n^*/N^*)$
Selección de padres	Toreno binario
Oprador de cruza	Cruza de un solo punto
Operador de mutación	Mutación bit flip
Elitismo	Los mejores 2 de la generación pasan directo
Mecanismo de remplazo	Reemplazo generacional con elitismo
Clasificador	LDA MASS

Calibración de parámetros

Tabla 3: Parámetros calibrados del algoritmo con Irace					
Parametro	Descripción	Tipo	Rango min	Rango max	Valores finales
n_gen	Número de Generaciones	Entero (i)	20	100	94
popSize	Tamaño de Población	Entero (i)	20	100	64
p_cruza	Probabilidad de Cruza	Real (r)	0.4	0.95	0.9
p_mut	Probabilidad de Mutación	Real (r)	0.05	0.2	0.05
lambda	Factor de Penalización (λ)	Real (r)	0.01	0.2	0.01

Diseño experimental

Tabla 4: Conjuntos de datos a evaluar utilizados en la evaluación experimental

Dataset	Muestras	Variables	Atributos expandidos	Clases	Característica
penguins	342	4	14	3	Linealmente separable
wines	178	13	104	3	Linealmente separable
Breast Cancer (WDBC)	569	30	495	2	Alta dimensionalidad
Ionosphere	351	34	629	2	Alta dimensionalidad
Cebolla3D	300	3	9	3	No lineal
Cebolla10D	300	10	65	3	No lineal
Cebolla20D	300	20	230	3	No lineal
pimadiabetes	768	8	44	2	Fuerte traslape
Indicadores 2015	2446	12	90	5	Muchas observaciones
Indicadores 2020	2470	12	90	5	Muchas observaciones

Diseño experimental

Tabla 5: Casos sintéticos Cebolla para evaluar problema sss.

Caso	Muestras	Atributos	Atributos expandido	Clases	Muestras por clase
1	150	3	9	3	50
2	150	10	65	3	50
3	15	3	9	3	5
4	15	10	65	3	5
5	15	15	135	3	5
5	15	15	135	3	5
6	15	17	170	3	5

Diseño experimental

Tabla 6. Métodos utilizados para la comparación experimental.

Método	Propósito en la comparación
LDA MASS	Línea base lineal y proyectiva; implementación usada internamente por GNLPDA
QDA	Clasificador discriminante con fronteras cuadráticas
KFDA Gauss	Alternativa kernel de Fisher para separación no lineal y proyección
SVM Pol(2)	Comparación frente a una transformación polinomial implícita de segundo grado
SVM Pol(3)	Comparación frente a una transformación polinomial implícita de mayor orden
SVM Gauss	Clasificador kernel no lineal ampliamente utilizado
GNLPDA	Método propuesto para tratar la no linealidad y ofrecer proyecciones

Diseño experimental

- **Diseño en bloques:**

Se generaron 30 muestras por *dataset* (partición 70/30) para evaluar y comparar todos los algoritmos bajo las mismas condiciones de datos.


- **Prueba de Friedman:** Prueba no paramétrica global utilizada para detectar si existen diferencias estadísticas significativas entre los algoritmos.
- **Pruebas Post-hoc de nemenyi:** Análisis por pares utilizado (tras Friedman) para identificar específicamente qué algoritmos son estadísticamente diferentes entre sí.

Resultados: Problema de SSS

Caso cebolla ideal (150 obs., 3 variables)


LDA Clásico

Obs: 150 | Vars: 3 | Terms: 9




LDA MASS

Obs: 150 | Vars: 3 | Terms: 9



KFDA (Kernel Gaussiano)

Obs: 150 | Vars: 3 | $\sigma: 0.06$




Resultados: Problema de SSS

Caso cebolla con muestras pequeñas (5 obs., 10 variables)


LDA Clásico

Obs: 15 | Vars: 10 | Terms: 65




LDA MASS

Obs: 15 | Vars: 10 | Terms: 65




KFDA (Kernel Gaussiano)

Obs: 15 | Vars: 10 | $\sigma: 0.044$




Resultados: Proyecciones

Caso cebolla 3D






Variables originales por pares,
Caso: Cebolla 3D




Resultados: Proyecciones

Caso cebolla 3D (3 clases)




Resultados: Proyecciones

Caso Pima diabetes (2 clases)




Resultados: Proyecciones

Caso Pima diabetes (2 clases)




Resultados: Proyecciones

Caso Indicadores 2020 (5 clases)



Resultados: Proyecciones


Caso Indicadores 2020 (5 clases)




Resultados: Proyecciones

Caso Indicadores 2020 (5 clases)


LDA MASS (Espacio 3D)



KFDA (Kernel Gauss)




GMLPDA (Propuesto)



Resultados: Comparativas de rendimiento

Caso cebolla (3 clases)


Comparativa de algoritmos - Cebolla3D



Resultados: Comparativas de rendimiento


Comparativa global

$\chi^2 = 142.551$
G.L. = 6
P<0.001




Comparativa solo no lineales

$\chi^2 = 62.972$
G.L. = 4
P<0.001



Resultados: Comparativas de rendimiento

Caso Pima diabetes (2 clases)




Resultados: Comparativas de rendimiento

Comparativa global

$\chi^2 = 49.158$

G.L. = 6

P<0.001




Comparativa solo no lineales

$\chi^2 = 15.129$


G.L. = 4

P<0.001



Resultados: Comparativas de rendimiento


Caso Indicadores 2020 (5 clases)



Resultados: Comparativas de rendimiento


Comparativa global

$\chi^2 = 169.856$
G.L. = 6
P<0.001



Comparativa solo no lineales

$\chi^2 = 103.811$
G.L. = 4
P<0.001




Resultados: Comparativas de rendimiento

Tabla 7: Resumen de rendimiento y tiempo de GNLPDA


Dataset	Variables	Min	Max	Mediana	Media	Desv. Est.	Tiempo (Media)	Tiempo (D.E)
penguins	4	0.9	1	0.98	0.98	0.01	4.68	5.68
wines	13	0.8	1	0.94	0.94	0.04	882.39	441.21
Breast Cancer (WDBC)	30	0.9	0.98	0.96	0.96	0.01	2496.78	958.95
Ionosphere	34	0.8	0.95	0.89	0.89	0.03	3221.6	1585.83
Cebolla3D	3	0.9	0.99	0.97	0.97	0.02	3.83	4.65
Cebolla10D	10	0.8	0.97	0.9	0.9	0.03	2238.17	1102.28
Cebolla20D	20	0.7	0.93	0.83	0.82	0.05	1772.73	596.16
pimadiabetes	8	0.7	0.81	0.77	0.77	0.02	515.97	292.13
Indicadores 2015	12	0.9	0.94	0.92	0.92	0.01	1245.84	321.24
Indicadores 2020	12	0.9	0.96	0.93	0.93	0.01	715.43	39.82

GNLPDA es una alternativa intermedia
entre interpretabilidad y manejo de la no linealidad.




LDA / QDA

simples · eficientes · interpretables



GNLPDA

explícito · no lineal · trazable



SVM / KFDA

flexibles · implícitos · menos
trazables



Conclusiones

- **Se logro desarrollar e implementar el marco de expansión y selección de variables.**
- **Es capaz de tratar con la no linealidad**
- **Mantiene estabilidad computacional frente al SSS problem.**
- **No llega a superar sistemáticamente a los kernels pero tiene un desempeño competitivo ante ellos.**
- **Logra proyecciones en baja dimensión que resumen la geometría interna de los conjuntos de datos.**
- **El modelo mantiene trazabilidad.**



Trabajo a futuro

- **Experimentar con otras funciones de fitness para inducir la búsqueda (F1-score)**
- **Experimentar con otra métaheurística de búsqueda (Evolución diferencial)**



GRACIAS POR SU ATENCIÓN



Referencias

Agatra, D. F. N., Marutho, D., & Xiong, X. (2025). Evaluating PCA and LDA to improve machine learning classification of consumer behavior in health informatics. *Journal of Intelligent Computing and Health Informatics (JICHI)*. Vol, 6(1).

Al-Milli, N., Hudaib, A., & Obeid, N. (2021). Population diversity control of genetic algorithm using a novel injection method for bankruptcy prediction problem. *Mathematics*, 9(8), 823.

Araveeporn, A., & Banditvilai, S. (2023). A classification study in high-dimensional data of linear discriminant analysis and regularized discriminant analysis. *WSEAS Trans. Math*, 22, 315–323.

Bahloul, R., Hewahi, N., & Harrath, Y. (2025). FastTree-guided genetic algorithm for credit scoring feature selection. *Computers*, 14(12), 566.

Briscik, M., Dillies, M.-A., & Déjean, S. (2023). Improvement of variables interpretability in kernel PCA. *BMC Bioinformatics*, 24(1), 282.

Buhas, B. A., Muntean, L. A.-M., Ploussard, G., Feciche, B. O., Andras, I., Toma, V., Maghiar, T. A., Crişan, N., Ştiufiuc, R.-I., & Lucaciu, C. M. (2024). Renal cell carcinoma discrimination through attenuated total reflection fourier transform infrared spectroscopy of dried human urine and machine learning techniques. *International Journal of Molecular Sciences*, 25(18), 9830.

Referencias

- Du, K.-L., Jiang, B., Lu, J., Hua, J., & Swamy, M. (2024). Exploring kernel machines and support vector machines: Principles, techniques, and future directions. *Mathematics*, 12(24), 3935.
- Jalili, A., Saleki, Z., Luo, Y., Pan, F., Chen, A. X., & Draayer, J. P. (2025). Performance of various kernel functions for mass prediction with support vector machine. *The European Physical Journal A*, 61(6), 143.
- Kim, D., Park, S. H., & Baek, J.-G. (2018). A KERNEL FISHER DISCRIMINANT ANALYSIS-BASED TREE ENSEMBLE CLASSIFIER: KFDA FOREST. *International Journal of Industrial Engineering*, 25(5).
- Lara-Arellano, E., Takacs, A., Tovar-Arriaga, S., & Rodríguez-Reséndiz, J. (2025). Feature generation with genetic algorithms for imagined speech electroencephalogram signal classification. *Eng*, 6(4), 75.
- Li, Z., Nie, F., Wang, R., & Li, X. (2024). A revised formation of trace ratio LDA for small sample size problem. *IEEE Transactions on Neural Networks and Learning Systems*.
- Liu, J., Feng, M., Xiu, X., Liu, W., & Zeng, X. (2024). Efficient and robust sparse linear discriminant analysis for data classification. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 9(1), 617–629.