



Universidad Veracruz



COVNNEC-App

Mejora del discriminante lineal usando transformaciones polinomiales y algoritmos genéticos

Instituto de Investigaciones en Inteligencia Artificial
Maestría en Inteligencia Artificial

Research Group on Computer Vision, Neural Networks
Evolutionary Computation and Applications

Presenta: Angel García Báez

Director: Héctor Gabriel Acosta Mesa
Codirector: Adriana Laura López Lobato


Índice

- Introducción
- Definición del problema
- Pregunta de investigación
- Propuesta
- Justificación
- Hipótesis
- Objetivos
- Metodología
- Resultados preliminares
- Observaciones finales
- Trabajo en proceso
- Referencias

Motivación

- **Aprendizaje automático:** Enseñar a las computadoras a aprender directamente a partir de datos para identificar patrones y tomar decisiones.

Aprendizaje supervisado (Clásificación/Predicción)



Problemas en el machine learning

Maldición de la dimensionalidad

Obs.	X1	X2	X3	X4	X5	X6	X7
1							
2							
3							
4							
5							

7 vars > 5 obs




Técnicas de reducción de dimensionalidad

- Técnicas que toman las variables originales y crean nuevas variables proyectadas en un menor número de dimensiones.


Obs.	X1	X2	X3	X4	X5
1					
2					
3					
4					
5					
6					



Obs.	X1'	X2'	X3'
1			
2			
3			
4			
5			
6			




Técnicas de reducción de dimensionalidad




Técnicas de reducción de dimensionalidad


**PCA: Máxima la
varianza**





**LDA: Maximiza la separación
entre grupos**



Técnicas de reducción de dimensionalidad




Técnicas de reducción de dimensionalidad




Problemas en el machine learning

Separabilidad de los datos

Linealmente separable



No Linealmente separable



Técnicas de para tratar la no-linealidad

- **Expansión de características:** Construye nuevas características a partir de las originales usando una estructura de polinomio.


Obs.	X_1	X_2	X_1^2	X_1X_2	X_2^2	X_1^3	$X_1^2X_2$	$X_1X_2^2$	X_2^3	X_1^4	$X_1^3X_2$	$X_1^2X_2^2$	$X_1X_2^3$	X_2^4
1														
2														
3														
4														
5														
6														

Diagram illustrating the expansion of features into polynomial degrees:


- Grado = 1:** X_1 , X_2
- Grado = 2:** X_1^2 , X_1X_2 , X_2^2
- Grado = 3:** X_1^3 , $X_1^2X_2$, $X_1X_2^2$, X_2^3
- Grado = 4:** X_1^4 , $X_1^3X_2$, $X_1^2X_2^2$, $X_1X_2^3$, X_2^4

Técnicas de para tratar la no-linealidad

Captura relaciones no lineales.



Crece rápidamente en complejidad



Limitaciones de las técnicas

Tecnica	Ventajas	Limitaciones
PCA	Reduce dimensionalidad.	- No supervisado - Sensible a la dimensionalidad - Sensible a la no linealidad
LDA	Reduce dimensionalidad de manera informada.	- Supervisado - Sensible a la dimensionalidad - Sensible a la no linealidad - Exige cumplimiento de supuestos de distribución
Wrapper	Selecciona subconjuntos de variables que aportan más al rendimiento de los modelos.	- Costo computacional alto al generar los modelos con los posibles subconjuntos.
Expansión polinomial	Captura relaciones no lineales	- Crece rápidamente con el numero de variables. - Alto consumo de recursos computacionales.



Definición del problema

- **Sensibilidad de Métodos Clásicos:** LDA, PCA y técnicas similares dependen estrictamente de la linealidad, cumplimiento de supuestos y de la invertibilidad de las matrices de dispersión.
- **Costo de la Expansión:** Las transformaciones polinomiales resuelven la no linealidad, pero aumentan considerablemente el número de variables y son costosas computacionalmente.
- Existe la necesidad de proyectar datos no lineales en baja dimensión (2D/3D) sin sacrificar la estabilidad matemática de los métodos clásicos y sin que sea computacionalmente intratable.



Pregunta de investigación

- **¿Es posible combinar el potencial de la expansión de características con la eficiencia de los métodos de reducción de dimensionalidad, mediante un esquema de selección inteligente, para lograr la separación de datos no lineales y su proyección en máximo 2D/3D?**



Propuesta

- Diseñar e implementar un algoritmo **WRAPPER** para selección de características que combine la expansión polinomial y la reducción de la dimensionalidad.



Justificación

- **Interpretabilidad:** A diferencia de las redes neuronales o SVM (Cajas Negras), este método permite conocer qué interacciones de variables generan la clasificación.
- **Visualización:** Permite "ver" la estructura de datos complejos en 2D o 3D con fronteras claras.
- **Parsimonia:** Encuentra el subconjunto mínimo necesario de variables para resolver el problema.



Hipótesis

La implementación de un mecanismo de selección de variables sobre una expansión polinomial permitirá alcanzar **índices de precisión estadísticamente equivalentes** a los modelos no lineales del estado del arte, con la ventaja distintiva de **filtrar la redundancia dimensional** para generar proyecciones visualizables en 2D y 3D que revelen la estructura de dispersión de las clases.



Objetivos

- **Objetivo general**

Desarrollar un esquema de extracción de características que combine la expansión polinomial con métodos de reducción de dimensionalidad clásica, mediante un mecanismo de selección inteligente, para mejorar la separabilidad y visualización de datos no lineales.


- **Objetivos particulares**

- **Evaluar** el impacto de la no linealidad en el desempeño de los métodos clásicos de reducción de dimensionalidad (como LDA).
- **Diseñar e implementar** un mecanismo de selección que optimice el espacio expandido eliminando los términos redundantes y permita su visualización en baja dimensión.
- **Validar** la efectividad del enfoque propuesto y su capacidad de separación.




Algoritmo propuesto

GENETIC NON LINEAL POLINOMIAL DISCRIMINANT ANALYSIS




Algoritmos genéticos

Es una técnica de optimización heurística basada en replicar el mecanismo de evolución y adaptación de los organismos.



BINARIO

1	1	0	1	0	1	1	0
---	---	---	---	---	---	---	---



Dataset y comparativa

Dataset	Muestras	Variables	Clases
penguins	342	4	3
Cebolla3D	300	3	3
Cancer Wisconsin	569	30	2


Método	Manejo de la linealidad	Visualizable
LDA	Lineal	Sí
QDA	Cuadrático	No
SVM (Poly 2)	No lineal	No
SVM (Poly 3)	No lineal	No
SVM (Gauss)	No lineal	No
GNLPDA (Prouesto)	No lineal	Sí

Algoritmo propuesto

Método	Manejo de la linealidad	Visualizable
LDA	Lineal	Sí
QDA	Cuadrático	No
SVM (Poly 2)	No lineal	No
SVM (Poly 3)	No lineal	No
SVM (Gauss)	No lineal	No
GNLPDA (Propuesto)	No lineal	Sí

Resultados Preliminares

Caso 1: Penguin Palmers




Resultados Preliminares

Caso 1: Penguin Palmers

GPN-LDA Projection: 1.2.penguins

Accuracy: 0.991 | Total Vars: 3



Variables
3/4


Términos
expandidos
3/9

Lin 1: MasaCorporal

Interact 2: LongitudPico*MasaCorporal, MasaCorporal*AnchoPico

Resultados Preliminares

Caso 2: Cebolla 3D




Resultados Preliminares

Caso 2: Cebolla 3D

GPN-LDA Projection: 3.1.Cebolla3D

Accuracy: 0.973 | Total Vars: 5




Variables
3/3

Términos
expandidos
5/9

Lin 2: V2, V3
Quad 3: V1², V2², V3²

Resultados Preliminares

Caso 3: Cancer Wisconsin




Resultados Preliminares

Caso 3: Cancer Wisconsin

GPN-LDA Projection: 4.1.CancerWisconsin

Accuracy: 0.977 | Total Vars: 27



Variables
11/30

Términos
expandidos
27 / 77

Lin 5: concave_points3, radius3, smoothness3, symmetry1, texture1

Quad 2: radius3², texture2²

Interact 20: compactness3*symmetry1, compactness3*texture3, concave_points3*texture1, radius2*concave_points3, radius2*radius3, radius2*texture1, smoothness3*com

Resultados Preliminares

Tabla 2: Resultados internos del algoritmo

Dataset	No. Vars	Vars E1	Vars E2	Accuracy	Precision	Recall	F1Score	Time (S)
penguins	4	3.00 ± 0.00	3.00 ± 0.00	0.99 ± 0.00	0.99 ± 0.00	0.98 ± 0.00	0.99 ± 0.00	1.46 ± 1.32
Cebolla3D	3	3.00 ± 0.00	5.00 ± 0.00	0.97 ± 0.00	0.98 ± 0.00	0.97 ± 0.00	0.97 ± 0.00	1.27 ± 1.12
CancerWisconsin	30	10.03 ± 2.04	21.10 ± 9.66	0.97 ± 0.00	0.96 ± 0.01	1.00 ± 0.00	0.98 ± 0.00	1607.91 ± 148.83



Resultados Preliminares

Tabla 3: Resultados comparativos

Dataset	LDA	QDA	SVM Poly2	SVM Poly3	SVM GAUSS	GNLPDA
penguins	0.99 ± 0.02	0.99 ± 0.02	0.88 ± 0.06	0.98 ± 0.02	0.98 ± 0.02	0.99 ± 0.00
Cebolla3D	0.35 ± 0.07	0.94 ± 0.05	0.98 ± 0.02	0.50 ± 0.09	0.99 ± 0.02	0.97 ± 0.00
Cancer Wisconsin	0.96 ± 0.03	0.96 ± 0.02	0.87 ± 0.05	0.96 ± 0.03	0.97 ± 0.03	0.97 ± 0.00

Conclusiones

- Los casos de prueba tienen más observaciones que sujetos.
- El algoritmo propuesto se desempeña bien ante un caso lineal y no lineal.
- El rendimiento de la precisión alcanzado es bueno.
- Obtiene proyecciones que se observan linealmente separables.
- Se puede conocer las variables que selecciona para lograr las proyecciones y el rendimiento mostrado.



Referencias

- Asaduzzaman, A., Uddin, M. R., & Sibai, F. N. (2024). Dimensionality reduction by machine learning for cost-effective data analysis.
- Barradas-Palmeros, J.-A., Mezura-Montes, E., Rivera-López, R., & Acosta-Mesa, H.-G. (2024). Computational cost reduction in wrapper approaches for feature selection: A case of study using permutational-based differential evolution. 2024 IEEE Congress on Evolutionary Computation (CEC), 1–8.
- Bharadiya, J. P. (2023). A tutorial on principal component analysis for dimensionality reduction in machine learning. International Journal of Innovative Science and Research Technology, 8(5), 2028–2032.
- Bishop, C. M., & Nasrabadi, N. M. (2006). Pattern recognition and machine learning (Vol. 4). Springer.
- Cover, T. M. (1965). Geometrical and statistical properties of systems of linear inequalities with applications in pattern recognition. IEEE Transactions on Electronic Computers, EC-14(3), 326–334.
<https://doi.org/10.1109/PGEC.1965.264137>
- Danubianu, M., Pentiuc, S. G., & Danubianu, D. M. (2012). Data dimensionality reduction for data mining: A combined filter-wrapper framework. International Journal Of Computers Communications & Control, 7(5), 824–831.
- Feng, S., & Wang, H. (2021). Comparison of PCA and LDA dimensionality reduction algorithms based on wine dataset. 2021 33rd Chinese Control and Decision Conference (CCDC), 2791–2796.
- Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. Annals of Eugenics, 7(2), 179–188.
- Gao, H., & Davis, J. W. (2006). Why direct LDA is not equivalent to LDA. Pattern Recognition, 39(5), 1002–1006.
- Härdle, W., & Simar, L. (2007). Applied multivariate statistical analysis. Springer.
- Horst, A. M., Hill, A. P., & Gorman, K. B. (2020). Palmerpenguins: Palmer archipelago (antarctica) penguin data.
<https://doi.org/10.5281/zenodo.3960218>
- Huang, R., Liu, Q., Lu, H., & Ma, S. (2002). Solving the small sample size problem of LDA. 2002 International Conference on Pattern Recognition, 3, 29–32.
- Kanade, V. (2016). Basis expansion, regularization, validation.

Referencias

- Lin, C.-C., & Chen, A.-P. (2004). Fuzzy discriminant analysis with outlier detection by genetic algorithm. *Computers & Operations Research*, 31(6), 877–888. [https://doi.org/10.1016/s0305-0548\(03\)00040-6](https://doi.org/10.1016/s0305-0548(03)00040-6)
- McLachlan, G. J. (2004). *Discriminant Analysis and Statistical Pattern Recognition*. John Wiley & Sons.
- Niu, G., & Ma, Z. (2021). Local quasi-linear embedding based on kronecker product expansion of vectors. *Journal of Intelligent & Fuzzy Systems*, 41(1), 2195-2205.
- Ran, R., Wang, T., Li, Z. et al. Polynomial linear discriminant analysis. *J Supercomput* 80, 413–434 (2024). <https://doi.org/10.1007/s11227-023-05485-9>
- Silalahi, D. D., Reaño, C. E., Lansigan, F. P., Panopio, R. G., y Bantayan, N. C. (2016). Linear Discriminant Analysis vs. Genetic Algorithm Neural Network with Principal Component Analysis for Hyperdimensional Data Analysis: A study on Ripeness Grading of Oil Palm (*Elaeis guineensis* Jacq.) Fresh Fruit. *Philippine Statistician*, 65(2).
- Singh, G., Pal, Y., & Dahiya, A. K. (2023). Classification of power quality disturbances using linear discriminant analysis. *Applied Soft Computing*, 138, 110181.
- Qu, L., & Pei, Y. (2024). A Comprehensive Review on Discriminant Analysis for Addressing Challenges of Class-Level Limitations, Small Sample Size, and Robustness. *Processes*, 12(7), 1382.
- Xu, Y., & Li, E. (2024). Robust locally nonlinear embedding (RLNE) for dimensionality reduction of high-dimensional data with noise. *Neurocomputing*, 127900.


Gracias por su atención



Algoritmo genético para guiar la búsqueda

A	B	A ²	B ²	AB	→	1	1	1	1	1
A			B ²	AB	→	1	0	0	1	1

- **Representación:** Binaria
- **Fitness:** $Accuracy - \lambda * No.de Variables$
- **Selección de padres:** selection proportional to fitness
- **Operador de cruza:** Cruza de un solo punto con prob. del 80%.
- **Operador de mutación:** Mutación bitflip con prob. del 10%.
- **Elitismo:** Los 2 mejores individuos pasan a la siguiente generación.



Revisión de la literatura

Manejo de la no linealidad

Authors	Method	Year	Contribution	Use
R. A. Fisher	LDA	1936	Maximize class separation when projecting data.	Classification of specimens (e.g., irises).
Ran R., et al.	PLDA	2024	Polynomial mapping to improve class separation.	Dimensionality reduction and classification.
Yang, Z., et al.	KFDA	2024	KFDA optimization for greater accuracy and speed.	Diagnosis of chemical failures.
Liu, J., et al.	KPCA-TSO-LSSVM	2024	Extract key features to increase accuracy.	Energy risk assessment.

Revisión de la literatura

Variante de LDA que manejan no linealidad y SSS problem

Author(S)	Year	Technique	Main contribution	Use of PLDA
Liu & Guo	2024	WLDA: A cost-sensitive version of LDA.	Improves LDA performance on imbalanced datasets by weighting classes.	Cites PLDA as State of the Art and use as comparative method
Sudibyo et al.	2024	iLDA: Iterative LDA.	Handles non-Gaussian data and small sample size (SSS) problems.	Cites PLDA as State of the Art
Zheng et al.	2024	Fusion of VIS-NIR Spectroscopy + Image Processing (SVM > CNN).	Fast, non-destructive method to monitor tea fermentation.	Cites LDA theory
Hu et al.	2025	DbDRA: Inter-spectral distance-based algorithm.	Reliably identifies related microbial species (outperforms PCA/LDA).	Cites LDA theory
Song et al.	2025	THz-TDS Spectroscopy + LDA-DCNN model.	Real-time monitoring of black tea fermentation by measuring polyphenols.	Cites PLDA as State of the Art
Sudibyo et al.	2025	DRCT: Iterative method extending LDA's coordinate transformation.	Overcomes LDA limitations (SSS, non-Gaussian data, intra-class structure).	Cites PLDA as State of the Art

Bateria de casos para simular

Case	Observations	Attributes	Atr. Pol. expansion (2)	Class	Sample by class
1	15	3	9	3	5
2	150	3	9	3	50
3	15	10	65	3	5
4	150	10	65	3	50
5	15	15	135	3	5
6	15	17	170	3	5

	More observations than variables. Avoid SSS problems.
	More variables than observations in the expansion. Possible SSS problems
	More variables than observations. SSS problems guaranteed.