



Universidad Veracruz



COVNNEC-App

# Mejora del discriminante lineal usando transformaciones polinomiales y algoritmos genéticos

Instituto de Investigaciones en Inteligencia Artificial  
Maestría en Inteligencia Artificial

Research Group on Computer Vision, Neural Networks  
Evolutionary Computation and Applications


**Presenta: Angel García Báez**

**Director: Héctor Gabriel Acosta Mesa**  
**Codirector: Adriana Laura López Lobato**

# Motivación

- **Aprendizaje automático:** Enseñar a las computadoras a aprender directamente a partir de datos para identificar patrones y tomar decisiones.

## Aprendizaje supervisado (Clásificación/Predicción)



# Problemas en el machine learning


## Maldición de la dimensionalidad

| Obs. | X1 | X2 | X3 | X4 | X5 | X6 | X7 |
|------|----|----|----|----|----|----|----|
| 1    |    |    |    |    |    |    |    |
| 2    |    |    |    |    |    |    |    |
| 3    |    |    |    |    |    |    |    |
| 4    |    |    |    |    |    |    |    |
| 5    |    |    |    |    |    |    |    |


7 vars > 5 obs

## Separabilidad de los datos

Linealmente separable



No linealmente separable






# Técnicas de reducción de dimensionalidad

- Técnicas que toman las variables originales y crean nuevas variables proyectadas en un menor número de dimensiones.


| Obs. | X1 | X2 | X3 | X4 | X5 |
|------|----|----|----|----|----|
| 1    |    |    |    |    |    |
| 2    |    |    |    |    |    |
| 3    |    |    |    |    |    |
| 4    |    |    |    |    |    |
| 5    |    |    |    |    |    |
| 6    |    |    |    |    |    |



| Obs. | X1' | X2' | X3' |
|------|-----|-----|-----|
| 1    |     |     |     |
| 2    |     |     |     |
| 3    |     |     |     |
| 4    |     |     |     |
| 5    |     |     |     |
| 6    |     |     |     |



# Técnicas de reducción de dimensionalidad



# Técnicas de para tratar la no-linealidad

- **Expansión de características:** Construye nuevas características a partir de las originales usando una estructura de polinomio.

| Obs. | $x_1$ | $x_2$ | $x_1^2$ | $x_1x_2$ | $x_2^2$ | $x_1^3$ | $x_1^2x_2$ | $x_1x_2^2$ | $x_2^3$ | $x_1^4$ | $x_1^3x_2$ | $x_1^2x_2^2$ | $x_1x_2^3$ | $x_2^4$ |
|------|-------|-------|---------|----------|---------|---------|------------|------------|---------|---------|------------|--------------|------------|---------|
| 1    |       |       |         |          |         |         |            |            |         |         |            |              |            |         |
| 2    |       |       |         |          |         |         |            |            |         |         |            |              |            |         |
| 3    |       |       |         |          |         |         |            |            |         |         |            |              |            |         |
| 4    |       |       |         |          |         |         |            |            |         |         |            |              |            |         |
| 5    |       |       |         |          |         |         |            |            |         |         |            |              |            |         |
| 6    |       |       |         |          |         |         |            |            |         |         |            |              |            |         |


Diagram illustrating the expansion of features into polynomial degrees:

- Grado = 1:  $x_1, x_2$
- Grado = 2:  $x_1^2, x_1x_2, x_2^2$
- Grado = 3:  $x_1^3, x_1^2x_2, x_1x_2^2, x_2^3$
- Grado = 4:  $x_1^4, x_1^3x_2, x_1^2x_2^2, x_1x_2^3, x_2^4$




# Técnicas de para tratar la no-linealidad


**Captura relaciones no lineales.**



**Crece rápidamente en complejidad**





# Técnicas de reducción de dimensionalidad





# Técnicas de reducción de dimensionalidad



# Limitaciones de las técnicas

| Técnica              | Ventajas                                                                            | Limitaciones                                                                                                                                                                                          |
|----------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| LDA                  | Reduce dimensionalidad de manera informada.                                         | <ul style="list-style-type: none"><li>- Supervisado</li><li>- Sensible a la dimensionalidad</li><li>- Sensible a la no linealidad</li><li>- Exige cumplimiento de supuestos de distribución</li></ul> |
| Wrapper              | Selecciona subconjuntos de variables que aportan más al rendimiento de los modelos. | <ul style="list-style-type: none"><li>- Costo computacional alto al generar los modelos con los posibles subconjuntos.</li></ul>                                                                      |
| Expansión polinomial | Captura relaciones no lineales                                                      | <ul style="list-style-type: none"><li>- Crece rápidamente con el número de variables.</li><li>- Alto consumo de recursos computacionales.</li></ul>                                                   |



# Definición del problema

## Definición del problema

Datos reales presentan **alta no linealidad** y estructura compleja

La expansión polinomial resuelve la no linealidad, pero genera **alta dimensionalidad**

En escenarios de **Small Sample Size (SSS)**, LDA puede volverse inestable

Riesgo de **fallo algebraico** en LDA clásico

## Justificación

Modelos como **SVM y redes neuronales** son efectivos

Pero actúan como “**cajas negras**” (baja interpretabilidad)

Se requiere mantener **interpretabilidad en 2D/3D**

Necesidad de **parsimonia (pocas variables relevantes)**



# Pregunta de investigación, hipótesis y objetivo


**¿Es posible mejorar el desempeño y la interpretabilidad de LDA en escenarios no lineales mediante un enfoque híbrido de expansión polinomial y selección genética de variables?**

**La integración de un Algoritmo Genético Binario sobre un espacio polinomial expandido permite identificar subconjuntos parsimoniosos de características que mejoran el Accuracy de LDA y mantienen separabilidad en 2D/3D.**

**Diseñar, implementar y evaluar un esquema basado en algoritmos genéticos y transformaciones polinomiales para optimizar el espacio de características de LDA en datos no lineales.**


# Algoritmo propuesto

## GENETIC NON LINEAL POLINOMIAL DISCRIMINANT ANALYSIS





# Algoritmos genéticos

Es una técnica de optimización heurística basada en replicar el mecanismo de evolución y adaptación de los organismos.



BINARIO




# Datos y técnicas de comparación

| Dataset          | Muestras | Variables | Clases |
|------------------|----------|-----------|--------|
| penguins         | 342      | 4         | 3      |
| Cebolla3D        | 300      | 3         | 3      |
| Cancer Wisconsin | 569      | 30        | 2      |

| Método                   | Manejo de la linealidad | Visualizable |
|--------------------------|-------------------------|--------------|
| LDA                      | Lineal                  | Sí           |
| QDA                      | Cuadrático              | No           |
| SVM (Poly 2)             | No lineal               | No           |
| SVM (Poly 3)             | No lineal               | No           |
| SVM (Gauss)              | No lineal               | No           |
| <b>GNLPDA (Prouesto)</b> | <b>No lineal</b>        | <b>Sí</b>    |

# Resultados

## Caso 1: Penguin Palmers






# Resultados

## Caso 1: Penguin Palmers

GPN-LDA Projection: 1.2.penguins

Accuracy: 0.991 | Total Vars: 3



Variables  
3/4



Términos  
expandidos  
3/9

Lin 1: MasaCorporal

Interact 2: LongitudPico\*MasaCorporal, MasaCorporal\*AnchoPico

# Resultados

## Caso 2: Cebolla 3D




# Resultados

## Caso 2: Cebolla 3D

### GPN-LDA Projection: 3.1.Cebolla3D

Accuracy: 0.973 | Total Vars: 5




Lin 2: V2, V3  
Quad 3: V1<sup>2</sup>, V2<sup>2</sup>, V3<sup>2</sup>

Variables  
3/3

Términos  
expandidos  
5/9

# Resultados

## Caso 3: CancerWisconsin




# Resultados Preliminares

## Caso 3: Cancer Wisconsin

GPN-LDA Projection: 4.1.CancerWisconsin

Accuracy: 0.977 | Total Vars: 27



Variables  
11/30

Términos  
expandidos  
27 / 77

Lin 5: concave\_points3, radius3, smoothness3, symmetry1, texture1

Quad 2: radius3<sup>2</sup>, texture2<sup>2</sup>

Interact 20: compactness3\*symmetry1, compactness3\*texture3, concave\_points3\*texture1, radius2\*concave\_points3, radius2\*radius3, radius2\*texture1, smoothness3\*com

# Resultados

Tabla 2: Resultados internos del algoritmo

| Dataset         | No. Vars | Vars E1          | Vars E2          | Accuracy        | Precision       | Recall          | F1Score         | Time (S)             |
|-----------------|----------|------------------|------------------|-----------------|-----------------|-----------------|-----------------|----------------------|
| penguins        | 4        | 3.00 $\pm$ 0.00  | 3.00 $\pm$ 0.00  | 0.99 $\pm$ 0.00 | 0.99 $\pm$ 0.00 | 0.98 $\pm$ 0.00 | 0.99 $\pm$ 0.00 | 1.46 $\pm$ 1.32      |
| Cebolla3D       | 3        | 3.00 $\pm$ 0.00  | 5.00 $\pm$ 0.00  | 0.97 $\pm$ 0.00 | 0.98 $\pm$ 0.00 | 0.97 $\pm$ 0.00 | 0.97 $\pm$ 0.00 | 1.27 $\pm$ 1.12      |
| CancerWisconsin | 30       | 10.03 $\pm$ 2.04 | 21.10 $\pm$ 9.66 | 0.97 $\pm$ 0.00 | 0.96 $\pm$ 0.01 | 1.00 $\pm$ 0.00 | 0.98 $\pm$ 0.00 | 1607.91 $\pm$ 148.83 |

# Resultados

Tabla 3: Resultados comparativos

| Dataset          | LDA                               | QDA                               | SVM Poly2                         | SVM Poly3                         | SVM GAUSS                         | GNLPDA          |
|------------------|-----------------------------------|-----------------------------------|-----------------------------------|-----------------------------------|-----------------------------------|-----------------|
| penguins         | <b><math>0.99 \pm 0.02</math></b> | <b><math>0.99 \pm 0.02</math></b> | <b><math>0.88 \pm 0.06</math></b> | <b><math>0.98 \pm 0.02</math></b> | <b><math>0.98 \pm 0.02</math></b> | $0.99 \pm 0.00$ |
| Cebolla3D        | <b><math>0.35 \pm 0.07</math></b> | <b><math>0.94 \pm 0.05</math></b> | $0.98 \pm 0.02$                   | <b><math>0.50 \pm 0.09</math></b> | $0.99 \pm 0.02$                   | $0.97 \pm 0.00$ |
| Cancer Wisconsin | <b><math>0.96 \pm 0.03</math></b> | <b><math>0.96 \pm 0.02</math></b> | <b><math>0.87 \pm 0.05</math></b> | <b><math>0.96 \pm 0.03</math></b> | $0.97 \pm 0.03$                   | $0.97 \pm 0.00$ |

# Conclusiones

- Los casos de prueba tienen más observaciones que sujetos.
- El algoritmo propuesto se desempeña bien ante un caso lineal y no lineal.
- El rendimiento de la precisión alcanzado es bueno.
- Obtiene proyecciones que se observan linealmente separables.
- Se puede conocer las variables que selecciona para lograr las proyecciones y el rendimiento mostrado.





# Referencias

- Asaduzzaman, A., Uddin, M. R., & Sibai, F. N. (2024). Dimensionality reduction by machine learning for cost-effective data analysis.
- Barradas-Palmeros, J.-A., Mezura-Montes, E., Rivera-López, R., & Acosta-Mesa, H.-G. (2024). Computational cost reduction in wrapper approaches for feature selection: A case of study using permutational-based differential evolution. 2024 IEEE Congress on Evolutionary Computation (CEC), 1–8.
- Bharadiya, J. P. (2023). A tutorial on principal component analysis for dimensionality reduction in machine learning. International Journal of Innovative Science and Research Technology, 8(5), 2028–2032.
- Bishop, C. M., & Nasrabadi, N. M. (2006). Pattern recognition and machine learning (Vol. 4). Springer.
- Cover, T. M. (1965). Geometrical and statistical properties of systems of linear inequalities with applications in pattern recognition. IEEE Transactions on Electronic Computers, EC-14(3), 326–334.  
<https://doi.org/10.1109/PGEC.1965.264137>
- Danubianu, M., Pentiuc, S. G., & Danubianu, D. M. (2012). Data dimensionality reduction for data mining: A combined filter-wrapper framework. International Journal Of Computers Communications & Control, 7(5), 824–831.
- Feng, S., & Wang, H. (2021). Comparison of PCA and LDA dimensionality reduction algorithms based on wine dataset. 2021 33rd Chinese Control and Decision Conference (CCDC), 2791–2796.
- Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. Annals of Eugenics, 7(2), 179–188.
- Gao, H., & Davis, J. W. (2006). Why direct LDA is not equivalent to LDA. Pattern Recognition, 39(5), 1002–1006.
- Härdle, W., & Simar, L. (2007). Applied multivariate statistical analysis. Springer.
- Horst, A. M., Hill, A. P., & Gorman, K. B. (2020). Palmerpenguins: Palmer archipelago (antarctica) penguin data.  
<https://doi.org/10.5281/zenodo.3960218>
- Huang, R., Liu, Q., Lu, H., & Ma, S. (2002). Solving the small sample size problem of LDA. 2002 International Conference on Pattern Recognition, 3, 29–32.
- Kanade, V. (2016). Basis expansion, regularization, validation.

# Referencias

- Lin, C.-C., & Chen, A.-P. (2004). Fuzzy discriminant analysis with outlier detection by genetic algorithm. *Computers & Operations Research*, 31(6), 877–888. [https://doi.org/10.1016/s0305-0548\(03\)00040-6](https://doi.org/10.1016/s0305-0548(03)00040-6)
- McLachlan, G. J. (2004). *Discriminant Analysis and Statistical Pattern Recognition*. John Wiley & Sons.
- Niu, G., & Ma, Z. (2021). Local quasi-linear embedding based on kronecker product expansion of vectors. *Journal of Intelligent & Fuzzy Systems*, 41(1), 2195-2205.
- Ran, R., Wang, T., Li, Z. et al. Polynomial linear discriminant analysis. *J Supercomput* 80, 413–434 (2024). <https://doi.org/10.1007/s11227-023-05485-9>
- Silalahi, D. D., Reaño, C. E., Lansigan, F. P., Panopio, R. G., y Bantayan, N. C. (2016). Linear Discriminant Analysis vs. Genetic Algorithm Neural Network with Principal Component Analysis for Hyperdimensional Data Analysis: A study on Ripeness Grading of Oil Palm (*Elaeis guineensis* Jacq.) Fresh Fruit. *Philippine Statistician*, 65(2).
- Singh, G., Pal, Y., & Dahiya, A. K. (2023). Classification of power quality disturbances using linear discriminant analysis. *Applied Soft Computing*, 138, 110181.
- Qu, L., & Pei, Y. (2024). A Comprehensive Review on Discriminant Analysis for Addressing Challenges of Class-Level Limitations, Small Sample Size, and Robustness. *Processes*, 12(7), 1382.
- Xu, Y., & Li, E. (2024). Robust locally nonlinear embedding (RLNE) for dimensionality reduction of high-dimensional data with noise. *Neurocomputing*, 127900.

**Gracias por su atención**

